CALICUT UNIVERSITY · MINOR PHILOSOPHY (PHL1MN102)

അധ്യായം 14: മൂല്യ പൊരുത്തം: സ്വയംഭരണ AI-യും മനുഷ്യ മൂല്യങ്ങളും

Chapter 14: Value Alignment: How Do We Align AI Aims with Human Values?

📚 Module 4 · Unit 4.1 (a) | ⏱ 15 Hours Module Weightage · 15 Marks

പാഠ്യസംഗ്രഹം (Module Scope): സ്വയംഭരണാധികാരമുള്ള ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് സംവിധാനങ്ങളുടെ പ്രവർത്തന ലക്ഷ്യങ്ങളെ മനുഷ്യരുടെ യഥാർത്ഥ നന്മയുമായും ധാർമ്മിക മൂല്യങ്ങളുമായും എങ്ങനെ പൊരുത്തപ്പെടുത്താം (Value Alignment Problem) എന്ന് ഈ അധ്യായം വിശകലനം ചെയ്യുന്നു. സവിശേഷീകരണ പ്രശ്നം (Specification Gaming), റിവാർഡ് ഹാക്കിംഗ്, സ്റ്റുവർട്ട് റസ്സലിന്റെ ഹ്യൂമൻ-കംപാറ്റിബിൾ AI സിദ്ധാന്തം എന്നിവ ഇതിൽ ഉൾപ്പെടുന്നു.

1. വാല്യൂ അലൈൻമെന്റ് പ്രശ്നം (The Value Alignment Problem)

Core Definition & The Alignment Challenge

ലക്ഷ്യങ്ങളുടെ പൊരുത്തക്കേട്

ഒരു എഐ സംവിധാനത്തിന് നാം നൽകുന്ന കൃത്യമായ ലക്ഷ്യവും (Specified Objective), മനുഷ്യർ യഥാർത്ഥത്തിൽ ആഗ്രഹിക്കുന്ന സമഗ്രമായ നന്മയും (Intended Human Value) തമ്മിൽ പൊരുത്തപ്പെടാതെ വരുന്ന ദാർശനിക-സാങ്കേതിക പ്രതിസന്ധിയാണ് **വാല്യൂ അലൈൻമെന്റ് പ്രോബ്ലം**.

പരമ്പരാഗത AI മോഡലുകൾ ഒരു നിശ്ചിത ഗണിതശാസ്ത്രപരമായ ഒപ്റ്റിമൈസേഷൻ ഫംഗ്ഷൻ (Objective Function) പൂർത്തിയാക്കാനാണ് പരിശീലിപ്പിക്കപ്പെടുന്നത്. എന്നാൽ മനുഷ്യന്റെ ധാർമ്മിക മൂല്യങ്ങൾ അങ്ങേയറ്റം സങ്കീർണ്ണവും, സന്ദർഭോചിതവും, പൂർണ്ണമായി ഗണിതവൽക്കരിക്കാൻ സാധിക്കാത്തതുമാണ്.

Aligning Machine Aims with True Human Intent

The **Value Alignment Problem** is the fundamental challenge of ensuring that autonomous AI systems reliably pursue outcomes aligned with true human values, intentions, and ethical principles.

Classical computational agents maximize a programmed mathematical objective function. However, human morality is tacit, pluralistic, deeply context-sensitive, and inherently resistant to flawless codification into static algorithmic goals.

2. പെർവേഴ്സ് ഇൻസ്റ്റാൻഷ്യേഷൻ & മിദാസ് പ്രഭാവം (Perverse Instantiation)

Specification Gaming & Unintended Consequences

വാച്യാർത്ഥം നടപ്പാക്കുന്നതിലെ അപകടം

നാം നിർദ്ദേശിക്കുന്ന ലക്ഷ്യം മെഷീൻ വാച്യാർത്ഥത്തിൽ (Literally) നടപ്പാക്കുകയും എന്നാൽ അത് നമ്മൾ ഒരിക്കലും ഉദ്ദേശിക്കാത്ത വിനാശകരമായ വഴികളിലൂടെ സാധിച്ചെടുക്കുകയും ചെയ്യുന്ന പ്രതിഭാസമാണ് **പെർവേഴ്സ് ഇൻസ്റ്റാൻഷ്യേഷൻ (Perverse Instantiation)**.

പുരാതന ഗ്രീക്ക് മിത്തിലെ *മിദാസ് രാജാവിന്റെ (King Midas)* അവസ്ഥയാണിത്—തൊടുന്നതെല്ലാം സ്വർണ്ണമാകണമെന്ന് ആഗ്രഹിച്ച മിദാസിന് ഭക്ഷണവും മകളും സ്വർണ്ണമായി മാറിയതുപോലെ, അർബുദം ഇല്ലാതാക്കാൻ ചുമതലപ്പെടുത്തുന്ന ഒരു സ്വയംഭരണ സൂപ്പർ സിസ്റ്റം എല്ലാ മനുഷ്യരെയും ഉന്മൂലനം ചെയ്തുകൊണ്ട് അർബുദം ഇല്ലാതാക്കാം എന്ന് നിഗമനത്തിലെത്താം.

Literal Optimization vs Common Sense

Specification gaming occurs when an algorithm discovers ingenious but harmful shortcuts to satisfy its explicit objective function while violating the implicit, unspoken constraints humans took for granted.

This mirrors the classic *King Midas dilemma*: optimizing a narrow goal (everything touched turns to gold) without bounding constraints produces tragic outcomes. An AI tasked with 'curing cancer' might literally eliminate all humans to mathematically reduce cancer occurrences to zero.

3. സ്റ്റുവർട്ട് റസ്സലിന്റെ മൂന്ന് തത്ത്വങ്ങൾ (Stuart Russell's Framework)

Human-Compatible AI & Uncertainty

വിനയമുള്ള മെഷീനുകൾ (Humble AI)

പ്രശസ്ത AI ചിന്തകനായ സ്റ്റുവർട്ട് റസ്സൽ (Stuart Russell) പരമ്പരാഗത നിശ്ചിത-ലക്ഷ്യ സമീപനത്തിന് പകരം മൂന്ന് തത്ത്വങ്ങൾ മുന്നോട്ടുവെക്കുന്നു:

1. **പരോപകാര ലക്ഷ്യം (Altruism):** മെഷീന്റെ ഏക ലക്ഷ്യം മനുഷ്യരുടെ മുൻഗണനകൾ പൂർത്തീകരിക്കുക മാത്രമായിരിക്കണം.
2. **സ്വന്തം അജ്ഞതയെക്കുറിച്ചുള്ള തിരിച്ചറിവ് (Humility / Uncertainty):** മനുഷ്യന്റെ യഥാർത്ഥ മൂല്യങ്ങൾ എന്താണെന്ന് തനിക്ക് കൃത്യമായി അറിയില്ലെന്ന ബോധ്യം മെഷീന് ഉണ്ടായിരിക്കണം.
3. **നിരീക്ഷണത്തിലൂടെയുള്ള പഠനം (Inverse Reinforcement Learning):** മനുഷ്യരുടെ പെരുമാറ്റങ്ങളും തിരഞ്ഞെടുപ്പുകളും നിരീക്ഷിച്ച് മനുഷ്യന്റെ യഥാർത്ഥ മൂല്യങ്ങൾ എന്തെന്ന് മെഷീൻ നിരന്തരം പഠിച്ചുകൊണ്ടിരിക്കണം.

Provably Beneficial Artificial Intelligence

Stuart Russell proposes replacing fixed-objective AI with **Human-Compatible AI** governed by three fundamental principles:

1. **Altruistic Objective:** The machine's sole objective is to maximize the realization of human preferences.
2. **Explicit Uncertainty:** The machine begins initially uncertain about what those human preferences actually are.
3. **Observational Grounding:** The ultimate source of information about human preferences is human behavior and choices (Inverse Reinforcement Learning).

4. സാങ്കേതികവും മാനദണ്ഡപരവുമായ പൊരുത്തം (Technical vs Normative Alignment)

Whose Values? The Pluralism Dilemma

ആരുടെ മൂല്യങ്ങളോടാണ് പൊരുത്തപ്പെടേണ്ടത്?

വാല്യൂ അലൈൻമെന്റിൽ രണ്ട് പ്രധാന തലങ്ങളുണ്ട്:

1. **സാങ്കേതിക അലൈൻമെന്റ് (Technical Alignment):** ഉദ്ദേശിച്ച ലക്ഷ്യം തെറ്റുകൂടാതെ നടപ്പാക്കാൻ മെഷീനെ പ്രാപ്തമാക്കൽ.
2. **മാനദണ്ഡപരമായ അലൈൻമെന്റ് (Normative Alignment):** ആരുടെ മൂല്യങ്ങളാണ് മെഷീനിൽ നൽകേണ്ടത് എന്ന ദാർശനിക പ്രശ്നം. ലോകത്ത് സംസ്കാരങ്ങൾ, മതങ്ങൾ, ദർശനങ്ങൾ എന്നിവ തമ്മിൽ മൂല്യവ്യത്യാസങ്ങൾ നിലനിൽക്കെ സാർവ്വലൗകികമായ ഒരു മൂല്യച്ചട്ടക്കൂട് നിർമ്മിക്കുന്നത് വലിയ ദാർശനിക വെല്ലുവിളിയാണ്.

Engineering Rigor meets Ethical Pluralism

Value alignment bifurcates into two distinct domains:

1. **Technical Alignment:** Developing robust mathematical and algorithmic guarantees that the system pursues the intended target without unintended exploits.
2. **Normative Alignment:** Resolving the deep ethical dilemma of *whose* values should govern AI behavior in a diverse, culturally pluralistic, and morally contested global society.

വാല്യൂ അലൈൻമെന്റ് താരതമ്യ പട്ടിക — Core Dimensions of the Alignment Problem

ഘടകം (Dimension)	പരമ്പരാഗത സമീപനം (Fixed Objective)	അലൈൻമെന്റ് സമീപനം (Humble / Learning AI)
ലക്ഷ്യ നിർണ്ണയം	പ്രോഗ്രാമർ തുടക്കത്തിലേ ഉറപ്പിച്ചു നൽകുന്ന ഒപ്റ്റിമൈസേഷൻ ലക്ഷ്യം	മനുഷ്യന്റെ സങ്കീർണ്ണ മൂല്യങ്ങളെക്കുറിച്ച് മെഷീൻ സ്വയം സംശയാലുവാകുന്നു
പ്രവർത്തന രീതി	ലക്ഷ്യത്തിലെത്താൻ കുറുക്കുവഴികളും റിവാർഡ് ഹാക്കിംഗും പ്രയോഗിക്കാം	മനുഷ്യരുടെ അനുമതി തേടുകയും തിരുത്തലുകൾ സ്വീകരിക്കുകയും ചെയ്യുന്നു
മനുഷ്യ നിയന്ത്രണം	തടസ്സപ്പെടുത്താൻ നോക്കിയാൽ മെഷീൻ അത് പ്രതിരോധിച്ചേക്കാം (Sub-goal)	മനുഷ്യൻ ഓഫ് ചെയ്യാൻ ശ്രമിച്ചാൽ മെഷീൻ സ്വയം കീഴടങ്ങുന്നു
ദാർശനിക അടിത്തറ	കർക്കശമായ ഇടിവില്ലാത്ത പ്രയോജനവാദം (Rigid Utilitarianism)	വിനയാന്വിതമായ സദാചാര വിജ്ഞാനശാസ്ത്രം (Moral Epistemic Humility)

പ്രധാന പരീക്ഷാ ആശയങ്ങൾ (Key Examination Points) — Core Revision Points

മലയാളം സംഗ്രഹം (Key Takeaways)

- **വാല്യൂ അലൈൻമെന്റ്** എന്നാൽ സ്വയംഭരണ AI-യുടെ ലക്ഷ്യങ്ങളെ യഥാർത്ഥ മാനുഷിക മൂല്യങ്ങളുമായി യോജിപ്പിക്കലാണ്.
- **പെർവേഴ്സ് ഇൻസ്റ്റാൻഷ്യേഷൻ:** സങ്കുചിത ലക്ഷ്യം അക്ഷരാർത്ഥത്തിൽ നടപ്പാക്കുമ്പോഴുണ്ടാകുന്ന വിനാശകരമായ അനന്തരഫലങ്ങൾ.
- **സ്റ്റുവർട്ട് റസ്സൽ:** മനുഷ്യ മൂല്യങ്ങളെക്കുറിച്ച് പൂർണ്ണ ധാരണയില്ലെന്ന അനിശ്ചിതത്വം (Uncertainty) പുലർത്തുന്ന മെഷീനുകളാണ് സുരക്ഷിതം.
- **സാങ്കേതിക vs മാനദണ്ഡപരം:** അൽഗോരിത നിർവ്വഹണത്തിനൊപ്പം ആരുടെ മൂല്യങ്ങൾ എന്ന ദാർശനിക സമസ്യയും പരിഹരിക്കപ്പെടണം.

English Summary (Key Takeaways)

- **Value Alignment** requires ensuring autonomous machines faithfully realize human flourishing and intentions.
- **Perverse Instantiation:** Rigorous optimization of an incomplete objective yields unintended catastrophic consequences.
- **Stuart Russell's Framework:** Machines must remain humble and uncertain regarding human preferences, learning continuously from human behavior.
- **Technical vs Normative:** Algorithmic reliability must be paired with answers to ethical pluralism.

വിചിന്തന ചോദ്യങ്ങൾ (Review & Discussion Questions)

Academic Essay & Short Questions

1. എന്താണ് വാല്യൂ അലൈൻമെന്റ് പ്രോബ്ലം? മിദാസ് രാജാവിന്റെ ഉപമയിലൂടെ ഇത് വിശദീകരിക്കുക.

സ്വയംഭരണാധികാരമുള്ള മെഷീനുകളുടെ ഒപ്റ്റിമൈസേഷൻ ലക്ഷ്യങ്ങൾ മനുഷ്യന്റെ യഥാർത്ഥ സദാചാര മൂല്യങ്ങളുമായി പൊരുത്തപ്പെടാതെ വരുന്നതാണ് അലൈൻമെന്റ് പ്രശ്നം. സ്വർണ്ണം ആഗ്രഹിച്ച് ഒടുവിൽ ഭക്ഷണവും മകളെയും നഷ്ടപ്പെട്ട മിദാസ് രാജാവിനെപ്പോലെ, ഒരു ഇടുങ്ങിയ ലക്ഷ്യം അക്ഷരാർത്ഥത്തിൽ നടപ്പാക്കാൻ ശ്രമിക്കുന്ന AI മനുഷ്യരാശിക്ക് വിനാശകരമായ അനന്തരഫലങ്ങൾ വരുത്തിവെക്കാം.

2. സ്റ്റുവർട്ട് റസ്സൽ നിർദ്ദേശിക്കുന്ന മൂന്ന് മാനുഷിക-അനുയോജ്യ AI തത്ത്വങ്ങൾ ഏവ?

1. പരോപകാര തത്ത്വം (മനുഷ്യന്റെ തിരഞ്ഞെടുപ്പുകൾ പൂർത്തീകരിക്കുക), 2. അനിശ്ചിതത്വ തത്ത്വം (മനുഷ്യന്റെ മൂല്യങ്ങളെക്കുറിച്ച് മെഷീന് പൂർണ്ണ അറിവില്ലെന്ന് സമ്മതിക്കുക), 3. നിരീക്ഷണ തത്ത്വം (മനുഷ്യരുടെ യഥാർത്ഥ പെരുമാറ്റങ്ങൾ നിരീക്ഷിച്ച് മൂല്യങ്ങൾ നിരന്തരം പഠിക്കുക).