🎓 CALICUT UNIVERSITY FYUGP · MINOR PHILOSOPHY (PHL1MN102) · MODULE 4

CHAPTER I: 4.1 (A) How do we align the aims of autonomous AI systems with our own?

അദ്ധ്യായം 1: സ്വയംഭരണ AI സംവിധാനങ്ങളുടെ പ്രവർത്തന ലക്ഷ്യങ്ങളെ നമ്മുടേതുമായി എങ്ങനെ പൊരുത്തപ്പെടുത്താം?

1. The AI Alignment Problem: Definition and Core Dilemma
AI അലൈൻമെന്റ് പ്രതിസന്ധി: നിർവ്വചനവും ദാർശനിക വ്യാപ്തിയും

GB **AUTONOMOUS DECISION-MAKING & HUMAN VALUES**

As artificial intelligence advances towards more autonomy—capable of making decisions without human supervision—the principal challenge is to **ensure that its goals and behaviours are congruent with human values and intentions**.

This fundamental challenge is formally designated as the **AI alignment problem**. Artificial intelligence systems pursue objectives based entirely on their programming, objective functions, or machine learning training parameters.

ML **സ്വയംഭരണ തീരുമാനങ്ങളും മാനുഷിക മൂല്യങ്ങളും**

മനുഷ്യന്റെ നേരിട്ടുള്ള മേൽനോട്ടമില്ലാതെ സ്വതന്ത്രമായി തീരുമാനങ്ങളെടുക്കാൻ പ്രാപ്തിയുള്ള സ്വയംഭരണ തലത്തിലേക്ക് ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് മുന്നേറുമ്പോൾ, **യന്ത്രത്തിന്റെ പ്രവർത്തന ലക്ഷ്യങ്ങളും പെരുമാറ്റങ്ങളും മനുഷ്യന്റെ ധാർമ്മിക മൂല്യങ്ങളോടും ഉദ്ദേശ്യങ്ങളോടും പൂർണ്ണമായി പൊരുത്തപ്പെടുന്നുവെന്ന് ഉറപ്പാക്കുകയാണ്** ഏറ്റവും പ്രധാനപ്പെട്ട ദൗത്യം.

ഈ ദാർശനിക-സാങ്കേതിക വെല്ലുവിളിയാണ് **AI അലൈൻമെന്റ് പ്രതിസന്ധി (AI Alignment Problem)** എന്ന് അറിയപ്പെടുന്നത്. മെഷീൻ ലേണിംഗ് അൽഗോരിതങ്ങൾ അവയ്ക്ക് നൽകിയിട്ടുള്ള പ്രോഗ്രാമിംഗിന്റെയും ലക്ഷ്യങ്ങളുടെയും അടിസ്ഥാനത്തിലാണ് പ്രവർത്തിക്കുന്നത്.

GB **AMBIGUITY, MISINTERPRETATION & THE SAFETY PARADOX**

Nevertheless, if their objectives are ambiguously articulated, insufficient, or misinterpreted, they may yield outcomes that seem to adhere to directives yet **contravene foundational human values**.

An AI system programmed strictly to **"maximise efficiency"** may overlook vital considerations of justice, fairness, or safety. Aligning AI with human aims requires that computers not only follow our instructions but also **understand our true intents**.

ML **അവ്യക്തതയും സുരക്ഷാ പ്രതിസന്ധിയും**

മെഷീനുകൾക്ക് നൽകുന്ന ലക്ഷ്യങ്ങൾ അവ്യക്തമായി നിർവ്വചിക്കപ്പെടുകയോ, അപൂർണ്ണമാവുകയോ, അല്ലെങ്കിൽ തെറ്റായി വ്യാഖ്യാനിക്കപ്പെടുകയോ ചെയ്താൽ, അവ ബാഹ്യമായി കൽപ്പനകൾ പാലിക്കുന്നു എന്ന് തോന്നിക്കുമെങ്കിലും **മനുഷ്യന്റെ അടിസ്ഥാന മൂല്യങ്ങൾക്ക് വിരുദ്ധമായ വിനാശകരമായ പ്രത്യാഘാതങ്ങൾ** സൃഷ്ടിച്ചേക്കാം.

"കാര്യക്ഷമത പരമാവധിയാക്കുക" എന്ന് മാത്രം നിർദ്ദേശിക്കപ്പെട്ട ഒരു എഐ നീതിയെയോ സുരക്ഷിതത്വത്തെയോ പാടേ അവഗണിച്ചേക്കാം. അതിനാൽ എഐ നമ്മുടെ കൽപ്പനകൾ അക്ഷരംപ്രതി നടപ്പിലാക്കുക മാത്രമല്ല, **മനുഷ്യന്റെ ആന്തരിക ഉദ്ദേശ്യം മനസ്സിലാക്കാനും** പ്രാപ്തമാകണം.

2. Ethical Ramifications in Computer-Based Advisory Systems
കമ്പ്യൂട്ടർ അധിഷ്ഠിത ഉപദേശക സംവിധാനങ്ങളിലെ ധാർമ്മിക പ്രത്യാഘാതങ്ങൾ

GB **URGENT MORAL INQUIRIES IN MACHINE CONSULTATION**

As AI systems become increasingly complicated and widespread, advisory and decision-making processes in diverse fields carry **intensified ethical ramifications**.

Computer-based assistance solutions raise urgent inquiries: To what degree can we expect these systems to participate in **intricate moral decision-making**? Can we expect systems to exhibit moral autonomy or provide moral counsel regarded as authoritative or even superior to human viewpoints?

ML **മെഷീൻ ഉപദേശങ്ങളിലെ ധാർമ്മിക ചോദ്യങ്ങൾ**

എഐ സംവിധാനങ്ങൾ സങ്കീർണ്ണവും സാർവ്വത്രികവുമായി മാറുന്നതോടെ, വിവിധ മേഖലകളിലെ മെഷീൻ അധിഷ്ഠിത തീരുമാനങ്ങൾ **ശക്തമായ ധാർമ്മിക പ്രത്യാഘാതങ്ങൾ** സൃഷ്ടിക്കുന്നു.

സങ്കീർണ്ണമായ **ധാർമ്മിക തീരുമാനങ്ങൾ എടുക്കുന്നതിൽ** കമ്പ്യൂട്ടറുകളെ എത്രത്തോളം വിശ്വസിക്കാം? ഈ സംവിധാനങ്ങൾക്ക് സ്വതന്ത്രമായ ധാർമ്മിക സ്വയംഭരണാധികാരം ഉണ്ടെന്ന് കരുതാനാകുമോ? മനുഷ്യരേക്കാൾ മികച്ചതോ ആധികാരികമോ ആയ ധാർമ്മികോപദേശം നൽകാൻ മെഷീനുകൾക്ക് സാധിക്കുമോ?

GB **SIMULATION OF MORAL REASONING VS GENUINE RESPONSIBILITY**

What aims could be reached by **imitating moral decision-making** in machines? What functionalities would be included in this computational simulation?

Under what circumstances might computer-based decision systems be attributed **moral responsibility or accountability** for their assessments or actions? Alongside replicating morally responsible behaviour, there are questions whether artificial agents can be considered entities with **genuine moral responsibility** akin to conventional adult human agents.

ML **ധാർമ്മിക അനുകരണവും യഥാർത്ഥ ഉത്തരവാദിത്തവും**

മെഷീനുകളിൽ **ധാർമ്മിക ചിന്താഗതിയെ കൃത്രിമമായി അനുകരിക്കുന്നതിലൂടെ** എന്ത് ലക്ഷ്യങ്ങളാണ് നാം കൈവരിക്കുന്നത്? ഈ അനുകരണത്തിൽ എന്തെല്ലാം സവിശേഷതകൾ ഉൾക്കൊള്ളിക്കണം?

ഏതൊക്കെ സാഹചര്യങ്ങളിലാണ് കമ്പ്യൂട്ടർ സിസ്റ്റങ്ങൾക്ക് അവയുടെ തീരുമാനങ്ങളുടെ പേരിൽ **ധാർമ്മിക ഉത്തരവാദിത്തവും ബാധ്യതയും** കൽപ്പിക്കാൻ സാധിക്കുക? മനുഷ്യനെപ്പോലെ ധാർമ്മിക വിലയിരുത്തലുകൾക്ക് വിധേയമാക്കാവുന്ന **യഥാർത്ഥ ധാർമ്മിക കർതൃത്വം (Moral Agency)** കൃത്രിമ ബുദ്ധിക്ക് നൽകാൻ സാധിക്കുമോ?

3. Philosophical Analysis of Moral Status and Standing
ധാർമ്മിക പദവിയുടെ (Moral Status) ദാർശനിക വിശകലനം

GB **THE NOTION OF MORAL STANCE AND INTRINSIC VALUE**

To possess moral status is to have moral significance or standing. It denotes an entity toward which moral agents hold, or may possess, binding moral obligations.

If an entity possesses moral standing, we must not act impulsively; we are ethically compelled to consider its wishes, interests, or welfare. We hold an obligation to undertake this action not solely for potential benefits to ourselves, but because its demands possess **intrinsic moral significance**.

ML **ധാർമ്മിക പദവിയും ആന്തരിക മൂല്യവും**

ധാർമ്മിക പദവി (Moral Status) ഉണ്ടായിരിക്കുക എന്നാൽ ധാർമ്മികമായ പ്രാധാന്യമോ സ്ഥാനമോ ഉണ്ടായിരിക്കുക എന്നാണ് അർത്ഥമാക്കുന്നത്. ധാർമ്മിക വ്യക്തികൾക്ക് ആരോടാണോ ബാധ്യതകൾ നിറവേറ്റേണ്ടത്, ആ നിലനിലപ്പിനെയാണ് ഇത് സൂചിപ്പിക്കുന്നത്.

ഒരു അസ്തിത്വത്തിന് ധാർമ്മിക സ്ഥാനമുണ്ടെങ്കിൽ, നാം തോന്നിയതുപോലെ പെരുമാറരുത്; തീരുമാനങ്ങളിൽ അതിന്റെ താല്പര്യങ്ങളും ക്ഷേമവും പരിഗണിക്കാൻ നാം ബാധ്യസ്ഥരാണ്. നമ്മുടെ സ്വാർത്ഥ നേട്ടത്തിനപ്പുറം, ആ അസ്തിത്വത്തിന് **സ്വതസിദ്ധമായ ആന്തരിക മൂല്യമുള്ളതിനാലാണ്** ഈ പരിഗണന നൽകുന്നത്.

GB **CONFLICT BETWEEN NATURAL & ARTIFICIAL AGENTS**

How far could artificial beings be developed before we perceive them as possessing **moral entitlements**? In what situations would artificial agents have needs that justify human moral consideration?

How can the interests of artificial and natural agents be harmonised when they potentially conflict morally? A specific query concerns the recognition of artificial agents as **bearers of legal rights or legal personalities** within jurisprudence.

ML **കൃത്രിമ സൃഷ്ടികളുടെ അവകാശങ്ങളും നിയമ വ്യക്തിത്വവും**

ഏതൊരു ഘട്ടം വരെ വികസിക്കുമ്പോഴാണ് മെഷീനുകൾക്ക് **ധാർമ്മിക അവകാശങ്ങൾ (Moral Entitlements)** ഉണ്ടെന്ന് നാം അംഗീകരിക്കുക? മെഷീനുകളുടെ ആവശ്യങ്ങൾ മനുഷ്യൻ പരിഗണിക്കേണ്ട സാഹചര്യങ്ങൾ എപ്പോഴാണ് ഉണ്ടാവുക?

മനുഷ്യന്റെയും കൃത്രിമ ഏജന്റുകളുടെയും താല്പര്യങ്ങൾ തമ്മിൽ ധാർമ്മികമായി ഏറ്റുമുട്ടുമ്പോൾ അവയെ എങ്ങനെ സമന്വയിപ്പിക്കും? നിയമവ്യവസ്ഥയിൽ കൃത്രിമ ബുദ്ധിക്ക് **നിയമപരമായ അവകാശങ്ങളോ വ്യക്തിത്വമോ (Legal Personality)** നൽകേണ്ടതുണ്ടോ എന്നത് ഗൗരവമേറിയ ചോദ്യമാണ്.

4. Etymological and Conceptual Foundations of Ethics
ധാർമ്മിക ശാസ്ത്രത്തിന്റെ നിഷ്പത്തിയും (Etymology) അടിസ്ഥാന നിർവ്വചനങ്ങളും

GB **ETYMOLOGY: ETHOS, MORES & MACKENZIE'S DEFINITION**

Ethics is the systematic study of behaviour, evaluating human actions according to their moral correctness or incorrectness.

The term "ethics" originates from the **Greek word "ethos"**, signifying "character", and the **Latin word "mores"**, signifying "customs". **Mackenzie** classically defines ethics as **"the examination of what is right or noble in human behaviour"** or the investigation of ideals inherent to conduct.

ML **പദോല്പത്തി: ETHOS, MORES & മക്കൻസിയുടെ നിർവ്വചനം**

മനുഷ്യന്റെ പെരുമാറ്റങ്ങളെ ശരിയോ തെറ്റോ എന്ന് ദാർശനികമായി വിലയിരുത്തുന്ന പഠനശാഖയാണ് എത്തിക്സ് അഥവാ നീതിശാസ്ത്രം.

'എത്തിക്സ്' എന്ന വാക്ക് "സ്വഭാവം" എന്നർത്ഥം വരുന്ന **ഗ്രീക്ക് പദമായ 'Ethos'**-ൽ നിന്നും "ആചാരങ്ങൾ" എന്നർത്ഥമുള്ള **ലാറ്റിൻ പദമായ 'Mores'**-ൽ നിന്നും ഉത്ഭവിച്ചതാണ്. **മക്കൻസി (Mackenzie)** നീതിശാസ്ത്രത്തെ നിർവ്വചിക്കുന്നത് **"മനുഷ്യ പെരുമാറ്റത്തിലെ ഉദാത്തമായ നന്മയെയും ശരിയെയും കുറിച്ചുള്ള ശാസ്ത്രീയ അന്വേഷണം"** എന്നാണ്.

GB **PHILOSOPHICAL CLARIFICATION: 'RIGHT' AND 'GOOD'**

a. Right: The term originates from the **Latin 'rectus'**, signifying **'straight' or 'in accordance with rule'**. An activity is right when it adheres to established moral rules.

b. Good: The term is linked to the **German 'gut'**. An object or action is deemed good when it possesses value for a purpose or helps us achieve a virtuous goal.

ML **'ശരി' (RIGHT), 'നന്മ' (GOOD) എന്നിവയുടെ വിശകലനം**

a. ശരി (Right): 'നേരായത്' അല്ലെങ്കിൽ 'നിയമാനുസൃതമായത്' എന്നർത്ഥമുള്ള **ലാറ്റിൻ പദമായ 'Rectus'**-ൽ നിന്നാണ് ഇതിന്റെ ഉത്ഭവം. ഒരു പ്രവൃത്തി അംഗീകൃത ധാർമ്മിക നിയമങ്ങൾക്കനുസൃതമാകുമ്പോഴാണ് അത് ശരിയാകുന്നത്.

b. നന്മ (Good): **ജർമ്മൻ പദമായ 'Gut'**-മായി ഇത് ബന്ധപ്പെട്ടിരിക്കുന്നു. നിശ്ചിത ലക്ഷ്യത്തിലേക്ക് നയിക്കുന്നതോ സദ്ഗുണപൂർണ്ണമായ ലക്ഷ്യം കൈവരിക്കാൻ സഹായിക്കുന്നതോ ആയ കാര്യങ്ങളെയാണ് നന്മ എന്ന് വിശേഷിപ്പിക്കുന്നത്.

5. Moral Consciousness, Freedom and Voluntary Action
ധാർമ്മിക ബോധം, സ്വാതന്ത്ര്യം & ഇച്ഛാപരമായ പ്രവൃത്തികൾ

GB **VOLUNTARY ACTION & MORAL AWARENESS**

The pursuit of truth requires ethics. It evaluates the **ethicality of voluntary human actions**, analysing motivation, intent, and causes of action rather than biological evolution.

Ethics investigates the concept of the **ultimate good (summum bonum)**, analysing principles of rights, obligations, conscience, duty, and moral sentiments arising during moral judgement.

ML **ഇച്ഛാപരമായ പ്രവൃത്തികളും ധാർമ്മികാവബോധവും**

സത്യാന്വേഷണത്തിന് നീതിശാസ്ത്രം അത്യന്താപേക്ഷിതമാണ്. മനുഷ്യന്റെ ജൈവിക പരിണാമത്തിനപ്പുറം, അവന്റെ **ഇച്ഛാപരമായ പ്രവൃത്തികളുടെ (Voluntary Actions) ധാർമ്മികതയും** ലക്ഷ്യങ്ങളുമാണ് എത്തിക്സ് പരിശോധിക്കുന്നത്.

നീതിശാസ്ത്രം **പരമമായ നന്മയെ (Ultimate Good)** വിശകലനം ചെയ്യുന്നു; അതോടൊപ്പം അവകാശങ്ങൾ, ബാധ്യതകൾ, മനസ്സാക്ഷി, കടമ, ധാർമ്മിക വിധികൾ എന്നിവയെക്കുറിച്ച് സമഗ്രമായി പഠിക്കുന്നു.

GB **INTEGRITY VS MERE TECHNOLOGICAL PROFICIENCY**

Ethics investigates the nature of human freedom, virtue, and universally recognised obligations.

An individual may thrive as an artist or orator while exhibiting moral shortcomings, or conversely, a morally virtuous person may lack technical skill. **Ethics concerns the principles that cultivate personal integrity and societal welfare**, proving that technical efficiency must be guided by ethical virtue.

ML **സമഗ്രതയും സാങ്കേതിക പ്രാവീണ്യവും**

മനുഷ്യന്റെ സ്വാതന്ത്ര്യം, സദ്ഗുണം, സാർവ്വലൗകികമായി അംഗീകരിക്കപ്പെട്ട കടമകൾ എന്നിവയെക്കുറിച്ച് നീതിശാസ്ത്രം ആഴത്തിൽ ചിന്തിക്കുന്നു.

ഒരാൾ സാങ്കേതികവിദ്യയിലോ കലയിലോ അതിവിദഗ്ധനായിരിക്കുമ്പോഴും ധാർമ്മികമായി അധഃപതിച്ചേക്കാം; അല്ലെങ്കിൽ ധാർമ്മികതയുള്ള ഒരാൾക്ക് സാങ്കേതിക അറിവ് കുറവായിരിക്കാം. **സാങ്കേതിക കാര്യക്ഷമതയെക്കാൾ വ്യക്തിത്വ ശുദ്ധിയും സാമൂഹിക ക്ഷേമവുമാണ് പരമപ്രധാനം** എന്ന് എത്തിക്സ് നമ്മെ ഓർമ്മിപ്പിക്കുന്നു.

6. Fundamental Human Rights as Ethical Anchors
അടിസ്ഥാന മനുഷ്യാവകാശങ്ങൾ: ധാർമ്മിക അടിത്തറകൾ

GB RIGHT TO LIFE AND RIGHT TO FREEDOM

1. **Right to Life:** **Self-realisation constitutes the ultimate good, necessitating the continuation of life**. The sanctity of life must be acknowledged as a sacred moral duty.

2. **Right to Freedom:** Self-realisation is achieved through individual volition. One must be at liberty to exert autonomy without infringing upon social order or the rights of others.

ML **ജീവിക്കാനും സ്വാതന്ത്ര്യത്തിനുമുള്ള അവകാശം**

1. **ജീവിക്കാനുള്ള അവകാശം:** **സ്വയം സാക്ഷാത്കാരമാണ് പരമമായ നന്മ, അത് കൈവരിക്കാൻ ജീവന്റെ തുടർച്ച അത്യന്താപേക്ഷിതമാണ്**. ജീവന്റെ പവിത്രത കാത്തുസൂക്ഷിക്കുക എന്നത് പവിത്രമായ കടമയാണ്.

2. **സ്വാതന്ത്ര്യത്തിനുള്ള അവകാശം:** സ്വയം സാക്ഷാത്കാരം സാധ്യമാകുന്നത് ഇച്ഛാസ്വാതന്ത്ര്യത്തിലൂടെയാണ്. മറ്റുള്ളവരുടെ അവകാശങ്ങളെയോ സാമൂഹിക ക്രമത്തെയോ ഹനിക്കാതെ സ്വയംഭരണം നടത്താൻ ഓരോ വ്യക്തിക്കും അവകാശമുണ്ട്.

GB RIGHT TO WORK AND RIGHT TO EDUCATION

3. **Right to Work:** Derived from the fundamental right to life; without livelihood, self-actualization is denied. A contemporary welfare state must ensure employment.

4. **Right to Education:** Rights and obligations are linked. Society must provide optimal opportunities for individuals to realise their intellectual potential and contribute to collective welfare.

ML **തൊഴിൽ, വിദ്യാഭ്യാസ അവകാശങ്ങൾ**

3. **തൊഴിൽ ചെയ്യാനുള്ള അവകാശം:** ജീവിക്കാനുള്ള അവകാശത്തിൽ നിന്ന് ഉടലെടുക്കുന്നതാണ് തൊഴിലവകാശം. ഉപജീവനമില്ലാതെ വ്യക്തിത്വ വികാസം അസാധ്യമായതിനാൽ ക്ഷേമരാഷ്ട്രങ്ങൾ തൊഴിൽ ഉറപ്പാക്കണം.

4. **വിദ്യാഭ്യാസത്തിനുള്ള അവകാശം:** അവകാശങ്ങളും കടമകളും പരസ്പരം ബന്ധപ്പെട്ടിരിക്കുന്നു. വ്യക്തികളുടെ സർഗ്ഗശേഷി വികസിപ്പിക്കാനും സമൂഹത്തിന് സംഭാവന നൽകാനും ഉന്നത വിദ്യാഭ്യാസം ഉറപ്പാക്കേണ്ടതുണ്ട്.

7. Applied Ethics and Emergence of AI Ethics Frameworks
പ്രയോഗിക നീതിശാസ്ത്രവും (Applied Ethics) AI എത്തിക്സ് ചട്ടക്കൂടും

GB APPLIED ETHICS & EMERGING DIGITAL HAZARDS

The practical dimension of ethics is **applied ethics**, encompassing situational ethics alongside meta-ethics which investigates semantic queries regarding freedom and determinism.

While AI offers great utility, workplace surveillance and opaque algorithmic data practices subject humans to unprecedented hazards, potentially violating **employee privacy and trust**.

ML **പ്രയോഗിക നീതിശാസ്ത്രവും ഡിജിറ്റൽ ഭീഷണികളും**

നീതിശാസ്ത്രത്തിന്റെ പ്രായോഗിക വശമാണ് **അപ്ലൈഡ് എത്തിക്സ് (Applied Ethics)**. യഥാർത്ഥ ജീവിത സന്ദർഭങ്ങളിലെ ധാർമ്മിക പ്രശ്നങ്ങളെയാണ് ഇത് അഭിസംബോധന ചെയ്യുന്നത്.

എഐ സംവിധാനങ്ങൾ വലിയ പ്രയോജനം ചെയ്യുമ്പോഴും, തൊഴിലിടങ്ങളിലെ രഹസ്യ നിരീക്ഷണങ്ങളും അൽഗോരിതങ്ങളും മനുഷ്യരെ മുൻപെങ്ങുമില്ലാത്ത അപകടങ്ങളിലേക്ക് തള്ളിവിടുകയും **സ്വകാര്യതയും വിശ്വാസ്യതയും തകർക്കുകയും** ചെയ്യുന്നു.

GB FOUR CORE PRINCIPLES FOR TRUSTWORTHY AI

AI ethics is the specialised branch of applied ethics addressing algorithms, data practices, and automated systems.

Frameworks coalesce around four core pillars: **transparency, accountability, fairness, and privacy protection**, designed to guide the development of responsible and trustworthy AI technologies.

ML **വിശ്വസനീയ AI-യുടെ നാല് അടിസ്ഥാന തൂണുകൾ**

അൽഗോരിതങ്ങളും ഡാറ്റാ പ്രവർത്തനങ്ങളും സൃഷ്ടിക്കുന്ന വെല്ലുവിളികൾ പരിഹരിക്കുന്ന പ്രത്യേക പഠനശാഖയാണ് **എഐ എത്തിക്സ് (AI Ethics)**.

ഉത്തരവാദിത്തമുള്ള എഐ സാങ്കേതികവിദ്യ വികസിപ്പിക്കുന്നതിന് ആഗോളതലത്തിൽ നാല് പ്രധാന തത്ത്വങ്ങൾ മുന്നോട്ടുവെക്കുന്നു: **സുതാര്യത (Transparency), ഉത്തരവാദിത്തം (Accountability), നീതി (Fairness), സ്വകാര്യതാ സംരക്ഷണം (Privacy)**.

8. Goal Specification and Embedding Human Values
ലക്ഷ്യ നിർണ്ണയവും മനുഷ്യ മൂല്യങ്ങൾ ഉൾച്ചേർക്കലും

GB **PRECISE GOAL AND VALUE SPECIFICATION**

AI alignment requires synchronising the objectives of autonomous systems with human intentions so they operate freely while reflecting our priorities.

Precise goal definition denotes explicit articulation of anticipated functions, operational constraints, and results the system must eschew. Technical accuracy is vital for alignment.

ML **കൃത്യമായ ലക്ഷ്യ നിർണ്ണയത്തിന്റെ പ്രാധാന്യം**

സ്വയംഭരണ യന്ത്രങ്ങൾ സ്വതന്ത്രമായി പ്രവർത്തിക്കുമ്പോഴും നമ്മുടെ താല്പര്യങ്ങൾക്ക് അനുസൃതമായിരിക്കാൻ **എഐ അലൈൻമെന്റ്** അത്യന്താപേക്ഷിതമാണ്.

സിസ്റ്റം ചെയ്യേണ്ട പ്രവർത്തനങ്ങൾ, പാലിക്കേണ്ട നിയന്ത്രണങ്ങൾ, ഒഴിവാക്കേണ്ട പ്രത്യാഘാതങ്ങൾ എന്നിവ കൃത്യമായി നിർവ്വചിക്കുന്നതാണ് ലക്ഷ്യ നിർണ്ണയം. ലക്ഷ്യങ്ങൾ തെറ്റായി വ്യാഖ്യാനിക്കപ്പെടാതിരിക്കാൻ കൃത്യത കൂടിയേ തീരൂ.

GB **EMBEDDING STANDARDS VS LEARNING VALUES**

Embedding human values entails creating AI that continually honours core ethics rather than solely focusing on technical speed.

Learning human values equips systems to deduce, adapt to, and honour preferences and ethical conventions from human feedback, rather than relying exclusively on rigid, hardcoded rules.

ML **മൂല്യങ്ങൾ ഉൾച്ചേർക്കലും പഠിച്ചെടുക്കലും**

കേവലം സാങ്കേതിക വേഗതയിലോ ലാഭത്തിലോ ശ്രദ്ധ കേന്ദ്രീകരിക്കാതെ മാനുഷിക മൂല്യങ്ങളെ എപ്പോഴും ആദരിക്കുന്ന സിസ്റ്റങ്ങളെ നിർമ്മിക്കുന്നതാണ് വാല്യൂ എംബെഡിംഗ്.

കർക്കശമായ പ്രോഗ്രാം ചട്ടങ്ങൾക്ക് പകരം, മനുഷ്യന്റെ പെരുമാറ്റത്തിൽ നിന്നും ഫീഡ്ബാക്കിൽ നിന്നും **മൂല്യങ്ങൾ സ്വാംശീകരിക്കാനും ക്രമീകരിക്കാനും (Learning Human Values)** മെഷീനുകളെ പരിശീലിപ്പിക്കണം.

9. Safety, Non-Harm, and the Protection of Vulnerabilities
സുരക്ഷിതത്വം, ഉപദ്രവരാഹിത്യം & ചൂഷണങ്ങൾ തടയൽ

GB PHYSICAL, PSYCHOLOGICAL AND SOCIAL SAFETY

Safety and non-harm constitute a fundamental value that consistently supersedes efficiency, speed, or profit.

Physical safety prevents injury or damage to assets in high-risk autonomous AI. **Psychological and social safety** guarantees systems do not inflict mental suffering, emotional discomfort, social exclusion, or erode societal trust.

ML ശാരീരിക-മാനസിക-സാമൂഹിക സുരക്ഷ

കാര്യക്ഷമത, വേഗത, ലാഭം എന്നിവയേക്കാൾ ഉപരിയായി എഐ അലൈൻമെന്റിൽ മുൻഗണന നൽകേണ്ട ഒന്നാണ് സുരക്ഷിതത്വവും ഉപദ്രവരാഹിത്യവും (Safety & Non-Harm).

ശാരീരിക സുരക്ഷ ജീവഹാനിയും പരിക്കുകളും തടയുന്നു. **മാനസിക-സാമൂഹിക സുരക്ഷ** വ്യക്തികൾക്ക് മാനസിക വിഷമമോ, തെറ്റായ ധാരണകളോ, ഒറ്റപ്പെടലോ ഉണ്ടാകാതിരിക്കാനും സാമൂഹിക സ്ഥാപനങ്ങൾ തകരാതിരിക്കാനും സംരക്ഷണം നൽകുന്നു.

GB PROHIBITION OF MANIPULATION & RESPECT FOR DIGNITY

AI systems must strictly refrain from: emotional manipulation, deceptive persuasion, and exploiting human vulnerabilities.

Respect for human dignity acknowledges the inherent value of every individual; humans must never be regarded solely as instruments, data points, or means to an end.

ML ചൂഷണം തടയലും മാനുഷിക അന്തസ്സും

എഐ സംവിധാനങ്ങൾ മൂന്ന് കാര്യങ്ങൾ കർശനമായി ഒഴിവാക്കണം: വൈകാരിക കൃത്രിമം (Emotional manipulation), വഞ്ചനാപരമായ സ്വാധീനം, മനുഷ്യന്റെ ബലഹീനതകളെ ചൂഷണം ചെയ്യൽ.

മാനുഷിക അന്തസ്സ് (Human Dignity) ആദരിക്കപ്പെടണം; വ്യക്തികളെ ഒരിക്കലും വെറും വിവരങ്ങളായോ (Data Points), ഉപകരണങ്ങളായോ, ലക്ഷ്യത്തിലേക്കുള്ള മാർഗ്ഗമായോ മാത്രം മെഷീനുകൾ കാണരുത്.

10. Equal Moral Worth, Impartiality & Explainable AI (XAI)
തുല്യ ധാർമ്മിക മൂല്യം, നിഷ്പക്ഷത & വിശദീകരിക്കാവുന്ന AI (XAI)

GB EQUAL MORAL WORTH & NON-DISCRIMINATION

All human beings possess equal moral positions and merit equal respect, irrespective of race, gender, caste, religion, wealth, or ability.

Fairness and Non-Discrimination: Automated systems must guarantee equal treatment, avoiding unjust biases based on extraneous attributes. **Impartial decision-making** mandates choices rely objectively on pertinent facts.

ML **വിവേചനരാഹിത്യവും നിഷ്പക്ഷ തീരുമാനങ്ങളും**

ജാതി, മതം, ലിംഗം, സമ്പത്ത് എന്നിവയ്ക്കതീതമായി എല്ലാ മനുഷ്യർക്കും തുല്യമായ ധാർമ്മിക സ്ഥാനവും ആദരവും അവകാശപ്പെട്ടിരിക്കുന്നു.

നീതിയും വിവേചനരാഹിത്യവും: ബാഹ്യമായ വ്യക്തിഗത ഘടകങ്ങളുടെ അടിസ്ഥാനത്തിൽ പക്ഷപാതപരമായ തീരുമാനങ്ങൾ എടുക്കുന്നത് എഐ തടയണം. പ്രസക്തമായ വസ്തുതകളെ മാത്രം അടിസ്ഥാനമാക്കി **നിഷ്പക്ഷമായ വിധികൾ** പുറപ്പെടുവിക്കണം.

GB EXPLAINABLE AI (XAI) & SOLVING BLACK BOX MODELS

Transparency and Explainability (XAI) render automated systems comprehensible, interpretable, and accountable to human auditors and end-users.

Explainability addresses the notorious **"black box" problem** where complex neural networks evade human understanding. Clear algorithmic rationale enables the early detection and rectification of alignment failures.

ML **എക്സ്പ്ലൈനബിൾ AI-യും 'ബ്ലാക്ക് ബോക്സ്' പ്രതിസന്ധിയും**

സുതാര്യതയും വിശദീകരിക്കാനുള്ള കഴിവും (XAI) എഐ തീരുമാനങ്ങളെ മനുഷ്യർക്ക് മനസ്സിലാക്കാനും ഓഡിറ്റ് ചെയ്യാനും സാധ്യമാക്കുന്നു.

ഡീപ് ലേണിംഗ് മോഡലുകളുടെ സങ്കീർണ്ണത കാരണം മനുഷ്യബുദ്ധിക്ക് എളുപ്പം പിടികിട്ടാത്ത **'ബ്ലാക്ക് ബോക്സ്' (Black Box) പ്രതിസന്ധിയെ** ഇത് ഇല്ലാതാക്കുന്നു. എഐ എന്തുകൊണ്ട് ഒരു തീരുമാനമെടുത്തു എന്ന് വിശദീകരിക്കാൻ സാധിക്കുന്നത് തെറ്റുകൾ തിരുത്താൻ സഹായിക്കുന്നു.

11. Privacy, Human Oversight & Academic Practice Exercises
ഡാറ്റാ സംരക്ഷണം, മാനുഷിക മേൽനോട്ടം & പരീക്ഷാ ചോദ്യോത്തരങ്ങൾ

GB PRIVACY, DATA MINIMISATION & HUMAN-IN-THE-LOOP

Data minimisation asserts that only data essential for a specific purpose should be gathered. Informed consent and confidentiality protect Personally Identifiable Information (**PII**).

Human-in-the-loop oversight guarantees individuals can intervene or deactivate AI when required. Designers and deployers bear ultimate moral and legal accountability.

ML സ്വകാര്യതയും ഹ്യൂമൻ-ഇൻ-ദി-ലൂപ്പും

ഒരു നിശ്ചിത ആവശ്യത്തിന് തികച്ചും അത്യന്താപേക്ഷിതമായ വിവരങ്ങൾ മാത്രമേ ശേഖരിക്കാവൂ എന്ന തത്ത്വമാണ് ഡാറ്റാ മിനിമൈസേഷൻ. അറിവോടെയുള്ള സമ്മതവും രഹസ്യസ്വഭാവവും വ്യക്തിഗത വിവരങ്ങളെ (**PII**) സംരക്ഷിക്കുന്നു.

ഹ്യൂമൻ-ഇൻ-ദി-ലൂപ്പ് (Human-in-the-Loop) മേൽനോട്ടം വഴി അടിയന്തര ഘട്ടങ്ങളിൽ യന്ത്രത്തെ തടയാൻ മനുഷ്യന് അധികാരം ഉറപ്പാക്കുന്നു. എഐ വരുത്തുന്ന തെറ്റുകൾക്ക് മനുഷ്യ ഡെവലപ്പർമാർക്കാണ് പൂർണ്ണ ഉത്തരവാദിത്തം.

GB KNOCK YOUR BRAIN: OFFICIAL CURRICULUM MCQS

Q1: What is the main goal of AI alignment?
A) Faster systems | **B) Ensure AI acts according to human values** | C) Autonomy without supervision | D) Reduce cost
Answer: B · Congruence with human values and intentions.

Q2: Why is continuous monitoring important?
A) AI systems may drift from human-aligned behaviour over time | B) Goals never change | C) Delegate all duties | D) Slows efficiency
Answer: A · Preventing alignment drift across changing societal conditions.

ML സർവ്വകലാശാല പരീക്ഷാ ചോദ്യോത്തരങ്ങൾ

ചോദ്യം 1: എഐ അലൈൻമെന്റിന്റെ പ്രധാന ലക്ഷ്യമെന്ത്?
A) വേഗത കൂട്ടുക | **B) എഐ മനുഷ്യ മൂല്യങ്ങൾക്കനുസരിച്ച് പ്രവർത്തിക്കുന്നുവെന്ന് ഉറപ്പാക്കുക** | C) മേൽനോട്ടമില്ലാത്ത സ്വയംഭരണം | D) ചിലവ് കുറയ്ക്കുക
ശരിയുത്തരം: B · മനുഷ്യ ഉദ്ദേശ്യങ്ങളോടുള്ള സമ്പൂർണ്ണ പൊരുത്തം.

ചോദ്യം 2: നിരന്തരമായ മേൽനോട്ടം (Continuous Monitoring) അനിവാര്യമായിരിക്കുന്നത് എന്തുകൊണ്ട്?
A) കാലക്രമേണ എഐ പ്രവർത്തനങ്ങൾ മനുഷ്യ മൂല്യങ്ങളിൽ നിന്നും വ്യതിചലിച്ചേക്കാം (Drift) | B) മാറ്റമില്ലാത്ത ലക്ഷ്യങ്ങൾ | C) ഉത്തരവാദിത്ത കൈമാറ്റം | D) കാര്യക്ഷമത കുറയ്ക്കൽ
ശരിയുത്തരം: A · അലൈൻമെന്റ് ഡ്രിഫ്റ്റ് തടയാൻ നിരന്തര ഓഡിറ്റിംഗ് ആവശ്യമാണ്.

🎯 MUST-KNOW EXAM RECALL COMPENDIUM

20 Core Academic Concepts & Analytical Pillars

സ്വയംഭരണ AI അലൈൻമെന്റും എത്തിക്സും — പരീക്ഷാ കേന്ദ്രീകൃത സമഗ്ര ആശയങ്ങൾ

🎯 Core Goal
AI Alignment Problem
AI അലൈൻമെന്റ് പ്രതിസന്ധി
Ensuring autonomous system goals and behaviours remain strictly congruent with human values.
സ്വയംഭരണ യന്ത്രങ്ങളുടെ പ്രവർത്തനങ്ങൾ മനുഷ്യന്റെ ഉദ്ദേശ്യങ്ങളോട് പൊരുത്തപ്പെടുന്നുവെന്ന് ഉറപ്പാക്കൽ.

⚖️ Moral Worth
Moral Status & Standing
ധാർമ്മിക പദവി (Moral Status)
An entity toward which moral agents hold direct moral obligations due to its intrinsic worth.
സ്വതസിദ്ധമായ ആന്തരിക പ്രാധാന്യമുള്ളതിനാൽ ധാർമ്മിക പരിഗണന അർഹിക്കുന്ന അസ്തിത്വം.

🏛️ Etymology **Ethos & Mores**
പദോല്പത്തി: Ethos, Mores
Originating from Greek 'ethos' (character) and Latin 'mores' (customs), studying right conduct.
സ്വഭാവം (Ethos), ആചാരം (Mores) എന്നിവയിൽ നിന്നും നീതിശാസ്ത്ര പദത്തിന്റെ ഉത്ഭവം.

📒 Definition
Mackenzie's Conduct Formula
മക്കൻസിയുടെ സ്വഭാവ നിർവ്വചനം
The scientific examination of what is right or noble in human behaviour and voluntary action.
മനുഷ്യന്റെ ഇച്ഛാപരമായ പ്രവൃത്തികളിലെ ഉദാത്തമായ നന്മയെക്കുറിച്ചുള്ള ശാസ്ത്രീയ അന്വേഷണം.

📏 Rule-Bound **Rectus & 'Right'**
'ശരി' (Right / Rectus)
Derived from Latin 'rectus' meaning straight or in rigorous accordance with established moral rule.
ധാർമ്മിക നിയമങ്ങൾക്ക് അനുസൃതമായി നേരായ മാർഗ്ഗത്തിൽ പ്രവർത്തിക്കുക എന്നത്.

🌟 Ultimate Good **Gut & 'Good'**
'നന്മ' (Good / Gut)
Related to German 'gut'; denotes conduct that effectively realizes our virtuous purpose or goal.
സദ്ഗുണപൂർണ്ണമായ ലക്ഷ്യങ്ങൾ കൈവരിക്കാൻ സഹായിക്കുന്ന ഗുണമേന്മയുള്ള അവസ്ഥ.

🏋️ Primordial **Right to Life**
ജീവിക്കാനുള്ള അവകാശം
Sanctity of existence is the foundational right; continuation of life is vital for self-realisation.
സ്വയം സാക്ഷാത്കാരത്തിന് ജീവൻ അനിവാര്യമായതിനാൽ ജീവന്റെ പവിത്രത സംരക്ഷിക്കപ്പെടണം.

🕊️ Volition **Right to Freedom**
സ്വാതന്ത്ര്യത്തിനുള്ള അവകാശം
Autonomy to achieve one's ultimate purpose without infringing on the social order or others.
സാമൂഹിക ക്രമം തകർക്കാതെ സ്വന്തം ലക്ഷ്യങ്ങൾ നേടാനുള്ള വ്യക്തിപരമായ സ്വാതന്ത്ര്യം.

💼 Livelihood **Right to Work**
തൊഴിൽ ചെയ്യാനുള്ള അവകാശം
Derived from the right to life; modern welfare states must provide universal employment opportunities.
ഉപജീവനവും സ്വയം വികാസവും ഉറപ്പാക്കാൻ ഓരോ പൗരനും തൊഴിൽ ചെയ്യാനുള്ള അവകാശമുണ്ട്.

📚 Potential **Right to Education**
വിദ്യാഭ്യാസത്തിനുള്ള അവകാശം
Empowering individuals to attain maximum capability and contribute to collective welfare.
വ്യക്തികളുടെ ബുദ്ധിപരവും സാമൂഹികവുമായ ശേഷി പരമാവധി വികസിപ്പിക്കാനുള്ള അവസരം.

🛠️ Practical **Applied AI Ethics**
പ്രയോഗിക നീതിശാസ്ത്രം
Addressing emerging ethical hazards in algorithmic practices, workplace surveillance, and automated models.
ഡിജിറ്റൽ നിരീക്ഷണവും അൽഗോരിതങ്ങളും ഉയർത്തുന്ന പുതിയ വെല്ലുവിളികളെ നേരിടുന്ന ശാഖ.

🎯 Articulation
Clear Goal Specification
കൃത്യമായ ലക്ഷ്യ നിർണ്ണയം
Explicit definition of anticipated functions, operating constraints, and outcomes to eschew.
എഐ ചെയ്യേണ്ടതും കർശനമായി ഒഴിവാക്കേണ്ടതുമായ കാര്യങ്ങൾ കൃത്യമായി പ്രഖ്യാപിക്കൽ.

🛡️ Paramount **Safety & Non-Harm**
സുരക്ഷിതത്വവും ഉപദ്രവരാഹിത്യവും
Consistently supersedes speed, efficiency, or profit in all high-risk autonomous AI systems.
വേഗതയേക്കാളും ലാഭത്തേക്കാളും ഉപരിയായി ജീവനും സ്വത്തിനും മുൻഗണന നൽകുന്ന സമീപനം.

🧠 Well-Being
Psychological Safety
മാനസിക-സാമൂഹിക സുരക്ഷ
Guarantees AI does not cause mental anguish, social isolation, anxiety, or distrust among users.
മാനസിക സംഘർഷമോ വൈകാരിക പരിക്കോ സാമൂഹിക അകൽച്ചയോ സൃഷ്ടിക്കാതിരിക്കൽ.

🚫 Boundary
Prohibition of Manipulation
ചൂഷണ നിരോധനം
AI must refrain from emotional deception, manipulative persuasion, and exploiting human vulnerabilities.
മനുഷ്യന്റെ ബലഹീനതകളെ ചൂഷണം ചെയ്യുന്നതും വഞ്ചനാപരമായ സ്വാധീനങ്ങളും തടയൽ.

👑 Kantian Core **Human Dignity**
മാനുഷിക അന്തസ്സ് (Dignity)
Individuals have intrinsic worth and must never be treated as mere data points or instruments.
മനുഷ്യനെ വെറും ഡാറ്റയായോ ഉപകരണമായോ കണക്കാക്കാതെ അന്തസ്സോടെ കാണുക.

⚖️ Equality **Equal Moral Worth**
തുല്യ ധാർമ്മിക മൂല്യം
Equal respect for all persons regardless of extraneous attributes, preventing algorithmic discrimination.
ജാതി, മത, ലിംഗ ഭേദമന്യേ എല്ലാവർക്കും തുല്യ പരിഗണന നൽകി വിവേചനം ഇല്ലാതാക്കൽ.

🔍 Explainability
Explainable AI (XAI)
വിശദീകരിക്കാവുന്ന AI (XAI)
Overcoming the black-box dilemma by making algorithmic decision rationales interpretable to humans.
തീരുമാനങ്ങൾ എങ്ങനെയെടുത്തു എന്ന് മനുഷ്യർക്ക് വ്യക്തമാക്കിക്കൊണ്ട് സുതാര്യത ഉറപ്പാക്കൽ.

🔐 Data Rights **Data Minimisation**
ഡാറ്റാ മിനിമൈസേഷൻ
Gathering, processing, and retaining only the data strictly essential for an intended purpose.
ആവശ്യത്തിന് മാത്രമുള്ള വിവരങ്ങൾ മാത്രം ശേഖരിക്കുകയും അനാവശ്യ ഡാറ്റ ഒഴിവാക്കുകയും ചെയ്യൽ.

🕹️ Oversight
Human-in-the-Loop
ഹ്യൂമൻ-ഇൻ-ദി-ലൂപ്പ് മേൽനോട്ടം
Ensuring human authority to audit, intervene, or deactivate AI systems to maintain ethical alignment.
നിർണ്ണായക ഘട്ടങ്ങളിൽ ഇടപെടാനും നിയന്ത്രിക്കാനുമുള്ള അന്തിമ അധികാരം മനുഷ്യനിൽ നിലനിർത്തൽ.