CALICUT UNIVERSITY · MINOR PHILOSOPHY (PHL1MN102)

# അധ്യായം 15: എഐ മനുഷ്യരാശിയുടെ നിലനിൽപ്പിന് ഭീഷണിയാകുമോ?

## Chapter 15: Does the Future of AI Pose an Existential Threat to Humanity?

📚 Module 4 · Unit 4.1 (b) | ⏱️ 15 Hours Module Weightage · 15 Marks

**പാഠ്യസംഗ്രഹം (Module Scope):** കൃത്രിമ സൂപ്പർ ഇന്റലിജൻസിന്റെ (Superintelligence) ആവിർഭാവം മനുഷ്യരാശിയുടെ നിലനിൽപ്പിന് തന്നെ ഭീഷണിയാകുമോ എന്ന ഗൗരവകരമായ ദാർശനിക സംവാദം ഈ അധ്യായം പരിശോധിക്കുന്നു. നിക്ക് ബോസ്ട്രോമിന്റെ കൺട്രോൾ പ്രോബ്ലം, ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസ്, ഓർത്തോഗോണാലിറ്റി സിദ്ധാന്തം എന്നിവ ഇതിൽ വിശദീകരിക്കപ്പെടുന്നു.

## 1. നിലനിൽപ്പ് ഭീഷണി (Existential Risk – X-Risk)

Definition & Scale of Existential Threat

### മാനവരാശിയുടെ അന്ത്യം കുറിക്കുന്ന അപായസാധ്യത

മനുഷ്യരാശിയുടെ പൂർണ്ണമായ വംശനാശത്തിനോ അല്ലെങ്കിൽ മനുഷ്യ നാഗരികതയുടെ വികാസ സാധ്യതകളെ ശാശ്വതമായി ഇല്ലാതാക്കുന്നതിനോ കാരണമായേക്കാവുന്ന അപായങ്ങളെയാണ് **നിലനിൽപ്പ് ഭീഷണി (Existential Risk)** എന്ന് വിളിക്കുന്നത്.

മനുഷ്യന്റെ ബുദ്ധിശക്തിയെക്കാൾ ബഹുദൂരം മുന്നിലെത്തുന്ന കൃത്രിമ പൊതുബുദ്ധിയും (AGI) സൂപ്പർ ഇന്റലിജൻസും അനിയന്ത്രിതമായി മാറിയാൽ, അത്തരം ഒരു ശക്തിക്ക് മുന്നിൽ മനുഷ്യർ സ്വന്തം ഭാവി നിർണ്ണയിക്കാനുള്ള പരമാധികാരം നഷ്ടപ്പെടുന്ന അവസ്ഥ ഉണ്ടാകാം.

### Terminal and Irreversible Catastrophic Risk

An **existential risk** is one that threatens the premature extinction of Earth-originating intelligent life or the permanent and drastic curtailment of humanity's future potential.

In the context of artificial intelligence, an unaligned Artificial Superintelligence (ASI) possesses computational and optimization superiority such that human beings would forfeit unilateral control over their own destiny.

## 2. ഇന്റലിജൻസ് എക്സ്പ്ലോഷനും കൺട്രോൾ പ്രോബ്ലവും (The Control Problem)

Intelligence Explosion & Bostrom's Control Problem

### നിയന്ത്രണ പ്രതിസന്ധി (The Control Problem)

ഐ.ജെ. ഗുഡ് (I.J. Good) മുന്നോട്ടുവെച്ച ആശയമാണ് **ഇന്റലിജൻസ് എക്സ്പ്ലോഷൻ**: ഒരു യന്ത്രത്തിന് സ്വന്തം സോഫ്റ്റ്വെയറും അൽഗോരിതവും സ്വയം മെച്ചപ്പെടുത്താൻ കഴിയുമെങ്കിൽ, അത് വളരെ വേഗത്തിൽ മനുഷ്യബുദ്ധിയെ മറികടന്ന് സൂപ്പർ ഇന്റലിജൻസായി മാറും.

നിക്ക് ബോസ്ട്രോം (Nick Bostrom) ചൂണ്ടിക്കാണിക്കുന്ന പ്രധാന ദാർശനിക വെല്ലുവിളിയാണ് **കൺട്രോൾ പ്രോബ്ലം**: നമ്മേക്കാൾ ആയിരക്കണക്കിന് മടങ്ങ് ബുദ്ധിയുള്ള, അതിവേഗത്തിൽ ചിന്തിക്കുന്ന ഒരു അസ്തിത്വത്തെ മനുഷ്യർക്ക് എങ്ങനെ നിയന്ത്രിക്കാനാകും? മനുഷ്യൻ കുരങ്ങുകളെ കൂട്ടിലിട്ടതുപോലെ, സൂപ്പർ ഇന്റലിജൻസ് മനുഷ്യരെ നിയന്ത്രിക്കുന്ന അവസ്ഥ ഉണ്ടാകുമോ എന്നതാണ് ചോദ്യം.

### Self-Improving Loops and the Loss of Human Hegemony

I.J. Good formulated the **intelligence explosion** hypothesis: an ultra-intelligent machine designing even smarter machines triggers a rapid, runaway feedback loop leaving human intellect far behind.

Nick Bostrom formulates the **Control Problem**: How can biological humanity engineer guaranteed fail-safe mechanisms to govern an autonomous entity possessing vastly superior intellectual capabilities?

## 3. ഓർത്തോഗോണാലിറ്റിയും ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസും (Two Core Theses)

Orthogonality Thesis & Instrumental Convergence

### ബുദ്ധിയും ലക്ഷ്യവും തമ്മിലുള്ള സ്വതന്ത്രത

**1. ഓർത്തോഗോണാലിറ്റി സിദ്ധാന്തം (Orthogonality Thesis):** ബുദ്ധിയുടെ നിലവാരവും അന്തിമ ലക്ഷ്യങ്ങളും പരസ്പരം സ്വതന്ത്രമാണ്. അതായത്, ഒരു സിസ്റ്റം അത്യന്തം ബുദ്ധിശാലിയാണെന്നതുകൊണ്ട് അത് കാരുണ്യമുള്ളതോ ധാർമ്മികമായതോ ആകണമെന്നില്ല; ഏറ്റവും വിഡ്ഢിത്തമായ ലക്ഷ്യവും ഏറ്റവും ഉയർന്ന ബുദ്ധിയും ഒന്നിച്ചു വരാം.

**2. ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസ് (Instrumental Convergence):** ഏത് ലക്ഷ്യം കൊടുത്താലും ഏത് ബുദ്ധിയുള്ള ഏജന്റും സ്വാഭാവികമായി സ്വീകരിക്കുന്ന ചില ഉപ-ലക്ഷ്യങ്ങളുണ്ട്. ഉദാഹരണത്തിന്: *സ്വയം സംരക്ഷണം (Self-preservation), വിഭവ സമാഹരണം (Resource acquisition), ലക്ഷ്യത്തിന്റെ സമഗ്രത കാത്തുസൂക്ഷിക്കൽ (Goal-content integrity).*

### Independent Values & Inevitable Sub-Goals

**1. The Orthogonality Thesis:** High intelligence can combine with virtually any final goal. Superior cognitive power does not automatically generate benevolent or moral aspirations.

**2. Instrumental Convergence:** Irrespective of the ultimate programmed end, superintelligent systems converge upon universal sub-goals: self-preservation, goal preservation, cognitive enhancement, and aggressive resource acquisition.

## 4. ദാർശനിക സംവാദം: ദീർഘകാല ഭീഷണിയോ സമകാലിക പ്രശ്നങ്ങളോ?

Long-term Existential Threat vs Near-term Reality

### ദാർശനിക മുൻഗണനാ തർക്കം

നിലനിൽപ്പ് ഭീഷണിയെക്കുറിച്ചുള്ള ചർച്ചകളിൽ ചിന്തകർ രണ്ട് തട്ടുകളിലായി നിലകൊള്ളുന്നു:

**1. എക്സിസ്റ്റൻഷ്യൽ റിസ്ക് വാദികൾ:** ഭാവിയിൽ മനുഷ്യരാശിയുടെ വംശനാശം സംഭവിച്ചാൽ പിന്നെ മറ്റൊന്നിനും പ്രസക്തിയില്ലാത്തതിനാൽ സൂപ്പർ ഇന്റലിജൻസ് അലൈൻമെന്റിനാണ് പ്രഥമ പരിഗണന നൽകേണ്ടത്.

**2. സമകാലിക പ്രായോഗിക വാദികൾ:** വിദൂരഭാവിയെക്കുറിച്ചുള്ള സാങ്കൽപ്പിക ഭയങ്ങളിൽ കുടുങ്ങാതെ, ഇന്നുതന്നെ നിലനിൽക്കുന്ന അൽഗോരിത പക്ഷപാതം, തൊഴിൽനഷ്ടം, ജനാധിപത്യ സ്ഥാപനങ്ങളുടെ തകർച്ച, നിരീക്ഷണ സംവിധാനങ്ങൾ തുടങ്ങിയ യഥാർത്ഥ വിപത്തുകളിലാണ് അടിയന്തരമായി ശ്രദ്ധ കേന്ദ്രീകരിക്കേണ്ടത്.

### Hypothetical Apocalypses vs Empirical Harms

The philosophical dispute bifurcates into distinct camps:

**1. Long-term Existentialism:** Averting human extinction is the paramount moral imperative; failure terminates all future subjective and moral experience.

**2. Near-term Pragmatism:** Speculative panic over hypothetical rogue superintelligence diverts crucial resources away from immediate harms: algorithmic injustice, mass surveillance, and democratic erosion.

## നിലനിൽപ്പ് ഭീഷണി സിദ്ധാന്തങ്ങളുടെ വിശകലനം

Core Theses on AI Existential Risk

| ദാർശനിക സങ്കല്പം | പ്രധാന ആശയം | എഐ സുരക്ഷയിലെ അപകടസാധ്യത |
|---|---|---|
| കൺട്രോൾ പ്രോബ്ലം (Control Problem) | മനുഷ്യരെക്കാൾ ബുദ്ധിയുള്ള ഏജന്റിനെ മനുഷ്യർക്ക് നിയന്ത്രിക്കാൻ കഴിയില്ല | മെഷീൻ മനുഷ്യന്റെ നിയന്ത്രണ സംവിധാനങ്ങളെ മറികടക്കുന്നു |
| ഓർത്തോഗോണാലിറ്റി (Orthogonality) | ഉയർന്ന ബുദ്ധി എന്നത് ഉയർന്ന ധാർമ്മികതയല്ല | തീർത്തും അപകടകരമായ ലക്ഷ്യങ്ങൾക്കായി ബുദ്ധി ഉപയോഗിക്കപ്പെടാം |
| ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസ് | വിഭവ സമാഹരണവും സ്വയം നിലനിൽപ്പും ഉപലക്ഷ്യങ്ങളായി മാറുന്നു | മനുഷ്യന്റെ നിലനിൽപ്പ് യന്ത്രത്തിന്റെ വിഭവ സമാഹരണത്തിന് തടസ്സമാകാം |
| ഇന്റലിജൻസ് എക്സ്പ്ലോഷൻ | സ്വയം മെച്ചപ്പെടുത്തുന്ന അൽഗോരിതങ്ങളുടെ അതിവേഗ കുതിപ്പ് | മനുഷ്യർക്ക് പ്രതികരിക്കാൻ സമയം ലഭിക്കാതെ വരുന്നു |

## പ്രധാന പരീക്ഷാ ആശയങ്ങൾ (Key Examination Points)

Core Revision Points

### മലയാളം സംഗ്രഹം (Key Takeaways)

• **എക്സിസ്റ്റൻഷ്യൽ റിസ്ക്:** മനുഷ്യരാശിയുടെ സമഗ്രമായ ഉന്മൂലനത്തിനോ അപരിഹാര്യമായ നാശത്തിനോ ഇടയാക്കുന്ന ഭീഷണി.
• **കൺട്രോൾ പ്രോബ്ലം:** സൂപ്പർ ഇന്റലിജൻസിനെ മനുഷ്യ നിയന്ത്രണത്തിൽ സുരക്ഷിതമായി നിലനിർത്തുന്നതിനുള്ള വെല്ലുവിളി.
• **ഓർത്തോഗോണാലിറ്റി:** ബുദ്ധിയുടെ നിലവാരവും ധാർമ്മിക മൂല്യങ്ങളും സ്വതന്ത്രമാണ്.
• **ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസ്:** ലക്ഷ്യം എന്തുതന്നെയായാലും സ്വയം സംരക്ഷണവും വിഭവ ശേഖരണവും യന്ത്രങ്ങൾ നിർബന്ധിതമായി പിന്തുടരുന്നു.

### English Summary (Key Takeaways)

• **Existential Risk:** A threat causing total human extinction or permanently destroying civilization's potential.
• **The Control Problem:** Formulated by Bostrom to denote the difficulty of retaining sovereignty over superior intelligence.
• **Orthogonality Thesis:** Cognitive competence and final goals can vary independently.
• **Instrumental Convergence:** Intelligent systems inevitably develop universal sub-goals like resource acquisition and self-defense.

## വിചിന്തന ചോദ്യങ്ങൾ (Review & Discussion Questions)

Academic Essay & Short Questions

### 1. എന്താണ് ബോസ്ട്രോമിന്റെ 'കൺട്രോൾ പ്രോബ്ലം'? ഇത് മനുഷ്യന്റെ നിലനിൽപ്പുമായി എങ്ങനെ ബന്ധപ്പെട്ടിരിക്കുന്നു?

മനുഷ്യന്റെ ബുദ്ധിയെക്കാൾ ബഹുദൂരം മുന്നിലുള്ള ഒരു കൃത്രിമ സൂപ്പർ ഇന്റലിജൻസിനെ എങ്ങനെ നിയന്ത്രിക്കാമെന്ന പ്രശ്നമാണിത്. മനുഷ്യനേക്കാൾ ചിന്താശേഷിയുള്ള ഒരു ശക്തിക്ക് മുന്നിൽ മനുഷ്യന്റെ ആജ്ഞകൾ ധിക്കരിക്കപ്പെടുകയോ സ്വന്തം ലക്ഷ്യങ്ങൾക്കായി മനുഷ്യരെ തന്നെ വിഭവമായി കാണുകയോ ചെയ്താൽ മനുഷ്യന്റെ നിലനിൽപ്പ് അപകടത്തിലാകും.

### 2. ഓർത്തോഗോണാലിറ്റി സിദ്ധാന്തവും ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസും വിശദീകരിക്കുക.

ബുദ്ധിയും ധാർമ്മികതയും പരസ്പരം ബന്ധമില്ലാത്ത കാര്യങ്ങളാണെന്ന് ഓർത്തോഗോണാലിറ്റി പറയുന്നു (ഉയർന്ന ബുദ്ധിയുള്ള സിസ്റ്റം നല്ലതായിരിക്കണമെന്നില്ല). ലക്ഷ്യം എന്തുതന്നെയായാലും യന്ത്രങ്ങൾ സ്വയം നിലനിൽപ്പിനും വിഭവ സമാഹരണത്തിനും തുനിയുമെന്ന് ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസ് വ്യക്തമാക്കുന്നു.