മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 16: മെഷീൻ ലേണിംഗിലെ അൽഗോരിതമിക് പക്ഷപാതങ്ങൾ തടയൽ (Preventing Algorithmic Biases)

Module 4 · Chapter 16: Algorithmic Bias, Fairness Metrics & Explainable AI (XAI) · Calicut University B.A. Philosophy FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

1. എൽ.എം.എസ് അവലോകനവും പഠന ലക്ഷ്യങ്ങളും (LMS Module Overview & Objectives)

LMS Overview: Syllabus unit 4.2(a) investigates how to prevent learning algorithms from acquiring and amplifying morally objectionable biases. In modern machine learning, systems trained on historical data frequently perpetuate racial, gender, socio-economic, and caste discrimination in criminal justice (COMPAS), mortgage lending, hiring (Amazon recruitment tool), and healthcare algorithms. We critically examine sources of bias, mathematical definitions of algorithmic fairness, Explainable AI (XAI), and Ethics-by-Design.

LMS ലക്ഷ്യങ്ങൾ: അൽഗോരിതമിക് ബയാസ് (Algorithmic Bias) എന്താണെന്ന് മനസ്സിലാക്കുക; ചരിത്രപരമായ ഡാറ്റയിലെ വിവേചനങ്ങൾ മെഷീൻ ലേണിംഗ് മോഡലുകളിലേക്ക് എങ്ങനെ പടരുന്നുവെന്ന് പരിശോധിക്കുക; ഫെയർനസ് മെട്രിക്സ് (Demographic Parity, Equalized Odds), ക്ലൈൻബർഗിന്റെ അസാദ്ധ്യതാ സിദ്ധാന്തം (Impossibility Theorem of Fairness) എന്നിവ പഠിക്കുക; എക്സ്പ്ലെയ്നബിൾ എഐ (XAI), എത്തിക്സ്-ബൈ-ഡിസൈൻ (Ethics-by-Design) എന്നിവയുടെ പ്രാധാന്യം തിരിച്ചറിയുക.

2. പക്ഷപാതങ്ങളുടെ ഉറവിടങ്ങളും തരങ്ങളും (Sources & Forms of Algorithmic Bias)

EN **Taxonomy of Algorithmic Biases:** Bias in AI is rarely the result of overt malice by software developers; it fundamentally reflects systemic social injustices encoded in training data:

- **Historical / Pre-existing Bias:** Occurs when the training data accurately reflects an already unjust world (e.g., historical arrest rates reflecting biased policing).
- **Representation / Sampling Bias:** Marginalized groups are drastically underrepresented in training corpuses (e.g., facial recognition software failing on dark-skinned women due to datasets over-representing light-skinned males).
- **Proxy Discrimination:** Redacting sensitive protected attributes (race, gender) fails because the algorithm easily reconstructs them from correlated proxies (zip codes, browsing history, school attended).
- **Feedback Loops (Self-Fulfilling Prophecy):** Biased predictive policing sends more officers to low-income neighborhoods, leading to more arrests, generating more biased training data.

ML **അൽഗോരിതമിക് പക്ഷപാതങ്ങളുടെ വർഗ്ഗീകരണം:** സോഫ്റ്റ്‌വെയർ എൻജിനീയർമാർ മനഃപൂർവ്വം ഉണ്ടാക്കുന്നതല്ല മറിച്ച് നമ്മുടെ സമൂഹത്തിൽ നിലനിൽക്കുന്ന അനീതികൾ ഡാറ്റയിലൂടെ യന്ത്രം പഠിച്ചെടുക്കുന്നതാണ് അൽഗോരിതമിക് ബയാസ്:

- **ചരിത്രപരമായ പക്ഷപാതം (Historical Bias):** ഭൂതകാല സമൂഹത്തിലെ വിവേചനങ്ങൾ അതേപടി രേഖപ്പെടുത്തപ്പെട്ട ഡാറ്റ ഉപയോഗിക്കുമ്പോൾ യന്ത്രവും അതേ വിവേചനം ശരിയാണെന്ന് കരുതുന്നു.
- **സാമ്പിളിംഗ് പക്ഷപാതം (Representation Bias):** ന്യൂനപക്ഷ വിഭാഗങ്ങളുടെയോ പാർശ്വവൽക്കരിക്കപ്പെട്ടവരുടെയോ വിവരങ്ങൾ ഡാറ്റാബേസിൽ വേണ്ടത്ര ഉൾപ്പെടുത്താത്ത അവസ്ഥ (ഉദാ: കറുത്തവർഗ്ഗക്കാരായ സ്ത്രീകളുടെ മുഖം തിരിച്ചറിയുന്നതിൽ ഫേഷ്യൽ റെക്കഗ്നിഷൻ പരാജയപ്പെടുന്നത്).
- **പ്രോക്സി വിവേചനം (Proxy Discrimination):** ജാതിയോ ലിംഗമോ മറച്ചുവെച്ചാലും, താമസിക്കുന്ന സ്ഥലം (പിൻകോഡ്), പഠിച്ച സ്കൂൾ എന്നിവയിൽ നിന്ന് യന്ത്രം ആ വിവരങ്ങൾ ചികഞ്ഞെടുത്ത് വിവേചനം കാണിക്കുന്നത്.
- **ഫീഡ്ബാക്ക് ലൂപ്പ് (Feedback Loop):** മുൻവിധിയോടെയുള്ള അൽഗോരിതം നൽകുന്ന നിർദ്ദേശങ്ങൾ കൂടുതൽ വിവേചനപരമായ അറസ്റ്റുകളിലേക്ക് നയിക്കുകയും അത് വീണ്ടും കൂടുതൽ പക്ഷപാതപരമായ ഡാറ്റയായി മാറുകയും ചെയ്യുന്നത്.



3. ഗണിതശാസ്ത്രപരമായ ഫെയർനെസ് തത്വങ്ങൾ (Mathematical Criteria for Fairness)

ഫെയർനെസ് മെട്രിക്സുകളും അവ തമ്മിലുള്ള സംഘർഷവും:

- **Demographic Parity (സ്റ്റാറ്റിസ്റ്റിക്കൽ തുല്യത):** ഒരു ആനുകൂല്യം (ഉദാ: ജോലി അല്ലെങ്കിൽ വായ്പ) എല്ലാ വിഭാഗങ്ങൾക്കും അവരുടെ ജനസംഖ്യാ അനുപാതത്തിന് തുല്യമായി ലഭിക്കണം: $P(\hat{Y}=1 | A=0) = P(\hat{Y}=1 | A=1)$.
- **Equalized Odds (തുല്യ സാധ്യത):** എല്ലാ വിഭാഗങ്ങളിലും തുല്യമായ ട്രൂ പോസിറ്റീവ് റേറ്റും (TPR) ഫോൾസ് പോസിറ്റീവ് റേറ്റും (FPR) ഉണ്ടായിരിക്കണം. യോഗ്യതയുള്ളവർക്ക് തുല്യ പരിഗണന ലഭിക്കണം.
- **Kleinberg's Impossibility Theorem (2016):** ജോൺ ക്ലൈൻബർഗ്ഗും സംഘവും തെളിയിച്ചതുപോലെ, രണ്ട് വ്യത്യസ്ത വിഭാഗങ്ങളിൽ അടിസ്ഥാന കൃത്യത നിരക്കുകൾ വ്യത്യസ്തമായിരിക്കുമ്പോൾ, ഈ മൂന്ന് ഫെയർനെസ് മാനദണ്ഡങ്ങളും ഒരേസമയം പാലിക്കുക ഗണിതശാസ്ത്രപരമായി അസാധ്യമാണ്!

4. എൽ.എം.എസ് ചോദ്യോത്തരങ്ങൾ (LMS Questions & In-Depth Answers)

EN **LMS Core Question 1: What is "Ethics-by-Design" in machine learning?**

Answer: Ethics-by-Design is an engineering paradigm where moral constraints, fairness audits, transparency metrics, and privacy safeguards are baked into the architectural design from the ground up, rather than added as superficial post-hoc corrections.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 1: മെഷീൻ ലേണിംഗിലെ 'എത്തിക്സ്-ബൈ-ഡിസൈൻ' (Ethics-by-Design) എന്നാൽ എന്ത്?**

ഉത്തരം: സോഫ്റ്റ്വെയർ നിർമ്മിച്ചു കഴിഞ്ഞതിനു ശേഷം പുറത്തുനിന്ന് തിരുത്തലുകൾ നടത്തുന്നതിന് പകരം, സിസ്റ്റത്തിന്റെ ആദ്യ രൂപരേഖ മുതൽ തന്നെ ധാർമ്മികതയും, നീതിയും, സുതാര്യതയും അതിന്റെ ഘടനയിൽ ഉൾച്ചേർക്കുന്ന എഞ്ചിനീയറിംഗ് രീതിയാണിത്.

EN **LMS Core Question 2: Why does optimizing purely for statistical accuracy amplify discrimination?**
Answer: When an objective function minimizes loss solely based on accuracy, the algorithm naturally exploits historical majoritarian patterns. Since marginalized groups form a statistical minority in the data, the model optimizes its overall score by sacrificing accuracy and fairness for the minority group.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 2: കേവല കൃത്യതയ്ക്ക് (Pure Accuracy) വേണ്ടി മാത്രം ഒപ്റ്റിമൈസ് ചെയ്യുന്നത് വിവേചനം കൂട്ടുന്നത് എന്തുകൊണ്ട്?**
ഉത്തരം: ഒരു മെഷീൻ കൂടുതൽ ശതമാനം ശരിയാക്കാൻ വേണ്ടി മാത്രം ശ്രമിക്കുമ്പോൾ, അത് ജനസംഖ്യയിലെ ഭൂരിപക്ഷ വിഭാഗത്തിന്റെ സ്വഭാവങ്ങളെ മാത്രം അടിസ്ഥാനമാക്കുന്നു. ന്യൂനപക്ഷങ്ങളെ അവഗണിച്ചാലും അതിന്റെ മൊത്തത്തിലുള്ള സ്കോർ ഉയർന്നു നിൽക്കുമെന്നതിനാൽ, ഇത് പാർശ്വവൽക്കരിക്കപ്പെട്ട വിഭാഗങ്ങൾക്ക് വലിയ അനീതിയുണ്ടാക്കുന്നു.

5. പരീക്ഷാ കേന്ദ്രീകൃത 20 സുപ്രധാന പോയിന്റുകൾ (20 Deep Exam Points)

1

Algorithmic Bias (അൽഗോരിതമിക് പക്ഷപാതം): Systematic and unfair deviations in automated outputs that privilege certain demographic groups over others. ചില ജനവിഭാഗങ്ങൾക്ക് കൂടുതൽ മുൻഗണന നൽകുകയും മറ്റുള്ളവരെ അന്യായമായി തഴയുകയും ചെയ്യുന്ന ഓട്ടോമേറ്റഡ് വ്യതിയാനം.

2

Historical Bias: Bias inherent in past real-world data reflecting historical racism, patriarchy, or economic inequality. ചരിത്രപരമായ വിവേചനങ്ങളും അനീതികളും ഡാറ്റാബേസിൽ പ്രതിഫലിക്കുന്നതുവഴി ഉണ്ടാകുന്ന പക്ഷപാതം.

3

Representation / Sampling Bias: The failure of a training set to represent the true distribution of diverse social groups accurately. ഡാറ്റാ ശേഖരണത്തിൽ ന്യൂനപക്ഷ വിഭാഗങ്ങളെ തുല്യമായി ഉൾപ്പെടുത്താത്തതുമൂലം ഉണ്ടാകുന്ന പോരായ്മ.

4

Proxy Variables (പ്രോക്സി വേരിയബിളുകൾ): Neutral features (like postal code, hobbies, or school names) that mathematically leak protected attributes like race or caste. ജാതിയോ മതമോ മാറ്റിനിർത്തിയാലും പിൻകോഡ് പോലെയുള്ള വിവരങ്ങളിലൂടെ ആ വിവേചനം വീണ്ടും കടന്നുവരുന്നത്.

5

Demographic Parity: Fairness metric demanding that the decision rate (e.g. loan approval) be identical across all protected groups regardless of qualification base rates. യോഗ്യതകൾ എന്തുതന്നെയായാലും എല്ലാ വിഭാഗങ്ങൾക്കും തുല്യ അനുപാതത്തിൽ ആനുകൂല്യങ്ങൾ ലഭിക്കണമെന്ന് പറയുന്ന ഫെയർനെസ് മാനദണ്ഡം.

6

Equalized Odds: Demands that true positive rates and false positive rates be equal across all protected demographics. തുല്യ യോഗ്യതയുള്ളവർക്ക് തുല്യ പരിഗണന നൽകുകയും തെറ്റായ നിരസിക്കലുകൾ എല്ലാ വിഭാഗത്തിലും തുല്യമായിരിക്കുകയും വേണം.

7

Kleinberg's Impossibility Theorem: Proves that except under trivial conditions, different mathematical fairness definitions (Calibration, Parity, Balance) are mutually incompatible. വ്യത്യസ്ത ഗണിതശാസ്ത്രപരമായ ഫെയർനെസ് നിർവ്വചനങ്ങൾ ഒരേസമയം ഒരുമിച്ച് പാലിക്കാൻ കഴിയില്ലെന്ന തെളിവ്.

8

Pre-processing Fairness Methods: Re-sampling, re-weighting, or scrubbing biased training datasets before feeding them to the algorithm. മോഡലിനെ പരിശീലിപ്പിക്കുന്നതിന് മുൻപായി ഡാറ്റയിലെ പക്ഷപാതങ്ങൾ കണ്ടെത്തി തുല്യമാക്കുന്ന രീതി.

9

In-processing Fairness Methods: Injecting mathematical fairness constraints directly into the loss function during model training. അൽഗോരിതത്തിന്റെ ടെയിനിംഗ് വേളയിൽത്തന്നെ നീതിയുക്തമായ നിയന്ത്രണങ്ങൾ സമവാക്യത്തിൽ ഉൾപ്പെടുത്തുന്ന രീതി.

10

Post-processing Fairness Methods: Adjusting decision thresholds and cutoff scores for different groups after the model has produced raw predictions. പ്രവചനങ്ങൾക്ക് ശേഷം ഔട്ട്പുട്ട് സ്കോറുകളിൽ മാറ്റങ്ങൾ വരുത്തി തുല്യത ഉറപ്പാക്കുന്നത്.

11

Ethics-by-Design (Value-Sensitive Design): Proactively embedding human rights and ethical constraints into the system architecture from inception. തുടക്കം മുതൽ തന്നെ ധാർമ്മിക മൂല്യങ്ങളെ സിസ്റ്റത്തിന്റെ ഡിസൈനിൽ ഉൾച്ചേർക്കുന്ന സമീപനം.

12

Ethical Impact Assessment (EIA): A rigorous pre-deployment audit examining the social, civil, and human rights consequences of an AI system. ഒരു എഐ വിന്യസിക്കുന്നതിന് മുൻപായി അത് സമൂഹത്തിൽ ഉണ്ടാക്കാൻ സാധ്യതയുള്ള പ്രത്യാഘാതങ്ങൾ വിലയിരുത്തുന്ന സമഗ്ര പരിശോധന.

13

Explainable AI (XAI): Techniques (LIME, SHAP) designed to reveal the internal reasoning and influential features of opaque black-box models. ബ്ലാക്ക് ബോക്സ് മോഡലുകൾ എടുത്ത തീരുമാനത്തിന്റെ കാരണങ്ങൾ മനുഷ്യർക്ക് മനസ്സിലാകുന്ന തരത്തിൽ വിശദീകരിക്കുന്ന സാങ്കേതികവിദ്യ.

14

Disparate Impact: When an ostensibly neutral policy or algorithm results in disproportionate adverse effects on a protected class. പുറമെ നിഷ്പക്ഷമെന്ന് തോന്നുമെങ്കിലും ഒരു പ്രത്യേക ജനവിഭാഗത്തിന് ദോഷകരമായി ഭവിക്കുന്ന ഫലം.

15

Counterfactual Fairness: A decision is fair if it would remain identical had the individual belonged to a different demographic group in a parallel world. ഒരാൾ മറ്റൊരു സമുദായത്തിലോ ലിംഗത്തിലോ ആയിരുന്നുവെങ്കിൽ പോലും ഇതേ തീരുമാനം തന്നെ ലഭിക്കുമായിരുന്നുവെങ്കിൽ അത് നീതിയുക്തമാണ്.

16

COMPAS Algorithm Controversy (ProPublica 2016): Demonstrated that a recidivism risk algorithm predicted higher false positive crime risk for Black defendants than White defendants. കുറ്റവാളികളുടെ റിസ്ക് പ്രവചിക്കുന്ന അൽഗോരിതങ്ങൾ വർണ്ണവിവേചനം കാണിക്കുന്നുവെന്ന് വെളിപ്പെടുത്തിയ പ്രൊപബ്ലിക്ക അന്വേഷണം.

17

Auditing Datasets: Mandatory verification of datasets for intersectional balance (gender, race, disability, age). ഡാറ്റാബേസിൽ എല്ലാ വിഭാഗങ്ങളുടെയും പ്രാതിനിധ്യം ഉണ്ടെന്ന് ഉറപ്പുവരുത്തുന്ന ഓഡിറ്റിംഗ് പ്രക്രിയ.

18

Concept Drift in Fairness: An algorithm deemed fair at deployment can become discriminatory as real-world demographics and cultural norms shift. കാലം മാറുമ്പോൾ മുൻപ് നീതിയുക്തമായിരുന്ന അൽഗോരിതങ്ങളിൽ പുതിയ വിവേചനങ്ങൾ ഉടലെടുക്കാം.

19

Perils of Pure Accuracy Optimization: Maximizing accuracy at all costs rewards the model for exploiting majoritarian bias while silencing minorities. പരമാവധി കൃത്യത മാത്രം നോക്കുമ്പോൾ ന്യൂനപക്ഷങ്ങളെ തഴഞ്ഞ് ഭൂരിപക്ഷ താല്പര്യങ്ങൾക്ക് മുൻതൂക്കം ലഭിക്കുന്നു.

20

Right to Explanation (EU GDPR): Legal entitlement of individuals subject to automated decisions to obtain meaningful explanations of the logic involved. കമ്പ്യൂട്ടർ എടുത്ത തീരുമാനത്തിന്റെ യുക്തി അറിയാൻ പൗരനുള്ള നിയമപരമായ അവകാശം.

6. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (MCQs & Solutions)

Q86: What is the primary underlying cause of algorithmic bias in machine learning?

A. Excess computational processing power

B. Models inherit, encode, and magnify biases present in historical training datasets (ശരിയുത്തരം)

C. The inherent perfection of mathematical equations

D. Hardware network bandwidth limitations

പാഠഭാഗ വിശകലനം: ചരിത്രപരമായ മനുഷ്യ രേഖകളിലും ഡാറ്റയിലുമുള്ള പക്ഷപാതങ്ങൾ മെഷീൻ ലേണിംഗ് മോഡലുകൾ പഠിച്ചെടുക്കുന്നതാണ് അൽഗോരിതമിക് ബയാസിന്റെ പ്രധാന കാരണം.

വിശദീകരണം: മുൻകാല മനുഷ്യ സമൂഹത്തിലെ തെറ്റുകൾ അടങ്ങിയ ഡാറ്റയിൽ പരിശീലനം നേടുമ്പോൾ മോഡലുകൾ ആ വിവേചനങ്ങളെ സ്വാഭാവികമായി ഏറ്റെടുക്കുന്നു.

Q87: How can developers directly diagnose systemic discrimination in an AI model?

A. By blindly increasing the training dataset size

B. Through independent algorithmic fairness audits and parity evaluations (ശരിയുത്തരം)

C. By upgrading server graphics cards

D. By applying network data encryption

പാഠഭാഗ വിശകലനം: ഫെയർനെസ് ഓഡിറ്റുകളും സ്റ്റാറ്റിസ്റ്റിക്കൽ പാരിറ്റി പരിശോധനകളും വഴിയാണ് അൽഗോരിതങ്ങളിലെ വിവേചനം കണ്ടെത്തുന്നത്.

വിശദീകരണം: സ്വതന്ത്രമായ പരിശോധനകളിലൂടെ വിവിധ ജനവിഭാഗങ്ങളിലെ ട്രൂ പോസിറ്റീവ്, ഫോൾസ് പോസിറ്റീവ് നിരക്കുകൾ വിശകലനം ചെയ്യണം.

Q88: In ethical algorithm design, how are fairness constraints best handled?

A. Left entirely to database engineers

B. Integrated directly into the mathematical objective function during training (ശരിയുത്തരം)

C. Ignored until public lawsuits occur

D. Addressed solely by post-deployment marketing campaigns

പാഠഭാഗ വിശകലനം: മോഡൽ പരിശീലിപ്പിക്കുന്ന വേളയിൽത്തന്നെ നഷ്ട സമവാക്യത്തിൽ (Loss function) ഫെയർനെസ് മാനദണ്ഡങ്ങൾ ഉൾപ്പെടുത്തണം.

വിശദീകരണം: ഒബ്ജക്ടീവ് ഫംഗ്ഷനിൽ മാത്തമാറ്റിക്കൽ നിയന്ത്രണങ്ങൾ വരുത്തുന്നത് പക്ഷപാതങ്ങൾ തുടക്കത്തിലേ തടയാൻ സഹായിക്കും.

Q89: Post-deployment algorithmic monitoring is necessary because:

A. Models never change after being trained once

B. Models encounter shifting demographic distributions and emerging real-world feedback loops (ശരിയുത്തരം)

C. Edge cases never cause any harm

D. Algorithms are inherently self-correcting without intervention

പാഠഭാഗ വിശകലനം: യഥാർത്ഥ ലോകത്ത് ജനസംഖ്യാ വിതരണവും സാഹചര്യങ്ങളും മാറുമ്പോൾ അൽഗോരിതങ്ങളിൽ പുതിയ വ്യതിയാനങ്ങൾ വരാം.

വിശദീകരണം: പുതിയ ഡാറ്റാ വിതരണങ്ങൾ നേരിടുമ്പോൾ കൃത്യത ഉറപ്പാക്കാൻ തുടർച്ചയായ മോണിറ്ററിംഗ് ആവശ്യമാണ്.

Q90: What is the main danger of optimizing an AI model purely for raw statistical accuracy?

A. It guarantees fair and equitable decisions

B. It systematically exploits historical majority advantages and reinforces social inequities (ശരിയുത്തരം)

C. It makes the system run too slowly

D. It eliminates all forms of human prejudice

പാഠഭാഗ വിശകലനം: കേവല കൃത്യത മാത്രം നോക്കുമ്പോൾ ഭൂരിപക്ഷത്തിന്റെ പാറ്റേണുകൾക്ക് മുൻഗണന ലഭിക്കുകയും ന്യൂനപക്ഷങ്ങൾ അനീതിക്ക് ഇരയാവുകയും ചെയ്യുന്നു.

വിശദീകരണം: ഭൂരിപക്ഷ ജനവിഭാഗത്തെ തൃപ്തിപ്പെടുത്തി ഉയർന്ന സ്കോർ നേടാൻ മോഡൽ ശ്രമിക്കുന്നത് ചരിത്രപരമായ അസമത്വങ്ങളെ നിലനിർത്തുന്നു.

Q91: Ethical AI optimization differs from commercial optimization because it:

A. Maximizes short-term execution speed only

B. Intentionally balances accuracy with fairness, transparency, and human flourishing (ശരിയുത്തരം)

C. Aims purely at reducing electricity expenses

D. Replaces human judges completely with computers

പാഠഭാഗ വിശകലനം: ലാഭം മാത്രം നോക്കാതെ നീതിയും സുതാര്യതയും മനുഷ്യാവകാശങ്ങളും ഒപ്റ്റിമൈസേഷന്റെ ഭാഗമാക്കുന്നതാണ് എത്തിക്കൽ AI.

വിശദീകരണം: കേവല വാണിജ്യ ലാഭത്തിന് പകരം പൊതുനന്മയും തുല്യനീതിയും എത്തിക്കൽ ഒപ്റ്റിമൈസേഷന്റെ ലക്ഷ്യമാണ്.

Q92: Comprehensive ethical optimization safeguards systems against:

A. Algorithmic bias and discriminatory decisions

B. Unsafe behavioral failures in high-stakes settings

C. Both algorithmic bias and unsafe/discriminatory decisions (ശരിയുത്തരം)

D. Normal hardware wear and tear

പാഠഭാഗ വിശകലനം: സമഗ്രമായ ധാർമ്മിക ഒപ്റ്റിമൈസേഷൻ പക്ഷപാതപരമായ തീരുമാനങ്ങളെയും വിനാശകരമായ സുരക്ഷാ വീഴ്ചകളെയും ഒരേപോലെ തടയുന്നു.

വിശദീകരണം: പക്ഷപാതം തടയുന്നതിനൊപ്പം സിസ്റ്റത്തിന്റെ പ്രവർത്തന സുരക്ഷയും സംരക്ഷിക്കാൻ ഇത് അനിവാര്യമാണ്.

Q93: The architectural methodology that incorporates moral principles into systems from inception is called:

A. Post-hoc Error Correction

B. Ethics-by-Design (Value-Sensitive Design) (ശരിയുത്തരം)

C. Social Disruption Engineering

D. Reverse Data Mining

പാഠഭാഗ വിശകലനം: സോഫ്റ്റ്വെയറിന്റെ തുടക്കത്തിൽത്തന്നെ ധാർമ്മിക നിയമങ്ങൾ ഉൾപ്പെടുത്തി ഡിസൈൻ ചെയ്യുന്നതിനെ Ethics-by-Design എന്ന് വിളിക്കുന്നു.

വിശദീകരണം: പിന്നീട് തിരുത്തുന്നതിന് പകരം അടിത്തറയിൽത്തന്നെ ധാർമ്മികത ഉറപ്പാക്കുന്ന എൻജിനീയറിംഗ് രീതിയാണിത്.

Q94: A formal pre-deployment evaluation that investigates potential harms and human rights impacts is called:

A. Computational Stress Test

B. Ethical & Human Rights Impact Assessment (EIA) (ശരിയുത്തരം)

C. Marketing Focus Survey

D. Intellectual Property Clearance

പാഠഭാഗ വിശകലനം: വിന്യാസത്തിന് മുൻപ് മനുഷ്യാവകാശ പ്രത്യാഘാതങ്ങൾ പഠിക്കുന്ന ഔദ്യോഗിക പരിശോധനയാണ് എത്തിക്കൽ ഇംപാക്ട് അസ്സസ്സ്മെന്റ് (EIA).

വിശദീകരണം: നിയമപരവും സാമൂഹികവുമായ പ്രശ്നങ്ങൾ മുൻകൂട്ടി കണ്ട് പരിഹരിക്കാൻ EIA അനിവാര്യമാണ്.