CALICUT UNIVERSITY · MINOR PHILOSOPHY (PHL1MN102)

അധ്യായം 16: അൽഗോരിതം പക്ഷപാതം: വിവേചനങ്ങൾ തടയുന്നതിനുള്ള ദാർശനിക മാർഗ്ഗങ്ങൾ

Chapter 16: Algorithmic Bias: Preventing Unfair Biases in Machine Learning

📚 Module 4 · Unit 4.2 (a) | ⏱️ 15 Hours Module Weightage · 15 Marks

പാഠ്യസംഗ്രഹം (Module Scope): മെഷീൻ ലേണിംഗ് അൽഗോരിതങ്ങൾ ചരിത്രപരമായ ഡാറ്റയിൽ നിന്നും മനുഷ്യസമൂഹത്തിലെ ലിംഗ-വംശീയ-വർഗ്ഗ വിവേചനങ്ങൾ അതേപടി അനുകരിച്ച് പക്ഷപാതപരമായ തീരുമാനങ്ങളെടുക്കുന്നത് എങ്ങനെ തടയാം എന്ന് ഈ അധ്യായം അപഗ്രഥിക്കുന്നു. നീതി (Fairness), സുതാര്യത (Transparency), ഉത്തരവാദിത്തം (Accountability) എന്നീ FATE തത്ത്വങ്ങൾ വിശദീകരിക്കപ്പെടുന്നു.

1. അൽഗോരിതം പക്ഷപാതം: നിർവ്വചനവും ഉറവിടങ്ങളും (Sources of Bias)

Definition & Origins of Algorithmic Discrimination

യന്ത്രങ്ങൾ പക്ഷപാതം പഠിക്കുന്നത് എങ്ങനെ?

അൽഗോരിതങ്ങൾ നിഷ്പക്ഷമായ ഗണിതസൂത്രങ്ങളാണെന്ന ജനകീയ ധാരണ തെറ്റാണ്. ഒരു എഐ സിസ്റ്റം വ്യവസ്ഥാപിതമായി ഏതെങ്കിലും ഒരു പ്രത്യേക വിഭാഗത്തിനെതിരെ അന്യായമായ അനീതി കാട്ടുമ്പോഴാണ് **അൽഗോരിതം പക്ഷപാതം (Algorithmic Bias)** ഉണ്ടാകുന്നത്.

പ്രധാന ഉറവിടങ്ങൾ:

1. ചരിത്രപരമായ ഡാറ്റാ പക്ഷപാതം: മനുഷ്യസമൂഹത്തിൽ നൂറ്റാണ്ടുകളായി നിലനിന്നിരുന്ന വംശീയ-ലിംഗ വിവേചനങ്ങൾ അടങ്ങിയ പഴയ ഡാറ്റ പഠനത്തിനായി നൽകുമ്പോൾ മെഷീൻ അത് ശാശ്വത സത്യമായി കാണുന്നു.

2. പ്രതിനിധാനക്കുറവ് (Sampling Bias): ന്യൂനപക്ഷങ്ങളുടെ വിവരങ്ങൾ ഡാറ്റാബേസിൽ വേണ്ടത്ര ഉൾപ്പെടുത്താതിരിക്കൽ.

3. പ്രോക്സി വേരിയബിളുകൾ: നേരിട്ടുള്ള ജാതി/വംശ വിവരങ്ങൾ ഒഴിവാക്കിയാലും പിൻകോഡോ വിലാസമോ പോലുള്ള ഘടകങ്ങളിലൂടെ പരോക്ഷ വിവേചനം കടന്നുകൂടുന്നു.

Flawed Data In, Flawed Justice Out

Algorithmic bias refers to systematic and unfair discrimination produced by computer systems favoring certain privileged groups while disenfranchising marginalized populations.

Primary catalysts include:

1. Historical training biases: Past human prejudices embedded in historical data archives are replicated and amplified.

2. Sampling deficiencies: Marginalized communities are grossly under-represented in model benchmarks.

3. Proxy features: Even if protected attributes (race, gender) are excluded, correlated variables (postal codes, credit inquiries) serve as surrogate discriminatory channels.

2. നീതിശാസ്ത്രപരമായ പ്രത്യാഘാതങ്ങൾ (Ethical Implications: COMPAS)

Real-World Injustice: Recidivism & Hiring

യഥാർത്ഥ ലോകത്തിലെ വിവേചനങ്ങൾ

നീതിനിർവ്വഹണ രംഗം (COMPAS Algorithm): അമേരിക്കൻ കോടതികളിൽ പ്രതികൾ വീണ്ടും കുറ്റകൃത്യം ചെയ്യാനുള്ള സാധ്യത മുൻകൂട്ടി പ്രവചിക്കാൻ ഉപയോഗിച്ച COMPAS അൽഗോരിതം കറുത്തവർഗ്ഗക്കാർക്കെതിരെ ഇരട്ടി തെറ്റായ റിസ്ക് സ്കോറുകൾ (False Positives) നൽകിയതായി കണ്ടെത്തുകയുണ്ടായി.

തൊഴിൽ റിക്രൂട്ട്മെന്റ്: പ്രമുഖ കമ്പനികളുടെ റിക്രൂട്ട്മെന്റ് അൽഗോരിതങ്ങൾ മുൻകാല റെക്കോർഡുകൾ പരിശോധിച്ച് സ്ത്രീകളുടെ റെസ്യൂമെകൾ സ്വാഭാവികമായി തള്ളിക്കളഞ്ഞത് വലിയ ധാർമ്മിക പ്രതിസന്ധിയുണ്ടാക്കി. ഒരു അൽഗോരിതത്തിന്റെ കണക്കുകൂട്ടൽ വ്യക്തികളുടെ അടിസ്ഥാന അവകാശങ്ങളെയും അവസരങ്ങളെയും നിഷേധിക്കുന്നു.

Quantified Discrimination in High-Stakes Arenas

Criminal Justice (COMPAS): Risk-assessment algorithms designed to predict recidivism systematically yielded higher false-positive rates for Black defendants compared to white counterparts.

Algorithmic Hiring: Automated CV-screening engines penalized resumes containing the word 'women's' due to historic male dominance in technical roles, illustrating how unmonitored optimization entrenches systemic exclusion.

3. ഫെയർനസ് സങ്കല്പങ്ങൾ (Theories of Algorithmic Fairness)

Philosophical Conceptions of Fairness

വ്യക്തിഗത നീതിയും ഗ്രൂപ്പ് നീതിയും

അൽഗോരിതത്തിൽ 'നീതി' (Fairness) എന്നത് ഒരൊറ്റ മാനദണ്ഡമല്ലെന്ന് തത്ത്വചിന്ത വ്യക്തമാക്കുന്നു:

1. വ്യക്തിഗത നീതി (Individual Fairness): സമാന യോഗ്യതകളും സാഹചര്യങ്ങളുമുള്ള രണ്ട് വ്യക്തികളോട് അൽഗോരിതം ഒരുപോലെ പെരുമാറണം.

2. ഗ്രൂപ്പ് നീതി / ഡെമോഗ്രാഫിക് പാരിറ്റി (Group Fairness): വ്യത്യസ്ത സാമൂഹിക വിഭാഗങ്ങൾക്കിടയിൽ പോസിറ്റീവ് തീരുമാനങ്ങളുടെ അനുപാതം തുല്യമായിരിക്കണം.

ദാർശനിക പ്രതിസന്ധി: ഒരേ സമയം വ്യക്തിഗത നീതിയും ഗ്രൂപ്പ് നീതിയും പൂർണ്ണമായി പാലിക്കുക എന്നത് ഗണിതശാസ്ത്രപരമായി അസാധ്യമാണെന്ന് ഗവേഷണങ്ങൾ തെളിയിക്കുന്നു. ഇവിടെ നാം ഏത് ധാർമ്മിക സിദ്ധാന്തത്തിനാണ് മുൻഗണന നൽകുന്നത് എന്നത് പ്രധാനമാണ്.

Individual Equity vs Group Parity

Philosophical definitions of fairness in machine learning conflict mathematically:

1. Individual Fairness: Treats similar individuals identically regardless of group affiliation.

2. Group Fairness / Demographic Parity: Requires equal selection proportions across diverse protected classes.

Impossibility Theorem: Mathematical fairness metrics cannot simultaneously satisfy independence, separation, and sufficiency, requiring unavoidable normative trade-offs.

4. പരിഹാരങ്ങൾ: FATE ചട്ടക്കൂടും ഓഡിറ്റിംഗും (FATE & Debiasing)

FATE Framework & Algorithmic Governance

പക്ഷപാത നിർമ്മാർജ്ജന വഴികൾ

അൽഗോരിതങ്ങളെ ധാർമ്മികമായി ഉത്തരവാദിത്തമുള്ളതാക്കാൻ **FATE** ചട്ടക്കൂട് മുന്നോട്ടുവെക്കുന്നു:

- **Fairness (നീതി):** വിവേചനരഹിതമായ ഡാറ്റാ നിർമ്മാണവും പ്രീ-പ്രോസസ്സിംഗ് തിരുത്തലുകളും.
- **Accountability (ഉത്തരവാദിത്തം):** അൽഗോരിതം തെറ്റ് ചെയ്താൽ സാങ്കേതിക കമ്പനികളും സ്ഥാപനങ്ങളും നിയമപരമായ ഉത്തരവാദിത്തം ഏറ്റെടുക്കണം.
- **Transparency (സുതാര്യത):** ബ്ലാക്ക്-ബോക്സ് മാതൃകകൾ മാറ്റി ന്യായീകരണങ്ങൾ വ്യക്തമാക്കുന്ന എക്സ്പ്ലെയ്നബിൾ AI (XAI) വികസിപ്പിക്കുക.
- **Ethics (ധാർമ്മികത):** സ്വതന്ത്ര വിദഗ്ധരുടെ ആഭിമുഖ്യത്തിലുള്ള അൽഗോരിതമിക് ഓഡിറ്റിംഗ് (Algorithmic Auditing).

Institutional & Algorithmic Safeguards

The **FATE framework** grounds institutional algorithmic justice:

- **Fairness:** Mathematical debiasing across pre-processing, in-processing, and post-processing stages.
- **Accountability:** Clear liability models enforcing human responsibility for automated decisions.
- **Transparency:** Explainable AI (XAI) breaking through opaque 'black-box' deep networks.
- **Ethics:** Independent external auditing panels verifying social compliance before deployment.

പക്ഷപാത പരിഹാര ഘട്ടങ്ങൾ

Technical Debiasing Intervention Pipeline

ഘട്ടം (Stage)	പ്രവർത്തന രീതി (Intervention)	ധാർമ്മിക ലക്ഷ്യം (Ethical Goal)
പ്രീ-പ്രോസസ്സിംഗ് (Pre-processing)	പരിശീലന ഡാറ്റയിൽ നിന്ന് മുൻവിധികളും പ്രോക്സി ഘടകങ്ങളും നീക്കം ചെയ്യൽ	ചരിത്രപരമായ വിവേചനങ്ങൾ മോഡൽ കാണാതിരിക്കാൻ ഉറപ്പാക്കുന്നു
ഇൻ-പ്രോസസ്സിംഗ് (In-processing)	അൽഗോരിതത്തിന്റെ ലക്ഷ്യ സൂത്രത്തിൽ ഫെയർനസ് പെനാൽറ്റികൾ ഉൾപ്പെടുത്തൽ	കൃത്യതയ്ക്കൊപ്പം തുല്യതയ്ക്കും തുല്യ ഗണിത മൂല്യം നൽകുന്നു
പോസ്റ്റ്-പ്രോസസ്സിംഗ് (Post-processing)	മോഡൽ നൽകുന്ന അന്തിമ തീരുമാനങ്ങളുടെ ത്രെഷോൾഡുകൾ പുനഃക്രമീകരിക്കൽ	വിവിധ ഗ്രൂപ്പുകൾക്ക് തുല്യ പരിഗണന ലഭിക്കുന്നുണ്ടെന്ന് ഉറപ്പാക്കൽ
എക്സ്പ്ലെയ്നബിൾ എഐ (XAI)	തീരുമാനങ്ങൾക്ക് കാരണമായ ലോജിക് മനുഷ്യർക്ക് വായിക്കാവുന്നതാക്കൽ	അന്യായമായ വിവേചനം കോടതികൾക്ക് ഓഡിറ്റ് ചെയ്യാൻ സഹായിക്കുന്നു

പ്രധാന പരീക്ഷാ ആശയങ്ങൾ (Key Examination Points)

Core Revision Points

മലയാളം സംഗ്രഹം (Key Takeaways)

- **അൽഗോരിതം പക്ഷപാതം:** മുൻകാല വിവേചനങ്ങൾ ഡാറ്റയിലൂടെ മെഷീൻ സ്വയമേവ പുനരുൽപ്പാദിപ്പിക്കുന്ന പ്രതിഭാസം.
- **പ്രോക്സി ഘടകങ്ങൾ:** സംരക്ഷിത വിവരങ്ങൾ മറച്ചാലും പരോക്ഷ തെളിവുകളിലൂടെ വിവേചനം ആവർത്തിക്കപ്പെടാം.
- **FATE തത്ത്വങ്ങൾ:** ഫെയർനസ്, അക്കൗണ്ടബിലിറ്റി, ട്രാൻസ്പരൻസി, എത്തിക്സ് എന്നിവ അൽഗോരിത വികാസത്തിൽ അനിവാര്യമാണ്.
- **ഓഡിറ്റിംഗ്:** വിവേചനരഹിതമായ പ്രവർത്തനത്തിന് സ്വതന്ത്ര ബാഹ്യ നിരീക്ഷണം നിർബന്ധമാണ്.

English Summary (Key Takeaways)

- **Algorithmic Bias:** Systemic disparate impact resulting from biased historical training datasets.
- **Proxy Variables:** Excluding direct identifiers does not prevent indirect discrimination.
- **FATE Principles:** Fairness, Accountability, Transparency, and Ethics form the ethical pillar.
- **Explainability (XAI):** Transparent decision paths are essential for legitimate judicial auditing.

വിചിന്തന ചോദ്യങ്ങൾ (Review & Discussion Questions)

Academic Essay & Short Questions

1. എന്താണ് അൽഗോരിതമിക് പക്ഷപാതം? പരിശീലന ഡാറ്റയിലെ വിവേചനം എങ്ങനെയാണ് ഇതിന് കാരണമാകുന്നത്?

കമ്പ്യൂട്ടർ അൽഗോരിതങ്ങൾ ചില പ്രത്യേക വിഭാഗങ്ങൾക്കെതിരെ അന്യായമായി വിവേചനം പുലർത്തുന്നതാണ് അൽഗോരിതമിക് പക്ഷപാതം. മുൻകാല മനുഷ്യസമൂഹത്തിലെ പക്ഷപാതങ്ങൾ അടങ്ങിയ ഡാറ്റയാണ് യന്ത്രങ്ങൾക്ക് നൽകുന്നതെങ്കിൽ, യന്ത്രം ആ ചരിത്രപരമായ അസമത്വങ്ങളെ സാധാരണ നിയമങ്ങളായി സ്വീകരിച്ച് പക്ഷപാതപരമായ തീരുമാനങ്ങളെടുക്കുന്നു.

2. FATE ചട്ടക്കൂടിന്റെ പ്രധാന ഘടകങ്ങൾ ഏതൊക്കെയാണ്?

ഫെയർനസ് (നീതി), അക്കൗണ്ടബിലിറ്റി (ഉത്തരവാദിത്തം), ട്രാൻസ്പരൻസി (സുതാര്യത), എത്തിക്സ് (ധാർമ്മികത) എന്നിവയാണ് FATE ചട്ടക്കൂടിന്റെ നാല് ഘടകങ്ങൾ.