മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 16: മെഷീൻ ലേണിംഗിലെ അൽഗോരിതമിക് പക്ഷപാതങ്ങൾ തടയൽ (Preventing Algorithmic Biases)

Module 4 · Chapter 16: Algorithmic Bias, Fairness Metrics & Explainable AI (XAI) · Calicut University B.A. Philosophy FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

1. എൽ.എം.എസ് അവലോകനവും പഠന ലക്ഷ്യങ്ങളും (LMS Module Overview & Objectives)

LMS Overview: Syllabus unit 4.2(a) investigates how to prevent learning algorithms from acquiring and amplifying morally objectionable biases. In modern machine learning, systems trained on historical data frequently perpetuate racial, gender, socio-economic, and caste discrimination in criminal justice (COMPAS), mortgage lending, hiring (Amazon recruitment tool), and healthcare algorithms. We critically examine sources of bias, mathematical definitions of algorithmic fairness, Explainable AI (XAI), and Ethics-by-Design.

LMS ലക്ഷ്യങ്ങൾ: അൽഗോരിതമിക് ബയാസ് (Algorithmic Bias) എന്താണെന്ന് മനസ്സിലാക്കുക; ചരിത്രപരമായ ഡാറ്റയിലെ വിവേചനങ്ങൾ മെഷീൻ ലേണിംഗ് മോഡലുകളിലേക്ക് എങ്ങനെ പടരുന്നുവെന്ന് പരിശോധിക്കുക; ഫെയർനസ് മെട്രിക്സ് (Demographic Parity, Equalized Odds), ക്ലൈൻബർഗിന്റെ അസാദ്ധ്യതാ സിദ്ധാന്തം (Impossibility Theorem of Fairness) എന്നിവ പഠിക്കുക; എക്സ്പ്ലെയ്നബിൾ എഐ (XAI), എത്തിക്സ്-ബൈ-ഡിസൈൻ (Ethics-by-Design) എന്നിവയുടെ പ്രാധാന്യം തിരിച്ചറിയുക.

2. പക്ഷപാതങ്ങളുടെ ഉറവിടങ്ങളും തരങ്ങളും (Sources & Forms of Algorithmic Bias)

EN **Taxonomy of Algorithmic Biases:** Bias in AI is rarely the result of overt malice by software developers; it fundamentally reflects systemic social injustices encoded in training data:

- **Historical / Pre-existing Bias:** Occurs when the training data accurately reflects an already unjust world (e.g., historical arrest rates reflecting biased policing).
- **Representation / Sampling Bias:** Marginalized groups are drastically underrepresented in training corpuses (e.g., facial recognition software failing on dark-skinned women due to datasets over-representing light-skinned males).
- **Proxy Discrimination:** Redacting sensitive protected attributes (race, gender) fails because the algorithm easily reconstructs them from correlated proxies (zip codes, browsing history, school attended).
- **Feedback Loops (Self-Fulfilling Prophecy):** Biased predictive policing sends more officers to low-income neighborhoods, leading to more arrests, generating more biased training data.

ML **അൽഗോരിതമിക് പക്ഷപാതങ്ങളുടെ വർഗ്ഗീകരണം:** സോഫ്റ്റ്‌വെയർ എൻജിനീയർമാർ മനഃപൂർവ്വം ഉണ്ടാക്കുന്നതല്ല മറിച്ച് നമ്മുടെ സമൂഹത്തിൽ നിലനിൽക്കുന്ന അനീതികൾ ഡാറ്റയിലൂടെ യന്ത്രം പഠിച്ചെടുക്കുന്നതാണ് അൽഗോരിതമിക് ബയാസ്:

- **ചരിത്രപരമായ പക്ഷപാതം (Historical Bias):** ഭൂതകാല സമൂഹത്തിലെ വിവേചനങ്ങൾ അതേപടി രേഖപ്പെടുത്തപ്പെട്ട ഡാറ്റ ഉപയോഗിക്കുമ്പോൾ യന്ത്രവും അതേ വിവേചനം ശരിയാണെന്ന് കരുതുന്നു.
- **സാമ്പിളിംഗ് പക്ഷപാതം (Representation Bias):** ന്യൂനപക്ഷ വിഭാഗങ്ങളുടെയോ പാർശ്വവൽക്കരിക്കപ്പെട്ടവരുടെയോ വിവരങ്ങൾ ഡാറ്റാബേസിൽ വേണ്ടത്ര ഉൾപ്പെടുത്താത്ത അവസ്ഥ (ഉദാ: കറുത്തവർഗ്ഗക്കാരായ സ്ത്രീകളുടെ മുഖം തിരിച്ചറിയുന്നതിൽ ഫേഷ്യൽ റെക്കഗ്നിഷൻ പരാജയപ്പെടുന്നത്).
- **പ്രോക്സി വിവേചനം (Proxy Discrimination):** ജാതിയോ ലിംഗമോ മറച്ചുവെച്ചാലും, താമസിക്കുന്ന സ്ഥലം (പിൻകോഡ്), പഠിച്ച സ്കൂൾ എന്നിവയിൽ നിന്ന് യന്ത്രം ആ വിവരങ്ങൾ ചികഞ്ഞെടുത്ത് വിവേചനം കാണിക്കുന്നത്.
- **ഫീഡ്ബാക്ക് ലൂപ്പ് (Feedback Loop):** മുൻവിധിയോടെയുള്ള അൽഗോരിതം നൽകുന്ന നിർദ്ദേശങ്ങൾ കൂടുതൽ വിവേചനപരമായ അറസ്റ്റുകളിലേക്ക് നയിക്കുകയും അത് വീണ്ടും കൂടുതൽ പക്ഷപാതപരമായ ഡാറ്റയായി മാറുകയും ചെയ്യുന്നത്.



3. പ്രധാന യഥാർത്ഥ കേസ് സ്റ്റഡികൾ (Real-World Benchmark Case Studies)

EN **Landmark Cases of Algorithmic Discrimination:**

- **COMPAS Recidivism Algorithm (ProPublica, 2016):** Used across US courtrooms to assess risk of re-offending. ProPublica discovered Black defendants were falsely flagged as future criminals at almost twice the rate of white defendants (44.9% vs 23.5%), while white defendants were far more frequently mislabeled as low-risk.
- **Amazon's AI Hiring Tool (2018):** Scanned resumes trained on 10 years of tech applicants (predominantly male). The AI penalized resumes containing the word "women's" (e.g., "women's chess club") and downgraded graduates of female colleges. Amazon abandoned the tool.
- **Gender Shades Study (Joy Buolamwini & Timnit Gebru, 2018):** Commercial facial analysis systems (IBM, Microsoft) exhibited error rates below 1% for lighter-skinned men, but error rates soared to 34.7% for darker-skinned women.

ML **അൽഗോരിതമിക് വിവേചനത്തിന്റെ പ്രധാന യഥാർത്ഥ സംഭവങ്ങൾ:**

- **കോമ്പാസ് (COMPAS) ജൂഡീഷ്യൽ അൽഗോരിതം:** കുറ്റവാളികൾ വീണ്ടും കുറ്റം ചെയ്യുമോ എന്ന് പ്രവചിക്കാൻ അമേരിക്കൻ കോടതികൾ ഉപയോഗിച്ച ഈ സിസ്റ്റം, കറുത്തവർഗ്ഗക്കാർ വീണ്ടും കുറ്റം ചെയ്യുമെന്ന് ഇരട്ടിയിലധികം തെറ്റായ പ്രവചനം നടത്തുകയും വെള്ളക്കാർക്ക് വഴിവിട്ട അനുകൂല്യം നൽകുകയും ചെയ്തതായി പ്രോപബ്ലിക്ക കണ്ടെത്തി.
- **ആമസോണിന്റെ റിക്രൂട്ട്മെന്റ് എഐ:** കഴിഞ്ഞ പത്ത് വർഷത്തെ ജീവനക്കാരുടെ ഡാറ്റ പഠിച്ച ഈ സിസ്റ്റം പുരുഷന്മാർക്ക് കൂടുതൽ മാർക്ക് നൽകുകയും സ്ത്രീകളുടെ പേരുകളോ 'വിമൻസ് കോളേജ്' എന്ന വാക്കുകളോ ഉള്ള റെസ്യൂമുകളെ തഴയുകയും ചെയ്തു. ഒടുവിൽ ആമസോണിന് പദ്ധതി ഉപേക്ഷിക്കേണ്ടി വന്നു.
- **ജെൻഡർ ഷേഡ്സ് പഠനം (ബോലാംവിനി & ഗെബ്രു):** ഐബിഎം, മൈക്രോസോഫ്റ്റ് ഫേഷ്യൽ റെക്കഗ്നിഷൻ വെളുത്ത പുരുഷന്മാരെ 99% കൃത്യതയോടെ തിരിച്ചറിഞ്ഞപ്പോൾ കറുത്തവർഗ്ഗക്കാരായ സ്ത്രീകളിൽ തെറ്റ് 34.7% വരെ ഉയർന്നതായി കണ്ടെത്തി.

ഗണിതശാസ്ത്രപരമായ ഫെയർനെസ് തത്വങ്ങളും ക്ലൈൻബർഗ് അസാദ്ധ്യതാ സിദ്ധാന്തവും:

- **Demographic Parity:** പോസിറ്റീവ് തീരുമാനങ്ങൾ ജനസംഖ്യാ അനുപാതത്തിന് തുല്യമായി ലഭിക്കണം: $P(\hat{Y}=1 | A=0) = P(\hat{Y}=1 | A=1)$.
- **Equalized Odds:** യോഗ്യരായ വ്യക്തികളിൽ തുല്യമായ ട്രൂ പോസിറ്റീവ് റേറ്റും ഫോൾസ് പോസിറ്റീവ് റേറ്റും ഉറപ്പാക്കണം.
- **Kleinberg's Impossibility Theorem (2016):** രണ്ട് വ്യത്യസ്ത വിഭാഗങ്ങളിൽ അടിസ്ഥാന നിരക്കുകൾ വ്യത്യസ്തമായിരിക്കുമ്പോൾ, ഈ മാനദണ്ഡങ്ങൾ ഒരേസമയം പാലിക്കുക ഗണിതശാസ്ത്രപരമായി അസാധ്യമാണ്!

4. എൽ.എം.എസ് സമഗ്ര ചോദ്യോത്തരങ്ങൾ (Comprehensive LMS Questions & Answers)

EN **LMS Core Question 1: What is "Ethics-by-Design" in machine learning systems?**
Answer: Ethics-by-Design is an engineering paradigm where moral constraints, fairness audits, transparency metrics, and privacy safeguards are baked into the architectural design from the ground up, rather than added as superficial post-hoc corrections.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 1: മെഷീൻ ലേണിംഗിലെ 'എത്തിക്സ്-ബൈ-ഡിസൈൻ' (Ethics-by-Design) എന്നാൽ എന്ത്?**
ഉത്തരം: സോഫ്റ്റ്വെയർ നിർമ്മിച്ചു കഴിഞ്ഞതിനു ശേഷം പുറത്തുനിന്ന് തിരുത്തലുകൾ നടത്തുന്നതിന് പകരം, സിസ്റ്റത്തിന്റെ ആദ്യ രൂപരേഖ മുതൽ തന്നെ ധാർമ്മികതയും, നീതിയും, സുതാര്യതയും അതിന്റെ ഘടനയിൽ ഉൾച്ചേർക്കുന്ന എഞ്ചിനീയറിംഗ് രീതിയാണിത്.

EN **LMS Core Question 2: Why does removing sensitive demographic labels fail to prevent discrimination?**
Answer: Simply removing protected attributes (like race or gender) is termed "Fairness through Blindness" and fails completely because high-dimensional machine learning easily identifies latent proxy features (e.g., zip codes, shopping habits, language syntax) that correlate tightly with the protected classes, allowing the algorithm to reconstruct and discriminate based on the forbidden attribute.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 2: ജാതിയോ ലിംഗമോ ഡാറ്റയിൽ നിന്ന് ഒഴിവാക്കിയതുകൊണ്ട് മാത്രം വിവേചനം ഇല്ലാതാകാത്തത് എന്തുകൊണ്ട്?**
ഉത്തരം: ജാതിയോ ലിംഗമോ നേരിട്ട് രേഖപ്പെടുത്തിയിട്ടില്ലെങ്കിലും, അവർ താമസിക്കുന്ന സ്ഥലം (പിൻകോഡ്), വാങ്ങുന്ന സാധനങ്ങൾ, സംസാരിക്കുന്ന രീതി തുടങ്ങിയ മറ്റ് അനുബന്ധ വിവരങ്ങളിൽ (Proxies) നിന്ന് യന്ത്രം വ്യക്തികളുടെ പശ്ചാത്തലം തിരിച്ചറിയുകയും അതേ വിവേചനം പരോക്ഷമായി ആവർത്തിക്കുകയും ചെയ്യുന്നു.

EN **LMS Core Question 3: What is the "Right to Explanation" under GDPR Article 22?**

Answer: The European Union's General Data Protection Regulation (GDPR) mandates that individuals subjected to automated decisions that significantly affect them have the right to obtain meaningful human intervention, express their point of view, and receive a transparent explanation of the decision logic.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 3: യൂറോപ്യൻ യൂണിയന്റെ GDPR ആർട്ടിക്കിൾ 22 പ്രകാരമുള്ള 'Right to Explanation' എന്താണ്?**

ഉത്തരം: കമ്പ്യൂട്ടർ അൽഗോരിതം വഴി ഒരാൾക്ക് വായ്പയോ ജോലിയോ നിഷേധിക്കപ്പെടുകയാണെങ്കിൽ, ആ തീരുമാനം എന്ത് കാരണം കൊണ്ടാണ് എടുത്തത് എന്ന് അറിയാനും, അതിൽ മനുഷ്യന്റെ നേരിട്ടുള്ള പുനഃപരിശോധന ആവശ്യപ്പെടാനുമുള്ള പൗരന്റെ മൗലികമായ നിയമപരമായ അവകാശമാണിത്.

EN **LMS Core Question 4: How does Explainable AI (XAI) such as SHAP and LIME reduce algorithmic bias?**

Answer: Techniques like SHAP (Shapley Additive exPlanations) and LIME (Local Interpretable Model-agnostic Explanations) deconstruct black-box deep models by quantifying the positive or negative contribution of each input feature toward a specific prediction, enabling auditors to detect whether illegitimate discriminatory weights were utilized.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 4: എക്സ്പ്ലെയ്നബിൾ എഐ (XAI) എങ്ങനെയാണ് അൽഗോരിതമിക് പക്ഷപാതങ്ങൾ കുറയ്ക്കുന്നത്?**

ഉത്തരം: കറുത്ത പെട്ടി പോലെയുള്ള ന്യൂറൽ നെറ്റ്വർക്കുകളുടെ ഉള്ളറകളിൽ ഓരോ ഇൻപുട്ട് വിവരത്തിനും (ഫീച്ചർ) എത്രത്തോളം പ്രാധാന്യം നൽകിയാണ് സിസ്റ്റം തീരുമാനം എടുത്തത് എന്ന് ലളിതമായ ഗ്രാഫുകളിലൂടെ വ്യക്തമാക്കിത്തരാൻ SHAP, LIME പോലുള്ള XAI ടൂളുകൾ സഹായിക്കുന്നു. ഇത് അന്യായമായ വിവേചനങ്ങൾ കണ്ടുപിടിക്കാൻ ഓഡിറ്റർമാരെ സഹായിക്കുന്നു.

5. പരീക്ഷാ കേന്ദ്രീകൃത 20 സുപ്രധാന പോയിന്റുകൾ (20 Deep Exam Points)

1

Algorithmic Bias (അൽഗോരിതമിക് പക്ഷപാതം): Systematic and unfair discrimination generated by automated computer systems that privileges one group over another.

2

Historical Bias: Disparities already embedded in society being replicated because the machine assumes the historical distribution represents ideal ground truth.

3

Representation / Sampling Bias: Underrepresenting minority demographics in training sets, causing catastrophic error spikes on those populations.

4

Proxy Discrimination: Indirect bias where an algorithm uses correlated neutral data (zip codes) as a surrogate for sensitive protected attributes.

5

COMPAS Algorithm Case (2016): Infamous recidivism tool that exhibited higher false-positive rates for Black defendants compared to white defendants.

6

Gender Shades Study (2018): Joy Buolamwini and Timnit Gebru's study demonstrating intersectional demographic error disparities in commercial facial AI.

7

Amazon AI Hiring Tool (2018): Scrapped automated recruiting tool that systematically downgraded resumes containing female indicators.

8

Demographic Parity (Statistical Parity): Fairness criterion requiring equal positive prediction rates across all demographic groups regardless of base rates.

9

Equalized Odds: Requiring equal True Positive Rates and False Positive Rates across protected demographic subgroups.

10

Kleinberg's Impossibility Theorem (2016): Mathematical proof that multiple competing fairness definitions cannot be simultaneously satisfied when base rates differ.

11

Ethics-by-Design: Architectural paradigm incorporating ethical guidelines, privacy boundaries, and fairness checks from initial conception.

12

Fairness Through Unawareness: Naive assumption that deleting protected attributes prevents bias, debunked by high-dimensional proxy correlations.

13

Explainable AI (XAI): Methods enabling humans to understand and trace the internal reasoning and feature contributions of machine learning models.

14

SHAP & LIME: Model-agnostic local interpretation algorithms quantifying feature importance in complex black-box neural networks.

15

Feedback Loops in Predictive Policing: Sending police to historically targeted neighborhoods creates higher arrests, creating biased data confirming the initial bias.

16

GDPR Article 22: European legal mandate providing subjects with the right not to be subject to solely automated decisions with significant impacts.

17

Data Nutrition Labels: Documentation standards for datasets detailing provenance, demographic coverage, collection methodology, and known limitations.

18

Adversarial Debiasing: In-processing training method where a secondary discriminator tries to predict protected attributes, forcing the primary model to learn unbiased representations.

19

Pre-processing vs Post-processing: Debiasing before model training (re-sampling) versus adjusting classification thresholds after model training.

20

Sociotechnical Justice: The understanding that algorithmic bias cannot be resolved by math alone; it requires restructuring real-world social institutions.

6. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (MCQs & Solutions)

Q87: In the famous ProPublica investigation (2016) of the COMPAS recidivism risk tool, the algorithm was found to:

A. Make zero prediction mistakes across all defendants

B. Produce significantly higher false-positive rates for Black defendants compared to white defendants (ശരിയുത്തരം)

C. Favor female candidates over male candidates in tech jobs

D. Overestimate the risk of white defendants while giving leniency to Black defendants

പാഠഭാഗ വിശകലനം: കോമ്പാസ് അൽഗോരിതം കുറ്റവർഗ്ഗക്കാർ വീണ്ടും കുറ്റം ചെയ്യുമെന്ന് ഇരട്ടിയിലധികം തെറ്റായ പ്രവചനം നടത്തി.

വിശദീകരണം: ഫോൾസ് പോസിറ്റീവ് നിരക്കിലെ ഈ വലിയ അന്തരം ചരിത്രപരമായ വിവേചനത്തിന്റെ തെളിവാണ്.

Q88: Why is "Fairness Through Unawareness" (simply removing race or gender from the dataset) ineffective?

A. Because machines cannot read text data

B. Because machine learning easily reconstructs protected attributes from correlated proxies like zip codes and purchasing history (ശരിയുത്തരം)

C. Because neural networks only work with biological chromosomes

D. Because GDPR explicitly forbids data cleansing

പാഠഭാഗ വിശകലനം: ജാതിയോ ലിംഗമോ നേരിട്ട് കാണിച്ചില്ലെങ്കിലും അനുബന്ധ വിവരങ്ങളിൽ നിന്ന് യന്ത്രം അത് തിരിച്ചറിയും.

വിശദീകരണം: താമസസ്ഥലം, സ്കൂൾ തുടങ്ങിയ പ്രോക്സികൾ വഴി പഴയ വിവേചനം തന്നെ മോഡൽ പുനഃസൃഷ്ടിക്കുന്നു.

Q89: Kleinberg's Impossibility Theorem (2016) proves that in algorithmic fairness:

A. Neural networks can never reach 50% training accuracy

B. Key mathematical criteria of fairness (such as calibration and balance for the false rates) are mathematically incompatible when base rates differ (ശരിയുത്തരം)

C. Computers are fundamentally incapable of calculating fractions

D. Humans always prefer automated judges over human magistrates

പാഠഭാഗ വിശകലനം: ജനസംഖ്യാ ഗ്രൂപ്പുകളിലെ അടിസ്ഥാന നിരക്കുകൾ വ്യത്യസ്തമായിരിക്കുമ്പോൾ എല്ലാ ഫെയർനെസ് നിയമങ്ങളും ഒരേസമയം പാലിക്കാൻ കഴിയില്ല.

വിശദീകരണം: ഗണിതശാസ്ത്രപരമായി ഫെയർനെസ് നിർവ്വചനങ്ങൾ പരസ്പരവിരുദ്ധമാണെന്ന് ക്ലൈൻബർഗ് തെളിയിച്ചു.

Q90: Joy Buolamwini and Timnit Gebru's "Gender Shades" study demonstrated that commercial facial recognition software:

A. Worked flawlessly across all ethnic populations

B. Had error rates below 1% for lighter-skinned men, but error rates soared to over 30% for darker-skinned women (ശരിയുത്തരം)

C. Refused to recognize faces wearing spectacles

D. Was biased only against older individuals

പാഠഭാഗ വിശകലനം: ഡാറ്റാബേസിൽ കറുത്തവർഗ്ഗക്കാരായ സ്ത്രീകളുടെ പ്രാതിനിധ്യം കുറവായതിനാൽ അവരുടെ മുഖം തിരിച്ചറിയുന്നതിൽ വലിയ പിഴവുകൾ സംഭവിച്ചു.

വിശദീകരണം: ഇൻസെക്ഷണൽ ഡാറ്റാ ബയാസിന്റെ ഏറ്റവും വലിയ ഉദാഹരണമാണ് ജെൻഡർ ഷേഡ്സ് പഠനം.

Q91: Explainable AI (XAI) frameworks like SHAP and LIME primarily assist in fairness auditing by:

A. Erasing all neural weights to create random outputs

B. Providing interpretable feature attributions showing which input variables influenced an automated decision (ശരിയുത്തരം)

C. Speeding up GPU rendering during 3D video game play

D. Replacing human judges with automated decision trees

പാഠഭാഗ വിശകലനം: ഒരു തീരുമാനം എടുക്കാൻ ഏതൊക്കെ ഇൻപുട്ടുകൾ കാരണമായി എന്ന് സുതാര്യമായി കാണിച്ചുതരുന്നതാണ് XAI.

വിശദീകരണം: വിവേചനപരമായ ഘടകങ്ങൾ തീരുമാനത്തെ സ്വാധീനിച്ചിട്ടുണ്ടോ എന്ന് കണ്ടെത്താൻ ഇത് ഓഡിറ്റർമാരെ സഹായിക്കുന്നു.
