🎓 CALICUT UNIVERSITY FYUGP · MINOR PHILOSOPHY (PHL1MN102) · MODULE 4

CHAPTER III: 4.2(A) How do we prevent learning algorithms from acquiring morally objectionable biases?

അദ്ധ്യായം 3: മെഷീൻ ലേണിംഗ് അൽഗോരിതങ്ങൾ ധാർമ്മികമായി ആക്ഷേപകരമായ പക്ഷപാതങ്ങൾ ആർജ്ജിക്കുന്നത് എങ്ങനെ തടയാം?

1. Transition from Human Judgment to Algorithmic Decisions

മനുഷ്യന്റെ വിവേചനാധികാരത്തിൽ നിന്നും അൽഗോരിതമിക് തീരുമാനങ്ങളിലേക്കുള്ള മാറ്റം

GB HISTORICAL DECISION-MAKING & ALGORITHMIC AUTOMATION

For most of human history, people made pivotal choices affecting other individuals: hiring employees, approving loans, diagnosing illnesses, manufacturing, and legal adjudication.

In recent decades, artificial intelligence systems have increasingly supplanted human gatekeepers. While automated decisions promise unprecedented speed and scale, they risk systematizing and codifying deep societal injustices into mathematical code.

ML മനുഷ്യന്റെ തീരുമാനങ്ങളും യന്ത്രവൽക്കരണവും

മനുഷ്യചരിത്രത്തിലുടനീളം മറ്റുള്ളവരുടെ ജീവിതത്തെ സ്വാധീനിക്കുന്ന പ്രധാന തീരുമാനങ്ങൾ മനുഷ്യർ തന്നെയാണ് എടുത്തിരുന്നത്: തൊഴിൽ നൽകൽ, ബാങ്ക് വായ്പകൾ അനുവദിക്കൽ, രോഗനിർണ്ണയം, നീതിനിർവ്വഹണം എന്നിവ ഇതിൽപ്പെടുന്നു.

എന്നാൽ സമീപകാലത്ത്, ഈ തീരുമാനങ്ങൾ സ്വയംഭരണ കമ്പ്യൂട്ടർ അൽഗോരിതങ്ങൾക്ക് കൈമാറ്റം ചെയ്യപ്പെടുന്നു. ഇത് വേഗത വർദ്ധിപ്പിക്കുമെങ്കിലും, സമൂഹത്തിലെ ചരിത്രപരമായ അനീതികളെ ഗണിതശാസ്ത്ര കോഡുകളിലൂടെ സ്ഥിരപ്പെടുത്തുന്ന അപകടകരമായ അവസ്ഥ സൃഷ്ടിക്കുന്നു.

GB THE MYTH OF ALGORITHMIC OBJECTIVITY

A prevalent misconception assumes that because mathematical algorithms rely on data and quantitative calculations, they are inherently neutral, objective, and devoid of prejudice.

In reality, learning algorithms assimilate and replicate patterns directly from historical training data, absorbing systemic inequities and presenting biased conclusions under the deceptive guise of scientific neutrality.

ML അൽഗോരിതമിക് നിഷ്പക്ഷതയെക്കുറിച്ചുള്ള മിഥ്യാധാരണ

കമ്പ്യൂട്ടർ പ്രോഗ്രാമുകൾ ഡാറ്റയും കണക്കുകൂട്ടലുകളും അടിസ്ഥാനമാക്കിയാണ് പ്രവർത്തിക്കുന്നത് എന്നതിനാൽ, അവ പക്ഷപാതരഹിതവും പൂർണ്ണ നിഷ്പക്ഷവുമാണെന്ന തെറ്റായ ധാരണ വ്യാപകമാണ്.

യഥാർത്ഥത്തിൽ, മെഷീൻ ലേണിംഗ് അൽഗോരിതങ്ങൾ ചരിത്രപരമായ ഡാറ്റയിൽ നിന്നാണ് പഠിക്കുന്നത് എന്നതിനാൽ, മുൻകാലങ്ങളിൽ സമൂഹത്തിൽ നിലനിന്നിരുന്ന എല്ലാ പക്ഷപാതങ്ങളെയും സ്വാംശീകരിക്കുകയും ശാസ്ത്രീയ നിഷ്പക്ഷതയുടെ മറവിൽ അവയെ വീണ്ടും നടപ്പിലാക്കുകയും ചെയ്യുന്നു.

2. Ingraining Societal Prejudices into Machine Learning Models

സമൂഹത്തിലെ മുൻവിധികളെ യന്ത്രങ്ങൾ സ്വാംശീകരിക്കുന്ന വിധം

GB ASSIMILATION OF HISTORICAL DISCRIMINATION

As AI assimilates statistical patterns from existing training corpora, societal discriminatory practices—such as gender bias, racial prejudice, caste hierarchies, or economic inequality—become firmly ingrained in algorithmic decision pathways.

Consequently, automated models produce systematically inequitable outcomes in high-stakes domains including employment recruitment, predictive criminal policing, medical resource allocation, and credit underwriting.

ML ചരിത്രപരമായ വിവേചനങ്ങളുടെ സ്വാംശീകരണം

നിലവിലുള്ള ഡാറ്റാബേസുകളിൽ നിന്ന് പാറ്റേണുകൾ മനസ്സിലാക്കുമ്പോൾ, സമൂഹത്തിൽ നിലനിന്നിരുന്ന **ലിംഗവിവേചനം, വംശീയ മുൻവിധികൾ, ജാതീയത, സാമ്പത്തിക അസമത്വങ്ങൾ** എന്നിവയെല്ലാം അൽഗോരിതത്തിന്റെ ചിന്താരീതിയിൽ ആഴത്തിൽ വേരൂന്നുന്നു.

ഇതിന്റെ ഫലമായി, **ജോലി തിരഞ്ഞെടുപ്പ്, കുറ്റകൃത്യ പ്രവചനം, ചികിത്സാ സൗകര്യങ്ങളുടെ വിതരണം, ബാങ്ക് വായ്പകൾ** തുടങ്ങിയ നിർണ്ണായക മേഖലകളിൽ മെഷീനുകൾ വിവേചനപരമായ തീരുമാനങ്ങൾ എടുക്കുന്നു.

GB AMPLIFICATION VS SIMPLE REFLECTION

Algorithms do not merely mirror societal prejudices; they actively amplify and entrench existing structural inequalities through dynamic feedback loops.

When biased algorithmic scores deny loans or interviews to marginalized demographics, the resulting economic deprivation generates fresh real-world data confirming the algorithm's skewed predictions, creating a self-reinforcing discriminatory cycle.

ML പക്ഷപാതങ്ങളുടെ വർദ്ധനവും ഫീഡ്ബാക്ക് ലൂപ്പും

അൽഗോരിതങ്ങൾ നിലവിലുള്ള വിവേചനങ്ങളെ പ്രതിഫലിപ്പിക്കുക മാത്രമല്ല ചെയ്യുന്നത്; അവ **സാമൂഹിക അസമത്വങ്ങളെ ഇരട്ടിയാക്കി ശക്തിപ്പെടുത്തുകയും** ചെയ്യുന്നു.

മെഷീൻ നൽകിയ പക്ഷപാതപരമായ മാർക്കുകൾ കാരണം പാർശ്വവൽക്കരിക്കപ്പെട്ട വിഭാഗങ്ങൾക്ക് തൊഴിലോ വായ്പയോ നിഷേധിക്കപ്പെടുമ്പോൾ, അത് പുതിയ ഡാറ്റയായി മാറി അൽഗോരിതത്തിന്റെ തെറ്റായ നിഗമനങ്ങളെ വീണ്ടും സാധൂകരിക്കുന്നു.

3. Representation Disparities: Minorities and Protected Classes

പ്രാതിനിധ്യക്കുറവും പാർശ്വവൽക്കരിക്കപ്പെട്ട സമൂഹങ്ങളും

GB DISPROPORTIONATE HARM TO VULNERABLE GROUPS

Algorithmic discrimination renders computational decision-making severely detrimental to minorities and under-represented communities, perpetuating entrenched historical disadvantages.

Ethnicity denotes shared cultural, linguistic, historical, or ancestral traits. When machine learning models trained on dominant population samples are deployed universally, error rates and false rejection rates surge catastrophically for minority demographics.

ML ദുർബല ജനവിഭാഗങ്ങൾ നേരിടുന്ന നാശനഷ്ടങ്ങൾ

അൽഗോരിതമിക് വിവേചനം ന്യൂനപക്ഷങ്ങൾക്കും പിന്നാക്ക ജനവിഭാഗങ്ങൾക്കും കനത്ത പ്രഹരമായി മാറുകയും, അവർ പരമ്പരാഗതമായി അനുഭവിച്ചുവരുന്ന പിന്നാക്കാവസ്ഥയെ ഊട്ടിയുറപ്പിക്കുകയും ചെയ്യുന്നു.

വംശീയത (Ethnicity) എന്നത് പങ്കിട്ട സംസ്കാരം, ഭാഷ, പാരമ്പര്യം എന്നിവയെയാണ് സൂചിപ്പിക്കുന്നത്. ഭൂരിപക്ഷ ജനവിഭാഗങ്ങളുടെ വിവരങ്ങൾ വെച്ച് പരിശീലിപ്പിച്ച മോഡലുകൾ എല്ലാവർക്കുമായി പ്രയോഗിക്കുമ്പോൾ ന്യൂനപക്ഷങ്ങൾ തെറ്റായി നിരസിക്കപ്പെടുന്നു.

GB FACIAL RECOGNITION AND ERROR DISPARITIES

Commercial facial analysis algorithms demonstrate stark performance differentials: near-perfect accuracy for light-skinned males, contrasted with error rates exceeding 30% for dark-skinned females.

This empirical disparity stems directly from under-representation in foundational training benchmarks, proving that skewed datasets generate fundamentally unjust technical systems.

ML ഫേഷ്യൽ റെക്കഗ്നിഷനിലെ കൃത്യതയില്ലായ്മ

വാണിജ്യ ഫേഷ്യൽ റെക്കഗ്നിഷൻ ടൂളുകൾ പരിശോധിച്ചപ്പോൾ, വെളുത്ത വർഗ്ഗക്കാരായ പുരുഷന്മാരിൽ കൃത്യത കാണിച്ചപ്പോൾ, കറുത്ത വർഗ്ഗക്കാരായ സ്ത്രീകളിൽ പിശകുകളുടെ നിരക്ക് 30 ശതമാനത്തിലധികമായി ഉയർന്നു.

പരിശീലന ഡാറ്റാബേസുകളിൽ ന്യൂനപക്ഷങ്ങളുടെ വിവരങ്ങൾ ഉൾപ്പെടുത്താതിരുന്നതാണ് ഈ വലിയ സാങ്കേതിക പിഴവിന് കാരണമായത് എന്ന് വ്യക്തമാണ്.

4. Labour Market Discrimination and Automated Screening

തൊഴിൽ വിപണിയിലെ വിവേചനവും ഓട്ടോമേറ്റഡ് സ്ക്രീനിംഗും

GB AUTOMATED HIRING ALGORITHMS

Corporate recruitment increasingly utilizes automated algorithms to filter thousands of job applications, screening resumes based on keywords, prestige metrics, and tenure patterns.

Because historical corporate leadership was predominantly homogeneous, learning algorithms trained on decades of past hiring data systematically penalize female and minority applicants.

ML റിക്രൂട്ട്മെന്റ് അൽഗോരിതങ്ങളുടെ പക്ഷപാതം

വൻകിട കമ്പനികൾ ആയിരക്കണക്കിന് തൊഴിൽ അപേക്ഷകൾ പരിശോധിക്കാൻ ഓട്ടോമേറ്റഡ് എഐ സ്ക്രീനിംഗ് ടൂളുകളെയാണ് ഇന്ന് വ്യാപകമായി ഉപയോഗിക്കുന്നത്.

കഴിഞ്ഞ ദശാബ്ദങ്ങളിൽ ഉയർന്ന പദവികളിൽ പുരുഷ മേധാവിത്വമായിരുന്നു നിലനിന്നിരുന്നത് എന്നതിനാൽ, പഴയ ഡാറ്റ വെച്ച് പഠിച്ച എഐ സ്ത്രീകൾ അയച്ച അപേക്ഷകളെ തഴയുകയും നിരാകരിക്കുകയും ചെയ്യുന്നു.

GB ALGORITHMIC PENALIZATION OF WOMEN'S CREDENTIALS

In high-profile real-world implementations, natural language models penalized candidate resumes containing terms such as "women's soccer" or graduates from all-women colleges.

This demonstrates that without deliberate ethical constraints, optimization algorithms naturally treat historical privilege as merit and marginalization as incompetence.

ML സ്ത്രീകളുടെ യോഗ്യതകൾ തഴയപ്പെടൽ

ചില ആഗോള കമ്പനികളുടെ എഐ പരീക്ഷണങ്ങളിൽ, റെസ്യുമെയിൽ 'വനിതാ കോളേജ്' എന്നോ 'വനിതാ ക്ലബ്ബ്' എന്നോ പരാമർശമുള്ള അപേക്ഷകൾക്ക് സിസ്റ്റം മാർക്ക് കുറച്ചതായി കണ്ടെത്തി.

ധാർമ്മിക നിയന്ത്രണങ്ങൾ ഏർപ്പെടുത്തിയില്ലെങ്കിൽ, ചരിത്രപരമായ ആധിപത്യത്തെ കഴിവായും പാർശ്വവൽക്കരണത്തെ അയോഗ്യതയായും മെഷീനുകൾ തെറ്റിദ്ധരിക്കുമെന്നതിന്റെ തെളിവാണിത്.

5. Gender Prejudice, Societal Roles and Labeling Bias
ലിംഗവിവേചനം, പരമ്പരാഗത വേഷങ്ങൾ & ലേബലിംഗ് പക്ഷപാതം

GB ORIGIN OF GENDER PREJUDICE IN TRAINING DATASETS

Gender prejudice originates from historical datasets documenting unequal societal roles, pay disparities, and gendered occupational segregation.

Word embedding models in natural language processing famously associate male pronouns with "doctor", "executive", and "engineer", while associating female pronouns with "nurse", "homemaker", and "receptionist".

ML പരിശീലന ഡാറ്റയിലെ ലിംഗപരമായ മുൻവിധികൾ

സമൂഹത്തിൽ പണ്ടുതൊട്ടേ നിലനിന്നിരുന്ന തൊഴിൽ വിഭജനങ്ങളും, വേതന അസമത്വങ്ങളും, സ്ത്രീവിരുദ്ധ മുൻവിധികളുമാണ് ലിംഗപക്ഷപാതത്തിന് കാരണമാകുന്നത്.

ലാംഗ്വേജ് മോഡലുകളിൽ പുരുഷ പദങ്ങളെ "ഡോക്ടർ", "ഡയറക്ടർ", "എഞ്ചിനീയർ" എന്നിവയോടും, സ്ത്രീ പദങ്ങളെ "നഴ്സ്", "അടുക്കള ജോലി", "സഹായി" എന്നിവയോടും അൽഗോരിതം സ്വാഭാവികമായി ബന്ധിപ്പിക്കുന്നു.

GB LABELING BIASES AND HUMAN EVALUATOR PREJUDICE

Supervised learning requires human annotators to label training examples (e.g. grading essays, classifying loan risk, or tagging suspicious activity).

When human annotators harbor subconscious racial or gender prejudices, their subjective biases are directly embedded into "ground truth" training labels, creating fundamentally corrupted target objectives.

ML ലേബലിംഗിലെ മനുഷ്യ പക്ഷപാതങ്ങൾ

മെഷീൻ ലേണിംഗ് മോഡലുകളെ പരിശീലിപ്പിക്കാൻ ഡാറ്റയെ തരംതിരിക്കുന്നത് (Labeling) മനുഷ്യരാണ്. ഇതിൽ മനുഷ്യരുടെ സ്വന്തം മുൻവിധികൾ കലരുന്നു.

ഡാറ്റാ ലേബൽ ചെയ്യുന്ന വ്യക്തികൾക്ക് വംശീയമോ ലിംഗപരമോ ആയ മുൻവിധികളുണ്ടെങ്കിൽ, അത് എഐ പഠിച്ചെടുക്കുന്ന 'സത്യം' (Ground Truth) ആയി മാറുകയും സിസ്റ്റത്തെ ശാശ്വതമായി ദുഷിപ്പിക്കുകയും ചെയ്യുന്നു.

6. The Fallacy of 'Fairness through Blindness' and Proxies

'അന്ധത വഴിയുള്ള നീതി' എന്ന മിഥ്യയും പ്രോക്സി വിവേചനവും

GB THE INSUFFICIENCY OF REMOVING PROTECTED ATTRIBUTES

A naive solution proposes eliminating sensitive attributes (e.g. removing "race", "gender", or "caste" columns from databases) to ensure fair treatment.

Excluding protected characteristics from algorithms is entirely insufficient to avert discrimination. Complex learning algorithms readily discover correlated proxy variables that reconstruct the excluded attribute with alarming accuracy.

ML വിവരങ്ങൾ മറച്ചുവെച്ചതുകൊണ്ട് മാത്രം നീതി ഉറപ്പാകില്ല

ഡാറ്റാബേസിൽ നിന്ന് ജാതി, മതം, ലിംഗം എന്നീ കോളങ്ങൾ ഒഴിവാക്കിയാൽ വിവേചനം അവസാനിക്കും എന്ന നിഷ്കളങ്കമായ വാദം തികച്ചും തെറ്റാണ്.

ഈ വിവരങ്ങൾ നീക്കം ചെയ്തതുകൊണ്ട് മാത്രം അൽഗോരിതമിക് വിവേചനം തടയാനാവില്ല. സങ്കീർണ്ണമായ മെഷീൻ ലേണിംഗ് ടൂളുകൾ മറ്റ് അനുബന്ധ ഘടകങ്ങളിലൂടെ ഒളിഞ്ഞിരിക്കുന്ന ഈ വിവരങ്ങളെ കൃത്യമായി പുനർനിർമ്മിക്കുന്നു.

GB PROXY DISCRIMINATION IN REAL-WORLD SYSTEMS

Proxy discrimination occurs when seemingly neutral features—such as postal zip codes, shopping patterns, high school alumni networks, or vocabulary choices—correlate tightly with race, gender, or wealth.

An algorithm utilizing residential location to assess creditworthiness ends up de facto discriminating against historically segregated racial minorities, perpetuating systemic redlining under an algorithmic veneer.

ML പ്രോക്സി വിവേചനം (PROXY DISCRIMINATION)

പിൻകോഡുകൾ, പഠിച്ച സ്കൂളുകൾ, വാങ്ങൽ രീതികൾ തുടങ്ങിയ നിരുപദ്രവകരമെന്ന് തോന്നുന്ന കാര്യങ്ങൾ വംശത്തോടും ജാതിയോടും സാമ്പത്തികാവസ്ഥയോടും ശക്തമായി ബന്ധപ്പെട്ടിരിക്കുന്നതിനെയാണ് പ്രോക്സി വേരിയബിളുകൾ എന്ന് വിളിക്കുന്നത്.

താമസസ്ഥലം മാത്രം അടിസ്ഥാനമാക്കി ലോൺ നൽകാതിരിക്കുമ്പോൾ, അത് ആ പ്രദേശത്ത് താമസിക്കുന്ന ന്യൂനപക്ഷങ്ങൾക്ക് വായ്പ നിഷേധിക്കുന്ന പരോക്ഷ വിവേചനമായി (Redlining) മാറുന്നു.

7. Embedding Fairness Constraints into Mathematical Objectives ഗണിതശാസ്ത്ര ലക്ഷ്യങ്ങളിൽ നീതിയുടെ നിബന്ധനകൾ ഉൾച്ചേർക്കൽ

GB INCORPORATING FORMAL FAIRNESS METRICS

Embedding fairness constraints entails intentionally designing algorithms to adhere to mathematically specified ethical standards during objective optimization.

Common formal definitions include: **1. Demographic Parity** (acceptance rates must be equal across protected groups); **2. Equalized Odds** (true positive and false positive rates must be balanced across groups); **3. Individual Fairness** (similar individuals receive similar treatment).

ML നീതിയുടെ ഗണിതശാസ്ത്ര അളവുകോലുകൾ

അൽഗോരിതത്തിന്റെ കണക്കുകൂട്ടലുകളിൽ തന്നെ കർശനമായ ധാർമ്മിക നിബന്ധനകൾ ഉൾച്ചേർക്കുന്ന പ്രക്രിയയാണിത് .

പ്രധാന അളവുകോലുകൾ: **1. ഡെമോഗ്രാഫിക് പാരിറ്റി:** എല്ലാ ജനവിഭാഗങ്ങൾക്കും തുല്യ അനുപാതത്തിൽ തിരഞ്ഞെടുക്കപ്പെടാനുള്ള അവസരം ഉറപ്പാക്കൽ; **2. ഇക്വലൈസ്ഡ് ഓഡ്സ്:** യോഗ്യരായവരെ തിരഞ്ഞെടുക്കുന്നതിലും പിഴവുകൾ വരുത്തുന്നതിലും എല്ലാ ഗ്രൂപ്പുകളിലും തുല്യത പാലിക്കൽ.

GB THE MATHEMATICAL IMPOSSIBILITY THEOREM

Computer scientists have proven mathematically that mutually exclusive fairness metrics cannot all be satisfied simultaneously whenever baseline base rates differ across groups.

This mathematical reality forces developers and society to make explicit philosophical and ethical choices: which definition of justice takes precedence in a given social context?

ML നീതിയുടെ ഗണിതശാസ്ത്രപരമായ പ്രതിസന്ധി

സമൂഹത്തിലെ യാഥാർത്ഥ്യങ്ങൾ വ്യത്യസ്തമായിരിക്കുമ്പോൾ, **എല്ലാ നീതിയുടെ അളവുകോലുകളും ഒരേസമയം പൂർണ്ണമായി തൃപ്തിപ്പെടുത്താൻ ഒരു ഗണിതശാസ്ത്ര മോഡലിനും കഴിയില്ലെന്ന്** തെളിയിക്കപ്പെട്ടിട്ടുണ്ട്.

ഇത് സാങ്കേതിക പ്രശ്നമല്ല, മറിച്ച് ദാർശനികമായ ഒന്നാണ്: ഒരു പ്രത്യേക സാഹചര്യത്തിൽ **ഏത് നീതിബോധത്തിനാണ് മുൻഗണന നൽകേണ്ടത്** എന്ന് മനുഷ്യ സമൂഹം തന്നെ തീരുമാനിക്കേണ്ടതുണ്ട്.

8. Data Preprocessing, Re-sampling & Algorithmic Debiasing

ഡാറ്റാ പ്രീ-പ്രോസസ്സിംഗും പക്ഷപാത ലഘൂകരണ രീതികളും

GB THREE STAGES OF ALGORITHMIC DEBIASING

Engineers combat algorithmic bias across three technical pipeline stages:

1. **Pre-processing:** Re-sampling, re-weighting, and augmenting historical datasets to rectify representation deficits before training begins.
2. **In-processing:** Modifying loss functions with penalty regularization terms punishing discriminatory decision boundaries.
3. **Post-processing:** Adjusting classification decision thresholds across groups to guarantee equitable real-world impact.

ML പക്ഷപാതം ഒഴിവാക്കാനുള്ള മൂന്ന് ഘട്ടങ്ങൾ

എഐ സംവിധാനങ്ങളിൽ പക്ഷപാതം തിരുത്താൻ മൂന്ന് സാങ്കേതിക ഘട്ടങ്ങൾ ഉപയോഗിക്കുന്നു:

1. **പ്രീ-പ്രോസസ്സിംഗ്:** പരിശീലനത്തിന് മുൻപ് തന്നെ പിന്നാക്ക വിഭാഗങ്ങളുടെ ഡാറ്റ കൂടുതൽ ചേർത്തും ബാലൻസ് ചെയ്തും വിവരങ്ങൾ ശുദ്ധീകരിക്കൽ.
2. **ഇൻ-പ്രോസസ്സിംഗ്:** മോഡൽ പഠിക്കുമ്പോൾ തന്നെ വിവേചനപരമായ തീരുമാനങ്ങൾക്ക് പിഴ ചുമത്തുന്ന അൽഗോരിതങ്ങൾ ഉപയോഗിക്കൽ.
3. **പോസ്റ്റ്-പ്രോസസ്സിംഗ്:** യഥാർത്ഥത്തിൽ തീരുമാനങ്ങൾ പുറത്തുവിടുമ്പോൾ തുല്യനീതി ഉറപ്പാക്കാൻ കട്ട്-ഓഫ് മാർക്കുകൾ പുനർക്രമീകരിക്കൽ.

GB DISPARATE IMPACT MITIGATION

Disparate impact occurs when a facially neutral policy or model produces substantially disparate and disadvantageous outcomes for a protected group.

Mitigating disparate impact requires continuous statistical parity audits to ensure technology serves as an instrument of social justice rather than automated disenfranchisement.

ML ഡിസ്പരേറ്റ് ഇംപാക്ട് ലഘൂകരണം

പുറമേക്ക് നിഷ്പക്ഷമെന്ന് തോന്നിക്കുന്ന ഒരു നയം പാർശ്വവൽക്കരിക്കപ്പെട്ട വിഭാഗങ്ങൾക്ക് ദോഷകരമായി ഭവിക്കുന്നതിനെയാണ് ഡിസ്പരേറ്റ് ഇംപാക്ട് (Disparate Impact) എന്ന് വിളിക്കുന്നത്.

ഇത്തരം പ്രത്യാഘാതങ്ങൾ തടയാൻ തുടർച്ചയായ സ്റ്റാറ്റിസ്റ്റിക്കൽ ഓഡിറ്റിംഗ് നടത്തുകയും, സാങ്കേതികവിദ്യ സാമൂഹിക നീതിക്ക് വേണ്ടി നിലകൊള്ളുന്നുവെന്ന് ഉറപ്പാക്കുകയും വേണം.

9. Algorithmic Auditing, Explainability and Model Cards

അൽഗോരിതമിക് ഓഡിറ്റിംഗും മോഡൽ കാർഡുകളും

GB **INDEPENDENT ALGORITHMIC AUDITING**

Relying on self-regulation by tech corporations is widely recognized as ethically inadequate.

Independent third-party algorithmic auditing subjects models to rigorous red-teaming, testing for discriminatory output differentials across sensitive intersectional identities prior to public deployment.

ML **സ്വതന്ത്ര അൽഗോരിതമിക് ഓഡിറ്റിംഗ്**

ടെക് കമ്പനികളുടെ സ്വന്തം മേൽനോട്ടത്തിൽ മാത്രം വിശ്വസിക്കുന്നത് സുരക്ഷിതമല്ലെന്ന് ലോകം തിരിച്ചറിഞ്ഞിട്ടുണ്ട്.

സ്വതന്ത്രരായ വിദഗ്ധ സമിതികൾ അൽഗോരിതങ്ങളെ സമഗ്രമായി പരിശോധിച്ച് (Algorithmic Auditing), വിവിധ ജനവിഭാഗങ്ങളോട് മോഡൽ പക്ഷപാതം കാണിക്കുന്നുണ്ടോ എന്ന് പരസ്യപ്പെടുത്തുന്നതിന് മുൻപ് ഉറപ്പാക്കണം.

GB **MODEL CARDS AND DATASHEETS FOR DATASETS**

Pioneering ethicists propose standardized documentation: Model Cards and Datasheets for Datasets.

These documents explicitly disclose training demographics, evaluation metrics, performance limitations, and intended operating contexts, institutionalizing accountability and radical transparency.

ML **മോഡൽ കാർഡുകളും സുതാര്യതയും**

സാങ്കേതികവിദ്യയിലെ സുതാര്യത ഉറപ്പാക്കാൻ മോഡൽ കാർഡുകൾ (Model Cards), ഡാറ്റാ ഷീറ്റുകൾ എന്നിവ ഉപയോഗിക്കുന്നു.

എന്തെല്ലാം വിവരങ്ങൾ ഉപയോഗിച്ചാണ് സിസ്റ്റം പഠിച്ചത്, ഇതിന്റെ പോരായ്മകൾ എന്തൊക്കെയാണ്, എവിടെയൊക്കെ ഇത് പ്രയോഗിക്കാൻ പാടില്ല എന്ന വിവരങ്ങൾ പരസ്യപ്പെടുത്തുന്നത് വഴി ഉത്തരവാദിത്തം സ്ഥാപിച്ചെടുക്കാൻ സാധിക്കുന്നു.

10. Legal Frameworks, Human Rights and Democratic Oversight
നിയമ ചട്ടക്കൂടുകൾ, മനുഷ്യാവകാശങ്ങൾ & ജനാധിപത്യ നിയന്ത്രണം

GB ENFORCING NON-DISCRIMINATION PROTECTIONS

Constitutional principles of equal protection mandate that automated systems cannot circumvent civil rights statutes.

Legal regulations require developers to bear legal liability for disparate outcomes, guaranteeing that individuals harmed by algorithmic decisions possess a legally enforceable Right to Explanation and redress.

ML ഭരണഘടനാപരമായ തുല്യനീതി സംരക്ഷണം

ഭരണഘടന ഉറപ്പുനൽകുന്ന തുല്യനീതിയും പൗരാവകാശങ്ങളും നിഷേധിക്കാൻ ഒരു അൽഗോരിതത്തിനും അനുവാദമില്ല.

എഐ സംവിധാനങ്ങൾ വരുത്തുന്ന വിവേചനങ്ങൾക്ക് നിർമ്മാതാക്കൾ ശിക്ഷാർഹരാണെന്ന് നിയമങ്ങൾ അനുശാസിക്കുന്നു; കൂടാതെ എഐ തള്ളിക്കളഞ്ഞ തീരുമാനങ്ങൾക്ക് പിന്നിലെ കാരണം ചോദിച്ചറിയാനുള്ള അവകാശവും (Right to Explanation) പൗരനുണ്ട്.

GB PARTICIPATORY DESIGN WITH IMPACTED COMMUNITIES

Democratizing AI governance requires incorporating the voices of historically marginalized groups into the initial formulation of algorithmic models.

Participatory design ensures that ethical values and social justice priorities define technical parameters, preventing high-tech solutions from replicating past colonial or patriarchal oppression.

ML സമൂഹത്തിന്റെ പങ്കാളിത്തത്തോടുകൂടിയ നിർമ്മാണം

എഐ സാങ്കേതികവിദ്യയുടെ ഗുണദോഷങ്ങൾ അനുഭവിക്കുന്ന സാധാരണ ജനങ്ങളെയും പിന്നാക്ക വിഭാഗങ്ങളെയും ഈ സംവിധാനങ്ങളുടെ രൂപകൽപ്പനയിൽ പങ്കാളികളാക്കണം.

പങ്കാളിത്ത രൂപകൽപ്പന (Participatory Design) വഴി സാമൂഹിക നീതിക്ക് മുൻഗണന നൽകിക്കൊണ്ട് ചരിത്രപരമായ വിവേചനങ്ങൾ ആവർത്തിക്കപ്പെടാതെ നോക്കാൻ സാധിക്കുന്നു.

11. Academic Curriculum Practice Questions & Analytical Drill
സർവ്വകലാശാല പരീക്ഷാ ചോദ്യോത്തരങ്ങൾ & വിശകലന പരിശീലനം

GB KNOCK YOUR BRAIN: OFFICIAL CURRICULUM MCQS

Q1: Why does excluding protected attributes fail to eliminate bias?
A) Algorithms forget rules | B) Proxies like zip codes and browsing patterns correlate tightly with protected traits | C) Algorithms become too fast | D) Data storage limitations
Answer: B · The fallacy of fairness through blindness due to proxy variables.

Q2: What is the primary cause of algorithmic bias in recruitment?
A) Random software bugs | B) Machine learning trained on historical datasets reflecting male-dominated past hiring | C) Excessive memory capacity | D) Lack of math models
Answer: B · Ingestion and amplification of historical human prejudices.

ML സർവ്വകലാശാല പരീക്ഷാ ചോദ്യോത്തരങ്ങൾ

ചോദ്യം 1: ജാതിയും ലിംഗവും ഡാറ്റയിൽ നിന്ന് ഒഴിവാക്കിയതുകൊണ്ട് മാത്രം വിവേചനം അവസാനിക്കാത്തത് എന്തുകൊണ്ട്?
A) എഐ നിയമങ്ങൾ മറന്നുപോകുന്നു | B) പിൻകോഡും മറ്റ് പ്രോക്സി വേരിയബിളുകളും വഴി ഇത്തരം വിവരങ്ങൾ അൽഗോരിതം കണ്ടെത്തുന്നു | C) കമ്പ്യൂട്ടറിന്റെ വേഗത കൂടുന്നു | D) മെമ്മറിയുടെ കുറവ്
ശരിയുത്തരം: B · പ്രോക്സി വേരിയബിളുകളിലൂടെയുള്ള പരോക്ഷ വിവേചനം.

ചോദ്യം 2: തൊഴിൽ തിരഞ്ഞെടുപ്പിൽ എഐ പക്ഷപാതം കാണിക്കാൻ പ്രധാന കാരണമെന്ത്?
A) പ്രോഗ്രാമിംഗിലെ സാങ്കേതിക പിഴവ് | B) മുൻകാലങ്ങളിലെ പുരുഷ മേധാവിത്വപരമായ ചരിത്ര ഡാറ്റയിൽ നിന്ന് എഐ പഠിച്ചെടുത്തത് കാരണം | C) വലിയ മെമ്മറി ഉള്ളതിനാൽ | D) കണക്കുകൾ തെറ്റിയതുകൊണ്ട്
ശരിയുത്തരം: B · ചരിത്രപരമായ വിവേചനങ്ങളെ അൽഗോരിതം സത്യമായി സ്വീകരിച്ചു.

GB CORE ANALYTICAL ESSAY TOPICS

1. **The Impossibility Theorem of Fairness:** Explain why mathematical definitions of fairness conflict and discuss how policymakers should resolve this tension.
2. **Preventing Algorithmic Discrimination:** Outline a comprehensive framework combining data debiasing, third-party auditing, and constitutional protections.

ML പ്രധാന പരീക്ഷാ ഉപന്യാസ വിഷയങ്ങൾ

1. **നീതിയുടെ ഗണിതശാസ്ത്ര വൈരുദ്ധ്യം:** എല്ലാ നീതിമാനദണ്ഡങ്ങളും ഒരേസമയം തൃപ്തിപ്പെടുത്താൻ കഴിയില്ലെന്ന ഗണിതശാസ്ത്ര സത്യത്തെക്കുറിച്ച് ചർച്ച ചെയ്യുക.
2. **അൽഗോരിതമിക് വിവേചനം തടയൽ:** ഡാറ്റാ ശുദ്ധീകരണം, സ്വതന്ത്ര ഓഡിറ്റിംഗ്, ഭരണഘടനാ അവകാശങ്ങൾ എന്നിവ സംയോജിപ്പിച്ചുള്ള പ്രതിരോധ തന്ത്രം രൂപപ്പെടുത്തുക.

⚡ HIGH-YIELD SYNTHESIS · KNOCK YOUR BRAIN

20 Very Important Knock Your Brain Points on Algorithmic Bias, Fairness & Machine Discrimination

മെഷീൻ ലേണിംഗ് അൽഗോരിതങ്ങളിലെ മുൻവിധികൾ: ഏറ്റവും പ്രധാനപ്പെട്ട 20 പരീക്ഷാ പോയിന്റുകൾ

⚖️ CORE CONCEPT — Algorithmic Bias
അൽഗോരിതമിക് പക്ഷപാതം

Systematic and repeatable errors in computer systems that create unfair outcomes across protected classes.
പ്രത്യേക ജനവിഭാഗങ്ങളോട് അന്യായമായ വിവേചനം സൃഷ്ടിക്കുന്ന വ്യവസ്ഥാപിത പിഴവുകൾ.

🏛️ ORIGIN — Historical Data Prejudice
ചരിത്രപരമായ മുൻവിധികൾ

Pre-existing societal discrimination reflected directly in training data and assimilated by machine learning models.
സമൂഹത്തിൽ പണ്ടുതൊട്ടേ നിലനിന്നിരുന്ന വിവേചനങ്ങൾ ഡാറ്റയിലൂടെ എഐ പഠിച്ചെടുക്കൽ.

🔍 PROXY TRAP — Proxy Discrimination
പ്രോക്സി വിവേചനം

Neutral variables (e.g. zip codes, alumni networks) encoding sensitive traits and replicating unfair treatment.
പിൻകോഡ് പോലുള്ള വിവരങ്ങളിലൂടെ ജാതിയും വംശവും കണ്ടെത്തി വിവേചനം കാണിക്കൽ.

🚫 FALLACY — Fairness through Blindness
'അന്ധത വഴിയുള്ള നീതി' എന്ന മിഥ്യ

The erroneous assumption that removing sensitive demographic labels prevents algorithmic discrimination.
കോളങ്ങൾ നീക്കം ചെയ്തതുകൊണ്ട് മാത്രം വിവേചനം അവസാനിക്കുമെന്ന തെറ്റായ ധാരണ.

📉 SAMPLE DEFICIT — Representation Bias
പ്രാതിനിധ്യ പക്ഷപാതം

Under-representation of minority demographics in training datasets leading to severe error spikes.
പരിശീലന വിവരങ്ങളിൽ ന്യൂനപക്ഷങ്ങളുടെ വിവരങ്ങൾ കുറവായതിനാൽ വരുന്ന ഗുരുതര പിഴവുകൾ.

👥 HUMAN FLAW — Labeling / Annotator Bias
ലേബലിംഗ് പക്ഷപാതം

Subjective prejudices of human annotators embedded into foundational 'ground truth' classifications.
ഡാറ്റ തരംതിരിക്കുന്ന മനുഷ്യരുടെ സ്വന്തം മുൻവിധികൾ എഐയുടെ ലക്ഷ്യമായി മാറുന്ന അവസ്ഥ.

💼 RECRUITMENT — Automated Hiring Disparity
തൊഴിൽ തിരഞ്ഞെടുപ്പിലെ പക്ഷപാതം

Algorithms penalizing female and minority credentials based on past male-dominated corporate hiring.
പഴയ പുരുഷ മേധാവിത്വ ഡാറ്റ കാരണം സ്ത്രീകളുടെ റെസ്യൂമെകൾ തഴയപ്പെടുന്നത്.

📊 METRIC — Demographic Parity
ഡെമോഗ്രാഫിക് പാരിറ്റി

Requiring identical positive outcome rates across all protected demographic subgroups.
എല്ലാ വിഭാഗങ്ങൾക്കും ഒരേ അനുപാതത്തിൽ വിജയസാദ്ധ്യത ഉറപ്പാക്കുന്ന സമത്വ രീതി.

⚖️ METRIC — Equalized Odds
ഇക്വലൈസ്ഡ് ഓഡ്സ്

Ensuring true positive and false positive rates are equal across all protected demographic groups.
ശരിയായ തിരഞ്ഞെടുപ്പിലും തെറ്റായ നിരസിക്കലിലും ഗ്രൂപ്പുകൾക്കിടയിൽ തുല്യത പാലിക്കൽ.

🧩 PARADOX — Impossibility Theorem of Fairness
നീതിയുടെ അസാദ്ധ്യതാ സിദ്ധാന്തം

Mathematical proof that demographic parity and predictive parity cannot both hold under unequal base rates.
വ്യത്യസ്ത നീതിമാനദണ്ഡങ്ങൾ ഒരേസമയം ഗണിതശാസ്ത്രപരമായി പൂർണ്ണമാക്കാൻ കഴിയില്ലെന്ന തെളിവ്.

🧹 PRE-STAGE — Pre-processing Debiasing
പ്രീ-പ്രോസസ്സിംഗ് ഡീബയാസിംഗ്

Re-sampling, re-weighting, and augmenting historical datasets prior to model training.
മോഡൽ പഠിക്കുന്നതിന് മുൻപ് തന്നെ ഡാറ്റയിലെ അസമത്വങ്ങൾ പരിഹരിച്ചു മാറ്റൽ.

⚙️ IN-STAGE — In-processing Regularization
ഇൻ-പ്രോസസ്സിംഗ് റെഗുലറൈസേഷൻ

Incorporating explicit mathematical fairness penalty terms into model objective functions.
വിവേചനപരമായ തീരുമാനങ്ങൾക്ക് സ്വയം പിഴ ചുമത്തുന്ന അൽഗോരിതങ്ങൾ നിർമ്മിക്കൽ.

🎯 POST-STAGE — Post-processing Thresholding
പോസ്റ്റ്-പ്രോസസ്സിംഗ് തിരുത്തലുകൾ

Adjusting classification thresholds across demographic groups to ensure

⚠️ HARM — Disparate Impact
ഡിസ്പറേറ്റ് ഇംപാക്ട്

Facially neutral algorithmic policies producing substantially unequal outcomes for protected groups.
പുറമേക്ക് നിഷ്പക്ഷമെന്ന്