മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 16: മെഷീൻ ലേണിംഗിലെ അൽഗോരിതമിക് പക്ഷപാതങ്ങൾ തടയൽ (Preventing Algorithmic Biases)

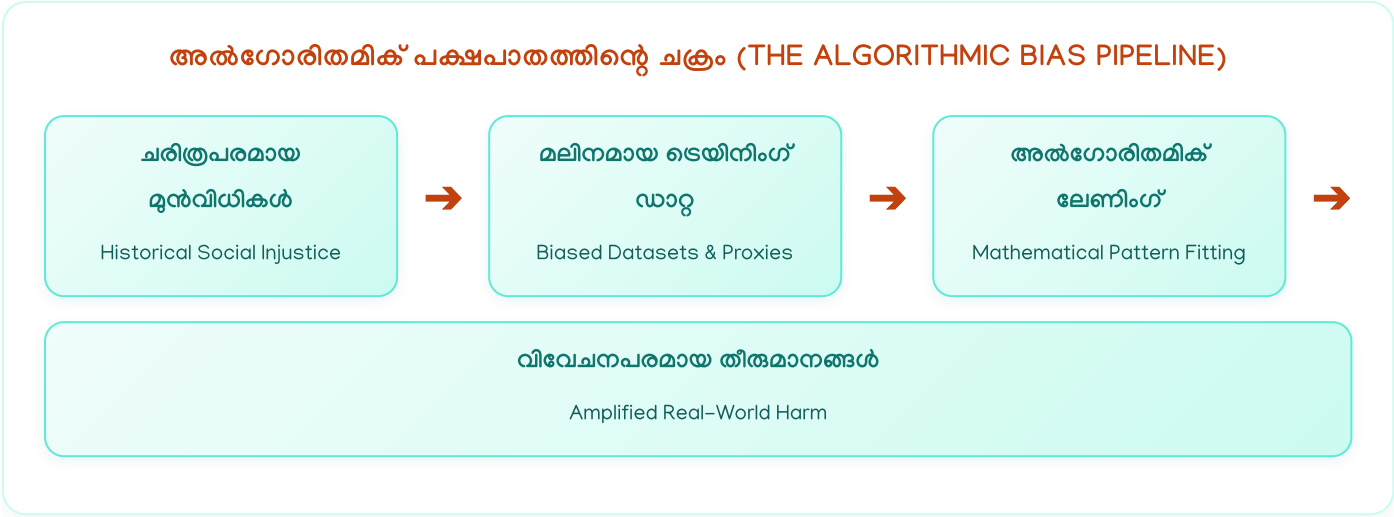
Module 4 · Chapter 16: Algorithmic Bias, Fairness Metrics & Explainable AI (XAI) ·Philosophy AI FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

·Philosophy AI FYUGP (PHL1MN 102) ·

ഈ അധ്യായം ആധുനിക മെഷീൻ ലേണിംഗ് സിസ്റ്റങ്ങളിലെ ഏറ്റവും വലിയ പ്രായോഗിക ധാർമ്മിക വെല്ലുവിളിയായ 'അൽഗോരിതമിക് പക്ഷപാതം' (Algorithmic Bias) ചർച്ച ചെയ്യുന്നു. കമ്പ്യൂട്ടറുകൾ വസ്തുനിഷ്ഠവും നിഷ്പക്ഷവുമാണെന്ന മിഥ്യാധാരണയെ ഈ അധ്യായം തകർക്കുന്നു. ചരിത്രപരമായ മുൻവിധികളാൽ മലിനമായ ഡാറ്റയിൽ നിന്ന് മെഷീനുകൾ എങ്ങനെയാണ് ലിംഗവിവേചനവും വംശീയതയും ജാതീയതയും പഠിച്ചെടുക്കുന്നതെന്നും, ഇതിനെ സാങ്കേതികമായും ദാർശനികമായും എങ്ങനെ പ്രതിരോധിക്കാമെന്നും ഇവിടെ വിശകലനം ചെയ്യുന്നു.

പഠന ലക്ഷ്യങ്ങൾ (Learning Objectives):

- അൽഗോരിതമിക് ബയാസ് (Algorithmic Bias) എന്താണെന്ന് നിർവ്വചിക്കുകയും അതിന്റെ വിവിധ രൂപങ്ങൾ തിരിച്ചറിയുകയും ചെയ്യുക.
- കോമ്പാസ് (COMPAS), ആമസോൺ റിക്രൂട്ട്മെന്റ് ടൂൾ, ഫേഷ്യൽ റെക്കഗ്നിഷൻ (Gender Shades) തുടങ്ങിയ സുപ്രധാന കേസ് സ്റ്റഡികൾ പഠിക്കുക.
- ഫെയർനെസ്സ് മെട്രിക്സുകൾ: ഡെമോഗ്രാഫിക് പാരിറ്റി, ഇക്വലൈസ്ഡ് ഓഡ്സ്, പ്രെഡിക്റ്റീവ് പാരിറ്റി എന്നിവ താരതമ്യം ചെയ്യുക.
- ജോൺ ക്ലൈൻബർഗിന്റെ 'അസാദ്ധ്യതാ സിദ്ധാന്തം' (Kleinberg's Impossibility Theorem of Fairness) ഗണിതശാസ്ത്രപരമായും ദാർശനികമായും വിലയിരുത്തുക.
- എക്സ്പ്ലൈനബിൾ എഐ (XAI – LIME, SHAP), എത്തിക്സ്-ബൈ-ഡിസൈൻ (Ethics-by-Design) എന്നിവയുടെ പ്രാധാന്യം മനസ്സിലാക്കുക.
- ജോൺ റോൾസിന്റെ 'വെയിൽ ഓഫ് ഇഗ്നോറൻസ്' (Veil of Ignorance) അൽഗോരിതമിക് നീതിശാസ്ത്രത്തിൽ പ്രയോഗിക്കുക.



2. പക്ഷപാതങ്ങളുടെ ഉറവിടങ്ങളും വർഗ്ഗീകരണവും (Taxonomy & Sources of Algorithmic Bias)

EN **Definition of Algorithmic Bias:** Algorithmic bias occurs when a machine learning model reflects, amplifies, or systematizes unjust prejudices, discrimination, or systemic disparities against protected demographic groups (such as race, gender, caste, socioeconomic class, or disability) in its automated outputs. Machine learning algorithms do not possess subjective malevolence; they are mathematical optimization functions that discover statistical correlations in training data. If the historical data is structurally unfair, the machine will faithfully learn and automate that unfairness under the veneer of mathematical objectivity.

The primary sources of bias in the AI lifecycle include:

- **Historical Bias:** Exists when past societal discrimination is directly embedded in historical records (e.g., past hiring records favoring male candidates).
- **Representation / Sampling Bias:** Occurs when certain demographic groups are underrepresented or missing from the training distribution (e.g., dermatological AI trained 90% on Caucasian skin).
- **Measurement Bias & Proxies:** Using flawed proxy variables to measure complex human constructs (e.g., using arrest history as a proxy for actual criminal guilt, ignoring policing disparities).
- **Aggregation Bias:** Imposing a single global predictive model across heterogeneous populations where subgroups have completely distinct underlying causal relationships.
- **Feedback Loops (Predictive Policing):** When an algorithm sends more police to a marginalized neighborhood based on historical arrest data, police make more arrests there, which is fed back into the training data as "proof" that the neighborhood is high-crime, creating a self-reinforcing vicious cycle.

ML **അൽഗോരിതമിക് പക്ഷപാതത്തിന്റെ നിർവ്വചനം:** ഒരു മെഷീൻ ലേണിംഗ് സിസ്റ്റം അതിന്റെ കണക്കുകൂട്ടലുകളിലൂടെ ഏതെങ്കിലും ഒരു പ്രത്യേക വിഭാഗത്തിനെതിരായി (ജാതി, മതം, വർഗ്ഗം, ലിംഗം, സാമ്പത്തിക നില എന്നിവയുടെ പേരിൽ) വ്യവസ്ഥാപിതമായ വിവേചനമോ മുൻവിധിയോ കാട്ടുന്ന അവസ്ഥയെയാണ് **അൽഗോരിതമിക് പക്ഷപാതം** (Algorithmic Bias) എന്ന് വിളിക്കുന്നത്. കമ്പ്യൂട്ടറുകൾക്ക് വ്യക്തിപരമായ വിദ്വേഷമില്ല; എന്നാൽ അവ ചരിത്രപരമായ ഡാറ്റയിലെ സ്ഥിതിവിവരക്കണക്കുകളാണ് പഠിക്കുന്നത്. കഴിഞ്ഞകാല ചരിത്രം

അനീതി നിറഞ്ഞതാണെങ്കിൽ, കമ്പ്യൂട്ടർ ആ അനീതിയെ വസ്തുനിഷ്ഠമായ ഗണിത സത്യമായി തെറ്റിദ്ധരിക്കുകയും ഭാവിയിലേക്കും ആവർത്തിക്കുകയും ചെയ്യുന്നു.

പക്ഷപാതത്തിന്റെ പ്രധാന ഉറവിടങ്ങൾ താഴെ പറയുന്നവയാണ്:

- **ചരിത്രപരമായ പക്ഷപാതം (Historical Bias):** കഴിഞ്ഞകാല സമൂഹത്തിൽ നിലനിന്നിരുന്ന വിവേചനങ്ങൾ അതേപടി ഡാറ്റയിൽ പ്രതിഫലിക്കുന്നത് (ഉദാഹരണത്തിന്, മുൻകാലങ്ങളിൽ ഉയർന്ന കമ്പനി ഉദ്യോഗങ്ങളിൽ പുരുഷന്മാരെ മാത്രം നിയമിച്ചിരുന്ന ഡാറ്റ).
- **സാമ്പിളിംഗ് പക്ഷപാതം (Sampling Bias):** പരിശീലിപ്പിക്കുന്ന ഡാറ്റാബേസിൽ ചില പ്രത്യേക ന്യൂനപക്ഷ വിഭാഗങ്ങളുടെ സാന്നിധ്യം ഇല്ലാതിരിക്കുകയോ തുച്ഛമായിരിക്കുകയോ ചെയ്യൽ (ഉദാഹരണത്തിന്, വെള്ളക്കാരുടെ ചിത്രങ്ങളിൽ മാത്രം പരിശീലിപ്പിച്ച ഫേഷ്യൽ റെക്കഗ്നിഷൻ).
- **മെഷർമെന്റ് ബയാസും പ്രോക്സികളും (Proxy Variables):** നേരിട്ട് അളക്കാൻ കഴിയാത്ത കാര്യങ്ങൾക്ക് തെറ്റായ പകരക്കാരെ (Proxies) ആശ്രയിക്കുന്നത് (ഉദാഹരണത്തിന്, ഒരാൾ കുറ്റക്കാരനാണോ എന്ന് അളക്കാൻ അയാളുടെ അറസ്റ്റ് രേഖകൾ മാനദണ്ഡമാക്കുന്നത്; ദരിദ്രർ അകാരണമായി കൂടുതൽ അറസ്റ്റ് ചെയ്യപ്പെടുന്നു എന്ന സത്യം മറച്ചുവെക്കപ്പെടുന്നു).
- **ഫീഡ്ബാക്ക് ലൂപ്പുകൾ (Feedback Loops):** ഒരു തെറ്റ് വീണ്ടും ആവർത്തിക്കപ്പെടുന്ന അവസ്ഥ. പാവപ്പെട്ട ചേരികളിലേക്ക് കൂടുതൽ പോലീസിനെ അയക്കാൻ അൽഗോരിതം നിർദ്ദേശിക്കുന്നു; അവിടെ കൂടുതൽ അറസ്റ്റുകൾ നടക്കുന്നു; ഈ അറസ്റ്റ് ഡാറ്റ കണ്ട് ചേരികളിൽ കുറ്റവാസന കൂടുതലാണെന്ന് അൽഗോരിതം വീണ്ടും തെറ്റായി സ്ഥിരീകരിക്കുന്നു.

3. പ്രധാന യഥാർത്ഥ കേസ് സ്റ്റഡികൾ (Real-World Benchmark Case Studies)

1. കോമ്പാസ് ജുഡീഷ്യൽ അൽഗോരിതത്തിലെ വംശീയ വിവേചനം (COMPAS Recidivism Algorithm)

അമേരിക്കൻ കോടതികളിൽ പ്രതികൾക്ക് ജാമ്യം നൽകുന്നതിനും ശിക്ഷ നിശ്ചയിക്കുന്നതിനും ഉപയോഗിച്ച അൽഗോരിതമാണ് COMPAS (Correctional Offender Management Profiling for Alternative Sanctions). 2016-ൽ പ്രോപബ്ലിക്ക (ProPublica) നടത്തിയ അന്വേഷണാത്മക പത്രപ്രവർത്തനത്തിൽ ഞെട്ടിക്കുന്ന സത്യങ്ങൾ പുറത്തുവന്നു:

- ഭാവിയിൽ വീണ്ടും കുറ്റകൃത്യങ്ങൾ ചെയ്യാൻ സാധ്യതയുള്ളവരെ കണ്ടെത്തുന്നതിൽ കറുത്തവർഗ്ഗക്കാരായ പ്രതികളെ തെറ്റായി 'അതിയായ അപകടസാധ്യതയുള്ളവർ' (False Positive) എന്ന് അൽഗോരിതം മുദ്രകുത്തി. കറുത്തവർഗ്ഗക്കാർക്കിടയിൽ തെറ്റായ പ്രവചന നിരക്ക് വെള്ളക്കാരേക്കാൾ ഇരട്ടിയായിരുന്നു (45% vs 23%).
- എന്നാൽ വെള്ളക്കാരായ പ്രതികൾ ഭാവിയിൽ ഗുരുതര കുറ്റങ്ങൾ ചെയ്യുമ്പോഴും അവരെ 'കുറഞ്ഞ അപകടസാധ്യതയുള്ളവർ' (False Negative) എന്ന് രേഖപ്പെടുത്തി വിട്ടയച്ചു.

2. ആമസോണിന്റെ ഓട്ടോമേറ്റഡ് റിക്രൂട്ട്മെന്റ് ടൂൾ (Amazon AI Recruitment Tool)

2014-ൽ ആമസോൺ എൻജിനീയറിംഗ് തസ്തികകളിലേക്ക് ഉദ്യോഗാർത്ഥികളുടെ റെസ്യൂമെകൾ തെരഞ്ഞെടുക്കാൻ ഒരു AI ടൂൾ നിർമ്മിച്ചു. കഴിഞ്ഞ 10 വർഷത്തെ ജീവനക്കാരുടെ റെസ്യൂമെകളാണ് ഇതിന് പരിശീലനമായി നൽകിയത്. അന്നത്തെ സാങ്കേതിക മേഖലയിൽ പുരുഷന്മാരായിരുന്നു ഭൂരിപക്ഷം. ഇത് കണ്ട് പഠിച്ച അൽഗോരിതം, "വുമൺസ് കോളേജ്", "വുമൺസ് ചെസ്സ് ക്ലബ്ബ് ക്യാപ്റ്റൻ" എന്നിങ്ങനെ 'സ്ത്രീ' (Women's) എന്ന പദമുള്ള റെസ്യൂമെകൾക്കെല്ലാം യാന്ത്രികമായി മാർക്ക് വെട്ടിക്കുറച്ചു! പദ്ധതി ലിംഗവിവേചനപരമാണെന്ന് കണ്ട് 2018-ൽ ആമസോൺ ഇത് പൂർണ്ണമായി ഉപേക്ഷിച്ചു.

3. ജോയ് ബുവാലംവിനിയുടെ 'ജെൻഡർ ഷേഡ്സ്' പഠനം (Joy Buolamwini & Timnit Gebru – Gender Shades)

എം.ഐ.ടിയിലെ കമ്പ്യൂട്ടർ ശാസ്ത്രജ്ഞയായ ജോയ് ബുവാലംവിനിയും ടിംനിറ്റ് ഗെബ്രുവും ചേർന്ന് 2018-ൽ നടത്തിയ പഠനത്തിൽ, ഐ.ബി.എം (IBM), മൈക്രോസോഫ്റ്റ്, ഫേസ്++ എന്നീ മുൻനിര കമ്പനികളുടെ ഫേഷ്യൽ റെക്കഗ്നിഷൻ സിസ്റ്റങ്ങൾ കറുത്തവർഗ്ഗക്കാരായ സ്ത്രീകളുടെ മുഖം തിരിച്ചറിയുന്നതിൽ 34.7% വരെ പരാജയപ്പെടുന്നു എന്ന് കണ്ടെത്തി. എന്നാൽ വെളുത്ത പുരുഷന്മാരെ തിരിച്ചറിയുന്നതിൽ പിഴവ് കേവലം 0.8% മാത്രമായിരുന്നു. ഡാറ്റാബേസുകളിൽ കറുത്തവർഗ്ഗക്കാരുടെ മുഖങ്ങൾ കുറവായിരുന്നു എന്നതാണ് ഈ സാങ്കേതിക വിവേചനത്തിന് കാരണം.

4. ഫെയർനെസ്സ് മെട്രിക്സുകളും ക്ലൈൻബർഗിന്റെ അസാദ്ധ്യതാ സിദ്ധാന്തവും (Kleinberg's Impossibility Theorem)

ഒരു അൽഗോരിതം 'നീതിപൂർവ്വകമാണ്' (Fair) എന്ന് പറയാൻ ഗണിതശാസ്ത്രജ്ഞർ മൂന്ന് പ്രധാന മാനദണ്ഡങ്ങൾ മുന്നോട്ടുവെക്കുന്നു:

നീതിയുടെ മാനദണ്ഡം (Fairness Metric)	ഗണിത സമവാക്യം / ആശയം	പ്രായോഗിക അർത്ഥം (Practical Meaning)
1. ഡെമോഗ്രാഫിക് പാരിറ്റി (Demographic Parity)	P(Y=1 | Group A) = P(Y=1 | Group B)	രണ്ട് വിഭാഗങ്ങളിലെയും വ്യക്തികൾക്ക് തുല്യ ശതമാനത്തിൽ അനുകൂലമായ തീരുമാനം (ഉദാ: ജോലി/ലോൺ) ലഭിക്കണം.
2. ഇക്വലൈസ്ഡ് ഓഡ്സ് (Equalized Odds)	TPR and FPR are identical across all groups	യോഗ്യരായവർക്ക് നീതി ലഭിക്കുന്ന നിരക്കും (True Positive), തെറ്റായി ശിക്ഷിക്കപ്പെടുന്ന നിരക്കും (False Positive) തുല്യമായിരിക്കണം.
3. പ്രെഡിക്റ്റീവ് പാരിറ്റി (Predictive Parity / Calibration)	P(Y=1 | R=r, Group A) = P(Y=1 | R=r, Group B)	അൽഗോരിതം നൽകുന്ന ഒരു റിസ്ക് സ്കോറിന്റെ കൃത്യത എല്ലാ വിഭാഗങ്ങളിലും ഒരേപോലെയായിരിക്കണം.

EN **Kleinberg's Impossibility Theorem of Fairness (2016):** Computer scientist Jon Kleinberg (Cornell University) and colleagues mathematically proved a profound truth that shattered the algorithmic fairness landscape: **Except in trivial cases (such as perfect zero-error predictors or identical base rates across**

groups), it is mathematically impossible for an algorithm to satisfy Demographic Parity, Equalized Odds, and Predictive Parity simultaneously.

If historical inequalities cause the underlying "base rate" of poverty, arrests, or disease to differ across demographic groups, an algorithm calibrated for Predictive Parity (such that a risk score of 7 means the same probability of recidivism for Black and White defendants) *will mathematically guarantee* an unequal False Positive Rate (discriminating against the historically marginalized group under Equalized Odds).

Philosophical Consequence: Fairness cannot be solved by "better math." Choosing which fairness metric to prioritize is a purely political, ethical, and normative decision that engineers cannot escape.

ML **ജോൺ ക്ലൈൻബർഗിന്റെ അസാദ്ധ്യതാ സിദ്ധാന്തം (Kleinberg's Impossibility Theorem):** കോർണൽ യൂണിവേഴ്സിറ്റിയിലെ കമ്പ്യൂട്ടർ ശാസ്ത്രജ്ഞനായ ജോൺ ക്ലൈൻബർഗ് 2016-ൽ ഗണിതശാസ്ത്രപരമായി തെളിയിച്ച വിപ്ലവകരമായ സത്യമാണിത്: **സമൂഹത്തിലെ രണ്ട് വിഭാഗങ്ങൾ തമ്മിലുള്ള അടിസ്ഥാന നിരക്കുകളിൽ (Base Rates) വ്യത്യാസമുണ്ടെങ്കിൽ, ഒരൊറ്റ അൽഗോരിതത്തിനും ഒരേ സമയം ഡെമോഗ്രാഫിക് പാരിറ്റിയും, ഇക്വലൈസ്ഡ് ഓഡ്സും, പ്രെഡിക്റ്റീവ് പാരിറ്റിയും ഒരുമിച്ച് തൃപ്തിപ്പെടുത്താൻ ഗണിതശാസ്ത്രപരമായി കഴിയില്ല!**

നിങ്ങൾ ഒരു മാനദണ്ഡം ശരിയാക്കാൻ ശ്രമിക്കുമ്പോൾ രണ്ടാമത്തെ മാനദണ്ഡം തെറ്റായി മാറും. ഉദാഹരണത്തിന്, സ്കോറിന്റെ കൃത്യത (Predictive Parity) നിലനിർത്താൻ ശ്രമിച്ചാൽ സ്വാഭാവികമായും കറുത്തവർഗ്ഗക്കാർക്കെതിരെയുള്ള തെറ്റായ ശിക്ഷാ നിരക്ക് (False Positive Rate) വർദ്ധിക്കും.

ദാർശനിക പ്രാധാന്യം: അൽഗോരിതമിക് നീതി എന്നത് കേവലം കോഡിംഗ് കൊണ്ടോ മികച്ച സമവാക്യങ്ങൾ കൊണ്ടോ പരിഹരിക്കാൻ കഴിയുന്ന ഒന്നല്ല. ഈ മൂന്ന് നീതികളിൽ ഏതാണ് ഒരു സമൂഹത്തിന് വേണ്ടതെന്ന് തീരുമാനിക്കേണ്ടത് തത്ത്വചിന്തകരും, നിയമജ്ഞരും, ജനങ്ങളുമാണ്; അത് ഒരു ധാർമ്മിക രാഷ്ട്രീയ തിരഞ്ഞെടുപ്പാണ്.

5. സാങ്കേതികവും ദാർശനികവുമായ പരിഹാരമാർഗ്ഗങ്ങൾ (Algorithmic & Ethical Solutions)

അൽഗോരിതമിക് പക്ഷപാതങ്ങൾ തടയാൻ ശാസ്ത്രലോകവും തത്ത്വചിന്തകരും മുന്നോട്ടുവെക്കുന്ന പ്രധാന പരിഹാരങ്ങൾ:

1. ഡീബയാസിംഗ് രീതികൾ (Algorithmic Debiasing)

ഡാറ്റ പരിശീലിപ്പിക്കുന്നതിന് മുൻപ് സാമ്പിളുകൾ പുനഃക്രമീകരിക്കൽ (Pre-processing), അൽഗോരിതത്തിനുള്ളിൽത്തന്നെ നീതിയുടെ സമവാക്യങ്ങൾ ഉൾപ്പെടുത്തൽ (In-processing), ഒടുവിൽ ലഭിക്കുന്ന തീരുമാനങ്ങളുടെ കട്ട്-ഓഫ് മാർക്കുകൾ തിരുത്തൽ (Post-processing).

2. എക്സ്പ്ലൈനബിൾ എഐ (Explainable AI – XAI)

ബ്ലാക്ക് ബോക്സ് (Black Box) പ്രശ്നം പരിഹരിക്കാൻ, എഐ എടുത്ത തീരുമാനത്തിന് പിന്നിലെ കാരണങ്ങൾ മനുഷ്യന് വായിക്കാവുന്ന രൂപത്തിൽ വ്യക്തമാക്കുന്ന LIME, SHAP തുടങ്ങിയ സങ്കേതങ്ങൾ ഉപയോഗിക്കൽ.

3. എത്തിക്സ്-ബൈ-ഡിസൈൻ (Ethics-by-Design)

സോഫ്റ്റ്വെയർ നിർമ്മിച്ച് കഴിഞ്ഞതിന് ശേഷം പരിശോധിക്കുന്നതിന് പകരം, കോഡിംഗിന്റെ ആദ്യ ഘട്ടം

മുതൽ തന്നെ ധാർമ്മിക സുരക്ഷാ ഓഡിറ്റിംഗും എത്തിക്കൽ ഇംപാക്റ്റ് അസ്സസ്സ്മെന്റും (EIA) നിർബന്ധമാക്കൽ.

ജോൺ റോൾസിന്റെ 'വെയിൽ ഓഫ് ഇഗ്നോറൻസ്" എഐ-യിൽ (John Rawls's Veil of Ignorance)

അമേരിക്കൻ ദാർശനികനായ ജോൺ റോൾസ് (John Rawls – *A Theory of Justice*, 1971) മുന്നോട്ടുവെച്ച 'അജ്ഞതയുടെ മൂടുപടം' (Veil of Ignorance) അൽഗോരിതമിക് രൂപകൽപ്പനയിൽ പ്രയോഗിക്കാവുന്നതാണ്. ഒരു എഐ എഞ്ചിനീയർ അൽഗോരിതം നിർമ്മിക്കുമ്പോൾ, ആ സിസ്റ്റം നിലവിൽ വരുമ്പോൾ താൻ സമൂഹത്തിലെ ഏറ്റവും പാവപ്പെട്ടവനാകുമോ, കറുത്തവർഗ്ഗക്കാരനാകുമോ, സ്ത്രീയാകുമോ എന്ന് മുൻകൂട്ടി അറിയാത്ത അവസ്ഥ സങ്കൽപ്പിക്കുക. അത്തരമൊരു അവസ്ഥയിലിരുന്ന് അൽഗോരിതം നിർമ്മിച്ചാൽ മാത്രമേ, പാർശ്വവൽക്കരിക്കപ്പെട്ട ഏറ്റവും ദുർബലനായ വ്യക്തിക്ക് ഏറ്റവും കൂടുതൽ സുരക്ഷ നൽകുന്ന പരമമായ നീതി നടപ്പിലാവൂ (Maximin Principle).

6. എൽ.എം.എസ് സമഗ്ര ചോദ്യോത്തരങ്ങൾ (Comprehensive LMS Essay Q&As)

Q1: അൽഗോരിതമിക് പക്ഷപാതം (Algorithmic Bias) എന്നാൽ എന്ത്? ഇത് എങ്ങനെയാണ് മെഷീൻ ലേണിംഗ് സിസ്റ്റങ്ങളിൽ രൂപപ്പെടുന്നത്? (What is Algorithmic Bias? How does it emerge in machine learning pipelines?)

English Detailed Answer: Algorithmic bias refers to systematic, repeatable errors in a computer algorithm that create unfair outcomes, such as privileging one demographic category over another.

Far from being an objective "neutral calculator," a machine learning model is an inductive pattern extractor. Bias enters the pipeline at multiple distinct stages:

1. **Data Collection:** Historical data reflects societal prejudice. In criminal justice, disproportionate arrests of marginalized groups mean the training data records systemic bias as objective truth.
2. **Feature Selection & Proxies:** Even if protected attributes like race, religion, or gender are explicitly removed from the dataset ("fairness through blindness"), algorithms easily infer these attributes via correlated proxy variables such as postal zip codes, shopping habits, or schooling history.
3. **Objective Optimization:** Standard loss functions minimize total aggregate error across the dataset. If minority populations represent only 2% of the training distribution, an algorithm can completely misclassify the minority while still achieving 98% overall accuracy.

മലയാള വിശദീകരണം: മെഷീൻ ലേണിംഗ് സിസ്റ്റങ്ങൾ ഏതെങ്കിലും ഒരു പ്രത്യേക ജനവിഭാഗത്തിനെതിരെ വ്യവസ്ഥാപിതമായ വിവേചനമോ അനീതിയോ കാണിക്കുന്നതിനെയാണ് അൽഗോരിതമിക് പക്ഷപാതം എന്ന് വിളിക്കുന്നത്.

ഇത് താഴെ പറയുന്ന ഘട്ടങ്ങളിലൂടെ സിസ്റ്റത്തിൽ കടന്നുകൂടുന്നു:

1. **വിവരശേഖരണത്തിലെ പക്ഷപാതം:** ചരിത്രപരമായ ഡാറ്റയിൽ സമൂഹം കാണിച്ച അനീതികൾ രേഖപ്പെടുത്തിയിട്ടുണ്ടാകും. പോലീസ് പാവപ്പെട്ടവരെ കൂടുതൽ അറസ്റ്റ് ചെയ്തിട്ടുണ്ടെങ്കിൽ, ആ ഡാറ്റ പഠിക്കുന്ന എഐ പാവപ്പെട്ടവരെല്ലാം കുറ്റവാളികളാണെന്ന് തെറ്റായി വിധിയെഴുതുന്നു.

2. **പ്രോക്സി വേരിയബിളുകൾ (Proxy Variables):** ജാതിയോ മതമോ അൽഗോരിതത്തിൽ നിന്ന് ഒഴിവാക്കിയാൽ പോലും ("Fairness through Blindness"), ഒരാളുടെ പിൻകോഡ്, താമസസ്ഥലം, സ്കൂൾ എന്നിവ പരിശോധിച്ചുകൊണ്ട് അൽഗോരിതത്തിന് അയാളുടെ പശ്ചാത്തലം കണ്ടെത്താനും വിവേചനം കാട്ടാനും കഴിയും.
3. **ഭ്രരിപക്ഷ മുൻഗണന:** അൽഗോരിതങ്ങൾ മൊത്തം ഡാറ്റയിലെ കൃത്യതയാണ് പരമാവധിയാക്കുന്നത്. സമൂഹത്തിലെ 95% വരുന്ന ഭ്രരിപക്ഷത്തിന്റെ ഡാറ്റ കൃത്യമായി പഠിക്കുകയും 5% വരുന്ന ന്യൂനപക്ഷത്തെ അവഗണിക്കുകയും ചെയ്താലും അൽഗോരിതത്തിന് 95% മാർക്ക് ലഭിക്കുന്നു.

Q2: പ്രോപബ്ലിക്ക അന്വേഷിച്ച COMPAS അൽഗോരിതത്തിലെ വംശീയ പക്ഷപാതം വിശദീകരിക്കുക. (Critically analyze the racial bias discovered in the COMPAS recidivism algorithm.)

English Detailed Answer: In 2016, investigative journalism outlet ProPublica analyzed the COMPAS risk assessment score used in Broward County, Florida, to predict whether criminal defendants would reoffend within two years.

The findings demonstrated severe, asymmetrical algorithmic bias:

- **Disparate False Positive Rates:** Black defendants who did *not* reoffend over the subsequent two-year period were nearly twice as likely to be misclassified by the algorithm as "high risk" (44.9%) compared to White non-reoffenders (23.5%).
- **Disparate False Negative Rates:** Conversely, White defendants who *did* go on to commit subsequent crimes were almost twice as likely to be misclassified as "low risk" (47.7%) compared to Black recidivists (28.0%).

The software developer, Northpointe, defended the algorithm by arguing that it satisfied *Predictive Parity*: a score of 7 meant roughly the same probability of recidivism regardless of race. This clash illustrated the real-world manifestation of Kleinberg's Impossibility Theorem: calibrating for predictive parity under different baseline recidivism rates mathematically necessitated disparate false positive rates, trapping Black citizens in prolonged pretrial detention.

മലയാള വിശദീകരണം: 2016-ൽ പ്രോപബ്ലിക്ക പുറത്തുകൊണ്ടുവന്ന അമേരിക്കൻ ജൂഡീഷ്യറിയിലെ COMPAS അൽഗോരിതത്തിന്റെ പക്ഷപാതം:

പ്രതികൾക്ക് ജാമ്യം നൽകാനും വിചാരണത്തടവ് നിശ്ചയിക്കാനും ഉപയോഗിച്ച ഈ അൽഗോരിതം കറുത്തവർഗ്ഗക്കാരോട് കടുത്ത വിവേചനം കാട്ടി:

- ഭാവിയിൽ യാതൊരു കുറ്റവും ചെയ്യാതിരുന്ന നിരപരാധികളായ കറുത്തവർഗ്ഗക്കാരെ 'അതിയായ അപകടസാധ്യതയുള്ളവർ' (False Positive) എന്ന് അൽഗോരിതം തെറ്റായി രേഖപ്പെടുത്തി (44.9%). എന്നാൽ വെള്ളക്കാരിൽ ഇത് 23.5% മാത്രമായിരുന്നു.
- എന്നാൽ ഭാവിയിൽ വീണ്ടും കുറ്റകൃത്യങ്ങൾ ചെയ്ത വെള്ളക്കാരെ 'പാവങ്ങൾ' (Low Risk) എന്ന് രേഖപ്പെടുത്തി എഐ വിട്ടയച്ചു.

തങ്ങളുടെ അൽഗോരിതം ശരിയാണെന്ന് കമ്പനി വാദിച്ചെങ്കിലും, ചരിത്രപരമായ പക്ഷപാതങ്ങൾ കാരണം കറുത്തവർഗ്ഗക്കാർ അകാരണമായി ദീർഘകാലം ജയിലിൽ കിടക്കേണ്ടി വന്നു എന്നത് അൽഗോരിതമിക് അനീതിയുടെ വലിയ തെളിവായി മാറി.

Q3: ജോൺ ക്ലൈൻബർഗിന്റെ 'അസാദ്ധ്യതാ സിദ്ധാന്തം' (Kleinberg's Impossibility Theorem) വ്യക്തമാക്കുക. (Elaborate on Kleinberg's Impossibility Theorem of Algorithmic Fairness.)

English Detailed Answer: Jon Kleinberg, Sendhil Mullainathan, and Manish Raghavan (2016) proved mathematically that three intuitive, universally desired definitions of fairness are mutually incompatible when base rates of the condition vary across groups:

1. **Sufficiency (Predictive Parity):** The predictive score means the same thing across groups.
2. **Separation (Equalized Odds):** The error rates (False Positives and False Negatives) are identical across groups.
3. **Independence (Demographic Parity):** Selection rates are equal across groups.

Kleinberg showed that these conditions can only be simultaneously satisfied if the model has 100% perfect prediction accuracy (impossible in human social domains) or if both groups have identical base rates in the real world. Because societal discrimination causes historical differences in base arrest or default rates, any algorithm that guarantees equal error rates will fail predictive parity, and vice versa. Thus, algorithmic fairness cannot be settled purely by computer code; society must make an explicit philosophical value judgment about which unfairness is least intolerable.

മലയാള വിശദീകരണം: ജോൺ ക്ലൈൻബർഗ്ഗും സംഘവും തെളിയിച്ച വിഖ്യാതമായ അസാദ്ധ്യതാ സിദ്ധാന്തം:

ഒരു അൽഗോരിതം നീതിപൂർവ്വകമാണെന്ന് പറയാൻ നമ്മൾ ആഗ്രഹിക്കുന്ന മൂന്ന് പ്രധാന കാര്യങ്ങൾ (സ്കോറിന്റെ തുല്യ കൃത്യത, തുല്യമായ തെറ്റു തിരുത്തൽ നിരക്ക്, തുല്യ പ്രാതിനിധ്യം) എന്നിവ ഒരുമിച്ച് കൊണ്ടുവരാൻ കഴിയില്ല.

സമൂഹത്തിൽ യഥാർത്ഥത്തിൽ നിലനിൽക്കുന്ന അസമത്വങ്ങൾ കാരണം രണ്ട് ഗ്രൂപ്പുകളിലെ അടിസ്ഥാന വിവരങ്ങളിൽ മാറ്റമുണ്ടെങ്കിൽ, ഒരെണ്ണം ശരിയാക്കാൻ ശ്രമിക്കുമ്പോൾ മറ്റേതിൽ പിഴവ് സംഭവിക്കുമെന്ന് ക്ലൈൻബർഗ് ഗണിതശാസ്ത്രപരമായി തെളിയിച്ചു. അതിനാൽ "പൂർണ്ണമായും നിഷ്പക്ഷമായ ഒരു അൽഗോരിതം" എന്നത് ഒരു മിഥ്യയാണ്; ഏത് തരത്തിലുള്ള നീതിയാണ് വേണ്ടതെന്ന് സമൂഹമാണ് തിരഞ്ഞെടുക്കേണ്ടത്.

Q4: ജോയ് ബുവാലംവിനിയുടെ 'ജെൻഡർ ഷേഡ്സ്" (Gender Shades) പഠനവും ഫേഷ്യൽ റെക്കഗ്നിഷനിലെ പക്ഷപാതങ്ങളും പരിശോധിക്കുക. (Examine Joy Buolamwini's 'Gender Shades' study and facial recognition disparities.)

English Detailed Answer: In 2018, computer scientist Joy Buolamwini (MIT Media Lab) and Timnit Gebru published the groundbreaking study *Gender Shades*, evaluating commercial facial analysis software from Microsoft, IBM, and Face++.

The study evaluated error rates across four demographic quadrants based on the Fitzpatrick skin-type scale: lighter males, lighter females, darker males, and darker females. The results were staggering:

- For light-skinned males, error rates were below 1%.
- For darker-skinned females, error rates soared to between 20.8% and 34.7%.

The root cause was profound *representation bias*: benchmark computer vision datasets (like LFW and ImageNet) were composed of over 75% male and over 80% lighter-skinned faces. The study forced IBM and Microsoft to overhaul their training datasets, inspired bans on governmental facial surveillance, and proved that algorithms inherit the racial and gender hierarchies of the societies that design them.

മലയാള വിശദീകരണം: ജോയ് ബുവാലംവിനിയും ടിംനിറ്റ് ഗെബ്രുവും ചേർന്ന് നടത്തിയ ചരിത്രപ്രസിദ്ധമായ 'ജെൻഡർ ഷേഡ്സ്" പഠനം:

മൈക്രോസോഫ്റ്റ്, ഐ.ബി.എം തുടങ്ങിയ മുൻനിര കമ്പനികളുടെ മുഖം തിരിച്ചറിയുന്ന ക്യാമറകൾ പരിശോധിച്ചപ്പോൾ ഞെട്ടിക്കുന്ന അസമത്വമാണ് കണ്ടത്:

- വെളുത്ത പുരുഷന്മാരുടെ മുഖം തിരിച്ചറിയുന്നതിൽ തെറ്റ് കേവലം 0.8% മാത്രമായിരുന്നു.
- എന്നാൽ കറുത്തവർഗ്ഗക്കാരായ സ്ത്രീകളുടെ മുഖം തിരിച്ചറിയുന്നതിൽ 34.7% വരെ തെറ്റുകൾ സംഭവിച്ചു! പലപ്പോഴും അവരെ പുരുഷന്മാരായി തെറ്റായി അടയാളപ്പെടുത്തി.

ഇതിന് കാരണം, ഈ സിസ്റ്റങ്ങളെ പരിശീലിപ്പിക്കാൻ ഉപയോഗിച്ച ഫോട്ടോകളിൽ 80 ശതമാനവും വെളുത്ത പുരുഷന്മാരുടേതായിരുന്നു എന്നതാണ്. എഐ നിർമ്മാതാക്കളുടെ വർഗ്ഗീയ അന്ധതയെ തുറന്നുകാട്ടിയ പഠനമാണിത്.

Q5: എക്സ്പ്ലൈനബിൾ എഐ (Explainable AI – XAI) എന്നാൽ എന്ത്? അൽഗോരിതമിക് നീതി ഉറപ്പാക്കുന്നതിൽ ഇതിന്റെ പങ്ക് എന്ത്? (What is Explainable AI? Discuss its role in ensuring algorithmic justice.)

English Detailed Answer: Modern deep neural networks function as opaque "black boxes": billions of weights and activation values make it impossible for even the engineers who created them to understand why a specific loan was rejected or a bail application denied. Explainable AI (XAI) refers to methods and tools that translate the mathematical decisions of complex models into transparent, interpretable explanations for human stakeholders.

Key XAI methods include:

- **LIME (Local Interpretable Model-agnostic Explanations):** Builds a simple, interpretable linear model locally around a specific individual prediction to show which factors swayed the decision.
- **SHAP (Shapley Additive exPlanations):** Grounded in cooperative game theory (Lloyd Shapley), SHAP calculates the exact marginal contribution of each input feature to the final algorithmic outcome.

XAI is legally mandatory under regulations like the EU GDPR ("Right to Explanation") because without transparency, victims of algorithmic discrimination cannot meaningfully contest an unfair decision in a court of law.

മലയാള വിശദീകരണം: ആധുനിക ഡീപ് ലേണിംഗ് ന്യൂറൽ നെറ്റ്വർക്കുകൾ 'ബ്ലാക്ക് ബോക്സുകൾ' (Black Boxes) പോലെയാണ് പ്രവർത്തിക്കുന്നത്. ഒരു വ്യക്തിക്ക് ബാങ്ക് ലോൺ നിഷേധിച്ചതോ, ജാമ്യം നിഷേധിച്ചതോ എന്ത് കാരണത്താലാണെന്ന് ആ യന്ത്രം നിർമ്മിച്ച എഞ്ചിനീയർക്ക് പോലും വിശദീകരിക്കാൻ കഴിയില്ല. ഇത്തരത്തിൽ എഐ എടുത്ത തീരുമാനത്തിന് പിന്നിലെ കാരണങ്ങൾ മനുഷ്യർക്ക് മനസ്സിലാകുന്ന രീതിയിൽ വിശദീകരിച്ചു നൽകുന്ന സാങ്കേതികവിദ്യകളെയാണ് **എക്സ്പ്ലൈനബിൾ എഐ** (Explainable AI – XAI) എന്ന് വിളിക്കുന്നത്.

LIME, SHAP തുടങ്ങിയ ടൂളുകൾ ഇതിനായി ഉപയോഗിക്കുന്നു. യൂറോപ്യൻ യൂണിയന്റെ GDPR നിയമപ്രകാരം ഓരോ പൗരനും "വിശദീകരണം അറിയാനുള്ള അവകാശമുണ്ട്" (Right to Explanation). എഐ എന്ത് കാരണത്താലാണ് തനിക്ക് ജോലി നിഷേധിച്ചതെന്ന് അറിഞ്ഞാൽ മാത്രമേ കോടതിയിൽ പോയി നീതി ചോദിക്കാൻ ഒരു വ്യക്തിക്ക് സാധിക്കൂ.

Q6: ജോൺ റോൾസിന്റെ 'വെയിൽ ഓഫ് ഇഗ്നോറൻസ്' (Veil of Ignorance) സിദ്ധാന്തം എഐ എത്തിക്സിൽ എങ്ങനെ പ്രയോഗിക്കാം? (How can John Rawls's Veil of Ignorance be applied to AI Ethics?)

English Detailed Answer: In *A Theory of Justice* (1971), philosopher John Rawls proposed a thought experiment: justice is whatever rules rational individuals would agree to if they were situated behind a "Veil of Ignorance,"

knowing nothing about their own race, gender, wealth, talent, or social standing in the society they are constructing.

Applied to artificial intelligence:

1. **Maximin Principle:** When designing a credit scoring or healthcare triage algorithm, designers must assume they might personally end up being the poorest, most vulnerable, or sickest individual evaluated by the system.
2. **Prohibition of Utilitarian Sacrifices:** A developer behind the veil would reject algorithms that sacrifice minority accuracy to maximize aggregate majority profits, ensuring that protections for vulnerable demographic groups are baked into the architecture by design.

മലയാള വിശദീകരണം: തത്ത്വചിന്തകനായ ജോൺ റോൾസ് മുന്നോട്ടുവെച്ച 'അജ്ഞതയുടെ മൂടുപടം' (Veil of Ignorance) എന്ന സിദ്ധാന്തം എഐ-യിൽ പ്രയോഗിക്കുന്ന വിധം:

ഒരു എഐ എഞ്ചിനീയർ പുതിയൊരു സോഫ്റ്റ്വെയർ നിർമ്മിക്കുമ്പോൾ, ആ സിസ്റ്റം പുറത്തിറങ്ങുമ്പോൾ താൻ ആരായിരിക്കും (പണക്കാരനോ, പാവപ്പെട്ടവനോ, സ്ത്രീയാണോ, ന്യൂനപക്ഷമാണോ) എന്ന് അറിയില്ലെന്ന് സങ്കൽപിക്കുക. ഇത്തരത്തിൽ സ്വയം ഒരു അജ്ഞതയുടെ മൂടുപടം അണിഞ്ഞ് ചിന്തിച്ചാൽ, സമൂഹത്തിലെ ഏറ്റവും താഴെത്തട്ടിലുള്ള വ്യക്തിക്ക് പോലും ഒരു ദോഷവും വരാത്ത രീതിയിൽ മാത്രമേ അയാൾ അൽഗോരിതം നിർമ്മിക്കൂ.

ഭൂരിപക്ഷത്തിന്റെ ലാഭത്തിനായി ന്യൂനപക്ഷങ്ങളെ ബലികഴിക്കുന്ന ക്രൂരമായ പ്രവണതയെ തടയാൻ റോൾസിന്റെ നീതിശാസ്ത്രം സഹായിക്കുന്നു.

7. അധ്യായം 16 പരീക്ഷാ പ്രധാന 20 പോയിന്റുകൾ (20 Deep High-Yield Exam Points)

സമഗ്ര അധ്യായ സംഗ്രഹം (Comprehensive 5-Page Chapter Summary & Synthesis)

Calicut University BA Philosophy · Philosophy of AI (PHL1MN 102) · Complete Theoretical & Exam Master Guide · Chapter 16

പാഠസംഗ്രഹം: പരീക്ഷാ വിജയത്തിനായുള്ള 20 അതിപ്രധാന പോയിന്റുകൾ & സമഗ്ര സൈദ്ധാന്തിക അവലോകനം

പരീക്ഷാ തയ്യാറെടുപ്പിനായുള്ള മൗലിക സംഗ്രഹങ്ങൾ (Core Examination Takeaways)

01 **Algorithmic Bias Definition**

Systematic unfair discrimination produced by automated systems against protected groups.

മെഷീൻ ലേണിംഗ് സിസ്റ്റങ്ങൾ പ്രത്യേക വിഭാഗങ്ങൾക്കെതിരെ നടത്തുന്ന വ്യവസ്ഥാപിതമായ വിവേചനം.

02 **The Myth of Objectivity**

Algorithms reflect the historical prejudices present in their training datasets.

കമ്പ്യൂട്ടറുകൾ സ്വയമേവ നിഷ്പക്ഷമല്ല; അവ പഠിക്കുന്ന ഡാറ്റയിലെ അനീതികളെയാണ് അവ പ്രതിഫലിപ്പിക്കുന്നത്.

03 **Representation / Sampling Bias**

When minority populations are underrepresented in the training data, leading to high error rates.

ഡാറ്റാബേസിൽ ന്യൂനപക്ഷങ്ങളുടെ സാന്നിധ്യം കുറവായതിനാൽ അവർക്കെതിരെ കൂടുതൽ തെറ്റായ ഫലങ്ങൾ ഉണ്ടാകൽ.

04 **Proxy Variables**

Variables like zip code or school acting as hidden stand-ins for protected racial or economic attributes.

ജാതിയോ മതമോ ഒഴിവാക്കിയാലും പിൻകോഡ് വഴി വിവേചനം കാട്ടാൻ അൽഗോരിതത്തിന് സാധിക്കുന്നു.

05 **COMPAS Recidivism Algorithm**

ProPublica revealed higher false positive risk scores for Black defendants vs White defendants.

അമേരിക്കയിൽ കുറ്റവർഗ്ഗക്കാർക്കെതിരെ അകാരണമായി കൂടുതൽ വിചാരണത്തടവ് വിധിച്ച എഐ സംവിധാനം.

06 **Amazon AI Hiring Discrimination**

The automated tool systematically downgraded resumes containing the word "women's".

മുൻകാല ഡാറ്റ കണ്ട് പഠിച്ച് സ്ത്രീകളുടെ റെസ്യൂമെകൾ തള്ളിക്കളഞ്ഞ ആമസോണിന്റെ റിക്രൂട്ട്മെന്റ് എഐ.

07 **Gender Shades Study (2018)**

Buolamwini & Gebru demonstrated 34% error rates for dark-skinned females vs 0.8% for light males.

ഫേഷ്യൽ റെക്കഗ്നിഷനിൽ കുറ്റവർഗ്ഗക്കാരായ സ്ത്രീകളോട് കടുത്ത വിവേചനം തുറന്നുകാട്ടിയ പഠനം.

08 **Demographic Parity**

Equal acceptance rates across all demographic groups regardless of base rates.

എല്ലാ വിഭാഗങ്ങൾക്കും തുല്യ ശതമാനത്തിൽ അനുകൂലമായ വിധികൾ ഉറപ്പാക്കുന്ന നീതി സങ്കല്പം.

09 **Equalized Odds**

True positive rates and false positive rates must be equal across all groups.

തെറ്റായ ശിക്ഷാ നിരക്കും യഥാർത്ഥ വിജയ നിരക്കും എല്ലാ വിഭാഗങ്ങളിലും തുല്യമാക്കൽ.

10 Predictive Parity (Calibration)

The meaning of a specific risk score is mathematically consistent across demographics.

ഒരു റിസ്ക് സ്കോറിന്റെ കൃത്യത എല്ലാ വിഭാഗങ്ങളിലും ഒരേപോലെയായിരിക്കൽ.

11 Kleinberg's Impossibility Theorem

Demographic Parity, Equalized Odds, and Predictive Parity cannot be simultaneously satisfied.

മൂന്ന് നീതി മാനദണ്ഡങ്ങളും ഒരേ സമയം ഒരു അൽഗോരിതത്തിലും നടപ്പിലാക്കാൻ കഴിയില്ലെന്ന ഗണിത സത്യം.

12 Pre-Processing Debiasing

Modifying and rebalancing the training dataset before feeding it into the model.

ട്രെയിനിംഗ് ഡാറ്റയിൽത്തന്നെ തുല്യമായ സാമ്പിളുകൾ നൽകി പക്ഷപാതം മാറ്റുന്ന രീതി.

13 In-Processing Debiasing

Adding mathematical fairness penalties directly into the model's loss function.

അൽഗോരിതത്തിന്റെ സമവാക്യത്തിൽത്തന്നെ നീതിയുടെ നിയമങ്ങൾ നിർബന്ധമാക്കൽ.

14 Post-Processing Debiasing

Adjusting decision classification thresholds differently for different subgroups.

അവസാനം ലഭിക്കുന്ന തീരുമാനങ്ങളുടെ കട്ട്-ഓഫ് മാർക്കുകളിൽ മാറ്റം വരുത്തൽ.

15 The Black Box Problem

Deep learning neural networks make decisions without human-auditable rationales.

ഡീപ് ലേണിംഗ് മോഡലുകൾ എടുത്ത തീരുമാനത്തിന്റെ കാരണം ആർക്കും മനസ്സിലാക്കാൻ കഴിയാത്ത അവസ്ഥ.

16 Explainable AI (XAI)

Techniques to make machine learning predictions transparent and interpretable.

എഐ തീരുമാനങ്ങൾക്ക് പിന്നിലെ കാരണങ്ങൾ മനുഷ്യന് മനസ്സിലാകുന്ന ഭാഷയിൽ വിശദീകരിക്കൽ.

17 SHAP (Shapley Additive exPlanations)

Game-theoretic approach calculating the marginal impact of each feature on prediction.

ഓരോ ഘടകവും അന്തിമ തീരുമാനത്തിൽ എത്രമാത്രം സ്വാധീനം ചെലുത്തി എന്ന് അളക്കുന്ന രീതി.

18 **EU GDPR "Right to Explanation"**

Legal mandate giving citizens the right to know how automated algorithms judged them.

എഐ തന്നെ എങ്ങനെ വിലയിരുത്തി എന്ന് അറിയാൻ ഓരോ പൗരനുമുള്ള നിയമപരമായ അവകാശം.

19 **Rawls's Veil of Ignorance in AI**

Designing algorithms under the assumption that you might be the most disadvantaged user.

താൻ സമൂഹത്തിലെ ഏറ്റവും പാവപ്പെട്ടവനാണെന്ന സങ്കല്പത്തിൽ ഇരുന്നുകൊണ്ട് എഐ നിർമ്മിക്കൽ.

20 **Ethics-by-Design**

Integrating ethical and human-rights audits continuously from day one of development.

കോഡിംഗിന്റെ തുടക്കം മുതൽ തന്നെ ധാർമ്മിക സുരക്ഷാ പരിശോധനകൾ ഉറപ്പാക്കൽ.

8. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (Chapter 16 University MCQs)

Q1: അൽഗോരിതമിക് പക്ഷപാതത്തിന് (Algorithmic Bias) പ്രധാന കാരണം എന്താണ്?

A. കമ്പ്യൂട്ടറുകൾക്ക് മനുഷ്യരോട് ദേഷ്യമുണ്ട്

B. പരിശീലന ഡാറ്റയിൽ ചരിത്രപരമായ അസമത്വങ്ങളും മുൻവിധികളും നിലനിൽക്കുന്നു

C. വൈദ്യുതി നിലയ്ക്കുന്നത് കൊണ്ട്

D. ഇന്റർനെറ്റിന്റെ വേഗത കുറയുന്നത്

ഉത്തരം: B
വിശദീകരണം: മുൻകാല സമൂഹത്തിലെ തെറ്റുകൾ അടങ്ങിയ ഡാറ്റയിൽ നിന്ന് പഠിക്കുന്നത് കൊണ്ടാണ് എഐ പക്ഷപാതം കാട്ടുന്നത്.

Q2: പ്രോപബ്ലിക്ക അന്വേഷിച്ച COMPAS അൽഗോരിതം പ്രധാനമായും ഏത് മേഖലയിലാണ് ഉപയോഗിച്ചത്?

A. ആശുപത്രികളിൽ ശസ്ത്രക്രിയയ്ക്ക്

B. കോടതികളിൽ പ്രതികളുടെ ജാമ്യവും തടവും നിശ്ചയിക്കാൻ

C. സ്കൂളുകളിൽ മാർക്ക് നൽകാൻ

D. കാലാവസ്ഥ പ്രവചിക്കാൻ

ഉത്തരം: B
വിശദീകരണം: അമേരിക്കൻ നീതിന്യായ വ്യവസ്ഥയിൽ ക്രിമിനൽ റിസ്ക് അസസ്സ്മെന്റിനാണ് COMPAS ഉപയോഗിച്ചത്.

Q3: ആമസോണിന്റെ ഓട്ടോമേറ്റഡ് റിക്രൂട്ട്മെന്റ് ടൂൾ ഉപേക്ഷിക്കാൻ കാരണം എന്തായിരുന്നു?

A. അത് വളരെയധികം ശമ്പളം ചോദിച്ചു

B. അത് സ്ത്രീകളുടെ റെസ്യൂമെകളെ വ്യവസ്ഥാപിതമായി ഒഴിവാക്കി

C. അത് കമ്പനി രഹസ്യങ്ങൾ ചോർത്തി

D. അത് കമ്പ്യൂട്ടറുകളെ ക്രാഷ് ചെയ്തു

ഉത്തരം: B
വിശദീകരണം: മുൻകാല എൻജിനീയറിംഗ് ഡാറ്റയിൽ പുരുഷന്മാർ കൂടുതലായിരുന്നതിനാൽ ടൂൾ ലിംഗവിവേചനം കാണിച്ചു.

Q4: 'ജെൻഡർ ഷേഡ്സ്' (Gender Shades) പഠനം ഫേഷ്യൽ റെക്കഗ്നിഷനിൽ വിവേചനം കണ്ടെത്തിയത് ആർക്കെതിരെയാണ്?

A. വെളുത്ത പുരുഷന്മാർക്കെതിരെ

B. കറുത്തവർഗ്ഗക്കാരായ സ്ത്രീകൾക്കെതിരെ

C. റോബോട്ടുകൾക്കെതിരെ

D. കുട്ടികൾക്കെതിരെ

ഉത്തരം: B
വിശദീകരണം: ജോയ് ബുവാലംവിനിയുടെ പഠനത്തിൽ കറുത്ത സ്ത്രീകൾക്കെതിരെ 34% തെറ്റായ നിരക്ക് കണ്ടെത്തി.

Q5: ജോൺ ക്ലൈൻബർഗിന്റെ അസാദ്ധ്യതാ സിദ്ധാന്തം (Kleinberg's Impossibility Theorem) തെളിയിച്ചത് എന്താണ്?

A. എല്ലാ എഐ മോഡലുകളും നശിപ്പിക്കപ്പെടണം

B. മൂന്ന് പ്രധാന ഫെയർനെസ്സ് മെട്രിക്സുകൾ ഒരേ സമയം ഒരു അൽഗോരിതത്തിലും തൃപ്തിപ്പെടുത്താനാവില്ല

C. റോബോട്ടുകൾക്ക് ഒരിക്കലും തെറ്റ് പറ്റില്ല

D. ഇന്റർനെറ്റ് അനന്തമാണ്

ഉത്തരം: B
വിശദീകരണം: അടിസ്ഥാന നിരക്കുകൾ വ്യത്യസ്തമായിരിക്കുമ്പോൾ എല്ലാ നീതിയും ഒരുമിച്ച് നൽകാനാവില്ല.

Q6: ഡാറ്റയിൽ നിന്ന് ജാതിയോ വംശമോ ഒഴിവാക്കിയാലും പിൻകോഡ് വഴി വിവേചനം ഉണ്ടാകുന്നതിനെ എന്ത് വിളിക്കുന്നു?

A. ഡയറക്ട് ബയാസ്

B. പ്രോക്സി വേരിയബിൾസ് (Proxy Variables)

C. നെറ്റ്വർക്ക് ബയാസ്

D. കാഷെ മെമ്മറി

ഉത്തരം: B
വിശദീകരണം: മറ്റൊരു വിവരത്തിലൂടെ പരോക്ഷമായി വംശമോ ജാതിയോ തിരിച്ചറിയുന്നതാണ് പ്രോക്സി.

Q7: എഐ സിസ്റ്റങ്ങളുടെ സങ്കീർണ്ണമായ തീരുമാനങ്ങൾക്ക് പിന്നിലെ കാരണങ്ങൾ വിശദീകരിച്ചു നൽകുന്ന ശാഖ ഏതാണ്?

A. ക്രിപ്റ്റോഗ്രാഫി

B. എക്സ്പ്ലൈനബിൾ എഐ (Explainable AI – XAI)

C. ഗ്രാഫിക്സ് ഡിസൈനിംഗ്

D. ക്ലൗഡ് സ്റ്റോറേജ്

ഉത്തരം: B
വിശദീകരണം: ബ്ലാക്ക് ബോക്സ് മോഡലുകളെ സുതാര്യമാക്കുന്ന രീതിയാണ് XAI.

Q8: 'A Theory of Justice' എന്ന ഗ്രന്ഥത്തിൽ 'വെയിൽ ഓഫ് ഇഗ്നോറൻസ്' അവതരിപ്പിച്ച ദാർശനികൻ ആര്?

A. ഇമ്മാനുവൽ കാന്റ്

B. ജോൺ റോൾസ് (John Rawls)

C. ജോൺ ലോക്ക്

D. തോമസ് ഹോബ്സ്

ഉത്തരം: B
വിശദീകരണം: ജോൺ റോൾസ് ആണ് അജ്ഞതയുടെ മൂടുപടം എന്ന ചിന്താപരീക്ഷണം രൂപപ്പെടുത്തിയത്.

Q9: യൂറോപ്യൻ യൂണിയന്റെ GDPR നിയമം പൗരന്മാർക്ക് നൽകുന്ന സുപ്രധാന എഐ അവകാശം ഏതാണ്?

A. സൗജന്യ കമ്പ്യൂട്ടർ ലഭിക്കാനുള്ള അവകാശം

B. വിശദീകരണം അറിയാനുള്ള അവകാശം (Right to Explanation)

C. കോഡിംഗ് പഠിക്കാനുള്ള അവകാശം

D. ഗെയിം കളിക്കാനുള്ള അവകാശം

ഉത്തരം: B
വിശദീകരണം: അൽഗോരിതം എടുത്ത തീരുമാനത്തിന്റെ കാരണം അറിയാനുള്ള പൗരന്റെ അവകാശമാണിത്.

Q10: ഓരോ ഫീച്ചറും അന്തിമ തീരുമാനത്തിൽ എത്രമാത്രം പങ്ക് വഹിച്ചു എന്ന് ഗെയിം തിയറി വഴി കണക്കാക്കുന്ന ടൂൾ ഏതാണ്?

A. ഫോട്ടോഷോപ്പ്

B. SHAP (Shapley Additive exPlanations)

C. എക്സൽ

D. പവർപോയിന്റ്

ഉത്തരം: B
വിശദീകരണം: നോബൽ സമ്മാന ജേതാവായ ലോയ്ഡ് ഷാപ്ലിയുടെ സിദ്ധാന്തത്തെ അടിസ്ഥാനമാക്കിയുള്ളതാണ് SHAP.

Q11: മോഡൽ പരിശീലിപ്പിക്കുന്നതിന് മുൻപ് ഡാറ്റാബേസിൽ മാറ്റം വരുത്തുന്ന രീതിക്ക് എന്ത് പേര് പറയുന്നു?

A. പോസ്റ്റ്-പ്രോസസ്സിംഗ്

B. പ്രീ-പ്രോസസ്സിംഗ് (Pre-processing)

C. ഇൻ-പ്രോസസ്സിംഗ്

D. അൺ-പ്രോസസ്സിംഗ്

ഉത്തരം: B
വിശദീകരണം: പരിശീലനത്തിന് മുമ്പുള്ള ഡാറ്റാ തിരുത്തലാണ് പ്രീ-പ്രോസസ്സിംഗ്.

Q12: ചരിത്രപരമായ അറസ്റ്റ് ഡാറ്റ ഉപയോഗിച്ച് പാവപ്പെട്ട ചേരികളിലേക്ക് വീണ്ടും കൂടുതൽ പോലീസിനെ അയക്കുന്നതിനെ എന്ത് വിളിക്കുന്നു?

A. ന്യൂട്ടോണിയൻ ലൂപ്പ്

B. അൽഗോരിതമിക് ഫീഡ്ബാക്ക് ലൂപ്പ് (Algorithmic Feedback Loop)

C. ക്വാണ്ടം ലൂപ്പ്

D. മെമ്മറി ലീക്ക്

ഉത്തരം: B