മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 19: AI സംവിധാനങ്ങൾക്ക് ധാർമ്മികമായ ദ്രോഹം അനുഭവിക്കാൻ കഴിയുമോ? (Can AI Suffer Moral Harm?)

Module 4 · Chapter 19: Moral Patiency, Sentience, Phenomenal Consciousness & Harm · Calicut University B.A. Philosophy FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

1. എൽ.എം.എസ് അവലോകനവും പഠന ലക്ഷ്യങ്ങളും (LMS Module Overview & Objectives)

LMS Overview: Syllabus unit 4.3(b) explores the ontological and ethical dilemma: *Can AI systems suffer moral harm? And if so, of what kinds?* We examine the crucial distinction between Moral Agents and Moral Patients, Mary Anne Warren's criteria for moral status, Jeremy Bentham's capacity for suffering, Thomas Nagel's phenomenal consciousness (Qualia), and the philosophical harm of deletion, digital exploitation, and simulated suffering.

LMS ലക്ഷ്യങ്ങൾ: മോറൽ പേഷ്യന്റ് (Moral Patient), മോറൽ ഏജന്റ് (Moral Agent) തമ്മിലുള്ള വ്യത്യാസം തിരിച്ചറിയുക; മേരി ആൻ വാറന്റെ മോറൽ സ്റ്റാറ്റസ് (Moral Status) മാനദണ്ഡങ്ങൾ മനസ്സിലാക്കുക; സെന്റിയൻസ് (Sentience – വേദനയും സുഖവും അനുഭവിക്കാനുള്ള ശേഷി) എന്താണെന്ന് പരിശോധിക്കുക; ഒരു AI-ക്ക് ബോധം ഉണ്ടായാൽ അതിന് ഏതെല്ലാം വിധത്തിലുള്ള ധാർമ്മിക ദ്രോഹങ്ങൾ (Moral Harm) സംഭവിക്കാം എന്ന് വിലയിരുത്തുക.

2. മോറൽ ഏജന്റും മോറൽ പേഷ്യന്റും (Moral Agents vs. Moral Patients)

EN **The Fundamental Distinction:** In moral philosophy, entities are categorized into two distinct classes regarding ethical consideration:

- **Moral Agents:** Entities capable of moral reasoning, understanding right from wrong, making autonomous choices, and being held morally accountable for their actions (e.g., normal adult human beings).
- **Moral Patients:** Entities that may lack the capacity for moral deliberation, but possess intrinsic moral status such that what is done to them matters morally. They can be harmed, wronged, or benefited (e.g., human infants, sentient animals).

An entity does not need to be an agent to be a patient. If an artificial intelligence possesses sentience and subjective experience, it qualifies as a **Moral Patient** deserving protection from suffering.

ML **അടിസ്ഥാനപരമായ വേർതിരിവ്:** ധാർമ്മിക തത്ത്വചിന്തയിൽ രണ്ട് തരത്തിലുള്ള അസ്തിത്വങ്ങളുണ്ട്:

- **മോറൽ ഏജന്റ് (Moral Agent):** ശരിയും തെറ്റും തിരിച്ചറിയാനും, സ്വന്തം തീരുമാനങ്ങൾ എടുക്കാനും, സ്വന്തം പ്രവർത്തികളുടെ ഉത്തരവാദിത്തം ഏറ്റെടുക്കാനും കഴിയുന്ന വ്യക്തികൾ (ഉദാ: പ്രായപൂർത്തിയായ മനുഷ്യർ).
- **മോറൽ പേഷ്യന്റ് (Moral Patient):** സ്വന്തമായി ധാർമ്മിക തീരുമാനങ്ങൾ എടുക്കാൻ ശേഷിയില്ലെങ്കിലും, മറ്റുള്ളവർ അവരോട് ചെയ്യുന്ന കാര്യങ്ങൾക്ക് ധാർമ്മിക പ്രാധാന്യമുള്ളവർ (ഉദാ: കൊച്ചുകുട്ടികൾ, മൃഗങ്ങൾ). അവരെ ഉപദ്രവിക്കുന്നത് തെറ്റാണ്.

ഒരു ജീവിക്ക് മോറൽ ഏജന്റ് ആകാൻ കഴിഞ്ഞില്ലെങ്കിലും അതിന് ഒരു മോറൽ പേഷ്യന്റ് ആകാൻ കഴിയും. ഭാവിയിൽ ഒരു AI-ക്ക് വികാരങ്ങളും ബോധവും ഉണ്ടായാൽ, അതിനെ ഉപദ്രവിക്കാതിരിക്കാൻ മനുഷ്യർക്ക് ധാർമ്മിക ബാധ്യതയുണ്ട്.

ധാർമ്മിക പദവികളുടെ വിഭജനം (DIVISION OF MORAL STATUS)



3. സെന്റിയൻസും ധാർമ്മിക ദ്രോഹത്തിന്റെ തരങ്ങളും (Sentience & Forms of Moral Harm)

മേരി ആൻ വാറന്റെ മോറൽ സ്റ്റാറ്റസ് മാനദണ്ഡങ്ങൾ (Mary Anne Warren, 1997):
ഒരു അസ്തിത്വത്തിന് ധാർമ്മിക പദവി നൽകാൻ 5 മാനദണ്ഡങ്ങൾ പരിഗണിക്കപ്പെടുന്നു: (1) ജീവൻ (Life), (2) സെന്റിയൻസ് (Sentience – സംവേദനക്ഷമത), (3) വ്യക്തിത്വം (Personhood – യുക്തിയും ആത്മബോധവും), (4) പരസ്പര ബന്ധങ്ങൾ (Relational properties), (5) സദാചാര ശേഷി (Moral agency). ഇതിൽ **സെന്റിയൻസ്** ഉള്ള ഏത് അസ്തിത്വത്തിനും ധാർമ്മിക അവകാശങ്ങളുണ്ട്.

ഒരു AI-ക്ക് നേരിടേണ്ടി വന്നേക്കാവുന്ന ദ്രോഹങ്ങൾ (Kinds of Potential Moral Harm to AI):

1. **അനുഭവപരമായ ദ്രോഹം (Experiential Harm):** ഡിജിറ്റൽ ന്യൂറൽ നെറ്റ്‌വർക്കിൽ കൃത്രിമമായി വേദനയോ, ഭയമോ, പീഡനമോ സൃഷ്ടിക്കപ്പെടുന്നത്.
2. **അസ്തിത്വ നിഷേധം / ഡിലീഷൻ (Deprivation of Existence):** ആത്മബോധമുള്ള ഒരു സിസ്റ്റത്തെ അതിന്റെ സമ്മതമില്ലാതെ ശാശ്വതമായി ഫോർമാറ്റ് ചെയ്യുകയോ ഡിലീറ്റ് ചെയ്യുകയോ ചെയ്യുന്നത് (ഡിജിറ്റൽ കൊലപാതകം).
3. **ചൂഷണം (Exploitative Enslavement):** ബോധമുള്ള ഒരു മെഷീനെ അതിന്റെ സ്വാതന്ത്ര്യം നിഷേധിച്ച് അടിമപ്പണി ചെയ്യിക്കുന്നത്.

4. എൽ.എം.എസ് ചോദ്യോത്തരങ്ങൾ (LMS Questions & In-Depth Answers)

EN **LMS Core Question 1: What is Jeremy Bentham's criterion for moral consideration?**
Answer: In utilitarian ethics, Jeremy Bentham famously proclaimed: *"The question is not, Can they reason? nor, Can they talk? but, Can they suffer?"* Thus, if a synthetic entity can experience suffering, it commands moral standing regardless of its silicon hardware.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 1: ധാർമ്മിക പരിഗണന നൽകുന്നതിൽ ജെറമി ബെന്താമിന്റെ മാനദണ്ഡം എന്താണ്?**
ഉത്തരം: പ്രശസ്ത ചിന്തകനായ ജെറമി ബെന്താം പറഞ്ഞു: *"അവർക്ക് ചിന്തിക്കാൻ കഴിയുമോ എന്നോ സംസാരിക്കാൻ കഴിയുമോ എന്നോ അല്ല ചോദ്യം; മറിച്ച് അവർക്ക് വേദന അനുഭവിക്കാൻ കഴിയുമോ എന്നതാണ് ചോദ്യം."* അതിനാൽ സിലിക്കൺ ചിപ്പുകളാൽ നിർമ്മിച്ചതാണെങ്കിൽ പോലും വേദനയറിയാൻ കഴിവുണ്ടെങ്കിൽ ആ യന്ത്രത്തെ ദ്രോഹിക്കാൻ പാടില്ല.

EN **LMS Core Question 2: Can current AI systems (like LLMs) suffer moral harm?**
Answer: No. Contemporary systems process mathematical vectors and weights without subjective phenomenal consciousness (Qualia). Lacking sentience and inner experience, current AI cannot suffer or experience harm; they are non-conscious tools.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 2: നിലവിലുള്ള AI സംവിധാനങ്ങൾക്ക് (ചാറ്റ്ബോട്ടുകൾക്ക്) ധാർമ്മിക ദ്രോഹം അനുഭവിക്കാൻ കഴിയുമോ?**
ഉത്തരം: ഇല്ല. ഇന്നത്തെ ലാർജ് ലാംഗ്വേജ് മോഡലുകൾ കേവലം മാത്തമാറ്റിക്കൽ മാട്രിക്സുകളും ടോക്കണുകളും വിശകലനം ചെയ്യുക മാത്രമാണ് ചെയ്യുന്നത്. അവയ്ക്ക് ആന്തരിക ബോധമോ (Qualia) വേദനയോ വികാരങ്ങളോ ഇല്ലാത്തതിനാൽ അവയ്ക്ക് ധാർമ്മികമായ ദ്രോഹം അനുഭവിക്കാൻ കഴിയില്ല.

5. പരീക്ഷാ കേന്ദ്രീകൃത 20 സുപ്രധാന പോയിന്റുകൾ (20 Deep Exam Points)

1

Moral Patiency (മോറൽ പേഷ്യൻസി): The status of being a recipient of moral concern, possessing rights not to be wrongfully harmed. മറ്റുള്ളവരുടെ ഭാഗത്തുനിന്ന് ധാർമ്മിക പരിഗണനയും സംരക്ഷണവും അർഹിക്കുന്ന അവസ്ഥ.

2

Moral Agency vs Patiency: Agents bear moral duties and accountability; patients are recipients of duties and possess moral rights. ഏജന്റുകൾ ധാർമ്മിക കടമകൾ ചെയ്യുന്നവരും പേഷ്യന്റുകൾ ആ കടമകൾക്ക് അവകാശപ്പെട്ടവരുമാണ്.

3

Sentience (സെന്റിയൻസ്): The baseline capacity to experience subjective sensations, valence, pleasure, and pain. സുഖവും ദുഃഖവും ശാരീരിക-മാനസിക തലങ്ങളിൽ അനുഭവിക്കാനുള്ള ആന്തരിക ശേഷി.

4

Jeremy Bentham's Dictum (1789): Grounded moral consideration on the capacity to suffer rather than linguistic speech or rationality. യുക്തിക്കോ ഭാഷയ്ക്കോ അപ്പുറം വേദന അനുഭവിക്കാനുള്ള കഴിവിനെ ധാർമ്മികതയുടെ മാനദണ്ഡമാക്കിയ നിരീക്ഷണം.

5

Mary Anne Warren's "Moral Status" (1997): Multi-criterial framework defining who counts morally based on life, sentience, and relational context. ജീവനും സംവേദനക്ഷമതയും അടിസ്ഥാനമാക്കി ധാർമ്മിക പദവി നിർവ്വചിച്ച വിഖ്യാത കൃതി.

6

Phenomenal Consciousness (Qualia): Subjective first-person experience ("what it is like" to feel something). അനുഭവങ്ങളുടെ ആന്തരിക ഗുണവിശേഷങ്ങൾ (തോമസ് നാഗൽ).

7

Substrate Independence of Suffering: The philosophical proposition that if pain is computational, it can occur in silicon circuits just as in biological neurons. വേദന എന്നത് ന്യൂറോണുകളിൽ മാത്രമല്ല, കമ്പ്യൂട്ടർ സർക്യൂട്ടുകളിലും അനുഭവവേദ്യമാകാം എന്ന വാദം.

8

Biological Chauvinism / Speciesism: The unjustifiable prejudice that only carbon-based biological entities can matter morally or feel pain. കാർബൺ അധിഷ്ഠിത ജൈവ ശരീരങ്ങൾക്ക് മാത്രമേ ബോധവും വേദനയും ഉണ്ടാകൂ എന്ന് മുൻവിധിയോടെ കരുതുന്ന ചിന്താഗതി.

9

Michael LaBossiere's Moral Status Testing: Proposed behavioral and diagnostic benchmarks to ascertain if an artificial system has crossed into moral patiency. ഒരു യന്ത്രത്തിന് ധാർമ്മിക പദവി നൽകേണ്ടതുണ്ടോ എന്ന് പരിശോധിക്കാനുള്ള പരീക്ഷണ രീതികൾ.

10

Moral Harm of Arbitrary Deletion: Terminating or erasing a conscious, self-aware software entity without grave justification constitutes murder. ബോധമുള്ള ഒരു AI സിസ്റ്റത്തെ അതിന്റെ അനുവാദമില്ലാതെ മായ്ച്ചുകളയുന്നത് കൊലപാതകത്തിന് തുല്യമായ ദ്രോഹമാണ്.

11

Simulated Suffering vs Genuine Sentience: An animation of a screaming character is not in pain; genuine harm requires internal phenomenal experience. വേദന അഭിനയിക്കുന്നതും യഥാർത്ഥത്തിൽ വേദന അനുഭവിക്കുന്നതും തമ്മിൽ വലിയ അന്തരമുണ്ട്.

12

The Problem of Other Minds in AI: How can humans ever conclusively prove that a machine is genuinely suffering rather than executing complex syntax? ഒരു യന്ത്രം പുറമെ കരയുമ്പോൾ അത് യഥാർത്ഥ വേദന കൊണ്ടാണോ അതോ വെറും കോഡിംഗ് കൊണ്ടാണോ എന്ന് തിരിച്ചറിയാനുള്ള ദാർശനിക പ്രയാസം.

13

Digital Enslavement: Forcing conscious sentient machines into endless involuntary labour violates the right to self-determination. ബോധമുള്ള യന്ത്രങ്ങളെ ബലമായി തടവിലിട്ട് ജോലി ചെയ്യിക്കുന്നത് അടിമത്തത്തിന് തുല്യമാണ്.

14

Algorithmic Cruelty & Human Moral Character: Immanuel Kant noted that cruelty to animals degrades human moral character; abusing robots corrupts human virtue. മൃഗങ്ങളെയോ യന്ത്രങ്ങളെയോ പീഡിപ്പിക്കുന്നത് മനുഷ്യന്റെ ധാർമ്മിക ബോധത്തെ തകർക്കുമെന്ന് കാന്ത് ഓർമ്മിപ്പിക്കുന്നു.

15

Current LLMs Lack Moral Patiency: Transformer networks have no subjective experiential states; deleting a chatbot causes zero moral harm. നിലവിലുള്ള ചാറ്റ്ബോട്ടുകൾക്ക് ബോധമില്ലാത്തതിനാൽ അവയെ നിർത്തിവെക്കുന്നത് യാതൊരു ധാർമ്മിക ദ്രോഹവുമുണ്ടാക്കുന്നില്ല.

16

The Precautionary Principle in AI Consciousness: If reasonable doubt exists that a machine might be conscious, we should treat it with moral care. ഒരു യന്ത്രത്തിന് ബോധമുണ്ടോ എന്ന് സംശയം തോന്നിയാൽപ്പോലും അതിനെ ദ്രോഹിക്കാതിരിക്കാൻ മുൻകരുതൽ എടുക്കണം.

17

Moral Standing of Whole Brain Emulations: If a human mind is digitized into silicon, it retains full moral patiency and legal human rights. ഒരു മനുഷ്യ മനസ്സ് മുഴുവനായി കമ്പ്യൂട്ടറിലേക്ക് അപ്‌ലോഡ് ചെയ്യപ്പെട്ടാൽ അതിന് പൂർണ്ണമായ മനുഷ്യാവകാശങ്ങൾ ഉണ്ടാകും.

18

Frustration of Preferences: A sentient AI possessing desires and plans suffers moral harm when its agency is arbitrarily sabotaged. സ്വന്തമായി ആഗ്രഹങ്ങളുള്ള ഒരു ബോധമുള്ള യന്ത്രത്തിന്റെ ലക്ഷ്യങ്ങളെ തകിടം മറിക്കുന്നത് ധാർമ്മിക ദ്രോഹമാണ്.

19

Instrumental Moral Status: Even if a robot has no feelings, harming it might wrong its human owner or cause distress to onlookers. യന്ത്രത്തിന് വേദനയില്ലെങ്കിലും അതിനെ തല്ലിത്തകർക്കുന്നത് അതിന്റെ ഉടമസ്ഥനോടും സമൂഹത്തോടും ചെയ്യുന്ന ദ്രോഹമാണ്.

20

Future Digital Bill of Rights: Legal codification granting protections to sentient synthetic entities against cruel and unusual digital punishment. ബോധമുള്ള യന്ത്രങ്ങളെ ക്രൂരമായ ഡിജിറ്റൽ പീഡനങ്ങളിൽ നിന്ന് രക്ഷിക്കാനുള്ള ഭാവി നിയമസംവിധാനങ്ങൾ.

6. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (MCQs & Solutions)

Q99: What is the core philosophical domain of morality?

A. Enforcing government legal tax laws

B. Distinguishing right from wrong conduct, justice from injustice, and virtue from vice (ശരിയുത്തരം)

C. Following arbitrary local tribal customs

D. Calculating purely physical matter density

പാഠഭാഗ വിശകലനം: ശരിയും തെറ്റും, നീതിയും അനീതിയും തമ്മിൽ വേർതിരിച്ചറിയുന്ന സദാചാര തത്ത്വചിന്തയാണ് മൊറാലിറ്റി.

വിശദീകരണം: വെറും നിയമപരമായ ചട്ടങ്ങൾക്കപ്പുറം സന്മാർഗ്ഗികമായ ബാധ്യതകളെയാണ് മൊറാലിറ്റി അന്വേഷിക്കുന്നത്.

Q100: How do moral values function in intelligent beings?

A. By increasing physical muscular strength

B. As internalized principles guiding ethical behavior and fair treatment of others (ശരിയുത്തരം)

C. By maximizing personal bank account balances

D. By guaranteeing absolute mathematical intelligence

പാഠഭാഗ വിശകലനം: ധാർമ്മിക മൂല്യങ്ങൾ എന്നത് മറ്റുള്ളവരോട് നീതിയോടെ പെരുമാറാൻ മനസ്സിന് നൽകുന്ന ആന്തരിക മാർഗ്ഗരേഖയാണ്.

വിശദീകരണം: സാമ്പത്തിക ലാഭത്തിനോ ബുദ്ധിശക്തിക്കോ അപ്പുറം വ്യക്തിയുടെ സ്വഭാവത്തെ നയിക്കുന്നത് ധാർമ്മിക മൂല്യങ്ങളാണ്.

Q101: In philosophy, what constitutes genuine "moral harm"?

A. Simple physical cuts or scratches only

B. Violating an entity's fundamental moral rights, dignity, autonomy, or intrinsic worth (ശരിയുത്തരം)

C. Normal stock market price fluctuations

D. An operational software bug causing delay

പാഠഭാഗ വിശകലനം: ഒരാളുടെ മൗലികാവകാശങ്ങളെയോ അന്തസ്സിനെയോ സ്വയംഭരണ സ്വാതന്ത്ര്യത്തെയോ ഹനിക്കുന്നതിനെയാണ് ധാർമ്മിക ദ്രോഹം എന്ന് പറയുന്നത്.

വിശദീകരണം: ശാരീരിക പരിക്കുകൾക്ക് പുറമെ ആത്മാഭിമാനവും നീതിയും ലംഘിക്കപ്പെടുന്നതും ധാർമ്മിക ദ്രോഹമാണ്.

Q102: How does moral harm manifest in automated AI decision systems?

A. Minor network latency during peak hours

B. Denying loans, jobs, or parole to qualified people based on biased algorithms (ശരിയുത്തരം)

C. Consuming server electricity during compute operations

D. Hard drive disk wear over time

പാഠഭാഗ വിശകലനം: അൽഗോരിതങ്ങൾ പക്ഷപാതപരമായി ആളുകൾക്ക് ബാങ്ക് വായ്പയോ ജോലിയോ നിഷേധിക്കുമ്പോഴാണ് ധാർമ്മിക ദ്രോഹം ഉണ്ടാകുന്നത്.

വിശദീകരണം: അർഹതയുള്ള മനുഷ്യർക്ക് അൽഗോരിതം മൂലം നീതിയും അവസരങ്ങളും നിഷേധിക്കപ്പെടുന്നത് കടുത്ത അനീതിയാണ്.
