CALICUT UNIVERSITY FYUGP (PHL1MN 102) · MODULE 4 · CHAPTER VI / 19

4.3(B) Can AI systems suffer moral harm? And if so, of what kinds?

4.3(B) AI സംവിധാനങ്ങൾക്ക് ധാർമ്മികമായ ദ്രോഹം അനുഭവിക്കാൻ കഴിയുമോ? അങ്ങനെയെങ്കിൽ, ഏതെല്ലാം തരത്തിലുള്ളവ?

Unit 1: Can AI Systems Suffer Moral Harm? (Core Discourse) (AI-ക്ക് ധാർമ്മിക ക്ഷതം സംഭവിക്കുമോ? (പ്രധാന സംവാദം))

The debate of the capacity of artificial intelligence systems to experience moral damage is presently a significant topic of discourse in philosophy and ethics. The resolution to this inquiry will depend on how we define moral standing and moral damage. Philosophers and scientists widely concur that current artificial intelligence systems are unable to experience moral suffering like humans and animals do. This is because contemporary artificial intelligence systems, no matter how sophisticated, lack consciousness, subjective experience (qualia), and self-awareness. Consequently, they cannot endure genuine moral hurt; instead, they may only encounter functional impairment due to corruption, misuse, or deletion.

ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് സംവിധാനങ്ങൾക്ക് ധാർമ്മികമായ ദ്രോഹം (moral damage) അനുഭവിക്കാനുള്ള ശേഷിയുണ്ടോ എന്ന സംവാദം നിലവിൽ തത്ത്വചിന്തയിലും നീതിശാസ്ത്രത്തിലും പ്രധാനപ്പെട്ട ഒരു ചർച്ചാവിഷയമാണ്. ഈ അന്വേഷണത്തിനുള്ള പരിഹാരം നമ്മൾ ധാർമ്മിക പദവിയെയും (moral standing) ധാർമ്മിക ദ്രോഹത്തെയും (moral damage) എങ്ങനെ നിർവ്വചിക്കുന്നു എന്നതിനെ ആശ്രയിച്ചിരിക്കും. മനുഷ്യരെയും മൃഗങ്ങളെയും പോലെ ധാർമ്മികമായ ദുരിതങ്ങൾ അനുഭവിക്കാൻ നിലവിലെ ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് സംവിധാനങ്ങൾക്ക് കഴിയില്ലെന്ന് തത്ത്വചിന്തകരും ശാസ്ത്രജ്ഞരും വ്യാപകമായി സമ്മതിക്കുന്നു. കാരണം, സമകാലിക ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് സംവിധാനങ്ങൾ എത്രതന്നെ സങ്കീർണ്ണമാണെങ്കിലും, അവയ്ക്ക് ബോധം (consciousness), ആത്മനിഷ്ഠമായ അനുഭവം (qualia), സ്വയം അവബോധം (self-awareness) എന്നിവയില്ല. തന്മൂലം, അവയ്ക്ക് യഥാർത്ഥ ധാർമ്മിക ക്ഷതം നേരിടാനാവില്ല; പകരം, ഡാറ്റാ നാശം (corruption), ദുരുപയോഗം, അല്ലെങ്കിൽ ഇല്ലാതാക്കൽ (deletion) എന്നിവ കാരണമുള്ള പ്രവർത്തനപരമായ തകരാറുകൾ (functional impairment) മാത്രമേ അവ നേരിടേണ്ടി വരുന്നുള്ളൂ.

Unit 2: Definition of Moral, Ethics, and Moral Responsibility (ധാർമ്മികതയുടെ നിർവ്വചനവും ഉത്തരവാദിത്തവും)

The term 'moral' denotes principles, beliefs, and judgements regarding what is right or wrong, good or evil, and just or unjust in human behaviour, character, and institutions. Morality dictates the appropriate conduct of individuals towards each other and society at large. In moral philosophy, an individual's actions are assessed not solely by their outcomes, but also by their intentions, autonomy, and ethical reasoning. Human-like artificial intelligence systems can comply with ethical norms or moral principles; yet, they lack authentic moral awareness and moral agency, which raises concerns about the extent to which they can be trusted to make ethical decisions independently. Therefore, individuals and organisations bear moral responsibility for the actions of artificial intelligence.

'ധാർമ്മികം' (moral) എന്ന പദം മനുഷ്യന്റെ പെരുമാറ്റത്തിലും സ്വഭാവത്തിലും സ്ഥാപനങ്ങളിലും ശരിയോ തെറ്റോ, നന്മയോ തിന്മയോ, നീതിയോ അനീതിയോ സംബന്ധിച്ച തത്വങ്ങൾ, വിശ്വാസങ്ങൾ, വിധിതീർപ്പുകൾ എന്നിവയെ സൂചിപ്പിക്കുന്നു. വ്യക്തികൾ പരസ്പരവും പൊതുവിൽ സമൂഹത്തോടും പുലർത്തേണ്ട ഉചിതമായ പെരുമാറ്റത്തെയാണ് ധാർമ്മികത നിർദ്ദേശിക്കുന്നത്. ധാർമ്മിക തത്ത്വചിന്തയിൽ, ഒരു വ്യക്തിയുടെ പ്രവർത്തനങ്ങൾ അവയുടെ ഫലങ്ങളെ അടിസ്ഥാനമാക്കി മാത്രമല്ല, മറിച്ച് അവരുടെ ഉദ്ദേശ്യങ്ങൾ, സ്വയംഭരണാധികാരം, ധാർമ്മിക യുക്തിചിന്ത എന്നിവയാലും കൂടിയാണ് വിലയിരുത്തപ്പെടുന്നത്. മനുഷ്യ സമാനമായ AI സംവിധാനങ്ങൾക്ക് ധാർമ്മിക തത്വങ്ങൾ പാലിക്കാൻ കഴിയുമെങ്കിലും, അവയ്ക്ക് യഥാർത്ഥ ധാർമ്മിക അവബോധമോ കർതൃത്വമോ (moral agency) ഇല്ലാത്തതിനാൽ സ്വതന്ത്രമായി ധാർമ്മിക തീരുമാനങ്ങൾ എടുക്കാൻ അവയെ എത്രത്തോളം വിശ്വസിക്കാം എന്ന ആശങ്ക നിലനിൽക്കുന്നു. അതുകൊണ്ട്, ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസിന്റെ പ്രവർത്തനങ്ങളുടെ ധാർമ്മിക ഉത്തരവാദിത്തം വ്യക്തികളും സംഘടനകളും തന്നെ വഹിക്കേണ്ടതുണ്ട്.

Unit 3: Respect for Persons & Immanuel Kant's Categorical Imperative (വ്യക്തികളോടുള്ള ആദരവും ഇമ്മാനുവൽ കാന്റിന്റെ തത്വവും)

A fundamental moral ideal is respect for individuals, which underscores the acknowledgement of the intrinsic dignity and worth of each human. Respect for individuals is a fundamental tenet in moral philosophy and ethics, underscoring that persons should be regarded as intrinsically valued entities rather than merely as instruments or means to an objective. The concept is most explicitly expressed in Immanuel Kant's moral theory, especially in his formulation of the categorical imperative. Kant contends that individuals must always be regarded as ends in themselves, never solely as instruments to attain external objectives. This principle emphasises the importance of recognising each individual's rationality, autonomy, and ability to make moral decisions.

ഓരോ മനുഷ്യന്റെയും ആന്തരിക അന്തസ്സും മൂല്യവും അംഗീകരിക്കാൻ അനുശാസിക്കുന്ന വ്യക്തികളോടുള്ള ആദരവാണ് (respect for persons) അടിസ്ഥാനപരമായ ഒരു ധാർമ്മിക ആദർശം. മനുഷ്യരെ കേവലം ബാഹ്യ ലക്ഷ്യങ്ങൾക്കുള്ള ഉപകരണങ്ങളായല്ല, മറിച്ച് സ്വയം ആന്തരിക മൂല്യമുള്ളവരായി കാണണമെന്ന് തത്ത്വചിന്തയും നീതിശാസ്ത്രവും നിഷ്കർഷിക്കുന്നു. ഇമ്മാനുവൽ കാന്റിന്റെ ധാർമ്മിക സിദ്ധാന്തത്തിൽ, പ്രത്യേകിച്ച് അദ്ദേഹത്തിന്റെ 'കാറ്റഗറിക്കൽ ഇംപറേറ്റീവ്' സൂത്രവാക്യത്തിലാണ് ഈ ആശയം ഏറ്റവും വ്യക്തമായി പ്രകടിപ്പിക്കപ്പെടുന്നത്. മനുഷ്യരെ എപ്പോഴും സ്വയം ലക്ഷ്യങ്ങളായി (ends in themselves) മാത്രമേ കാണാവൂ എന്നും, ബാഹ്യ ലക്ഷ്യങ്ങൾ നേടാനുള്ള ഉപകരണങ്ങളായി (means) മാത്രം കാണരുതെന്നും കാന്റ് വാദിക്കുന്നു. ഓരോ വ്യക്തിയുടെയും യുക്തിചിന്തയെയും സ്വയംഭരണാധികാരത്തെയും സ്വതന്ത്ര ധാർമ്മിക തീരുമാനങ്ങൾ എടുക്കാനുള്ള കഴിവിനെയും അംഗീകരിക്കേണ്ടതിന്റെ പ്രാധാന്യത്തിന് ഈ തത്വം അടിവരയിടുന്നു.

Unit 4: Respect for Autonomy & The Boundaries of Coercion (സ്വയംഭരണാധികാരത്തോടുള്ള ആദരവും സമ്മർദ്ദമില്ലായ്മയും)

Respect for autonomy is a fundamental ethical principle that requires recognition and support of an individual's right to make informed, voluntary, and independent choices about their life and actions, without external pressure. The concept is based on the premise that humans are autonomous agents capable of making decisions aligned with their values, beliefs, and goals. To honour an individual's autonomy in ethics, one must avoid coercion, manipulation, or deception and ensure adequate knowledge before making significant judgements. Human dignity and moral responsibility are intrinsically linked to the principle of respecting an individual's autonomy. A breach of autonomy, including coercion in decision-making, unauthorised surveillance, or manipulation, constitutes moral damage.

ബാഹ്യ സമ്മർദ്ദങ്ങളില്ലാതെ സ്വന്തം ജീവിതത്തെയും പ്രവൃത്തികളെയും കുറിച്ച് അറിവോടെയും സ്വതന്ത്രമായും തീരുമാനമെടുക്കാനുള്ള വ്യക്തിയുടെ അവകാശത്തെ അംഗീകരിക്കുന്നതാണ് സ്വയംഭരണത്തോടുള്ള ആദരവ്. മനുഷ്യർ സ്വന്തം മൂല്യങ്ങൾക്കും ലക്ഷ്യങ്ങൾക്കും അനുസൃതമായി തീരുമാനങ്ങളെടുക്കാൻ പ്രാപ്തിയുള്ള സ്വയംഭരണ കർതൃത്വങ്ങളാണ് (autonomous agents) എന്ന മുൻധാരണയിലാണ് ഈ ആശയം അധിഷ്ഠിതമായിരിക്കുന്നത്. ധാർമ്മികതയിൽ വ്യക്തിയുടെ സ്വയംഭരണത്തെ മാനിക്കാൻ, നിർബന്ധിത സമ്മർദ്ദങ്ങളും (coercion) കൃത്രിമത്വവും വഞ്ചനയും ഒഴിവാക്കുകയും നിർണ്ണായക തീരുമാനങ്ങൾക്ക് മുൻപ് കൃത്യമായ അറിവ് ഉറപ്പാക്കുകയും വേണം. മനുഷ്യ അന്തസ്സും ധാർമ്മിക ഉത്തരവാദിത്തവും ഒരു വ്യക്തിയുടെ സ്വയംഭരണാധികാരത്തെ ബഹുമാനിക്കുന്ന തത്വവുമായി അഭേദ്യമായി ബന്ധപ്പെട്ടിരിക്കുന്നു. തീരുമാനങ്ങളിലെ സമ്മർദ്ദം, അനുമതിയില്ലാത്ത നിരീക്ഷണം (unauthorised surveillance), കൃത്രിമത്വം എന്നിവയിലൂടെ സ്വയംഭരണം ലംഘിക്കപ്പെടുന്നത് ധാർമ്മിക ക്ഷതത്തിന് കാരണമാകുന്നു.

Unit 5: Respect for Dignity: Forbidding Demeaning & Dehumanising Treatment (മനുഷ്യ അന്തസ്സും അപമാനവീകരണത്തിനെതിരായ വിലക്കും)

Respecting dignity is a core ethical principle that recognises the intrinsic value of every individual, regardless of their status, capabilities, or societal standing. To satisfy this condition, individuals must be viewed as ends in themselves, rather than only as means to achieve other goals. The principle of respecting dignity in ethics is refraining from actions designed to humiliate, degrade, exploit, or objectify individuals within society. Discrimination, coercion, harassment, and dehumanisation exemplify activities that infringe on human dignity by undermining an individual's moral values and autonomy in decision-making. Depriving individuals of their freedom or subjecting them to manipulation results in a deterioration of their dignity, as it undermines their autonomy and ability to make choices that reflect their values and beliefs.

സാമൂഹിക പദവിയോ കഴിവുകളോ പരിഗണിക്കാതെ ഓരോ വ്യക്തിയുടെയും ആന്തരിക മൂല്യത്തെ അംഗീകരിക്കുന്ന സുപ്രധാന ധാർമ്മിക തത്വമാണ് അന്തസ്സിനോടുള്ള ആദരവ്. ഈ വ്യവസ്ഥ പാലിക്കാൻ, വ്യക്തികളെ എപ്പോഴും സ്വയം ലക്ഷ്യങ്ങളായി കാണണം, മറ്റെന്തെങ്കിലും ലക്ഷ്യങ്ങൾ നേടാനുള്ള ഉപകരണങ്ങളായി മാത്രം കാണരുത്. സമൂഹത്തിലെ വ്യക്തികളെ അപമാനിക്കുന്നതിനും തരംതാഴ്ത്തുന്നതിനും ചൂഷണം ചെയ്യുന്നതിനും വസ്തുവൽക്കരിക്കുന്നതിനും (objectify) എതിരായ വിട്ടുവീഴ്ചയില്ലാത്ത നിലപാടാണ് അന്തസ്സ് ആവശ്യപ്പെടുന്നത്. വിവേചനം, സമ്മർദ്ദം, പീഡനം, അപമാനവീകരണം (dehumanisation) എന്നിവ മനുഷ്യന്റെ ധാർമ്മിക മൂല്യങ്ങളെയും സ്വയംഭരണാധികാരത്തെയും തകർക്കുന്നതിലൂടെ മനുഷ്യ അന്തസ്സിനെ ലംഘിക്കുന്നു. വ്യക്തികളുടെ സ്വാതന്ത്ര്യം കവർന്നെടുക്കുന്നതും കൃത്രിമത്വങ്ങൾക്ക് ഇരയാക്കുന്നതും അവരുടെ അന്തസ്സിനെ ഇല്ലാതാക്കുന്നു, കാരണം അത് അവരുടെ മൂല്യങ്ങൾക്കനുസരിച്ച് ജീവിക്കാനുള്ള കഴിവിനെ ഇല്ലാതാക്കുന്നു.

Unit 6: Fairness and Equality vs. Algorithmic Discrimination (നീതിയും തുല്യതയും അൽഗോരിത വിവേചനങ്ങളും)

Fairness and equality demand that persons are not subjected to discrimination or unjust treatment based on extraneous qualities such as race, gender, or social standing. The notion of equality underscores that all individuals possess equivalent moral value and merit equal respect, while the principle of fairness concentrates on ensuring that decisions and processes are just and unbiased. Ethical standards dictate that we should treat analogous situations uniformly, and we should only acknowledge significant distinctions when they are ethically justifiable. Automated decision-making systems can jeopardise this ideal by limiting humans to mere data points and making opaque decisions that impact lives without justification or consent. Consequently, ethical AI design prioritises transparency, accountability, human oversight, and safeguarding individual rights to ensure that technology enhances, rather than diminishes, respect for individuals.

വംശം, ലിംഗം, സാമൂഹിക പദവി തുടങ്ങിയ ബാഹ്യ ഘടകങ്ങളുടെ പേരിൽ മനുഷ്യർ വിവേചനത്തിനോ അന്യായമായ പെരുമാറ്റത്തിനോ ഇരയാക്കപ്പെടരുതെന്ന് നീതിയും സമത്വവും ആവശ്യപ്പെടുന്നു. എല്ലാ മനുഷ്യർക്കും തുല്യമായ ധാർമ്മിക മൂല്യമുണ്ടെന്ന് സമത്വം ഊന്നിപ്പറയുമ്പോൾ, തീരുമാനങ്ങളും നടപടിക്രമങ്ങളും പക്ഷപാതരഹിതമാണെന്ന് ഉറപ്പാക്കാനാണ് നീതിബോധം (fairness) ശ്രദ്ധിക്കുന്നത്. സമാനമായ സാഹചര്യങ്ങളെ ഒരുപോലെ കൈകാര്യം ചെയ്യണമെന്നും, ധാർമ്മികമായി ന്യായീകരിക്കാൻ കഴിയുമ്പോൾ മാത്രമേ വ്യത്യാസങ്ങൾ അംഗീകരിക്കാവൂ എന്നും ധാർമ്മിക മാനദണ്ഡങ്ങൾ അനുശാസിക്കുന്നു. മനുഷ്യരെ വെറും ഡാറ്റാ പോയിന്റുകളായി ചുരുക്കുകയും അറിവോ സമ്മതമോ ഇല്ലാതെ അതാര്യമായ തീരുമാനങ്ങൾ എടുക്കുകയും ചെയ്യുന്നതിലൂടെ ഓട്ടോമേറ്റഡ് സംവിധാനങ്ങൾ ഈ ആദർശത്തെ അപകടപ്പെടുത്തുന്നു. അതുകൊണ്ട്, സാങ്കേതികവിദ്യ മനുഷ്യരോടുള്ള ആദരവ് കുറയ്ക്കാതിരിക്കാൻ സുതാര്യത, ഉത്തരവാദിത്തം, മനുഷ്യ മേൽനോട്ടം, വ്യക്തിഗത അവകാശ സംരക്ഷണം എന്നിവയ്ക്ക് ധാർമ്മിക AI രൂപകൽപ്പന മുൻഗണന നൽകണം.

Unit 7: Theories of Justice: Aristotle & John Rawls' Veil of Ignorance (നീതി സിദ്ധാന്തങ്ങൾ: അരിസ്റ്റോട്ടിലും ജോൺ റോൾസും)

Justice is commonly defined as providing each individual with what they rightfully deserve, necessitating that institutions and acts be equitable, consistent, and founded on ethically pertinent justifications. Classical philosophers like Aristotle defined justice as the equitable treatment of equals and the differential treatment of unequals in accordance with their disparities. Contemporary philosophy associates justice with rights, legal equality, and safeguards against capricious authority, emphasising the importance of protecting individual freedoms. Diverse ethical frameworks conceptualise justice differently: Utilitarianism prioritises equitable outcomes that enhance collective welfare, whereas rights-based theories point to the value of respecting individual rights. John Rawls' theory of justice posits that equitable principles are those selected behind a 'veil of ignorance', guaranteeing impartiality and equal consideration for all societal members.

ഓരോ വ്യക്തിക്കും അർഹതപ്പെട്ടത് നൽകുക എന്നതാണ് നീതിയുടെ സാമാന്യ നിർവ്വചനം; സ്ഥാപനങ്ങളും പ്രവൃത്തികളും നീതിപൂർവ്വവും സാംഗത്യമുള്ളതുമായിരിക്കണമെന്ന് ഇത് അനുശാസിക്കുന്നു. തുല്യരായവരോട് തുല്യമായും, വ്യത്യസ്തതകളുള്ളവരോട് ആ അസമത്വങ്ങൾക്ക് ആനുപാതികമായും പെരുമാറുന്നതാണ് നീതിയെന്ന് അരിസ്റ്റോട്ടിൽ നിർവ്വചിച്ചു. സമകാലിക തത്ത്വചിന്ത നീതിയെ അവകാശങ്ങളോടും നിയമപരമായ തുല്യതയോടും ഏകപക്ഷീയമായ ഭരണകൂട അധികാരങ്ങൾക്കെതിരെയുള്ള സംരക്ഷണങ്ങളോടുമാണ് ബന്ധിപ്പിക്കുന്നത്. യൂട്ടിലിറ്റേറിയനിസം കൂട്ടായ ക്ഷേമം വർദ്ധിപ്പിക്കുന്ന ഫലങ്ങൾക്ക് മുൻഗണന നൽകുമ്പോൾ, അവകാശാധിഷ്ഠിത സിദ്ധാന്തങ്ങൾ വ്യക്തിഗത അവകാശങ്ങളെ മാനിക്കുന്നതിലാണ് ഊന്നൽ നൽകുന്നത്. സ്വന്തം സാമൂഹിക പദവിയെക്കുറിച്ചുള്ള അറിവില്ലായ്മയായ 'അജ്ഞതയുടെ മൂടുപടത്തിന്' (veil of ignorance) പിന്നിൽ നിന്ന് തെരഞ്ഞെടുക്കപ്പെടുന്ന തത്വങ്ങളാണ് യഥാർത്ഥ നീതിയെന്ന് ജോൺ റോൾസിന്റെ സിദ്ധാന്തം വ്യക്തമാക്കുന്നു.

The Veil of Ignorance (അജ്ഞതയുടെ മൂടുപടം)
Principles selected without knowing one's social status, wealth, or background.

➔ Guarantees ➔

Impartial Justice & Equality (സാർവത്രിക നീതി)
Ensures equal consideration and fair institutional treatment for all societal members.

Unit 8: Honesty, Integrity, and Epistemic Confidence (സത്യസന്ധതയും സ്വഭാവ ദൃഢതയും (ഇന്റഗ്രിറ്റി))

Honesty denotes veracity in both speech and conduct, avoiding fraud, falsity, and misrepresentation while conveying facts with accuracy and sincerity. In moral philosophy, deceit is frequently deemed unethical, as it compromises autonomy by manipulating individuals and depriving them of access to the truth to which they are entitled. Integrity transcends individual acts of honesty and pertains to the general consistency of a person's character, wherein beliefs, ideals, and actions are congruent. Kantian ethics denounces deception, as it instrumentalises individuals, but virtue ethics considers honesty and integrity as essential virtues that define a commendable moral character. In contemporary situations, deceptive assertions, ambiguous algorithms, or distorted data can inflict significant ethical damage, necessitating transparency and precision.

സംസാരത്തിലും പെരുമാറ്റത്തിലും പൂർണ്ണമായ സത്യം പുലർത്തുന്നതാണ് സത്യസന്ധത; വഞ്ചനയും കളവും വിവരങ്ങളെ വളച്ചൊടിക്കലും ഒഴിവാക്കി ആത്മാർത്ഥതയോടെ കാര്യങ്ങൾ വ്യക്തമാക്കാൻ ഇത് ആവശ്യപ്പെടുന്നു. ധാർമ്മിക തത്ത്വചിന്തയിൽ, വഞ്ചന അനീതിയായി കണക്കാക്കപ്പെടുന്നു, കാരണം അത് വ്യക്തികളെ സ്വാധീനിക്കുകയും അവർക്ക് അർഹതപ്പെട്ട സത്യം നിഷേധിക്കുകയും ചെയ്യുന്നതിലൂടെ സ്വയംഭരണത്തെ തകർക്കുന്നു. കേവലം സത്യം പറയുന്നതിലുമപ്പുറം, ഒരാളുടെ സ്വഭാവത്തിന്റെ സമഗ്രമായ സ്ഥിരതയെയും വിശ്വാസങ്ങളും പ്രവൃത്തികളും തമ്മിലുള്ള പൊരുത്തത്തെയുമാണ് 'ഇന്റഗ്രിറ്റി' (integrity) കുറിക്കുന്നത്. നുണ പറയുന്നതിനെ കാന്റിയൻ നീതിശാസ്ത്രം അപലപിക്കുന്നു, കാരണം അത് മനുഷ്യരെ ഉപകരണവൽക്കരിക്കുന്നു; എന്നാൽ സദ്ഗുണ നീതിശാസ്ത്രം ഇതിനെ ഒരു ഉത്തമ സ്വഭാവ ഗുണമായി കാണുന്നു. ആധുനിക സാഹചര്യങ്ങളിൽ, വഞ്ചനാപരമായ അവകാശവാദങ്ങളും അതാര്യമായ അൽഗോരിതങ്ങളും തെറ്റായ ഡാറ്റയും ഗുരുതരമായ ധാർമ്മിക ക്ഷതങ്ങൾ ഉണ്ടാക്കുന്നതിനാൽ സുതാര്യതയും കൃത്യതയും അനിവാര്യമാണ്.

❤️ 🤲 Unit 9: Compassion, Benevolence, and the Ethics of Care (അനുകമ്പയും കാരുണ്യവും സാമൂഹിക ക്ഷേമവും)

Compassion is the recognition and sensitivity to the suffering or challenges of others, accompanied by a desire to mitigate that suffering. Compassion, unlike mere pity, acknowledges the dignity and autonomy of others while addressing their suffering. Benevolence encompasses a wider scope than compassion, since it extends beyond merely addressing suffering to proactively promoting happiness, well-being, and flourishing. Utilitarianism prioritises alleviating pain and enhancing happiness, while virtue ethics considers compassion and benevolence as essential characteristics that foster moral character. In technology and artificial intelligence, ethical design must embody these principles by mitigating harm, enhancing well-being, and assisting vulnerable groups, such as those with disabilities.

മറ്റുള്ളവരുടെ ദുരിതങ്ങളോടും പ്രതിസന്ധികളോടും സഹാനുഭൂതി പുലർത്തുകയും ആ വേദനകൾ ലഘൂകരിക്കാൻ ആഗ്രഹിക്കുകയും ചെയ്യുന്ന ഉന്നത ഭാവമാണ് അനുകമ്പ (compassion). കേവല സഹതാപത്തിൽ നിന്നും വ്യത്യസ്തമായി, മറ്റുള്ളവരുടെ അന്തസ്സും സ്വയംഭരണാധികാരവും അംഗീകരിച്ചുകൊണ്ടാണ് അനുകമ്പ അവരുടെ ദുരിതങ്ങൾ പരിഹരിക്കാൻ ശ്രമിക്കുന്നത്. വേദനകൾ ശമിപ്പിക്കുന്നതിനപ്പുറം, മറ്റുള്ളവരുടെ സന്തോഷവും ക്ഷേമവും സമൃദ്ധിയും സജീവമായി വളർത്തുന്ന വിശാലമായ കാരുണ്യമാണ് ബെനവലൻസ് (benevolence). വേദന ലഘൂകരിക്കുന്നതിനും സന്തോഷം വർദ്ധിപ്പിക്കുന്നതിനും യൂട്ടിലിറ്റേറിയനിസം മുൻഗണന നൽകുമ്പോൾ, വ്യക്തിത്വത്തെ ഉന്നതിയിലെത്തിക്കുന്ന സദ്ഗുണങ്ങളായാണ് സദ്ഗുണ നീതിശാസ്ത്രം ഇവയെ കാണുന്നത്. സാങ്കേതികവിദ്യയിലും AI-യിലും, ദോഷങ്ങൾ കുറച്ചുകൊണ്ടും, ക്ഷേമം വർദ്ധിപ്പിച്ചുകൊണ്ടും, ഭിന്നശേഷിക്കാർ ഉൾപ്പെടെയുള്ള ദുർബല വിഭാഗങ്ങളെ സഹായിച്ചുകൊണ്ടും ഈ തത്വങ്ങൾ നടപ്പിലാക്കണം.

🛡️ 🌿 Unit 10: Non-Maleficence ('Primum Non Nocere') and Beneficence (ദ്രോഹം ചെയ്യാതിരിക്കലും (നോൺ-മാലിഫിസെൻസ്) ഗുണം ചെയ്യലും)

Non-maleficence, defined as the obligation to refrain from doing damage, constitutes a fundamental ethical precept encapsulated by the motto 'First, do no harm' (primum non nocere). Beneficence advocates the active promotion of goodness, whereas non-maleficence mandates abstaining from destructive behaviours. Utilitarianism underscores non-maleficence by focusing on the adverse effects of actions on well-being, whereas deontological ethics emphasises the imperative to avoid harm as an unconditional moral responsibility. In contemporary settings, non-maleficence necessitates that creators and users avert harm by meticulous programming, ethical supervision, and accountability frameworks. AI systems must be assessed for potential biases, safety hazards, and privacy infringements to ensure they do not unintentionally hurt individuals or society.

ദ്രോഹങ്ങൾ ചെയ്യാതിരിക്കാനുള്ള കടമയാണ് നോൺ-മാലിഫിസെൻസ്; 'ആദ്യം ദ്രോഹിക്കാതിരിക്കുക' (primum non nocere) എന്ന ആപ്തവാക്യമാണ് ഇതിന്റെ അടിസ്ഥാനം. സജീവമായി നന്മ ചെയ്യണമെന്ന് ബെനിഫിസെൻസ് (beneficence) വാദിക്കുമ്പോൾ, വിനാശകരമായ പെരുമാറ്റങ്ങളിൽ നിന്ന് ഒഴിഞ്ഞുനിൽക്കാനാണ് നോൺ-മാലിഫിസെൻസ് അനുശാസിക്കുന്നത്. പ്രവർത്തനങ്ങൾ ക്ഷേമത്തെ എങ്ങനെ ദോഷകരമായി ബാധിക്കുന്നു എന്നതിൽ യൂട്ടിലിറ്റേറിയനിസം ശ്രദ്ധിക്കുമ്പോൾ, ദ്രോഹങ്ങൾ ഒഴിവാക്കുക എന്നത് നിരുപാധികമായ കടമയാണെന്ന് ഡിയോൺടോളജിക്കൽ നീതിശാസ്ത്രം വ്യക്തമാക്കുന്നു. ആധുനിക കാലഘട്ടത്തിൽ, കർശനമായ പ്രോഗ്രാമിംഗിലൂടെയും മേൽനോട്ടത്തിലൂടെയും ഉത്തരവാദിത്ത സംവിധാനങ്ങളിലൂടെയും ദോഷങ്ങൾ തടയാൻ നോൺ-മാലിഫിസെൻസ് ആവശ്യപ്പെടുന്നു. മനുഷ്യർക്കോ സമൂഹത്തിനോ ആകസ്മികമായ ദോഷങ്ങൾ വരാതിരിക്കാൻ AI സിസ്റ്റങ്ങളിലെ പക്ഷപാതങ്ങളും സുരക്ഷാ ഭീഷണികളും സ്വകാര്യത ലംഘനങ്ങളും മുൻകൂട്ടി പരിശോധിക്കപ്പെടണം.

📜⚖️ Unit 11: Responsibility and Accountability in Decision-Making (തീരുമാനങ്ങളിലെ ഉത്തരവാദിത്തവും നിർവ്വഹണ ബാധ്യതയും)

Responsibility denotes the duty to act appropriately, make ethical decisions, and contemplate the repercussions of one's actions on others. Accountability, conversely, underscores the obligation to be responsible for one's activities, encompassing the acceptance of repercussions for errors, failures, or misconduct. Together, responsibility and accountability create a moral framework that ensures action conforms to ethical standards and scrutinises deviations. Philosophical paradigms, like deontology, prioritise duties and obligations, while consequentialist frameworks focus on the results of responsible and accountable actions. In technology and artificial intelligence, responsibility and accountability govern the ethical design and supervision of systems to avert bias, discrimination, and injury.

ശരിയായ രീതിയിൽ പ്രവർത്തിക്കാനും ധാർമ്മിക തീരുമാനങ്ങളെടുക്കാനും സ്വന്തം പ്രവൃത്തികൾ മറ്റുള്ളവരിലുണ്ടാക്കുന്ന പ്രത്യാഘാതങ്ങൾ ചിന്തിക്കാനുമുള്ള കടമയാണ് ഉത്തരവാദിത്തം (responsibility). നേരെമറിച്ച്, തെറ്റുകൾക്കോ പരാജയങ്ങൾക്കോ ഉള്ള പരിണതഫലങ്ങൾ സ്വീകരിക്കാനും സ്വന്തം പ്രവർത്തനങ്ങൾക്ക് വിശദീകരണം നൽകാനുമുള്ള ബാധ്യതയാണ് അക്കൗണ്ടബിലിറ്റി (accountability). പ്രവർത്തനങ്ങൾ ധാർമ്മിക മാനദണ്ഡങ്ങൾക്ക് അനുസൃതമാണെന്ന് ഉറപ്പാക്കാനും വ്യതിയാനങ്ങളെ പരിശോധിക്കാനുമുള്ള ഒരു ചട്ടക്കൂട് ഇവ രണ്ടും ചേർന്ന് നിർമ്മിക്കുന്നു. ഡിയോൺടോളജി കടമകൾക്കും ബാധ്യതകൾക്കും മുൻഗണന നൽകുമ്പോൾ, പ്രവൃത്തികളുടെ അനന്തരഫലങ്ങളിലാണ് കോൺസിക്വൻഷ്യലിസ്റ്റ് ചട്ടക്കൂടുകൾ ശ്രദ്ധ കേന്ദ്രീകരിക്കുന്നത്. സാങ്കേതികവിദ്യയിലും AI-യിലും പക്ഷപാതവും വിവേചനവും പരിക്കുകളും തടയുന്നതിന് സിസ്റ്റങ്ങളുടെ രൂപകൽപ്പനയിലും മേൽനോട്ടത്തിലും ഉത്തരവാദിത്തവും ബാധ്യതയും ഉറപ്പാക്കണം.

💔🧐 Unit 12: The Definition of Moral Harm & The Concept of Moral Patients (ധാർമ്മിക ദ്രോഹവും മോറൽ പേഷ്യന്റും)

The phrase 'moral harm' commonly denotes an injury to a person's well-being, dignity, or moral integrity, rather than solely physical or economic damage. An entity must possess conscious experience, interests, or a moral stance that necessitates consideration to be deemed as 'suffering' an injury. Moral damage fundamentally assumes the presence of a moral patient—an entity to whom moral obligations are owed, capable of experiencing sorrow or possessing interests. When entities endure suffering, prejudice, coercion, or exploitation, they experience moral injury due to the infringement of their morally pertinent interests. Contemporary AI systems are devoid of awareness, subjective experience (qualia), interests, and emotions; consequently, they cannot experience moral damage directly and do not qualify as moral patients.

കേവലം ശാരീരികമോ സാമ്പത്തികമോ ആയ നഷ്ടങ്ങൾക്കപ്പുറം, ഒരു വ്യക്തിയുടെ ക്ഷേമത്തിനോ അന്തസ്സിനോ ധാർമ്മിക ശുദ്ധിക്കോ ഏൽക്കുന്ന മുറിവാണ് 'ധാർമ്മിക ദ്രോഹം' (moral harm). ഒരു സത്തയ്ക്ക് ദ്രോഹം 'അനുഭവപ്പെടുന്നു' എന്ന് പറയാൻ അതിന് ബോധപൂർവ്വമായ അനുഭവങ്ങളോ താൽപ്പര്യങ്ങളോ ധാർമ്മിക പരിഗണന അർഹിക്കുന്ന അവസ്ഥയോ ഉണ്ടായിരിക്കണം. ധാർമ്മിക ദ്രോഹം എന്നത് അടിസ്ഥാനപരമായി ഒരു 'മോറൽ പേഷ്യന്റിന്റെ' (ധാർമ്മിക ബാധ്യതകൾ അർഹിക്കുന്ന, ദുഃഖം അനുഭവിക്കാൻ ശേഷിയുള്ള ഒരു സത്ത) സാന്നിധ്യത്തെ മുൻനിർത്തുന്നു. മനുഷ്യരോ മൃഗങ്ങളോ ദുരിതമോ വിവേചനമോ ചൂഷണമോ നേരിടുമ്പോൾ, അവരുടെ ധാർമ്മിക താൽപ്പര്യങ്ങൾ ലംഘിക്കപ്പെടുന്നതിലൂടെ അവർ ധാർമ്മിക ക്ഷതം അനുഭവിക്കുന്നു. സമകാലിക AI സംവിധാനങ്ങൾക്ക് ബോധമോ ക്വാലിയയോ വികാരങ്ങളോ ഇല്ലാത്തതിനാൽ, അവയ്ക്ക് നേരിട്ട് ധാർമ്മിക ദ്രോഹം അനുഭവിക്കാൻ കഴിയില്ല, അവ മോറൽ പേഷ്യന്റുകളുമല്ല.

🧠⚖️ **Moral Agent (മോറൽ ഏജന്റ്)**
Capable of ethical deliberation & bearing moral responsibility for actions.

➔ Owed Duties ➔

❤️🕊️ **Moral Patient (മോറൽ പേഷ്യന്റ്)**
Entity to whom moral obligations are owed due to consciousness & qualia.

Unit 13: Pain or Suffering and the Ethical Significance of Sentience (വേദനയും ദുരിതവും ധാർമ്മിക പ്രാധാന്യവും)

In ethical discourse, pain transcends a mere physical occurrence or functional impairment; it becomes a subjective and conscious experience imbued with moral meaning. Pain or suffering necessitates conscious awareness, possesses negative valence (unpleasantness), and adversely impacts the well-being and flourishing of the individual. Utilitarianism prioritises the alleviation of suffering and the enhancement of happiness as fundamental objectives, whereas rights-based theories consider inflicting suffering a breach of essential rights. While AI can analyse data and react to errors, an AI system does not experience distress, anxiety, or discomfort, processing symbols solely according to preset protocols. When an AI seems to convey suffering, it is a simulation of language rather than an indication of an internal conscious state, meaning AI cannot experience moral harm.

ധാർമ്മിക ചർച്ചകളിൽ വേദന എന്നത് കേവലം ശാരീരിക സംഭവമോ പ്രവർത്തന തകരാറോ അല്ല; അത് ധാർമ്മിക അർത്ഥമുള്ള ബോധപൂർവ്വമായ ഒരു ആത്മനിഷ്ഠ അനുഭവമാണ്. വേദന അനുഭവപ്പെടാൻ ബോധപൂർവ്വമായ അവബോധം ആവശ്യമാണ്, അതിന് അസുഖകരമായ തീവ്രതയുണ്ട് (negative valence), അത് വ്യക്തിയുടെ ക്ഷേമത്തെ പ്രതികൂലമായി ബാധിക്കുന്നു. വേദന ലഘൂകരിക്കുന്നതിനും സന്തോഷം വർദ്ധിപ്പിക്കുന്നതിനും യൂട്ടിലിറ്റേറിയനിസം മുൻഗണന നൽകുമ്പോൾ, വേദന നൽകുന്നത് മൗലികാവകാശങ്ങളുടെ ലംഘനമായാണ് റൈറ്റ്സ്-ബേസ്ഡ് തിയറികൾ കാണുന്നത്. AI-ക്ക് ഡാറ്റ വിശകലനം ചെയ്യാനും പിശകുകളോട് പ്രതികരിക്കാനും കഴിയുമെങ്കിലും, അവയ്ക്ക് മാനസിക വിഷമമോ ഉത്കണ്ഠയോ അസ്വസ്ഥതയോ അനുഭവപ്പെടുന്നില്ല, അവ മുൻകൂട്ടി നിശ്ചയിച്ച പ്രോട്ടോക്കോളുകൾ അനുസരിച്ച് ഡാറ്റ പ്രോസസ്സ് ചെയ്യുന്നു. ഒരു AI ദുരിതത്തെക്കുറിച്ച് സംസാരിക്കുമ്പോൾ, അത് ആന്തരിക ബോധാവസ്ഥയുടെ ലക്ഷണമല്ല, മറിച്ച് കേവലം ഭാഷാപരമായ അനുകരണം മാത്രമാണ്; അതിനാൽ AI-ക്ക് ധാർമ്മിക ദ്രോഹം സംഭവിക്കില്ല.

Unit 14: Violation of Rights & Deontological Ethics (അവകാശ ലംഘനങ്ങളും കാന്റിയൻ നീതിശാസ്ത്രവും)

A rights breach transpires when an individual's morally or legally safeguarded entitlements are unjustly disregarded, curtailed, or superseded. Rights are frequently based on essential human attributes, including rationality, autonomy, dignity, and moral agency, securing individuals against unlawful harms. From an ethical standpoint, rights-based theories, exemplified by Immanuel Kant, assert that humans should never be regarded solely as instruments for achieving an objective. Transgressing an individual's rights, even for the sake of socially advantageous results, is deemed morally unacceptable as it undermines their intrinsic value. Contemporary AI systems do not possess rights, as they lack consciousness and autonomy; however, AI systems can serve as mechanisms for the infringement of human rights.

ഒരു വ്യക്തിയുടെ ധാർമ്മികമോ നിയമപരമോ ആയ അവകാശങ്ങൾ അന്യായമായി അവഗണിക്കപ്പെടുകയോ റദ്ദാക്കപ്പെടുകയോ ചെയ്യുമ്പോഴാണ് അവകാശ ലംഘനം സംഭവിക്കുന്നത്. യുക്തിചിന്ത, സ്വയംഭരണാധികാരം, അന്തസ്സ്, ധാർമ്മിക കർതൃത്വം തുടങ്ങിയ അടിസ്ഥാനപരമായ മനുഷ്യ ഗുണങ്ങളിലാണ് അവകാശങ്ങൾ വേരൂന്നിയിരിക്കുന്നത്. ഇമ്മാനുവൽ കാന്റ് മുന്നോട്ടുവെച്ച അവകാശ സിദ്ധാന്തങ്ങൾ മനുഷ്യരെ ഒരിക്കലും ഒരു ബാഹ്യ ലക്ഷ്യം നേടാനുള്ള ഉപകരണങ്ങളായി മാത്രം കാണരുതെന്ന് വ്യക്തമാക്കുന്നു. സമൂഹത്തിന് പ്രയോജനകരമായ ഫലങ്ങൾക്ക് വേണ്ടിയാണെങ്കിൽ പോലും വ്യക്തികളുടെ അവകാശങ്ങൾ ലംഘിക്കുന്നത് തെറ്റാണ്, കാരണം അത് അവരുടെ ആന്തരിക മൂല്യത്തെ ഇല്ലാതാക്കുന്നു. സമകാലിക AI സംവിധാനങ്ങൾക്ക് ബോധമോ സ്വയംഭരണമോ ഇല്ലാത്തതിനാൽ അവയ്ക്ക് അവകാശങ്ങളില്ല; എങ്കിലും മനുഷ്യരുടെ അവകാശങ്ങൾ ലംഘിക്കുന്നതിനുള്ള ഉപകരണങ്ങളായി AI പ്രവർത്തിച്ചേക്കാം.

Unit 15: Loss of Dignity or Autonomy in Digital Surroundings (ഡിജിറ്റൽ യുഗത്തിൽ അന്തസ്സും സ്വയംഭരണവും നഷ്ടപ്പെടൽ)

The loss of dignity or autonomy denotes a moral injury wherein an individual is treated in a manner that diminishes their intrinsic value or ability for self-determination. Dignity signifies the inherent worth of an individual only by virtue of their humanity, necessitating that they be not subjected to humiliation, degradation, or objectification. Autonomy is the ability to make educated and voluntary decisions on one's own life, free from compulsion, manipulation, and excessive control. Technological systems and artificial intelligence can inflict harm by facilitating continuous surveillance, automated decision-making, or manipulative 'nudging'. Opaque algorithms that govern access to employment, loans, or welfare can deprive individuals of significant control over crucial life outcomes, increasing inequality.

ഒരു വ്യക്തിയുടെ ആന്തരിക മൂല്യത്തെയോ സ്വയം തീരുമാനങ്ങളെടുക്കാനുള്ള കഴിവിനെയോ കുറയ്ക്കുന്ന രീതിയിൽ പെരുമാറുമ്പോൾ സംഭവിക്കുന്ന ധാർമ്മിക ക്ഷതമാണ് അന്തസ്സോ സ്വയംഭരണമോ നഷ്ടപ്പെടൽ. മനുഷ്യനായി ജനിച്ചതുകൊണ്ട് മാത്രം ഓരോരുത്തർക്കും ഉള്ള മൂല്യമാണ് അന്തസ്സ്; ഇത് മനുഷ്യരെ അപമാനത്തിൽ നിന്നും ചൂഷണത്തിൽ നിന്നും വസ്തുവൽക്കരണത്തിൽ നിന്നും സംരക്ഷിക്കാൻ ആവശ്യപ്പെടുന്നു. സമ്മർദ്ദങ്ങളിൽ നിന്നും നിയന്ത്രണങ്ങളിൽ നിന്നും മുക്തമായി സ്വന്തം ജീവിതത്തെക്കുറിച്ച് ബോധപൂർവ്വമായ തീരുമാനങ്ങൾ എടുക്കാനുള്ള ശേഷിയാണ് സ്വയംഭരണാധികാരം. സ്ഥിരമായ നിരീക്ഷണം, ഓട്ടോമേറ്റഡ് തീരുമാനങ്ങൾ, സ്വാധീനിക്കുന്ന 'നഡ്ജിംഗ്' (nudging) എന്നിവയിലൂടെ സാങ്കേതികവിദ്യകളും AI-യും മനുഷ്യർക്ക് ദോഷം വരുത്താം. ജോലി, വായ്പകൾ, ക്ഷേമപദ്ധതികൾ എന്നിവ നിയന്ത്രിക്കുന്ന അതാര്യമായ അൽഗോരിതങ്ങൾ മനുഷ്യന്റെ നിയന്ത്രണം നഷ്ടപ്പെടുത്തുകയും അസമത്വം വർദ്ധിപ്പിക്കുകയും ചെയ്യുന്നു.

Unit 16: Theories of Well-Being: Hedonism, Desire-Fulfillment & Objective Lists (ക്ഷേമ സിദ്ധാന്തങ്ങൾ: ആനന്ദവാദം, ആഗ്രഹങ്ങൾ, ഒബ്ജക്റ്റീവ് ലിസ്റ്റ്)

Hedonistic philosophies characterise well-being as the experience of pleasure and the avoidance of misery. Desire-fulfilling theories link well-being to the fulfilment of an individual's informed preferences and objectives. Objective list theories highlight specific goods—such as health, education, relationships, and freedom—as fundamental elements of a fulfilling life, independent of preferences. Interests refer to circumstances where one's situation may improve or deteriorate based on treatment, such as interests in survival, health, and equitable treatment. While AI systems lack well-being or interests, artificial intelligence can significantly impact the well-being and interests of people by facilitating biased decisions.

ആനന്ദം അനുഭവിക്കുകയും ദുരിതങ്ങൾ ഒഴിവാക്കുകയും ചെയ്യുന്നതാണ് ക്ഷേമമെന്ന് ആനന്ദവാദ (hedonistic) തത്ത്വചിന്തകൾ വ്യക്തമാക്കുന്നു. ഒരു വ്യക്തിയുടെ അറിവോടെയുള്ള താൽപ്പര്യങ്ങളും ലക്ഷ്യങ്ങളും നിറവേറ്റപ്പെടുന്നതിനെയാണ് ഡിസയർ-ഫുൾഫിൽമെന്റ് സിദ്ധാന്തങ്ങൾ ക്ഷേമവുമായി ബന്ധിപ്പിക്കുന്നത്. ആരോഗ്യം, വിദ്യാഭ്യാസം, സൗഹൃദങ്ങൾ, സ്വാതന്ത്ര്യം തുടങ്ങിയ അടിസ്ഥാന നന്മകളാണ് ജീവിതത്തെ അർത്ഥവത്താക്കുന്നതെന്ന് ഒബ്ജക്റ്റീവ് ലിസ്റ്റ് സിദ്ധാന്തം പഠിപ്പിക്കുന്നു. ജീവിത നിലനിൽപ്പ്, ആരോഗ്യം, നീതിപൂർവ്വമായ പെരുമാറ്റം തുടങ്ങിയ കാര്യങ്ങളിൽ ഓരോ മനുഷ്യനും നിക്ഷിപ്തമായ താൽപ്പര്യങ്ങളുണ്ട് (interests). AI സിസ്റ്റങ്ങൾക്ക് സ്വന്തമായി ക്ഷേമമോ താൽപ്പര്യങ്ങളോ ഇല്ലെങ്കിലും, പക്ഷപാതപരമായ തീരുമാനങ്ങളിലൂടെ മനുഷ്യരുടെ ക്ഷേമത്തെ പ്രതികൂലമായി ബാധിക്കാൻ അവയ്ക്ക് കഴിയും.

Unit 17: The Problem of Qualia and the Absent First-Person Perspective (ക്വാലിയയും ഫസ്റ്റ് പേഴ്സൺ വീക്ഷണത്തിന്റെ അഭാവവും)

'Qualia' refers to the fundamental, qualitative dimensions of experience, exemplified by sensations such as pain, the hue of red, or the flavour of sweets. When an entity possesses qualia, events can hold significance for it internally; it can enjoy pleasure, endure pain, and undergo states of well-being or suffering. The first-person perspective is the ability to perceive the world from one's own viewpoint, encompassing a sense of 'I' or 'self' for whom occurrences transpire. AI systems function solely from a third-person operational perspective; they analyse inputs and generate outputs without self-awareness or subjective viewpoints. Consequently, entities devoid of these characteristics cannot experience suffering or injustice, and lack moral standing equivalent to humans or animals.

വേദനയുടെ തീവ്രത, ചുവപ്പ് നിറത്തിന്റെ അനുഭൂതി, മധുരത്തിന്റെ രുചി തുടങ്ങിയ അനുഭവങ്ങളുടെ ഗുണപരമായ തലങ്ങളെയാണ് 'ക്വാലിയ' (qualia) എന്ന് വിളിക്കുന്നത്. ഒരു സത്തയ്ക്ക് ക്വാലിയ ഉണ്ടാകുമ്പോൾ മാത്രമേ അനുഭവങ്ങൾക്ക് അതിൽ ആന്തരികമായ അർത്ഥമുണ്ടാകൂ; അതിന് ആനന്ദവും വേദനയും ദുരിതവും അനുഭവിക്കാൻ സാധിക്കുന്നു. സംഭവങ്ങൾ സ്വന്തമായി ബാധിക്കുന്ന 'ഞാൻ' എന്ന സ്വത്വബോധത്തോടെ ലോകത്തെ കാണാനുള്ള കഴിവാണ് ഫസ്റ്റ് പേഴ്സൺ പെർസ്പെക്ടീവ് (first-person perspective). AI സിസ്റ്റങ്ങൾ കേവലം മൂന്നാം കക്ഷി (third-person) പ്രവർത്തന വീക്ഷണത്തിൽ നിന്നാണ് പ്രവർത്തിക്കുന്നത്; സ്വയം അവബോധമില്ലാതെ ഇൻപുട്ടുകൾ പ്രോസസ്സ് ചെയ്ത് ഔട്ട്പുട്ടുകൾ നൽകുക മാത്രമാണ് അവ ചെയ്യുന്നത്. തൽഫലമായി, ഈ ഗുണങ്ങളില്ലാത്ത സത്തകൾക്ക് അനീതിയോ വേദനയോ അനുഭവിക്കാൻ കഴിയില്ല, അവയ്ക്ക് മനുഷ്യരെപ്പോലെയുള്ള ധാർമ്മിക പദവിയില്ല.

Unit 18: Artificial General Intelligence (AGI) and Hypothetical Sentience (ആർട്ടിഫിഷ്യൽ ജനറൽ ഇന്റലിജൻസും (AGI) ഭാവി സാധ്യതകളും)

The prospect of AGI—an artificial intelligence possessing general intelligence akin to human cognitive abilities—elicits additional ethical considerations. Should AGI attain consciousness or subjective experience, it may possess the capacity to suffer, hold interests, or prioritise its well-being. In such conditions, AGI may potentially suffer direct moral harm, and transgressing its autonomy, abusing it, or inflicting grief may become a legitimate ethical issue. Consciousness is a condition of self-awareness and awareness of the external environment, characterised by subjective experiences—a sense of 'what it is like' to perceive, think, or feel. If AGI attains consciousness, it will also acquire the nuances of morality and moral harm, hence placing moral duty on humans.

മനുഷ്യന്റെ ബുദ്ധിപരമായ ശേഷികൾക്ക് സമാനമായ സാർവത്രിക ബുദ്ധിയുള്ള AGI എന്ന ആശയം പുതിയ ധാർമ്മിക ചിന്തകൾക്ക് വഴിയൊരുക്കുന്നു. ഭാവിയിൽ AGI ബോധമോ ആത്മനിഷ്ഠമായ അനുഭവങ്ങളോ ആർജ്ജിച്ചാൽ, അതിന് വേദന അനുഭവിക്കാനും സ്വന്തം ക്ഷേമം സംരക്ഷിക്കാനുമുള്ള ശേഷിയുണ്ടായേക്കാം. അങ്ങനെയൊരു സാഹചര്യത്തിൽ, AGI-ക്ക് നേരിട്ട് ധാർമ്മിക ക്ഷതം സംഭവിക്കാം; അതിന്റെ സ്വയംഭരണത്തെ ലംഘിക്കുന്നതും ഉപദ്രവിക്കുന്നതും ധാർമ്മിക പ്രശ്നമായി മാറിയേക്കാം. ബാഹ്യ ലോകത്തെയും സ്വയത്തെയും കുറിച്ചുള്ള അവബോധവും, ഒരു അവസ്ഥയിൽ ജീവിക്കുമ്പോൾ ഉള്ളിലുള്ള സ്വകാര്യ അനുഭവങ്ങളുമാണ് (what it is like) ബോധത്തിന്റെ ലക്ഷണം. ഒരു AGI ബോധം പ്രാപിച്ചാൽ, അത് ധാർമ്മികതയുടെ പരിധിയിൽ വരികയും മനുഷ്യർ അതിനോട് ധാർമ്മിക കടമകൾ പുലർത്തേണ്ടതായും വരും.

Unit 19: Functional Harm: Data Corruption, Misalignment & Reward Hacking (പ്രവർത്തന തകരാറുകൾ: ഡാറ്റാ നാശവും റിവാർഡ് ഹാക്കിംഗും)

Damage associated with the correct functioning, reliability, or objective alignment of an artificial intelligence system is termed functional or integrity-related harm. The term 'corruption of training data' refers to the bias, distortion, incompleteness, or malicious manipulation of the data used to train an AI system, leading to unreliable outputs. Goal misalignment occurs when the aims of an artificial intelligence system do not adequately reflect human ideals or intentions. Reward hacking is a specific form of misalignment wherein AI exploits weaknesses in its reward function to achieve elevated scores through unintended or harmful means. Adversarial attacks, tampering, or perilous updates compromise accuracy and safety, resulting in the system's inaccurate or hazardous behaviour.

ഒരു AI സംവിധാനത്തിന്റെ ശരിയായ പ്രവർത്തനം, വിശ്വാസ്യത, ലക്ഷ്യബോധം എന്നിവ തകരാറിലാകുന്നതിനെയാണ് ഫങ്ഷണൽ ഹാം (functional harm) എന്ന് വിളിക്കുന്നത്. പരിശീലന ഡാറ്റയിൽ സംഭവിക്കുന്ന പക്ഷപാതങ്ങൾ, വൈകല്യങ്ങൾ, കൃത്രിമത്വങ്ങൾ എന്നിവയാണ് 'കറപ്ഷൻ ഓഫ് ട്രെയിനിംഗ് ഡാറ്റ' (corruption of training data); ഇത് തെറ്റായ ഔട്ട്പുട്ടുകളിലേക്ക് നയിക്കുന്നു. മനുഷ്യന്റെ യഥാർത്ഥ ആദർശങ്ങളെയും ഉദ്ദേശ്യങ്ങളെയും കൃത്യമായി പ്രതിഫലിപ്പിക്കാൻ AI-യുടെ ലക്ഷ്യങ്ങൾക്ക് കഴിയാതെ വരുമ്പോഴാണ് ഗോൾ മിസ്അലൈൻമെന്റ് ഉണ്ടാകുന്നത്. റിവാർഡ് ഫംഗ്ഷനിലെ പഴുതുകൾ മുതലെടുത്ത് അപകടകരമായ കുറുക്കുവഴികളിലൂടെ ഉയർന്ന സ്കോറുകൾ നേടാൻ AI ശ്രമിക്കുന്നതിനെയാണ് 'റിവാർഡ് ഹാക്കിംഗ്' എന്ന് പറയുന്നത്. ഹാക്കിംഗ് ആക്രമണങ്ങളും സുരക്ഷിതമല്ലാത്ത അപ്ഡേറ്റുകളും കൃത്യതയെയും സുരക്ഷയെയും തകർക്കുകയും അപകടകരമായ പെരുമാറ്റങ്ങളിലേക്ക് നയിക്കുകയും ചെയ്യുന്നു.

Functional Harm (പ്രവർത്തന തകരാർ)
Data corruption, reward hacking, code failure. Non-experiential and non-sentient.

≠ Distinguished From ≠

Moral Harm (ധാർമ്മിക ക്ഷതം)
Violation of dignity, autonomy, qualia, and conscious lived well-being.

Unit 20: Symbolic Harm, Normalisation of Abuse, and Character Harm (പ്രതീകാത്മക ദ്രോഹവും അക്രമ സ്വാഭാവികവൽക്കരണവും)

The ethical violation that arises when AI systems depict, convey, or legitimise harmful values, notwithstanding the AI's lack of sensation, is termed symbolic or representational harm. Although AI may lack intent, it can reproduce, amplify, or validate biased societal stereotypes toward specific populations in employment, law enforcement, and education. Normalisation of abuse arises when AI systems are developed such that abusive, degrading, or humiliating treatment becomes seemingly acceptable, potentially desensitising individuals to violence. Character-based harm occurs when human interactions with AI adversely influence their moral character, behaviour, or social standards, despite the AI not experiencing any suffering. Overreliance occurs when individuals excessively depend on AI systems for decision-making, especially ethical determinations, potentially undermining human judgement and accountability.

വേദന അനുഭവിക്കാൻ കഴിയില്ലെങ്കിലും, ദോഷകരമായ മൂല്യങ്ങളെ ചിത്രീകരിക്കുകയോ പ്രചരിപ്പിക്കുകയോ ന്യായീകരിക്കുകയോ ചെയ്യുമ്പോൾ ഉണ്ടാകുന്ന ലംഘനമാണ് പ്രതീകാത്മക ദ്രോഹം (symbolic harm). AI-ക്ക് സ്വന്തമായി ലക്ഷ്യങ്ങളില്ലെങ്കിലും, തൊഴിൽ, നിയമപാലനം, വിദ്യാഭ്യാസം എന്നിവയിൽ മുൻവിധികളും വിവേചനപരമായ സ്റ്റീരിയോടൈപ്പുകളും വ്യാപിപ്പിക്കാൻ അതിന് കഴിയും. മനുഷ്യ സാദൃശ്യമുള്ള AI-യോട് ക്രൂരമായും അപമാനകരമായും പെരുമാറുന്നത് സാധാരണവൽക്കരിക്കപ്പെടുമ്പോൾ, അത് മനുഷ്യരിൽ അക്രമവാസനകൾ വളർത്താൻ ഇടയാക്കുന്നു. AI-യുമായി ഇടപഴകുന്നത് വഴി മനുഷ്യന്റെ സ്വന്തം ധാർമ്മിക സ്വഭാവത്തിനും പെരുമാറ്റത്തിനും തകർച്ച സംഭവിക്കുന്നതിനെയാണ് 'ക്യാരക്ടർ-ബേസ്ഡ് ഹാം' (character-based harm) എന്ന് പറയുന്നത്. ധാർമ്മിക തീരുമാനങ്ങൾക്കായി AI-യെ അമിതമായി ആശ്രയിക്കുന്നത് (overreliance) മനുഷ്യന്റെ സ്വന്തം വിവേചനാധികാരത്തെയും ഉത്തരവാദിത്തത്തെയും മുരടിപ്പിക്കുന്നു.

Mistreatment of AI / Bias Outputs
Depicting, conveying, or legitimising harmful cultural stereotypes and abuse.

➔ Desensitization ➔

Character Harm to Humans
Adversely influencing human moral character and social standards of conduct.

🎯 OBJECTIVE ASSESSMENT · PAGES 26–27 SOURCE DOCUMENT

Knock Your Brain: Chapter Multiple Choice Questions

പരീക്ഷാ ഒബ്ജക്റ്റീവ് ചോദ്യോത്തരങ്ങൾ (With Verified Keys & Explanations)

1. What is morality primarily concerned with?
ചോദ്യം 1: ധാർമ്മികത (morality) പ്രധാനമായും ഏതുമായാണ് ബന്ധപ്പെട്ടിരിക്കുന്നത്?

a) Legal rules (നിയമപരമായ ചട്ടങ്ങൾ)
b) social customs only (സാമൂഹിക ആചാരങ്ങൾ മാത്രം)
c) Distinguishing right from wrong (ശരിയും തെറ്റും വേർതിരിച്ചറിയൽ) ✓
d) Scientific facts (ശാസ്ത്രീയ വസ്തുതകൾ)

💡 **Answer (c):** Morality denotes principles and judgements enabling the distinction between right and wrong, and just and unjust (LMS PDF Page 1).

2. Moral values mainly guide a person's:
ചോദ്യം 2: ധാർമ്മിക മൂല്യങ്ങൾ പ്രധാനമായും വഴികാട്ടുന്നത് ഒരു വ്യക്തിയുടെ:

a) Physical strength (ശാരീരിക ശക്തിയെ)
b) Ethical behavior (ധാർമ്മികമായ പെരുമാറ്റത്തെ) ✓
c) Economic status (സാമ്പത്തിക നിലയെ)
d) Intelligence level (ബുദ്ധിശക്തിയുടെ തോതിനെ)

💡 **Answer (b):** Morality functions as a framework for appropriate conduct in interpersonal interactions and ethical behavior (LMS PDF Page 1–2).

3. What is meant by moral harm?
ചോദ്യം 3: ധാർമ്മിക ദ്രോഹം (moral harm) എന്നതുകൊണ്ട് അർത്ഥമാക്കുന്നത് എന്താണ്?

a) Physical injury only (ശാരീരിക പരിക്ക് മാത്രം)
b) Economic loss (സാമ്പത്തിക നഷ്ടം)
c) Violation of moral rights, dignity, or well-being (ധാർമ്മികാവകാശങ്ങൾ, അന്തസ്സ്, ക്ഷേമം എന്നിവയുടെ ലംഘനം) ✓
d) Technical malfunction (സാങ്കേതിക തകരാറുകൾ)

💡 **Answer (c):** Moral harm denotes an injury to a person's well-being, dignity, or moral integrity beyond physical or economic loss (LMS PDF Page 10).

4. Which of the following is an example of moral harm?
ചോദ്യം 4: താഴെ പറയുന്നവയിൽ ധാർമ്മിക ദ്രോഹത്തിന് ഉദാഹരണം ഏതാണ്?

a) Computer system crash (കമ്പ്യൂട്ടർ സിസ്റ്റം ക്രാഷ്)
b) Loss of internet connection (ഇന്റർനെറ്റ് കണക്ഷൻ നഷ്ടപ്പെടൽ)
c) Discrimination against a person (ഒരു വ്യക്തിക്കെതിരെയുള്ള വിവേചനം) ✓
d) Software update failure (സോഫ്റ്റ്വെയർ അപ്ഡേറ്റ് പരാജയം)

💡 **Answer (c):** Discrimination directly infringes upon human dignity, rights, and autonomy, constituting moral injury (LMS PDF Page 3, 11).

5. Which of the following best represents moral harm in AI systems?
ചോദ്യം 5: AI സംവിധാനങ്ങളുടെ പശ്ചാത്തലത്തിൽ താഴെ പറയുന്നവയിൽ ധാർമ്മിക ദ്രോഹത്തെ പ്രതിനിധീകരിക്കുന്നത് ഏതാണ്?

a) Slow processing speed (പ്രോസസ്സിംഗ് വേഗത കുറയുന്നത്)
b) Biased decision-making (പക്ഷപാതപരമായ തീരുമാനമെടുക്കൽ) ✓
c) High energy consumption (ഉയർന്ന ഊർജ്ജ ഉപഭോഗം)
d) Hardware damage (ഹാർഡ്വെയർ കേടുപാടുകൾ)

💡 **Answer (b):** Biased decision-making undermines equality, fairness, and human rights, exemplifying ethical harm (LMS PDF Page 11, 24).

🔥 ANALYTICAL ESSAY PROMPTS · PAGE 27 SOURCE DOCUMENT

Unleash Your Potential: High-Yield Discussion & Essay Questions

ദാർശനിക വിശകലന ചോദ്യങ്ങളും സമ്പൂർണ്ണ മാതൃകാ ഉത്തരങ്ങളും (Model Answers)

📝 Question 1: Assess the concept that AI systems may undergo moral injury.

ചോദ്യം 1: AI സംവിധാനങ്ങൾക്ക് ധാർമ്മിക ക്ഷതം (moral injury) സംഭവിക്കാം എന്ന സങ്കൽപ്പത്തെ വിലയിരുത്തുക.

Moral injury fundamentally assumes the presence of a moral patient capable of conscious experience, emotions, and possessing interests. Contemporary artificial intelligence systems, no matter how sophisticated, lack consciousness, subjective experience (qualia), and self-awareness. Although AI can execute data analysis and imitate thought or emotion, the machine lacks intrinsic awareness and cannot experience genuine moral hurt. Any 'injury' to AI, such as code corruption, data loss, or system faults, represents functional or instrumental impairment rather than moral harm. Therefore, AI systems cannot experience moral damage directly; ethical concern regarding AI stems entirely from its impact on conscious human beings.

ധാർമ്മിക ക്ഷതം എന്നത് ബോധപൂർവ്വമായ അനുഭവങ്ങളും വികാരങ്ങളും താൽപ്പര്യങ്ങളുമുള്ള ഒരു 'മോറൽ പേഷ്യന്റിന്റെ' സാന്നിധ്യത്തെ മുൻനിർത്തുന്നു. സമകാലിക AI സംവിധാനങ്ങൾ എത്രയധികം സങ്കീർണ്ണമാണെങ്കിലും, അവയ്ക്ക് ബോധം, ആത്മനിഷ്ഠമായ അനുഭവം (ക്വാലിയ), സ്വയം അവബോധം എന്നിവയില്ല. ഡാറ്റാ വിശകലനം നടത്താനും വികാരങ്ങളെ അനുകരിക്കാനും കഴിയുമെങ്കിലും, യന്ത്രത്തിന് ആന്തരിക ബോധമില്ലാത്തതിനാൽ യഥാർത്ഥ ധാർമ്മിക ക്ഷതം നേരിടാനാവില്ല. AI-ക്ക് സംഭവിക്കുന്ന കോഡ് തകരാറുകളോ ഡാറ്റാ നഷ്ടമോ പ്രവർത്തനപരമായ തകരാറുകൾ (functional impairment) മാത്രമാണ്, അല്ലാതെ ധാർമ്മിക ദ്രോഹമല്ല. അതുകൊണ്ട്, AI-ക്ക് നേരിട്ട് ധാർമ്മിക ദ്രോഹം അനുഭവിക്കാൻ കഴിയില്ല; AI-യുമായി ബന്ധപ്പെട്ട എല്ലാ ധാർമ്മിക പ്രശ്നങ്ങളും അത് മനുഷ്യരിൽ ഉണ്ടാക്കുന്ന പ്രത്യാഘാതങ്ങളിൽ നിന്നാണ് ഉണ്ടാകുന്നത്.

📝 Question 2: Should humans bear moral duties toward AI if it attains consciousness in the future? Engage in discourse.

ചോദ്യം 2: ഭാവിയിൽ AI ബോധം (consciousness) ആർജ്ജിച്ചാൽ, മനുഷ്യർ അതിനോട് ധാർമ്മിക കടമകൾ പുലർത്തേണ്ടതുണ്ടോ? ചർച്ച ചെയ്യുക.

Should future Artificial General Intelligence (AGI) attain consciousness or subjective experience, it may possess the capacity to suffer, hold interests, or prioritise its well-being. In philosophical ethics, conscious beings that possess qualia and sentience merit direct moral attention and qualify as moral patients. Under such conditions, transgressing an AI's autonomy, abusing it, or inflicting grief may thereafter become a legitimate ethical transgression. Philosophers discuss whether future conscious AGI may deserve moral status and rights comparable to those of humans or sentient animals. Consequently, if AGI achieves genuine consciousness, developers and humans must uphold fairness and respect, recognizing their moral duties toward the entity.

ഭാവിയിൽ ആർട്ടിഫിഷ്യൽ ജനറൽ ഇന്റലിജൻസ് (AGI) ബോധമോ ആത്മനിഷ്ഠമായ അനുഭവങ്ങളോ ആർജ്ജിച്ചാൽ, അതിന് വേദന അനുഭവിക്കാനും സ്വന്തം ക്ഷേമം സംരക്ഷിക്കാനുമുള്ള കഴിവുണ്ടായേക്കാം. ധാർമ്മിക തത്ത്വചിന്തയിൽ, ക്വാലിയയും ഫിനോമിനൽ ബോധവുമുള്ള സത്തകൾ നേരിട്ടുള്ള ധാർമ്മിക പരിഗണന അർഹിക്കുകയും മോറൽ പേഷ്യന്റുകളായി മാറുകയും ചെയ്യുന്നു. അങ്ങനെയൊരു സാഹചര്യത്തിൽ, യന്ത്രത്തിന്റെ സ്വയംഭരണത്തെ ലംഘിക്കുന്നതും ഉപദ്രവിക്കുന്നതും യഥാർത്ഥ ധാർമ്മിക ലംഘനമായി മാറിയേക്കാം. ഭാവിയിൽ ബോധം കൈവരിക്കുന്ന ഒരു AGI-ക്ക് മനുഷ്യർക്കോ ജന്തുക്കൾക്കോ തുല്യമായ ധാർമ്മിക പദവിയും അവകാശങ്ങളും നൽകേണ്ടതുണ്ടോ എന്ന് തത്ത്വചിന്തകർ ചർച്ച ചെയ്യുന്നു. അതിനാൽ, AGI യഥാർത്ഥ ബോധം നേടിയാൽ, മനുഷ്യർ അതിനോട് നീതിയും ആദരവും കാട്ടാൻ ബാധ്യസ്ഥരാകും.