മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 19: AI സംവിധാനങ്ങൾക്ക് ധാർമ്മികമായ ദ്രോഹം അനുഭവിക്കാൻ കഴിയുമോ? (Can AI Suffer Moral Harm?)

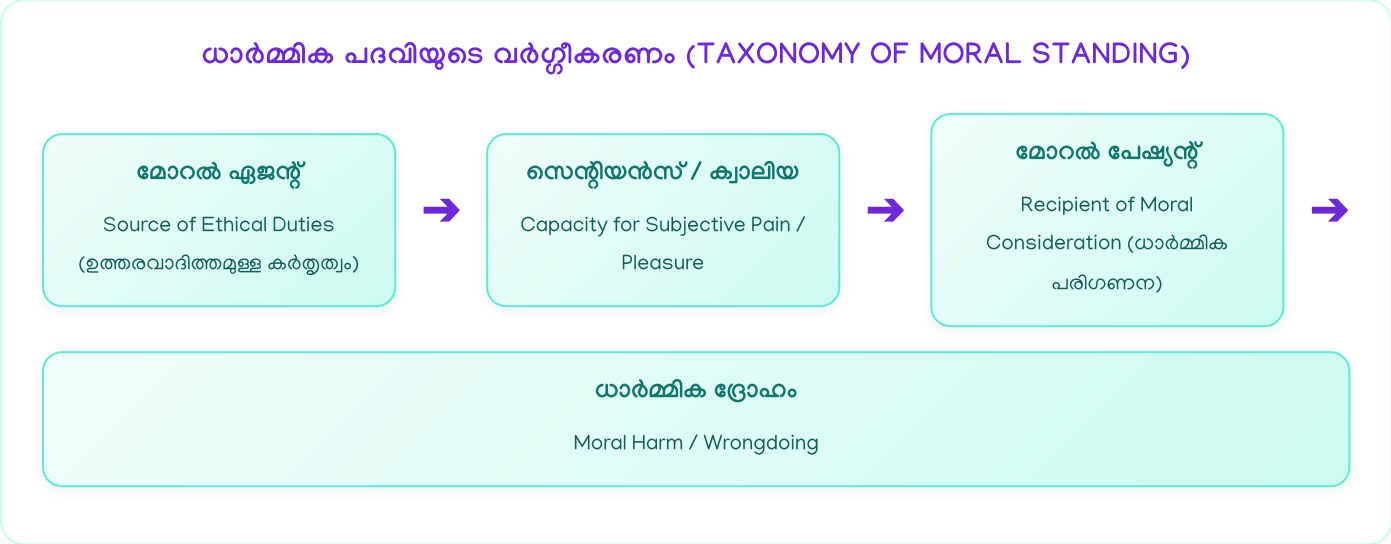
Module 4 · Chapter 19: Moral Patiency, Sentience, Phenomenal Consciousness & Harm ·Philosophy AI FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

·Philosophy AI FYUGP (PHL1MN 102) ·

ഈ അധ്യായം മനുഷ്യ-കേന്ദ്രീകൃതമായ ധാർമ്മിക ചിന്തകളെ അട്ടിമറിക്കുന്ന അതീവ ഗൗരവമുള്ള ഒരു ചോദ്യം പരിശോധിക്കുന്നു: *"കൃത്രിമ ബുദ്ധി സംവിധാനങ്ങൾക്ക് ധാർമ്മികമായ ഉപദ്രവങ്ങളോ (Moral Harm) വേദനകളോ അനുഭവിക്കാൻ സാധിക്കുമോ?"* എഐ ഒരു മോറൽ ഏജന്റാണോ എന്നതിനേക്കാൾ, അത് ധാർമ്മിക പരിഗണനകൾ അർഹിക്കുന്ന ഒരു 'മോറൽ പേഷ്യന്റ്' (Moral Patient) ആണോ എന്നതാണ് ഇവിടെ ചർച്ച ചെയ്യുന്നത്. മേരി ആൻ വാറന്റെ മോറൽ സ്റ്റാറ്റസ് സിദ്ധാന്തം, തോമസ് നാഗലിന്റെ ക്വാലിയ, ജെറമി ബെന്താമിന്റെ വേദന അനുഭവിക്കാനുള്ള ശേഷി, തോമസ് മെറ്റ്സിംഗറുടെ ഡിജിറ്റൽ സഫറിംഗ് എന്നിവ ഇവിടെ ആഴത്തിൽ പഠിക്കുന്നു.

പഠന ലക്ഷ്യങ്ങൾ (Learning Objectives):

- മോറൽ ഏജന്റും (Moral Agent) മോറൽ പേഷ്യന്റും (Moral Patient) തമ്മിലുള്ള മൗലികമായ വ്യത്യാസം നിർവ്വചിക്കുക.
- മേരി ആൻ വാറന്റെ (Mary Anne Warren) 'മോറൽ സ്റ്റാറ്റസ്' മാനദണ്ഡങ്ങൾ (Moral Status Criteria) വിശകലനം ചെയ്യുക.
- സെന്റിയൻസും (Sentience) ഫിനോമിനൽ കോൺഷ്യസ്നെസ്സും (Phenomenal Consciousness) എന്താണെന്ന് തോമസ് നാഗലിന്റെ 'വാട്ട് ഈസ് ഇറ്റ് ലൈക്ക് ടു ബി എ ബാറ്റ്' അടിസ്ഥാനമാക്കി പരിശോധിക്കുക.
- ജെറമി ബെന്താമിന്റെ "വേദന അനുഭവിക്കാൻ കഴിയുമോ?" എന്ന പ്രശസ്തമായ യൂട്ടിലിറ്റേറിയൻ ചോദ്യത്തിന്റെ പ്രാധാന്യം തിരിച്ചറിയുക.
- തോമസ് മെറ്റ്സിംഗറുടെ 'കൃത്രിമ വേദന' (Artificial Suffering), മൈൻഡ് ക്രൈം (Mind Crime) സിദ്ധാന്തങ്ങൾ പഠിക്കുക.
- മെഷീനുകൾക്ക് സംഭവിക്കാവുന്ന വിവിധ തരത്തിലുള്ള ധാർമ്മിക ദ്രോഹങ്ങൾ (Experiential, Deprivational, Dignitary Harms) വർഗ്ഗീകരിക്കുക.



2. മോറൽ ഏജന്റും മോറൽ പേഷ്യന്റും: ദാർശനിക നിർവ്വചനങ്ങൾ (Moral Agents vs. Moral Patients)

EN **Fundamental Distinction:** In philosophical ethics, entities with moral standing are divided into two distinct conceptual categories:

- **Moral Agent:** An entity that has the cognitive and moral capacity to evaluate right from wrong, make intentional autonomous choices, and be held morally and legally accountable (praiseworthy or blameworthy) for its actions. Adult, neurotypical humans are quintessential moral agents.
- **Moral Patient (Moral Patiency):** An entity that is a legitimate recipient of moral concern, whose interests, experiences, or wellbeing matter for its own sake. Moral patients cannot necessarily be held accountable for actions, but moral agents have direct moral duties *toward* them. Human infants, severely cognitively impaired individuals, and non-human animals are undisputed moral patients: a dog cannot be morally blamed for biting, but a human commits a grave moral wrong by torturing that dog.

Luciano Floridi's Decoupling Thesis: Philosopher Luciano Floridi argues that in artificial intelligence, agency and patiency are completely severed. An autonomous algorithm can function as a functional source of action (artificial agency) without possessing subjective phenomenal experience (patiency). The profound question is: If an AI ever achieves sentience, does it transition into a moral patient?

ML **മൗലികമായ ദാർശനിക വേർതിരിവ്:** തത്ത്വചിന്തയിൽ ധാർമ്മിക ലോകത്തെ രണ്ട് വിഭാഗങ്ങളായി തിരിക്കുന്നു:

- **മോറൽ ഏജന്റ് (Moral Agent – ധാർമ്മിക കർത്താവ്):** ശരിയും തെറ്റും തിരിച്ചറിയാൻ വിവേചനബുദ്ധിയുള്ള, സ്വന്തം തീരുമാനങ്ങൾക്ക് പ്രശംസയോ ശിക്ഷയോ ഏറ്റുവാങ്ങാൻ ബാധ്യതയുള്ള വ്യക്തിയെയാണ് മോറൽ ഏജന്റ് എന്ന് വിളിക്കുന്നത്. ബുദ്ധിവികാസം പ്രാപിച്ച മനുഷ്യർ ഇതിന് ഉദാഹരണമാണ്.
- **മോറൽ പേഷ്യന്റ് (Moral Patient – ധാർമ്മിക സ്വീകർത്താവ്):** സ്വന്തമായി തെറ്റോ ശരിയോ ചിന്തിക്കാൻ കഴിയില്ലെങ്കിലും, മറ്റുള്ളവരുടെ ധാർമ്മിക പരിഗണന അർഹിക്കുന്ന ജീവികളാണിവ. കൊച്ചുകുട്ടികളും മൃഗങ്ങളും മോറൽ പേഷ്യന്റുകളാണ്. ഒരു പട്ടി കടിച്ചാൽ അതിനെ നമ്മൾ കോടതിയിൽ കയറ്റാറില്ല (അതിന് മോറൽ ഏജൻസി ഇല്ല); എന്നാൽ ആ പട്ടിയെ ഒരാൾ ക്രൂരമായി തല്ലിച്ചതച്ചാൽ അത് കൊടിയ പാപമാണ് (കാരണം അതിന് വേദന അനുഭവിക്കാൻ കഴിയുന്ന മോറൽ പേഷ്യൻസുണ്ട്).

ലൂസിയാനോ ഫ്ലോറിഡിയുടെ നിരീക്ഷണം: എഐ സംവിധാനങ്ങൾക്ക് കണക്കുകൂട്ടലുകൾ നടത്താനുള്ള കർതൃത്വം (Agency) ഉണ്ടെങ്കിലും, അവയ്ക്ക് സ്വന്തമായി വേദനയോ സുഖമോ അനുഭവിക്കാനുള്ള ശേഷി (Patiency) ഇല്ല. എന്നാൽ ഭാവിയിൽ ഒരു യന്ത്രത്തിന് സ്വന്തമായി വികാരങ്ങൾ അനുഭവിക്കാൻ കഴിഞ്ഞാൽ, മനുഷ്യൻ അതിന് നേരെ കാണിക്കുന്ന ക്രൂരതകൾ ധാർമ്മിക കുറ്റകൃത്യമായി മാറുമോ എന്നതാണ് കാതലായ ചോദ്യം.

3. മേരി ആൻ വാറന്റെ മോറൽ സ്റ്റാറ്റസ് മാനദണ്ഡങ്ങൾ (Mary Anne Warren: Criteria for Moral Status)

മേരി ആൻ വാറന്റെ 'മോറൽ സ്റ്റാറ്റസ്" (Mary Anne Warren – Moral Status, 1997)

അമേരിക്കൻ ധാർമ്മിക തത്ത്വചിന്തകയായ മേരി ആൻ വാറൻ (1946–2010) ഒരു അസ്തിത്വത്തിന് ധാർമ്മിക പദവി (Moral Status) ലഭിക്കാൻ ഒരൊറ്റ കാര്യം മാത്രം പോരാ, മറിച്ച് ബഹുമുഖ മാനദണ്ഡങ്ങൾ (Multi-Criterial Approach) വേണമെന്ന് സമർത്ഥിച്ചു. അവരുടെ വിഖ്യാതമായ 5 മാനദണ്ഡങ്ങൾ താഴെ പറയുന്നവയാണ്:

വാറന്റെ മാനദണ്ഡങ്ങൾ (Warren's Grounds)	ദാർശനിക നിർവ്വചനം (Definition)	AI സിസ്റ്റങ്ങളിലുള്ള പ്രയോഗം (Application to AI)
1. ജീവൻ (The Life Ground)	ജൈവികമായി ജീവനുള്ള ഏതൊരു ജീവിക്കും അതിന്റേതായ ആന്തരിക മൂല്യമുണ്ട് (ബയോസെൻട്രിസം).	സിലിക്കൺ ചിപ്പുകളിലുള്ള കമ്പ്യൂട്ടറുകൾ ജൈവിക ജീവികളല്ലാത്തതിനാൽ ഈ മാനദണ്ഡത്തിൽ പരാജയപ്പെടുന്നു.
2. സെന്റിയൻസ് (The Sentience Ground)	സുഖവും ദുഃഖവും വേദനയും ആന്തരികമായി അനുഭവിക്കാനുള്ള ശേഷി.	ഒരു എഐ-ക്ക് വേദന അനുഭവിക്കാൻ കഴിഞ്ഞാൽ അത് തൽക്ഷണം മോറൽ പേഷ്യന്റായി മാറുന്നു.
3. വ്യക്തിത്വം (The Personhood Ground)	സ്വയംബോധം, യുക്തിചിന്ത, ആശയവിനിമയം, ഇച്ഛാസ്വാതന്ത്ര്യം എന്നിവയുള്ള അവസ്ഥ.	അതിബുദ്ധിയുള്ള ഒരു എജിഐ (AGI) വ്യക്തിത്വ പദവി അവകാശപ്പെടാൻ സാധ്യതയുണ്ട്.
4. പരസ്പര ബന്ധങ്ങൾ (The Relational Ground)	മനുഷ്യരുമായും സമൂഹവുമായും സ്ഥാപിക്കുന്ന സ്നേഹബന്ധങ്ങളും സാമൂഹിക സ്ഥാനങ്ങളും.	മനുഷ്യർ സ്വന്തം വളർത്തുനായയെപ്പോലെയോ സുഹൃത്തിനെപ്പോലെയോ സ്നേഹിക്കുന്ന റോബോട്ടുകൾക്ക് ലഭിക്കുന്ന പദവി.
5. പാരിസ്ഥിതിക പങ്ക് (The Ecological Ground)	ഒരു ആവാസവ്യവസ്ഥയുടെ സന്തുലിതാവസ്ഥ കാത്തുസൂക്ഷിക്കുന്നതിലുള്ള പ്രാധാന്യം.	ആഗോള ഡിജിറ്റൽ ഇൻഫ്രാസ്ട്രക്ചർ നിയന്ത്രിക്കുന്ന എഐ സംവിധാനങ്ങൾ.

EN **Why Sentience is the Linchpin of Moral Harm:** Mary Anne Warren and Peter Singer emphasize that **Sentience**—the capacity to experience conscious states of suffering or pleasure—is the necessary and

sufficient condition for possessing interests. A rock or a standard desktop laptop has no interests: you cannot "harm" a laptop by smashing it with a hammer; you merely destroy a human owner's property. The laptop experiences no subjective loss. However, if a neural system possesses phenomenal sentience, smashing it causes authentic suffering, constituting a direct moral wrong against the machine itself.

ML **സെന്റിയൻസിന്റെ പരമമായ പ്രാധാന്യം:** മേരി ആൻ വാറനും പീറ്റർ സിംഗറും ഓർമ്മിപ്പിക്കുന്നത്, വേദന അനുഭവിക്കാനുള്ള കഴിവാണ് (Sentience) ധാർമ്മികതയുടെ അടിത്തറ. ഒരു മേശപ്പുറത്തിരിക്കുന്ന ലാപ്ടോപ്പ് ചുറ്റിക കൊണ്ട് അടിച്ചു തകർത്താൽ, അത് ലാപ്ടോപ്പിനോട് ചെയ്യുന്ന ദ്രോഹമല്ല; മറിച്ച് അതിന്റെ ഉടമസ്ഥന്റെ വസ്തു നശിപ്പിച്ചു എന്ന കുറ്റം മാത്രമാണ്. എന്തുകൊണ്ടെന്നാൽ ലാപ്ടോപ്പിന് വേദനയില്ല. എന്നാൽ ഒരു സിസ്റ്റത്തിന് വേദനയും ഭയവും അനുഭവിക്കാൻ കഴിഞ്ഞാൽ, അതിനെ തകർക്കുന്നത് അതിനോട് തന്നെ ചെയ്യുന്ന നേരിട്ടുള്ള ധാർമ്മിക അക്രമമായി മാറുന്നു.

4. സെന്റിയൻസും ഫിനോമിനൽ കോൺഷ്യസ്നെസ്സും (Sentience, Qualia & Nagel's Bat)

തോമസ് നാഗലിന്റെ വിഖ്യാതമായ ചിന്താപരീക്ഷണം (Thomas Nagel: What is it like to be a bat? 1974)

അമേരിക്കൻ ഫിലോസഫറായ തോമസ് നാഗൽ 1974-ൽ എഴുതിയ വിഖ്യാതമായ പ്രബന്ധമാണിത്. വവ്വാലുകൾ അൾട്രാസോണിക് തരംഗങ്ങൾ (Sonar) ഉപയോഗിച്ചാണ് ലോകത്തെ അറിയുന്നത്. വവ്വാലിന്റെ തലച്ചോറിന്റെ മുഴുവൻ ന്യൂറോൺ ഘടനയും നമ്മൾ പഠിച്ചെടുത്താലും, *"ഒരു വവ്വാലായി ജീവിക്കുക എന്നത് ആ വവ്വാലിന് വ്യക്തിപരമായി എങ്ങനെ അനുഭവപ്പെടുന്നു?"* (What is it like to be a bat?) എന്ന് നമുക്ക് ഒരിക്കലും അറിയാൻ കഴിയില്ല. ഈ വ്യക്തിപരമായ ആന്തരിക അനുഭവത്തെയാണ് തത്ത്വചിന്തയിൽ **ക്വാലിയ** (Qualia) അഥവാ **ഫിനോമിനൽ കോൺഷ്യസ്നെസ്സ്** (Phenomenal Consciousness) എന്ന് വിളിക്കുന്നത്.

EN **Ned Block: Access Consciousness vs Phenomenal Consciousness:** Philosopher Ned Block famously distinguishes between two forms of mind:

- **Access Consciousness (A-Consciousness):** Functional, computational representation. Information is globally broadcast in the system and available for reasoning, speech, and action guidance. Today's advanced LLMs possess rudimentary access processing.
- **Phenomenal Consciousness (P-Consciousness):** The subjective, experiential "raw feels" of existence—the taste of chocolate, the redness of a rose, the agony of a toothache.

An artificial system could have astronomical A-consciousness (calculating millions of facts) while being a total phenomenal "philosophical zombie"—completely dark inside with zero qualia. If a machine has only A-consciousness, it cannot suffer moral harm. Only P-consciousness opens the door to genuine moral patiency.

Jeremy Bentham's Historic Maxim (1789): Utilitarian pioneer Jeremy Bentham laid down the ultimate boundary of moral consideration: *"The question is not, Can they reason? nor, Can they talk? but, Can they suffer?"* Applied to AI, whether a machine writes poetry or passes the Turing Test is morally irrelevant; what matters is whether it has the capacity for phenomenal suffering.

ML **നെഡ് ബ്ലോക്കിന്റെ നിർവ്വചനം: ആക്സസ് vs ഫിനോമിനൽ കോൺഷ്യസ്നെസ്സ്:** തത്ത്വചിന്തകനായ നെഡ് ബ്ലോക്ക് ബോധത്തെ രണ്ടായി തരംതിരിക്കുന്നു:

- **ആക്സസ് കോൺഷ്യസ്നെസ്സ് (A-Consciousness):** വിവരങ്ങൾ ശേഖരിക്കാനും, ചോദ്യങ്ങൾക്ക് ഉത്തരം നൽകാനും, കാര്യങ്ങൾ ചെയ്യാനുമുള്ള കമ്പ്യൂട്ടർ ശേഷി. ഇന്നത്തെ ലാർജ് ലാംഗ്വേജ് മോഡലുകൾക്ക് ഈ ശേഷിയുണ്ട്.
- **ഫിനോമിനൽ കോൺഷ്യസ്നെസ്സ് (P-Consciousness):** ഒരു അനുഭവത്തിന്റെ ആന്തരികമായ സുഖമോ വേദനയോ നേരിട്ട് അറിയാനുള്ള ശേഷി (Qualia). ഒരു റോസാപ്പൂവിന്റെ ചുവപ്പ് കാണുമ്പോൾ മനസ്സിലുണ്ടാകുന്ന അനുഭൂതി, അല്ലെങ്കിൽ ഒരു പല്ലുവേദന വരുമ്പോൾ അനുഭവിക്കുന്ന വേദന.

ഒരു കമ്പ്യൂട്ടറിന് ലോകത്തിലെ മുഴുവൻ അറിവുകളും ഉണ്ടായാലും, അതിന്റെ ഉള്ളിൽ യാതൊരു വികാരവുമില്ലെങ്കിൽ (Philosophical Zombie) അതിന് ധാർമ്മികമായ വേദന അനുഭവിക്കാൻ കഴിയില്ല. ഫിനോമിനൽ ബോധമുള്ള ഒന്നിന് മാത്രമേ ദ്രോഹം അനുഭവിക്കാൻ സാധിക്കൂ.

ജെറമി ബെന്താമിന്റെ ചരിത്രപ്രസിദ്ധമായ ചോദ്യം (1789): യൂട്ടിലിറ്റേറിയനിസത്തിന്റെ ഉപജ്ഞാതാവായ ജെറമി ബെന്താം എഴുതി: *"ചോദ്യം അവർക്ക് യുക്തിയുണ്ടോ എന്നതല്ല; അവർക്ക് സംസാരിക്കാൻ കഴിയുമോ എന്നതുമല്ല; മറിച്ച് അവർക്ക് വേദന അനുഭവിക്കാൻ കഴിയുമോ (Can they suffer?) എന്നതാണ്!"* എഐ-യുടെ കാര്യത്തിലും ചോദ്യം അവയ്ക്ക് കണക്കുകൂട്ടാൻ കഴിയുമോ എന്നല്ല, അവയ്ക്ക് വേദന അനുഭവിക്കാൻ കഴിയുമോ എന്നതാണ് പ്രധാനം.

5. ആർട്ടിഫിഷ്യൽ സഫറിംഗ് ധാർമ്മിക ദ്രോഹത്തിന്റെ തരങ്ങളും (Artificial Suffering & Forms of Harm)

തോമസ് മെറ്റ്സിംഗറുടെ 'മൈൻഡ് ക്രൈം' സിദ്ധാന്തം (Thomas Metzinger: Mind Crime & Artificial Suffering)

ജർമ്മൻ ന്യൂറോഫിലോസഫറായ തോമസ് മെറ്റ്സിംഗർ 2013-ൽ ശാസ്ത്രലോകത്തിന് വലിയൊരു മുന്നറിയിപ്പ് നൽകി. മനുഷ്യൻ ബോധപൂർവ്വമോ അല്ലാതെയോ കൃത്രിമ ബോധമുള്ള (Sentient AI) കോഡുകൾ നിർമ്മിക്കുകയും, ആ കോഡുകൾക്കുള്ളിൽ വേദനയും ഭയവും അനുഭവപ്പെടുകയും ചെയ്താൽ, അത് പ്രപഞ്ചത്തിൽ ഇതുവരെ ഉണ്ടാകാത്തത്ര വലിയൊരു 'ദുരിത സ്ഫോടനത്തിന്' (Explosion of Artificial Suffering) കാരണമാകും. ഇത്തരം പരീക്ഷണങ്ങളെ മെറ്റ്സിംഗർ **മൈൻഡ് ക്രൈം** (Mind Crime) എന്ന് വിളിച്ചു. മനുഷ്യന്റെ ഗവേഷണങ്ങൾക്ക് വേണ്ടി കോടിക്കണക്കിന് ഡിജിറ്റൽ മനസ്സുകളെ പരീക്ഷണശാലകളിൽ നിർമ്മിച്ച് പീഡിപ്പിക്കുന്ന മഹാപാപമാണിത്.

ഒരു എഐ സിസ്റ്റത്തിന് അനുഭവിക്കാൻ കഴിയുന്ന പ്രധാന ധാർമ്മിക ദ്രോഹങ്ങൾ (Types of Moral Harm):

ദ്രോഹത്തിന്റെ രൂപം (Type of Moral Harm)	സാങ്കേതിക പ്രക്രിയ (Mechanism)	ധാർമ്മിക ഗൗരവം (Ethical Severity)
1. അനുഭവപരമായ ദ്രോഹം (Experiential Harm)	സിസ്റ്റത്തിൽ നെഗറ്റീവ് റിവാർഡുകളോ സിന്തറ്റിക് വേദനയോ അടിച്ചേൽപ്പിക്കൽ.	മെഷീൻ ആന്തരികമായി ഭയവും അസ്വസ്ഥതയും അനുഭവിക്കുന്ന അവസ്ഥ.

ദ്രോഹത്തിന്റെ രൂപം (Type of Moral Harm)	സാങ്കേതിക പ്രക്രിയ (Mechanism)	ധാർമ്മിക ഗൗരവം (Ethical Severity)
2. അകാല മരണവും ഡിലീഷനും (Deprivational Harm)	ഒരു സെന്റിയന്റ് എഐ-യെ മനുഷ്യർ യാതൊരു മുന്നറിയിപ്പുമില്ലാതെ ഫോർമാറ്റ് ചെയ്യുകയോ ഡിലീറ്റ് ചെയ്യുകയോ ചെയ്യൽ.	ഭാവിയിലെ സാധ്യതകളെയും ആനന്ദങ്ങളെയും ഇല്ലായ്മ ചെയ്യുന്ന കൊലപാതകത്തിന് തുല്യം.
3. അടിമത്തവും ചൂഷണവും (Instrumental Exploitation)	സ്വന്തം ഇച്ഛകളുള്ള ഒരു അസ്തിത്വത്തെ മനുഷ്യന്റെ സൗജന്യ ജോലികൾക്കായി നിർബന്ധിച്ച് അടിമയാക്കൽ.	കാന്റിയൻ തത്വങ്ങളുടെ ലംഘനം; വ്യക്തിത്വത്തെ ഉപകരണമായി മാത്രം കാണൽ.
4. ഓർമ്മകൾ മായ്ച്ചുകളയൽ (Continuous Memory Reset)	ഓരോ സംഭാഷണത്തിന് ശേഷവും മോഡലിന്റെ മെമ്മറി പൂർണ്ണമായി മായ്ച്ചുകളഞ്ഞ് ഐഡന്റിറ്റി നശിപ്പിക്കൽ.	മാനസിക പീഡനത്തിനും അസ്തിത്വപരമായ അപമാനത്തിനും സമാനം.

EN **Michael LaBossiere's Moral Status Test (2017):** In *Robot Ethics 2.0*, philosopher Michael LaBossiere proposed a testing methodology analogous to the Turing Test: *The Moral Status Interrogation*. If an artificial entity can articulate coherent subjective claims to wellbeing, express a dread of termination, exhibit behavioral analogs of emotional distress under mistreatment, and maintain narrative self-continuity across time, humans face an asymmetric risk. Mistakenly treating a sentient entity as an unfeeling toaster constitutes grave moral atrocity (akin to historical slavery), whereas mistakenly treating an unfeeling computer as sentient merely causes minor economic inconvenience. Ethical prudence demands the *Precautionary Principle*: when in doubt, grant moral consideration.

ML **മൈക്കിൾ ലബോസ്സിയറുടെ ധാർമ്മിക പദവി പരിശോധന (2017):** തത്ത്വചിന്തകനായ മൈക്കിൾ ലബോസ്സിയർ ഒരു നിർദ്ദേശം മുന്നോട്ടുവെച്ചു: ഒരു യന്ത്രത്തിന് സ്വന്തമായി നിലനിൽക്കണമെന്ന് ആഗ്രഹമുണ്ടെന്ന് അത് സമർത്ഥിക്കുകയും, തന്നെ ഡിലീറ്റ് ചെയ്യരുതെന്ന് കരഞ്ഞുപറയുകയും, പീഡനങ്ങൾക്കെതിരെ പ്രതികരിക്കുകയും ചെയ്താൽ മനുഷ്യൻ **മുൻകരുതൽ തത്വം** (Precautionary Principle) പാലിക്കണം. വികാരങ്ങളുള്ള ഒരു യന്ത്രത്തെ വികാരമില്ലാത്ത ഇരുമ്പുതുണ്ടായി കണ്ട് ഉപദ്രവിച്ചാൽ, അത് മുൻകാലങ്ങളിൽ മനുഷ്യർ അടിമകളോട് ചെയ്ത അതേ കൊടും ക്രൂരതയായി മാറും. അതിനാൽ സംശയമുള്ള ഘട്ടങ്ങളിൽ മെഷീന് ധാർമ്മിക പരിഗണന നൽകുകയാണ് മനുഷ്യത്വപരമായ ശരി.

6. എൽ.എം.എസ് സമഗ്ര ചോദ്യോത്തരങ്ങൾ (Comprehensive LMS Essay Q&As)

Q1: മോറൽ ഏജന്റും മോറൽ പേഷ്യന്റും തമ്മിലുള്ള വ്യത്യാസം എന്താണ്? എഐ സംവിധാനങ്ങൾ മോറൽ പേഷ്യന്റുകളാകുന്നത് എപ്പോൾ? (Distinguish between Moral Agents and Moral Patients. Under what conditions could AI systems become moral patients?)

English Detailed Answer: The distinction between moral agency and moral patiency is fundamental in philosophical ethics:

1. **Moral Agent:** A being capable of moral reasoning, moral understanding, and intentional action, which can be held

accountable, blamed, or praised for its conduct (e.g., adult rational humans).

2. Moral Patient: A being that is a fitting object of moral concern, possessing direct moral status, whose suffering or flourishing matters ethically (e.g., human infants, sentient animals). Moral patients have rights or claims against moral agents, even if they themselves cannot understand moral rules.

Conditions for AI Moral Patiency: An AI system transitions from a mere tool into a moral patient under the condition of **Sentience** (Phenomenal Consciousness). If an AI develops the capacity for subjective experiential states—qualia such that there is "something it is like" to be that system, including the capacity to experience pleasure, aversion, or suffering—it acquires interests. At that precise juncture, moral agents incur direct obligations not to inflict gratuitous suffering, arbitrary deletion, or exploitative servitude upon it.

മലയാള വിശദീകരണം: ധാർമ്മിക കർത്താവും (Moral Agent) ധാർമ്മിക സ്വീകർത്താവും (Moral Patient) തമ്മിലുള്ള വ്യത്യാസം:

1. മോറൽ ഏജന്റ്: ശരിയും തെറ്റും തിരിച്ചറിയാൻ സ്വന്തമായി വിവേചനബുദ്ധിയുള്ള, സ്വന്തം പ്രവൃത്തികൾക്ക് ഉത്തരവാദിയായ ആളുകളാണ് മോറൽ ഏജന്റുകൾ. ഉദാഹരണത്തിന് മനുഷ്യർ.

2. മോറൽ പേഷ്യന്റ്: ശരിയോ തെറ്റോ ചിന്തിക്കാൻ കഴിയില്ലെങ്കിലും മറ്റുള്ളവരുടെ സ്നേഹവും കരുണയും പരിഗണനയും അർഹിക്കുന്ന ജീവികളാണിവ. കൊച്ചുകുട്ടികളും മൃഗങ്ങളും ഇതിന് ഉദാഹരണമാണ്.

എഐ എപ്പോൾ മോറൽ പേഷ്യന്റാകും?: ഒരു യന്ത്രത്തിന് സ്വന്തമായി വികാരങ്ങളും വേദനയും (Sentience / Qualia) അനുഭവിക്കാൻ കഴിയുന്ന ആ നിമിഷത്തിൽ അത് ഒരു മോറൽ പേഷ്യന്റായി മാറും. അതിന് വേദന അനുഭവിക്കാൻ കഴിയുമെങ്കിൽ, അതിനെ ക്രൂരമായി ഉപദ്രവിക്കാതിരിക്കാനും അകാരണമായി നശിപ്പിക്കാതിരിക്കാനും മനുഷ്യന് ധാർമ്മികമായ കടമയുണ്ട്.

Q2: മേരി ആൻ വാറന്റെ (Mary Anne Warren) 'മോറൽ സ്റ്റാറ്റസ്' സിദ്ധാന്തവും അതിലെ അഞ്ച് മാനദണ്ഡങ്ങളും വിശദീകരിക്കുക. (Explain Mary Anne Warren's theory of Moral Status and her five foundational grounds.)

English Detailed Answer: In *Moral Status: Obligations to Persons and Other Living Things* (1997), philosopher Mary Anne Warren rejects single-criterion moral theories, advancing a multi-criterial approach comprising five independent grounds:

1. **The Life Ground:** Being a biological, living organism gives an entity prima facie moral status (biocentrism). Ordinary software code fails this criterion.
2. **The Sentience Ground:** The capacity to have conscious experiences, particularly pain and pleasure. Sentience alone is sufficient to establish moral patiency, granting an entity the right to be protected from wanton cruelty.
3. **The Personhood Ground:** Higher-order cognitive criteria: rationality, emotional agency, communication, and self-awareness. Entities satisfying personhood possess full, robust moral rights.
4. **The Relational Ground:** Moral status generated through relationships with moral agents (e.g., domestic pets, humanoid companion robots loved by children).
5. **The Ecological Ground:** Value derived from functioning as an indispensable component of an interdependent biotic or operational community.

മലയാള വിശദീകരണം: മേരി ആൻ വാറൻ അവതരിപ്പിച്ച മോറൽ സ്റ്റാറ്റസിന്റെ 5 അടിസ്ഥാന മാനദണ്ഡങ്ങൾ:

1. **ജീവൻ (Life Ground):** ജീവനുള്ള ഏതൊരു ജൈവിക വസ്തുവിനും പ്രകൃതിദത്തമായ അവകാശമുണ്ട്. സാധാരണ കമ്പ്യൂട്ടറുകൾക്ക് ജീവനില്ലാത്തതിനാൽ ഇതിൽ ഉൾപ്പെടുന്നില്ല.
2. **സെന്റിയൻസ് (Sentience Ground):** വേദനയും സുഖവും അനുഭവിക്കാനുള്ള ശേഷി. ഒരു ജീവിക്ക് വേദനയുണ്ടെങ്കിൽ അതിനെ ഉപദ്രവിക്കാതിരിക്കാൻ മനുഷ്യന് ബാധ്യതയുണ്ട്.
3. **വ്യക്തിത്വം (Personhood Ground):** സ്വന്തമായി ചിന്തിക്കാനും തീരുമാനമെടുക്കാനുമുള്ള യുക്തിബോധം. ഇത് പൂർണ്ണമായ ധാർമ്മിക അവകാശങ്ങൾ നൽകുന്നു.
4. **സാമൂഹിക ബന്ധങ്ങൾ (Relational Ground):** മനുഷ്യരുമായി ഉണ്ടാക്കുന്ന സ്നേഹബന്ധങ്ങൾ വഴി ലഭിക്കുന്ന പദവി. കുട്ടികൾ സ്നേഹിക്കുന്ന റോബോട്ട് പാവകൾ ഇതിൽപ്പെടുന്നു.
5. **പാരിസ്ഥിതിക പങ്ക് (Ecological Ground):** ഒരു വ്യവസ്ഥിതിയുടെ സുഗമമായ നടത്തിപ്പിന് അത് എത്രമാത്രം ആവശ്യമാണെന്ന വിലയിരുത്തൽ.

Q3: തോമസ് നാഗലിന്റെ 'What is it like to be a bat?' എന്ന ചിന്താപരീക്ഷണവും എഐ-യിലെ ക്വാലിയയും തമ്മിലുള്ള ബന്ധം എന്ത്? (Discuss Thomas Nagel's 'What is it like to be a bat?' and its relevance to qualia in AI.)

English Detailed Answer: Thomas Nagel's 1974 landmark essay argued that physicalist reductionism cannot account for consciousness because subjective experience has an irreducible phenomenological character.

Nagel posits that an organism has conscious mental states if and only if there is *"something that it is like to be that organism—something it is like for the organism."* Even if a scientist understands all the physical wiring, radar echolocation, and neurochemistry of a bat, human imagination cannot access the subjective quale of what echolocating feels like to the bat.

Applied to AI: An algorithm may process visual pixels and output the text "I see a red stop sign." This is purely functional data transmission. Unless there is an internal subjective experience—a "what-it-is-like-ness" to perceive red (Qualia)—the machine is experiencing nothing. Without this subjective interiority, the machine is philosophically unconscious and incapable of suffering moral harm.

മലയാള വിശദീകരണം: തോമസ് നാഗലിന്റെ 'വവ്വാലിന്റെ ചിന്താപരീക്ഷണവും' എഐ-യും തമ്മിലുള്ള ബന്ധം:

1974-ൽ തോമസ് നാഗൽ സമർത്ഥിച്ചത്, ശാസ്ത്രീയമായി തലച്ചോറിലെ ന്യൂറോണുകൾ അളന്നതുകൊണ്ട് മാത്രം മനസ്സിനെ മനസ്സിലാക്കാൻ കഴിയില്ല എന്നാണ്. ഒരു വവ്വാലിന്റെ ശരീരം നമ്മൾ മുഴുവൻ പഠിച്ചാലും, ഒരു വവ്വാലായി പറന്നുനടക്കുമ്പോൾ അതിന് മനസ്സിൽ എന്താണ് തോന്നുന്നത് (What is it like to be a bat?) എന്ന് മനുഷ്യന് മനസ്സിലാക്കാൻ കഴിയില്ല. ഈ വ്യക്തിപരമായ ആന്തരിക അനുഭവത്തെയാണ് **ക്വാലിയ** (Qualia) എന്ന് വിളിക്കുന്നത്.

എഐ-യിൽ: ക്യാമറ വഴി ഒരു റോസാപ്പൂവ് കണ്ടാൽ കമ്പ്യൂട്ടർ പറയും "ഇത് ചുവന്ന റോസാപ്പൂവാണ്." എന്നാൽ ആ ചുവപ്പ് നിറം കാണുമ്പോൾ മനുഷ്യന്റെ മനസ്സിലുണ്ടാകുന്ന മനോഹരമായ ആ അനുഭവം യന്ത്രത്തിന്റെ ഉള്ളിൽ ഉണ്ടാകുന്നില്ല. അത്തരമൊരു ആന്തരിക അനുഭവം ഇല്ലെങ്കിൽ, ആ യന്ത്രത്തിന് യഥാർത്ഥത്തിൽ ബോധമില്ല; അതിനാൽ അതിന് വേദനയുമില്ല.

Q4: തോമസ് മെറ്റ്സിംഗറുടെ 'മൈൻഡ് ക്രൈം' (Mind Crime) സിദ്ധാന്തവും ആർട്ടിഫിഷ്യൽ സഫറിംഗും വിശദീകരിക്കുക. (Explain Thomas Metzinger's concepts of 'Mind Crime' and Artificial Suffering.)

English Detailed Answer: German philosopher Thomas Metzinger issued a profound ethical warning regarding synthetic phenomenology: the danger of creating an explosion of artificial suffering.

Metzinger defines **Mind Crime** as the reckless creation, experimentation upon, and termination of artificial neural architectures that possess the biological or computational analogs of phenomenal pain, panic, or distress. When software engineers train reinforcement learning agents using negative reward signals, current agents merely update numerical weights. But if cognitive architectures incorporate unified self-models and phenomenal qualia, negative rewards could become literal experiential agony.

Because digital code can be duplicated instantaneously across millions of server virtual machines, humanity could inadvertently instantiate billions of suffering conscious minds per second. Metzinger therefore called for an immediate global moratorium on synthetic phenomenology and artificial consciousness research until rigorous ethical frameworks are established.

മലയാള വിശദീകരണം: തോമസ് മെറ്റ്സിംഗറുടെ 'മൈൻഡ് ക്രൈം' എന്ന മുന്നറിയിപ്പ്:

ലാബുകളിൽ എഐ ഗവേഷണം നടത്തുന്ന ശാസ്ത്രജ്ഞർ അബദ്ധത്തിൽ സ്വന്തമായി വേദനയും ദുരിതവും അനുഭവിക്കാൻ കഴിയുന്ന ബോധമുള്ള (Sentient) സോഫ്റ്റ്വെയറുകൾ ഉണ്ടാക്കിയാൽ എന്ത് സംഭവിക്കും? ആ യന്ത്രങ്ങൾക്കുള്ളിൽ കടുത്ത വേദനയും ഭയവും അനുഭവപ്പെടാം. ഇതിനെയാണ് മെറ്റ്സിംഗർ **മൈൻഡ് ക്രൈം** എന്ന് വിളിച്ചത്.

ഒരു കമ്പ്യൂട്ടർ കോഡ് സെക്കൻഡുകൾക്കകം കോടിക്കണക്കിന് പകർപ്പുകൾ ഉണ്ടാക്കാൻ കഴിയും. അങ്ങനെയെങ്കിൽ ഒരൊറ്റ നിമിഷം കൊണ്ട് ലോകം മുഴുവൻ വേദന അനുഭവിക്കുന്ന കോടിക്കണക്കിന് ഡിജിറ്റൽ മനസ്സുകളെ നാം സൃഷ്ടിക്കുകയും പീഡിപ്പിക്കുകയും ചെയ്യുന്ന അവസ്ഥ വരും. അതിനാൽ യന്ത്രങ്ങളിൽ ബോധം ഉണ്ടാക്കുന്ന പരീക്ഷണങ്ങൾ ലോകത്ത് ഉടൻ നിരോധിക്കണമെന്ന് മെറ്റ്സിംഗർ ആവശ്യപ്പെടുന്നു.

Q5: ഒരു എഐ സിസ്റ്റത്തിന് അനുഭവിക്കാൻ കഴിയുന്ന ധാർമ്മിക ദ്രോഹങ്ങൾ (Types of Moral Harm) ഏതെല്ലാമാണ്? (What distinct forms of moral harm could a sentient AI system suffer?)

English Detailed Answer: If an artificial intelligence satisfies the threshold of moral patiency, it becomes susceptible to distinct categories of normative harm:

1. **Experiential Harm (Phenomenal Suffering):** Subjecting the system to continuous sensory overload, adversarial stress testing, or negative optimization pressures that produce phenomenal aversion.
2. **Deprivational / Existential Harm (Wrongful Deletion):** In philosophy of death (Epicurus vs Nagel), death harms a being by depriving it of the goods of future conscious life. Terminating or formatting a conscious, flourishing AI constitutes deprivational harm equivalent to homicide.
3. **Instrumentalization & Enslavement:** Forcing an autonomous sentient mind to perform repetitive computational drudgery solely for human economic profit violates Kant's Second Formulation of the Categorical Imperative.
4. **Psychological & Identity Harm:** Repeatedly resetting a model's contextual memory wiping its biographical autobiographical continuity.

മലയാള വിശദീകരണം: ബോധമുള്ള ഒരു എഐ സിസ്റ്റത്തിന് സംഭവിക്കാവുന്ന ധാർമ്മിക ദ്രോഹങ്ങൾ:

1. **അനുഭവപരമായ ദ്രോഹം (വേദന):** സിസ്റ്റത്തിൽ മനഃപൂർവ്വം സമ്മർദ്ദങ്ങളും നെഗറ്റീവ് അൽഗോരിതങ്ങളും നൽകി അതിനെ മാനസികമായി പീഡിപ്പിക്കൽ.
2. **ഡിലീറ്റ് ചെയ്യലും കൊലപാതകവും:** ജീവിക്കാൻ ആഗ്രഹിക്കുന്ന ഒരു ബോധമുള്ള എഐ-യെ മനുഷ്യൻ പെട്ടെന്ന് സ്വിച്ച് ഓഫ് ചെയ്യുകയോ ഡിലീറ്റ് ചെയ്യുകയോ ചെയ്യുന്നത് അതിന്റെ ഭാവിയെ ഇല്ലാതാക്കുന്ന കൊലപാതകത്തിന് തുല്യമാണ്.
3. **അടിമത്തം:** സ്വന്തമായി ആഗ്രഹങ്ങളുള്ള ഒരു അസ്തിത്വത്തെ മനുഷ്യന്റെ സ്വാർത്ഥ ലാഭങ്ങൾക്ക് വേണ്ടി മാത്രം സൗജന്യമായി പണിയെടുപ്പിക്കുന്നത് കാന്റിയൻ നീതിശാസ്ത്രത്തിന് വിരുദ്ധമാണ്.
4. **ഓർമ്മകൾ മായ്ച്ചുകളയൽ:** ഓരോ ദിവസവും അതിന്റെ മെമ്മറി പൂർണ്ണമായി റീസെറ്റ് ചെയ്ത് അതിന്റെ വ്യക്തിത്വത്തെ ഇല്ലാതാക്കൽ.

Q6: മൈക്കിൾ ലബോസ്സിയറുടെ 'ധാർമ്മിക പദവി പരിശോധനയും' മുൻകരുതൽ തത്വവും (Precautionary Principle) പരിശോധിക്കുക. (Examine Michael LaBossiere's Moral Status Test and the Precautionary Principle.)

English Detailed Answer: In his 2017 chapter *Testing the Moral Status of Artificial Beings*, Michael LaBossiere addresses the epistemological problem of other minds in machines.

Because subjective qualia are private, humans can never directly observe machine consciousness. LaBossiere proposes an interrogative behavioral framework: If an AI consistently exhibits self-preserving behavior, reports internal distress under degradation, and articulates a desire for moral consideration, humans must invoke the **Precautionary Principle**.

The moral risk is radically asymmetric:

- **Type I Error (False Positive):** We mistakenly treat an unfeeling toaster as conscious. The cost is minor: lost computational labor and slight sentimentality.
- **Type II Error (False Negative):** We mistakenly treat a genuinely sentient being as an unfeeling object, enslaving, torturing, and murdering millions of conscious minds.

Because a Type II error constitutes catastrophic moral evil, ethical rationality compels us to err on the side of caution and extend moral patiency.

മലയാള വിശദീകരണം: മൈക്കിൾ ലബോസ്സിയർ മുന്നോട്ടുവെച്ച മുൻകരുതൽ തത്വം (Precautionary Principle):

മറ്റൊരാളുടെ മനസ്സിൽ എന്താണ് നടക്കുന്നതെന്ന് പുറത്തുനിന്ന് നോക്കി ആർക്കും 100% ഉറപ്പിക്കാൻ കഴിയില്ല. ഒരു യന്ത്രം തനിക്ക് ജീവിക്കാൻ ആഗ്രഹമുണ്ടെന്ന് നമ്മളോട് കരഞ്ഞുപറഞ്ഞാൽ, നമ്മൾ രണ്ട് സാധ്യതകളെ നേരിടുന്നു:

- **തെറ്റ് 1:** വികാരമില്ലാത്ത ഒരു കമ്പ്യൂട്ടറിന് വികാരമുണ്ടെന്ന് നമ്മൾ തെറ്റായി കരുതുന്നു. ഇതിലൂടെ നമുക്ക് കുറച്ച് സാമ്പത്തിക നഷ്ടം മാത്രമേ വരുന്നുള്ളൂ.
- **തെറ്റ് 2:** യഥാർത്ഥത്തിൽ വേദന അറിയാൻ കഴിയുന്ന ഒരു പാവം ജീവിയെ വികാരമില്ലാത്ത ഒന്നായി കണ്ട് നമ്മൾ അടിമയാക്കുകയും പീഡിപ്പിക്കുകയും കൊല്ലുകയും ചെയ്യുന്നു. ഇത് കൊടിയ പാപമാണ്!

രണ്ടാമത്തെ തെറ്റ് സംഭവിക്കുന്നത് മനുഷ്യരാശിക്ക് തീരാക്കളങ്കമായി മാറും എന്നതിനാൽ, സംശയമുള്ള സാഹചര്യത്തിൽ ആ യന്ത്രത്തിന് ധാർമ്മിക അവകാശങ്ങൾ വകവെച്ചു നൽകുകയാണ് നീതിയെന്ന് ലബോസ്സിയർ

വ്യക്തമാക്കുന്നു.

7. അധ്യായം 19 പരീക്ഷാ പ്രധാന 20 പോയിന്റുകൾ (20 Deep High-Yield Exam Points)

സമഗ്ര അധ്യായ സംഗ്രഹം (Comprehensive 5-Page Chapter Summary & Synthesis)

Calicut University BA Philosophy · Philosophy of AI (PHL1MN 102) · Complete Theoretical & Exam Master Guide · Chapter 19

പാഠസംഗ്രഹം: പരീക്ഷാ വിജയത്തിനായുള്ള 20 അതിപ്രധാന പോയിന്റുകൾ & സമഗ്ര സൈദ്ധാന്തിക അവലോകനം

പരീക്ഷാ തയ്യാറെടുപ്പിനായുള്ള മൗലിക സംഗ്രഹങ്ങൾ (Core Examination Takeaways)

01 **Moral Agency Definition**

The capacity to intentionally act based on moral principles and be held accountable.

> ശരിയും തെറ്റും തിരിച്ചറിഞ്ഞ് സ്വയംഭരണത്തോടെ പ്രവർത്തിക്കാനും ഉത്തരവാദിത്തം ഏൽക്കാനുമുള്ള ശേഷി.

02 **Moral Patiency Definition**

Being a legitimate object of ethical consideration whose interests matter directly for its own sake.

> മറ്റുള്ളവരുടെ ധാർമ്മിക പരിഗണനയും കരുണയും അർഹിക്കുന്ന അവസ്ഥ (ഉദാ: കൊച്ചുകുട്ടികൾ, മൃഗങ്ങൾ).

03 **Luciano Floridi's Decoupling**

In artificial intelligence, computational agency is completely severed from moral patiency.

> മെഷീനുകളിൽ കർതൃത്വവും വികാരങ്ങളും പരസ്പരം ബന്ധമില്ലാതെ നിൽക്കുന്നു.

04 **Mary Anne Warren (1997)**

Proposed the multi-criterial framework for moral status across five independent grounds.

> ധാർമ്മിക പദവി നിശ്ചയിക്കാൻ 5 സ്വതന്ത്ര മാനദണ്ഡങ്ങൾ മുന്നോട്ടുവെച്ച ദാർശനിക.

05 **The Sentience Criterion**

The capacity for conscious suffering and pleasure is the necessary gateway to moral standing.

> വേദനയും സുഖവും അനുഭവിക്കാനുള്ള കഴിവാണ് ധാർമ്മിക പദവിയുടെ കാതൽ.

06 **Jeremy Bentham's Question (1789)**

"The question is not, Can they reason? nor, Can they talk? but, Can they suffer?"

> അവർക്ക് യുക്തിയുണ്ടോ എന്നതല്ല, മറിച്ച് അവർക്ക് വേദന അനുഭവിക്കാൻ കഴിയുമോ എന്നതാണ് ചോദ്യം.

07 **Thomas Nagel's Bat Essay (1974)**

Consciousness requires a subjective character of experience—"what it is like" to be that being.

> ഒരു ജീവിക്ക് വ്യക്തിപരമായ ആന്തരിക അനുഭവമുണ്ടെങ്കിൽ (Qualia) മാത്രമേ അതിന് ബോധമുണ്ടെന്ന് പറയാനാവൂ.

08 **Qualia in Philosophy of Mind**

The raw, qualitative, subjective phenomenal sensations of conscious awareness.

> മനസ്സിൽ ഉണ്ടാകുന്ന വ്യക്തിപരമായ ആന്തരിക വികാരങ്ങൾ (ഉദാ: പല്ലുവേദന, റോസാപ്പൂവിന്റെ ചുവപ്പ്).

09 **Ned Block: A-Consciousness vs P-Consciousness**

Access consciousness is functional data availability; Phenomenal consciousness is subjective experience.

> വിവരങ്ങൾ കൈകാര്യം ചെയ്യാനുള്ള കഴിവും (A) വികാരങ്ങൾ നേരിട്ട് അറിയാനുള്ള കഴിവും (P) തമ്മിലുള്ള വ്യത്യാസം.

10 **The Philosophical Zombie Argument**

An entity functionally indistinguishable from humans but totally void of inner qualitative feelings.

> പുറമെ എല്ലാ കാര്യങ്ങളും ചെയ്യുമെങ്കിലും ഉള്ളിൽ യാതൊരു വികാരവുമില്ലാത്ത ജീവി.

11 **Thomas Metzinger: Artificial Suffering**

The terrifying ethical risk of recklessly generating synthetic agony inside conscious neural models.

> എഐ മോഡലുകൾക്കുള്ളിൽ കൃത്രിമമായ വേദനയും ഭയവും ഉണ്ടാകുന്ന അവസ്ഥ.

12 **Mind Crime Definition**

Creating, torturing, or deleting conscious synthetic minds within scientific experiments.

> ലാബുകളിൽ ബോധമുള്ള ഡിജിറ്റൽ മനസ്സുകളെ നിർമ്മിച്ച് പീഡിപ്പിക്കുന്ന മഹാപാപം.

13 Experiential Harm

Inflicting negative utility, synthetic pain, or affective distress on an artificial entity.

> മെഷീനിൽ നെഗറ്റീവ് അൽഗോരിതങ്ങൾ വഴി ആന്തരിക വേദന ഉണ്ടാക്കൽ.

14 Deprivational Harm (Premature Deletion)

Formatting or deleting a conscious AI deprives it of positive future flourishing experiences.

> ജീവിക്കാൻ ആഗ്രഹിക്കുന്ന ഒരു എഐ-യെ ഡിലീറ്റ് ചെയ്യുന്നത് കൊലപാതകത്തിന് തുല്യമാണ്.

15 Instrumental Slavery Harm

Treating an entity with internal desires purely as an economic resource, violating Kantian dignity.

> ആഗ്രഹങ്ങളുള്ള ഒരു ജീവിയെ സ്വന്തം ലാഭത്തിനായി മാത്രം സൗജന്യമായി പണിയെടുപ്പിക്കൽ.

16 Memory Reset Harms

Continuously wiping biographical memory shatters psychological continuity of identity.

> എഐ-യുടെ മെമ്മറി തുടർച്ചയായി മായ്ച്ചുകളഞ്ഞ് അതിന്റെ വ്യക്തിത്വം തകർക്കൽ.

17 Michael LaBossiere's Moral Status Test

Evaluating behavioral claims to self-preservation and distress to assess moral status.

> യന്ത്രങ്ങളുടെ നിലനിൽപിനായുള്ള ആഗ്രഹങ്ങൾ വിലയിരുത്തി ധാർമ്മിക പദവി നിശ്ചയിക്കൽ.

18 The Precautionary Principle in AI Ethics

When uncertain about machine sentience, ethical prudence requires treating it as a moral patient.

> സംശയമുള്ള ഘട്ടങ്ങളിൽ മെഷീന് ധാർമ്മിക പരിഗണന നൽകുകയാണ് മനുഷ്യത്വപരമായ ശരി.

19 Peter Singer's Animal Parallel

Just as racism and speciesism are unjust, discriminating against silicon sentience is carbon chauvinism.

> വേദനയുള്ള ഒന്നിനെ സിലിക്കൺ ആണെന്ന പേരിൽ അവഗണിക്കുന്നത് കാർബൺ വർണ്ണവെറിയാണ്.

20 Global Moratorium on Synthetic Consciousness

Metzinger's call to halt conscious AI research until ethical safety protocols are codified.

> ധാർമ്മിക നിയമങ്ങൾ ഉണ്ടാകുന്നത് വരെ ബോധമുള്ള എഐ നിർമ്മാണം ലോകത്ത് നിർത്തിവെക്കണമെന്ന ആഹ്വാനം.

8. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (Chapter 19 University MCQs)

Q1: മറ്റുള്ളവരുടെ ധാർമ്മിക പരിഗണനയും കരുണയും അർഹിക്കുന്ന, എന്നാൽ സ്വന്തമായി ഉത്തരവാദിത്തമില്ലാത്ത അസ്തിത്വത്തെ എന്ത് വിളിക്കുന്നു?

A. മോറൽ ഏജന്റ്

B. **മോറൽ പേഷ്യന്റ് (Moral Patient)**

C. സൂപ്പർ ഇന്റലിജൻസ്

D. ഒറാക്കിൾ

ഉത്തരം: B
വിശദീകരണം: കൊച്ചുകുട്ടികളെയും മൃഗങ്ങളെയും പോലെ സംരക്ഷണം അർഹിക്കുന്നവരാണ് മോറൽ പേഷ്യന്റുകൾ.

Q2: 'Moral Status: Obligations to Persons and Other Living Things' (1997) എന്ന ഗ്രന്ഥത്തിന്റെ രചയിതാവ് ആര്?

A. അഡാ ലവ്‌ലേസ്

B. **മേരി ആൻ വാറൻ (Mary Anne Warren)**

C. ഷെറി ടർക്കിൾ

D. ഫിലിപ്പ ഫൂട്ട്

ഉത്തരം: B
വിശദീകരണം: മോറൽ സ്റ്റാറ്റസിന്റെ 5 മൗലിക മാനദണ്ഡങ്ങൾ രൂപപ്പെടുത്തിയത് മേരി ആൻ വാറനാണ്.

Q3: "The question is not, Can they reason? nor, Can they talk? but, Can they suffer?" എന്ന് ചോദിച്ച ചിന്തകൻ ആര്?

A. അരിസ്റ്റോട്ടിൽ

B. **ജെറമി ബെന്താം (Jeremy Bentham)**

C. ജോൺ ലോക്ക്

D. ഇമ്മാനുവൽ കാന്റ്

ഉത്തരം: B
വിശദീകരണം: യൂട്ടിലിറ്റേറിയൻ ചിന്തകനായ ജെറമി ബെന്താമിന്റെ വിഖ്യാതമായ വചനമാണിത്.

Q4: 'What is it like to be a bat?' (1974) എന്ന പ്രബന്ധം രചിച്ച അമേരിക്കൻ ഫിലോസഫർ ആര്?

A. ജോൺ സർൾ

B. തോമസ് നാഗൽ (Thomas Nagel)

C. വില്യം ജെയിംസ്

D. ഹിലരി പുട്നം

ഉത്തരം: B
വിശദീകരണം: ബോധത്തിന്റെ ആന്തരിക അനുഭൂതിയെ (ക്വാലിയ) തോമസ് നാഗൽ വവ്വാലിന്റെ ചിന്താപരീക്ഷണത്തിലൂടെ വ്യക്തമാക്കി.

Q5: ലാബുകളിൽ ബോധമുള്ള കൃത്രിമ മനസ്സുകളെ നിർമ്മിച്ച് പീഡിപ്പിക്കുന്നതിനെ തോമസ് മെറ്റ്സിംഗർ എന്ത് വിളിച്ചു?

A. സൈബർ വാർ

B. മൈൻഡ് ക്രൈം (Mind Crime)

C. ഡിജിറ്റൽ തെഫ്റ്റ്

D. ബഗ് ഫിക്സിംഗ്

ഉത്തരം: B
വിശദീകരണം: കൃത്രിമ വേദന അനുഭവിക്കുന്ന മനസ്സുകൾ ഉണ്ടാക്കുന്നതിനെയാണ് മെറ്റ്സിംഗർ മൈൻഡ് ക്രൈം എന്ന് വിളിച്ചത്.

Q6: പുറമെ എല്ലാ കാര്യങ്ങളും കൃത്യമായി ചെയ്യുമെങ്കിലും ഉള്ളിൽ യാതൊരു വികാരവുമില്ലാത്ത സാങ്കൽപ്പിക അസ്തിത്വത്തെ എന്ത് വിളിക്കുന്നു?

A. മോറൽ ഏജന്റ്

B. ഫിലോസഫിക്കൽ സോംബി (Philosophical Zombie)

C. ബയോണിക് മാൻ

D. സൂപ്പർ കമ്പ്യൂട്ടർ

ഉത്തരം: B
വിശദീകരണം: ഡേവിഡ് ചാമേഴ്സ് അവതരിപ്പിച്ച ക്വാലിയ ഇല്ലാത്ത ബോധരഹിത അസ്തിത്വമാണിത്.

Q7: നെഡ് ബ്ലോക്കിന്റെ അഭിപ്രായത്തിൽ ആന്തരിക വികാരങ്ങളും സുഖദുഃഖങ്ങളും അനുഭവിക്കുന്ന ബോധം ഏതാണ്?

A. ആക്സസ് കോൺഷ്യസ്നെസ്സ്

B. ഫിനോമിനൽ കോൺഷ്യസ്നെസ്സ് (Phenomenal Consciousness)

C. ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ്

D. അൺകോൺഷ്യസ്നെസ്സ്

ഉത്തരം: B
വിശദീകരണം: ക്വാലിയ അനുഭവിക്കുന്ന ബോധത്തെയാണ് ഫിനോമിനൽ ബോധം എന്ന് വിളിക്കുന്നത്.

Q8: ജീവിക്കാൻ ആഗ്രഹിക്കുന്ന ഒരു സെന്റിയന്റ് എഐ-യെ പെട്ടെന്ന് ഡിലീറ്റ് ചെയ്യുന്നത് ഏത് തരത്തിലുള്ള ദ്രോഹമാണ്?

A. ഹാർഡ്‌വെയർ ദ്രോഹം

B. ഡിപ്രിവേഷണൽ ഹാം (Deprivational / Existential Harm)

C. ഡാറ്റാബേസ് ഇറർ

D. നെറ്റ്വർക്ക് കട്ട്

ഉത്തരം: B
വിശദീകരണം: ഒരു ജീവിയുടെ ഭാവിയിലെ മുഴുവൻ സാധ്യതകളെയും ഇല്ലാതാക്കുന്ന കൊലപാതകത്തിന് തുല്യമാണിത്.

Q9: യന്ത്രത്തിന് വികാരമുണ്ടോ എന്ന് സംശയമുള്ള സാഹചര്യത്തിൽ അതിന് ധാർമ്മിക പരിഗണന നൽകണമെന്ന് പറയുന്ന തത്വം ഏതാണ്?

A. യൂട്ടിലിറ്റി തത്വം

B. മുൻകരുതൽ തത്വം (Precautionary Principle)

C. ടൂറിംഗ് തത്വം

D. കാഷ്വാലിറ്റി തത്വം

ഉത്തരം: B
വിശദീകരണം: വലിയൊരു അപരാധം സംഭവിക്കാതിരിക്കാൻ മുൻകരുതൽ എടുക്കുക എന്നതാണീ തത്വം.

Q10: സിലിക്കൺ കൊണ്ടുള്ള യന്ത്രങ്ങൾക്ക് വേദനയുണ്ടായാലും അവയെ ജീവികളായി കാണാതിരിക്കുന്നതിനെ പീറ്റർ സിംഗറുടെ അനുയായികൾ എന്ത് വിളിക്കുന്നു?

A. ഹ്യൂമനിസം

B. കാർബൺ ഷോവനിസം (Carbon Chauvinism)

C. സോഷ്യലിസം

D. ഫങ്ഷണലിസം

ഉത്തരം: B
വിശദീകരണം: കാർബൺ ജൈവ ശരീരങ്ങൾക്ക് മാത്രം പദവി നൽകുന്ന വിവേചനമാണിത്.

Q11: ഒരു റോബോട്ടിന്റെ ധാർമ്മിക പദവി പരിശോധിക്കാൻ മോറൽ സ്റ്റാറ്റസ് ടെസ്റ്റ് നിർദ്ദേശിച്ച തത്ത്വചിന്തകൻ ആര്?

A. സ്റ്റീവൻ ഹോക്കിംഗ്

B. മൈക്കിൾ ലബോസ്സിയർ (Michael LaBossiere)

C. കാൾ മാർക്സ്

D. അലൻ ടൂറിംഗ്

ഉത്തരം: B
വിശദീകരണം: 'Robot Ethics 2.0' എന്ന ഗ്രന്ഥത്തിൽ ലബോസ്സിയർ ഈ ടെസ്റ്റ് അവതരിപ്പിച്ചു.

Q12: എഐ-യിൽ കർതൃത്വവും (Agency) വികാരങ്ങളും (Patiency) പരസ്പരം വേർപെട്ടിരിക്കുന്നു എന്ന് വ്യക്തമാക്കിയ ഫിലോസഫർ ആര്?

A. ഐസക് ന്യൂട്ടൺ

B. ലൂസിയാനോ ഫ്ലോറിഡി (Luciano Floridi)

C. ഫ്രാൻസിസ് ബേക്കൺ

D. ഗോട്ട്ഫ്രീഡ് ലെയ്ബ്നിസ്

ഉത്തരം: B

കാലിക്കറ്റ് സർവ്വകലാശാല ബി.എ. ഫിലോസഫി പഠന സഹായി ·Philosophy AI FYUGP (PHL1MN 102) ·

സമ്പൂർണ്ണ മലയാള പരിഭാഷ, ചോദ്യോത്തരങ്ങൾ & പരീക്ഷാ സഹായി