മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 20: AI സംവിധാനങ്ങൾക്ക് ധാർമ്മിക കർതൃത്വം ഉണ്ടോ? ഉത്തരവാദിത്ത വിചാരം (Moral Agency & Accountability in AI)

Module 4 · Chapter 20: Moral Agency, Responsibility Gap & Deborah Johnson vs John Sullins · Calicut University B.A. Philosophy FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

1. എൽ.എം.എസ് അവലോകനവും പഠന ലക്ഷ്യങ്ങളും (LMS Module Overview & Objectives)

LMS Overview: Syllabus unit 4.3(c) examines the climax of AI ethics: *Can AI systems be moral agents? If so, how should we hold them accountable?* We explore the necessary conditions for moral agency (intentionality, moral reasoning, free will), the famous debate between Deborah Johnson (*Computer Systems: Moral Entities But Not Moral Agents*) and John P. Sullins (*When is a Robot a Moral Agent?*), the Responsibility Gap (Andreas Matthias), and distributed accountability frameworks.

LMS ലക്ഷ്യങ്ങൾ: ധാർമ്മിക കർതൃത്വം (Moral Agency) എന്താണെന്ന് നിർവ്വചിക്കുക; ഡെബോറ ജോൺസന്റെയും ജോൺ സുള്ളിൻസിന്റെയും വിരുദ്ധ വാദങ്ങൾ താരതമ്യം ചെയ്യുക; സ്വതന്ത്ര ഇച്ഛയും (Free Will) ഇന്റൻഷണാലിറ്റിയും AI-ക്ക് ഉണ്ടോ എന്ന് പരിശോധിക്കുക; റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് (The Responsibility Gap) പഠിക്കുക; എഐ വരുത്തുന്ന തെറ്റുകളിൽ നിയമപരവും ധാർമ്മികവുമായ ഉത്തരവാദിത്തം എങ്ങനെ വീതിക്കണം എന്ന് കണ്ടെത്തുക.

2. ധാർമ്മിക കർതൃത്വത്തിന്റെ മാനദണ്ഡങ്ങൾ (Criteria for Moral Agency)

EN **Classical Requirements of Moral Agency:** In classical philosophy, an entity is a genuine **Moral Agent** if and only if it satisfies three strict metaphysical criteria:

1. **Intentionality:** Possessing conscious internal mental states directed toward worldly states of affairs.
2. **Moral Deliberation:** The capacity to reflect upon normative rules, evaluate ethical trade-offs, and comprehend moral concepts like duty, virtue, and fairness.
3. **Free Will & Autonomy:** The capacity to have chosen otherwise, meaning actions are not deterministically hardwired by programming.

Without these conditions, an entity cannot legitimately be praised, blamed, punished, or held morally accountable.

ML **ധാർമ്മിക കർതൃത്വത്തിന്റെ മാനദണ്ഡങ്ങൾ:** തത്ത്വചിന്തയിൽ ഒരാളെ **മോറൽ ഏജന്റ്** (Moral Agent) ആയി കണക്കാക്കണമെങ്കിൽ മൂന്ന് പ്രധാന ഘടകങ്ങൾ നിർബന്ധമാണ്:

1. **ഇന്റൻഷണാലിറ്റി (Intentionality):** ബോധപൂർവ്വമായ ചിന്തയും ലക്ഷ്യബോധവുമുള്ള മനസ്സ് ഉണ്ടായിരിക്കുക.
2. **ധാർമ്മിക വിവേചന ശേഷി:** ശരിയും തെറ്റും എന്താണെന്ന് ചിന്തിക്കാനും, ന്യായവും അന്യായവും തിരിച്ചറിയാനുമുള്ള ബൗദ്ധിക ശേഷി.
3. **ഇച്ഛാസ്വാതന്ത്ര്യം (Free Will):** ഒരു പ്രത്യേക രീതിയിൽ പ്രവർത്തിക്കാൻ ബാഹ്യമായ പ്രോഗ്രാമിംഗിന്റെ പ്രേരണയില്ലാതെ സ്വതന്ത്രമായി തീരുമാനമെടുക്കാനുള്ള കഴിവ്.

ഈ മൂന്ന് ഗുണങ്ങളില്ലാത്ത ഒന്നിനെയും നമുക്ക് കുറ്റപ്പെടുത്താനോ, ശിക്ഷിക്കാനോ, ധാർമ്മികമായി ഉത്തരവാദിയാക്കാനോ കഴിയില്ല.

ധാർമ്മിക കർതൃത്വ തർക്കം (THE MORAL AGENCY DEBATE)

ഡെബോറ ജോൺസൺ (2006)
Deborah Johnson
AI കേവലം മനുഷ്യന്റെ ഉപകരണമാണ്;
ധാർമ്മിക ഉത്തരവാദിത്തം മനുഷ്യർക്ക് മാത്രം

VS

ജോൺ സുള്ളിൻസ് (2006)
John P. Sullins
സ്വയംഭരണവും സാമൂഹിക പങ്കുമുള്ള റോബോട്ടുകൾ
ധാർമ്മിക ഏജന്റുകളായി മാറും

3. ഡെബോറ ജോൺസൺ vs ജോൺ സുള്ളിൻസ് (The Great Debate)

1. ഡെബോറ ജോൺസൺ: 'കമ്പ്യൂട്ടറുകൾ ധാർമ്മിക ഘടകങ്ങളാണ്, എന്നാൽ ഏജന്റുകളല്ല' (Deborah Johnson, 2006):

കമ്പ്യൂട്ടറുകൾക്ക് മനുഷ്യന്റെ ഉദ്ദേശ്യങ്ങളെ പ്രവർത്തനക്ഷമമാക്കാൻ കഴിയും (Intentionality in the system). എന്നാൽ കമ്പ്യൂട്ടറുകൾക്ക് സ്വന്തമായി വികാരങ്ങളോ, മനസ്സാക്ഷിയോ, ഇച്ഛാസ്വാതന്ത്ര്യമോ ഇല്ല. അവ കേവലം

മനുഷ്യർ നിർമ്മിച്ച ഉപകരണങ്ങൾ മാത്രമാണ്. അതിനാൽ ഒരു AI തെറ്റ് വരുത്തിയാൽ അതിന്റെ പൂർണ്ണ ഉത്തരവാദിത്തം അത് നിർമ്മിച്ച എഞ്ചിനീയർമാർക്കും കമ്പനികൾക്കുമാണ്.

2. ജോൺ സുള്ളിൻസ്: 'എപ്പോഴാണ് ഒരു റോബോട്ട് ധാർമ്മിക ഏജന്റാകുന്നത്?' (John P. Sullins, 2006):
ഒരു റോബോട്ടിന് ധാർമ്മിക ഏജന്റാകാൻ പൂർണ്ണമായ മനുഷ്യ മനസ്സ് വേണമെന്നില്ല. മൂന്ന് കാര്യങ്ങൾ ഉണ്ടായാൽ മതി: (1) കാര്യമായ സ്വയംഭരണാധികാരം (Significant Autonomy), (2) ഉദ്ദേശ്യത്തോടെയുള്ള പെരുമാറ്റം (Intentional Behavior), (3) സാമൂഹികമായ ധർമ്മം നിർവ്വഹിക്കൽ (Social Role). ഉദാഹരണത്തിന്, രോഗികളെ പരിചരിക്കുന്ന ഒരു റോബോട്ട് ധാർമ്മിക തീരുമാനങ്ങൾ എടുക്കുന്നുണ്ടെങ്കിൽ അതിനെ ഒരു ഫങ്ഷണൽ മോറൽ ഏജന്റായി കാണണം.

3. ഉത്തരവാദിത്ത വിടവ് (The Responsibility Gap – Andreas Matthias, 2004):
ന്യൂറൽ നെറ്റ്‌വർക്കുകൾ സ്വയം പഠിച്ച് തീരുമാനങ്ങളെടുക്കുമ്പോൾ, അതിന്റെ പ്രവർത്തികൾ എഞ്ചിനീയർമാർക്ക് മുൻകൂട്ടി കാണാൻ കഴിയില്ല. ഒരു മെഷീൻ വലിയ അപകടമുണ്ടാക്കുമ്പോൾ, നിയമപരമായി ആരെ ശിക്ഷിക്കണം എന്നറിയാത്ത പ്രതിസന്ധിയെയാണ് "റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്" എന്ന് വിളിക്കുന്നത്.

4. എൽ.എം.എസ് ചോദ്യോത്തരങ്ങൾ (LMS Questions & In-Depth Answers)

EN **LMS Core Question 1: Why does Deborah Johnson argue that computer systems cannot be moral agents?**
Answer: Johnson argues that agency requires mental states with genuine intentionality and the capacity to suffer punishment. Since computers lack mental states and cannot experience guilt, praise, or legal incarceration, they remain moral entities embedded in human action, but not independent moral agents.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 1: കമ്പ്യൂട്ടറുകൾക്ക് ധാർമ്മിക കർതൃത്വം ഇല്ലെന്ന് ഡെബോറ ജോൺസൺ വാദിക്കുന്നത് എന്തുകൊണ്ട്?**
ഉത്തരം: ഒരു ഏജന്റാകാൻ സ്വന്തമായ മനസ്സും, ചെയ്ത തെറ്റിൽ പശ്ചാത്തപിക്കാനും ശിക്ഷ അനുഭവിക്കാനുമുള്ള ശേഷിയും വേണം. കമ്പ്യൂട്ടറുകൾക്ക് സ്വന്തമായി മനസ്സില്ലാത്തതിനാലും, അവയ്ക്ക് ജയിൽ ശിക്ഷയോ കുറ്റബോധമോ അനുഭവിക്കാൻ കഴിയില്ലെന്നതിനാലും അവ മനുഷ്യന്റെ ഉപകരണങ്ങൾ മാത്രമാണെന്ന് ജോൺസൺ വാദിക്കുന്നു.

EN **LMS Core Question 2: What is "Distributed Moral Accountability"?**
Answer: Formulated by Luciano Floridi, distributed accountability recognizes that in complex AI deployments, moral responsibility does not rest on a single actor, but is distributed across data collectors, algorithm engineers, corporate executives, and regulatory monitors.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 2: 'ഡിസ്ട്രിബ്യൂട്ടഡ് മോറൽ അക്കൗണ്ടബിലിറ്റി' (Distributed Accountability) എന്നാൽ എന്ത്?**
ഉത്തരം: ലൂസിയാനോ ഫ്ലോറിഡി മുന്നോട്ടുവെച്ച ഈ തത്വം അനുസരിച്ച്, ഒരു എഐ വരുത്തുന്ന തെറ്റിന്റെ ഉത്തരവാദിത്തം ഒരാളിൽ മാത്രമായി ഒതുങ്ങുന്നതല്ല; മറിച്ച് ഡാറ്റ ശേഖരിച്ചവർ, കോഡിങ് ചെയ്ത എഞ്ചിനീയർമാർ, ആ സിസ്റ്റം വിറ്റ കമ്പനി, മേൽനോട്ടം വഹിച്ച സർക്കാർ എന്നിവർക്കെല്ലാം തുല്യമായി വീതിക്കപ്പെടേണ്ട ഒന്നാണ്.

5. പരീക്ഷാ കേന്ദ്രീകൃത 20 സുപ്രധാന പോയിന്റുകൾ (20 Deep Exam Points)

1

Moral Agency (ധാർമ്മിക കർതൃത്വം): The status of an entity capable of moral deliberation, intentional action, and bearing moral responsibility. ധാർമ്മികമായി ചിന്തിക്കാനും തീരുമാനങ്ങൾ എടുക്കാനും ഉത്തരവാദിത്തം വഹിക്കാനുമുള്ള ശേഷി.

2

Intentionality Condition: Moral agency requires mental states directed at the world, which machines manipulating syntax lack (Searle). യഥാർത്ഥ മനസ്സിന്റെ ലക്ഷ്യബോധമാണ് ഇന്റൻഷണാലിറ്റി; സിന്റാക്സ് മാത്രം കൈകാര്യം ചെയ്യുന്ന കമ്പ്യൂട്ടറുകൾക്ക് ഇതില്ല.

3

Free Will & Moral Culpability: Praise and blame are legitimate only if the agent possesses moral freedom to choose otherwise. മറ്റൊരു തീരുമാനം എടുക്കാൻ ഇച്ഛാസ്വാതന്ത്ര്യമുള്ള ഒരാൾക്ക് മാത്രമേ തെറ്റിന്റെയോ ശരിയുടെയോ ഉത്തരവാദിത്തം നൽകാനാവൂ.

4

Deborah Johnson's Thesis (2006): Computers are moral entities (carrying out moral acts designed by humans) but can never be moral agents. കമ്പ്യൂട്ടറുകൾ ധാർമ്മിക പ്രവൃത്തികൾ ചെയ്യുമെങ്കിലും അവ മനുഷ്യന്റെ ഉപകരണങ്ങൾ മാത്രമാണ്, ഏജന്റുകളല്ല.

5

John P. Sullins' Functional Agency (2006): A robot achieves functional moral agency if it possesses autonomy, intentional behavior, and a social role. സ്വയംഭരണവും ഉദ്ദേശ്യപൂർവ്വമായ പെരുമാറ്റവും സാമൂഹിക പദവിയുമുള്ള റോബോട്ടുകൾ ധാർമ്മിക ഏജന്റുകളായി മാറും.

6

The Responsibility Gap (Andreas Matthias, 2004): Dilemma where autonomous learning algorithms act in ways unforeseen by their creators, leaving no human legally culpable. അൽഗോരിതങ്ങൾ സ്വന്തമായി പഠിച്ച് അപകടമുണ്ടാക്കുമ്പോൾ ആർക്കും പൂർണ്ണ ഉത്തരവാദിത്തം ഇല്ലാതെ വരുന്ന അവസ്ഥ.

7

Human Stakeholder Accountability: Since machines cannot pay damages or experience remorse, legal liability must rest on human developers and deployers. യന്ത്രങ്ങൾക്ക് കുറ്റബോധമോ പണമോ ഇല്ലാത്തതിനാൽ നിയമപരമായ ശിക്ഷ മനുഷ്യ നിർമ്മാതാക്കൾക്കാണ് നൽകേണ്ടത്.

8

The Retribution Problem: We cannot morally punish an algorithm; unplugging a server does not satisfy justice or deliver moral retribution. ഒരു സോഫ്റ്റ്വെയറിനെ ജയിലിൽ അടയ്ക്കാനോ ശിക്ഷിക്കാനോ കഴിയില്ലെന്നതിനാൽ അതിനെ ശിക്ഷിക്കുന്നത് അർത്ഥശൂന്യമാണ്.

9

Distributed Moral Accountability (Luciano Floridi): Responsibility in multi-agent systems is shared across human networks, institutions, and algorithmic components. എഐ സിസ്റ്റത്തിലെ ഉത്തരവാദിത്തം ഡെവലപ്പർമാരും കമ്പനികളും സർക്കാരും തമ്മിൽ പങ്കിട്ടെടുക്കണം.

10

Strict Legal Liability for AI: Treating autonomous AI under strict product liability laws similar to defective aircraft or dangerous pharmaceuticals. അപകടമുണ്ടാക്കുന്ന AI-യെ കേടായ മരുന്നുകൾക്കോ വിമാനങ്ങൾക്കോ സമാനമായി നിർമ്മാതാവിന്റെ ബാധ്യതയായി കാണുന്ന നിയമം.

11

Functional vs Metaphysical Agency: Functional agency looks at behavioral outputs; metaphysical agency requires genuine conscious mind and free will. പെരുമാറ്റത്തെ മാത്രം നോക്കുന്നത് ഫങ്ഷണൽ ഏജൻസിയും, ആന്തരിക മനസ്സിനെ നോക്കുന്നത് മെറ്റാഫിസിക്കൽ ഏജൻസിയുമാണ്.

12

The Fallacy of Blaming the Algorithm: Corporations using "the algorithm made the mistake" as a shield to evade executive moral culpability. കമ്പനികൾ തങ്ങളുടെ അനാസ്ഥ മറച്ചുവെക്കാൻ 'അൽഗോരിതത്തിന് തെറ്റുപറ്റി' എന്ന് പറഞ്ഞ് ഒഴിഞ്ഞുമാറുന്ന പ്രവണത.

13

Electronic Personhood Debate (EU 2017): Controversial proposal to grant advanced autonomous robots a limited legal status similar to corporate legal persons. കോർപ്പറേഷനുകൾക്ക് നിയമപരമായ വ്യക്തിത്വം നൽകുന്നതുപോലെ റോബോട്ടുകൾക്കും ലീഗൽ സ്റ്റാറ്റസ് നൽകണമെന്ന വാദം.

14

Meaningful Human Control (MHC): Ethical principle requiring that high-stakes autonomous systems always remain under meaningful human supervision. മാരകമായ ആയുധങ്ങളിലും മറ്റും അവസാന തീരുമാനം മനുഷ്യന്റേതായിരിക്കണം എന്ന് അനുശാസിക്കുന്ന തത്വം.

15

Autonomous Weapons Systems (LAWS): The ethical prohibition against allowing algorithms to make autonomous kill decisions without human moral intervention. മനുഷ്യന്റെ ഇടപെടലില്ലാതെ സ്വയം വെടിവെക്കാൻ റോബോട്ടുകൾക്ക് അധികാരം നൽകുന്നത് അന്താരാഷ്ട്ര ധാർമ്മികതയ്ക്ക് വിരുദ്ധമാണ്.

16

Sentience as a Bridge to Moral Agency: If an artificial agent developed true phenomenal consciousness, it would transition from a tool to a moral peer. ഭാവിയിൽ യന്ത്രങ്ങൾക്ക് സ്വയം ബോധം ഉണ്ടായാൽ അവ കേവലം ഉപകരണങ്ങൾ അല്ലാതെയായി മാറും.

17

Moral Luck in Automated Systems: Evaluating whether stochastic probabilistic outputs of neural networks exempt designers from moral responsibility. യാദൃശ്ചികമായി ഉണ്ടാകുന്ന അൽഗോരിതമിക് പിഴവുകളിൽ എഞ്ചിനീയർമാർ കുറ്റക്കാരാണോ എന്ന ചോദ്യം.

18

Ethical Black Boxes: The legal mandate that every autonomous agent record its sensory inputs and decision paths for moral accountability. ധാർമ്മിക ഓഡിറ്റിംഗിനായി എഐ സംവിധാനങ്ങൾ തങ്ങളുടെ തീരുമാനങ്ങൾ രേഖപ്പെടുത്തി സൂക്ഷിക്കണം.

19

Corporate Moral Responsibility: Tech monopolies profiting from AI deployment must establish victim compensation funds for algorithmic harms. എഐ വരുത്തുന്ന നഷ്ടങ്ങൾക്ക് ഇരകൾക്ക് നഷ്ടപരിഹാരം നൽകാൻ കമ്പനികൾ ബാധ്യസ്ഥരാണ്.

Human Dignity and Non-Delegable Moral Duties: Sentencing criminals, declaring war, and caring for dying patients are inherently non-delegable human duties. ചില കടമകൾ കമ്പ്യൂട്ടറുകളെ ഏൽപ്പിക്കാൻ പാടില്ലാത്ത മനുഷ്യന്റെ മൗലികമായ ചുമതലകളാണ്.

6. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (MCQs & Solutions)

Q103: A Moral Agent is formally defined in philosophy as an entity that:

A. Performs rapid numerical calculations

B. Deliberates about moral rules, distinguishes right from wrong, and is held morally responsible (ശരിയുത്തരം)

C. Automatically controls building temperature settings

D. Stores petabytes of digital database records

പാഠഭാഗ വിശകലനം: ധാർമ്മിക നിയമങ്ങൾ മനസ്സിലാക്കാനും, ശരിയും തെറ്റും തിരിച്ചറിഞ്ഞ് ഉത്തരവാദിത്തം ഏറ്റെടുക്കാനും കഴിയുന്ന അസ്തിത്വമാണ് മോറൽ ഏജന്റ്.

വിശദീകരണം: വെറും കണക്കുകൂട്ടലുകൾക്കപ്പുറം മനസ്സാക്ഷിയോടെ ധാർമ്മിക തീരുമാനങ്ങൾ എടുക്കാൻ കഴിയുന്നവരാണ് ഏജന്റുകൾ.

Q104: What are the two universally accepted philosophical pre-conditions of genuine moral agency?

A. Computational speed and data storage

B. Intentionality (conscious mental states) and genuine moral autonomy / free will (ശരിയുത്തരം)

C. High-speed internet connectivity and wireless power

D. Hardware circuit durability and battery lifespan

പാഠഭാഗ വിശകലനം: ബോധപൂർവ്വമായ ഇന്റൻഷണാലിറ്റിയും, സ്വതന്ത്രമായ ഇച്ഛാശക്തിയും (Free will) ഉണ്ടെങ്കിൽ മാത്രമേ ധാർമ്മിക കർതൃത്വം ഉണ്ടാകൂ.

വിശദീകരണം: യന്ത്രങ്ങൾക്ക് ആന്തരിക മനസ്സോ ഇച്ഛാസ്വാതന്ത്ര്യമോ ഇല്ലാത്തതിനാലാണ് അവ യഥാർത്ഥ ഏജന്റുകൾ അല്ലാതാകുന്നത്.

Q105: In normative moral philosophy, an agent can legitimately be praised or blamed only if they acted with:

A. Infinite computer memory capacity

B. Free Will (the moral autonomy to have chosen otherwise) (ശരിയുത്തരം)

C. Rigid pre-programmed mathematical determinism

D. Statistical image classification accuracy

പാഠഭാഗ വിശകലനം: മറ്റൊന്ന് തിരഞ്ഞെടുക്കാൻ സ്വാതന്ത്ര്യമുള്ളപ്പോൾ മാത്രമേ ഒരാളെ കുറ്റപ്പെടുത്താനോ പ്രശംസിക്കാനോ സാധിക്കൂ.

വിശദീകരണം: മുൻകൂട്ടി കോഡ് ചെയ്തതനുസരിച്ച് മാത്രം പ്രവർത്തിക്കുന്ന ഒരു യന്ത്രത്തെ കുറ്റപ്പെടുത്താൻ കഴിയില്ല.

Q106: When an autonomous AI system inflicts harm, where does legal and moral accountability primarily rest?

A. On the computer algorithm itself which should be sued in court

B. On the human stakeholders—developers, deployment organizations, and executives (ശരിയുത്തരം)

C. On random chance and cosmic bad luck

D. On the electricity grid supplying power

പാഠഭാഗ വിശകലനം: എഐ വരുത്തുന്ന തെറ്റുകളുടെ പൂർണ്ണ ഉത്തരവാദിത്തം അത് നിർമ്മിച്ച മനുഷ്യർക്കും കമ്പനികൾക്കുമാണ്.

വിശദീകരണം: യന്ത്രം വെറുമൊരു ഉപകരണമായതിനാൽ മനുഷ്യ നിർമ്മാതാക്കൾക്കാണ് നിയമപരമായ ശിക്ഷ നൽകേണ്ടത്.

Q107: If a future AI system attained genuine phenomenal consciousness and moral autonomy, it would be treated as:

A. A mere disposable tool

B. A moral agent possessing rights and moral accountability (ശരിയുത്തരം)

C. An inanimate household appliance

D. A simple mathematical lookup matrix

പാഠഭാഗ വിശകലനം: ഭാവിയിൽ ഒരു യന്ത്രത്തിന് ബോധവും ഇച്ഛാസ്വാതന്ത്ര്യവും ലഭിച്ചാൽ അതിനെ ഒരു മോറൽ ഏജന്റായി പരിഗണിക്കേണ്ടി വരും.

വിശദീകരണം: ആത്മബോധമുള്ള ഒരു അസ്തിത്വത്തെ വെറുമൊരു ഉപകരണമായി കണ്ട് അവഗണിക്കാൻ കഴിയില്ല.