മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 20: AI സംവിധാനങ്ങൾക്ക് ധാർമ്മിക കർതൃത്വം ഉണ്ടോ? ഉത്തരവാദിത്ത വിചാരം (Moral Agency & Accountability in AI)

Module 4 · Chapter 20: Moral Agency, Responsibility Gap & Deborah Johnson vs John Sullins · Calicut University B.A. Philosophy FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

1. എൽ.എം.എസ് അവലോകനവും പഠന ലക്ഷ്യങ്ങളും (LMS Module Overview & Objectives)

LMS Overview: കാലിക്കറ്റ് സർവ്വകലാശാലയുടെ ഫിലോസഫി ഓഫ് ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് (PHL1MN 102) മൊഡ്യൂൾ 4-ന്റെ സമാപന അധ്യായമായ ഇരുപതാം അധ്യായം സമകാലിക സാങ്കേതിക നീതിശാസ്ത്രത്തിലെ ഏറ്റവും ചൂടേറിയ തത്ത്വചിന്താ സംവാദമാണ് ചർച്ച ചെയ്യുന്നത്: *"റോബോട്ടുകൾക്കും സ്വയംഭരണ എഐ സംവിധാനങ്ങൾക്കും ധാർമ്മിക കർതൃത്വം (Moral Agency) ഉണ്ടോ? ഒരു മെഷീൻ വരുത്തിവെക്കുന്ന ദുരന്തങ്ങൾക്ക് ആരെയാണ് നിയമപരമായും ധാർമ്മികമായും പ്രതിക്കൂട്ടിൽ നിർത്തേണ്ടത്?"* ഡെബോറ ജോൺസന്റെയും ജോൺ സുള്ളിൻസിന്റെയും പരസ്പരവിരുദ്ധമായ നിലപാടുകൾ, ആൻഡ്രിയാസ് മത്തിയാസ് മുന്നോട്ടുവെച്ച 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്', യൂറോപ്യൻ യൂണിയൻ നിർദ്ദേശിച്ച ഇലക്ട്രോണിക് പേഴ്സൺഹുഡ്, ലൂസിയാനോ ഫ്ലോറിഡിയുടെ ഡിസ്ട്രിബ്യൂട്ടഡ് അക്കൗണ്ടബിലിറ്റി എന്നിവ ഇവിടെ സമഗ്രമായി വിശകലനം ചെയ്യപ്പെടുന്നു.

LMS പഠന ലക്ഷ്യങ്ങൾ (Learning Objectives):

- ധാർമ്മിക കർതൃത്വത്തിന്റെ (Moral Agency) പരമ്പരാഗത മാനദണ്ഡങ്ങൾ (ഇച്ഛാസ്വാതന്ത്ര്യം, ഇന്റൻഷണാലിറ്റി, ധാർമ്മിക ബോധം) നിർവ്വചിക്കുക.
- ഫുൾ മോറൽ ഏജൻസിയും ഫങ്ഷണൽ മോറൽ ഏജൻസിയും (Functional Moral Agency – Wallach & Allen) തമ്മിലുള്ള വ്യത്യാസം മനസ്സിലാക്കുക.
- ഡെബോറ ജോൺസന്റെ "കമ്പ്യൂട്ടറുകൾ ധാർമ്മിക എന്റിറ്റികളാണ്, ഏജന്റുകളല്ല" എന്ന വാദവും, ജോൺ സുള്ളിൻസിന്റെ മൂന്ന് മാനദണ്ഡങ്ങളും തമ്മിലുള്ള സംവാദം വിലയിരുത്തുക.
- ആൻഡ്രിയാസ് മത്തിയാസിന്റെ 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്' (The Responsibility Gap) എന്ന പ്രതിസന്ധി അപഗ്രഥിക്കുക.
- റോബോട്ടുകൾക്ക് നിയമപരമായ വ്യക്തിത്വം നൽകുന്നതിനെതിരെയുള്ള വാദങ്ങളും (Electronic Personhood as Liability Shield) കോർപ്പറേറ്റ് ഉത്തരവാദിത്തവും പഠിക്കുക.
- ലൂസിയാനോ ഫ്ലോറിഡിയുടെ 'വിതരണം ചെയ്യപ്പെട്ട ധാർമ്മിക ഉത്തരവാദിത്തം' (Distributed Moral Accountability) വിശകലനം ചെയ്യുക.

ധാർമ്മിക കർതൃത്വവും ഉത്തരവാദിത്ത വിടവും (MORAL AGENCY & RESPONSIBILITY GAP ARCHITECTURE)



2. ധാർമ്മിക കർതൃത്വത്തിന്റെ മാനദണ്ഡങ്ങൾ (Criteria for Moral Agency)

EN **Classical Philosophy of Moral Agency:** In classical Kantian and Aristotelian philosophy, an entity qualifies as a **Moral Agent** if and only if it fulfills three indispensable philosophical conditions:

1. **Autonomy & Free Will:** The entity must have genuine volition and freedom of choice, possessing the capacity to act otherwise rather than merely executing deterministic programming.
2. **Intentionality:** The entity must possess subjective beliefs, desires, and conscious purposes directed toward the world (Brentano's intentionality).
3. **Moral Understanding:** The entity must comprehend moral principles, recognizing concepts like duty, justice, cruelty, and fairness.

Levels of Artificial Morality (Colin Allen & Wendell Wallach): In *Moral Machines* (2008), Wallach and Allen propose a taxonomy to resolve whether machines can be moral:

- **Operational Morality:** Basic safety switches (e.g., a toaster that pops up to prevent burning bread). Morality resides entirely in the human designer.
- **Functional Morality:** Systems capable of computing and responding to morally sensitive situations without direct human oversight (e.g., an autonomous vehicle applying collision avoidance).
- **Full Moral Agency:** Autonomous consciousness and moral understanding equal to a rational human adult. Current AI completely lacks full agency.

ML **ധാർമ്മിക കർതൃത്വത്തിന്റെ പരമ്പരാഗത തത്ത്വങ്ങൾ:** ഇമ്മാനുവൽ കാന്റിന്റെയും അരിസ്റ്റോട്ടിലിന്റെയും തത്ത്വചിന്തയനുസരിച്ച്, ഒരാളെ 'മോറൽ ഏജന്റ്' (Moral Agent) എന്ന് വിളിക്കണമെങ്കിൽ മൂന്ന് പ്രധാന കാര്യങ്ങൾ ഉണ്ടായിരിക്കണം:

1. **ഇച്ഛാസ്വാതന്ത്ര്യം (Free Will & Autonomy):** സ്വന്തം ഇഷ്ടപ്രകാരം തിരഞ്ഞെടുപ്പുകൾ നടത്താനുള്ള സ്വാതന്ത്ര്യം. വെറും കോഡിംഗ് അനുസരിച്ച് മാത്രം പ്രവർത്തിക്കുന്ന ഒന്നാകാൻ പാടില്ല.
2. **ഇന്റൻഷണാലിറ്റി (Intentionality):** തന്റെ പ്രവൃത്തിയുടെ ഫലം എന്തായിരിക്കുമെന്ന് മനസ്സിലാക്കിക്കൊണ്ടുള്ള ആന്തരികമായ ഉദ്ദേശ്യം (ഉള്ളിലിരിപ്പ്).
3. **ധാർമ്മിക ബോധം (Moral Understanding):** എന്താണ് നീതി, എന്താണ് തെറ്റ്, എന്താണ് ക്രൂരത എന്ന് തിരിച്ചറിയാനുള്ള വിവേചനബുദ്ധി.

യന്ത്രങ്ങളുടെ ധാർമ്മികതയുടെ മൂന്ന് തലങ്ങൾ (Wallach & Allen): വെൻഡൽ വാലാക്കും കോളിൻ അല്ലനും ചേർന്ന് യന്ത്രങ്ങളുടെ ധാർമ്മികതയെ മൂന്നായി തരംതിരിക്കുന്നു:

- **ഓപ്പറേഷണൽ മൊറാലിറ്റി:** ഡിസൈനർ നിശ്ചയിച്ച സുരക്ഷാ നിയമങ്ങൾ മാത്രം അനുസരിക്കൽ (ഉദാ: ബ്രെഡ് കരിയാതെ തനിയെ ഓഫ് ആകുന്ന ടോസ്റ്റർ). ഇവിടെ യന്ത്രത്തിന് ധാർമ്മികതയില്ല, ഡിസൈനർക്കാണ് ധാർമ്മികത.
- **ഫങ്ഷണൽ മൊറാലിറ്റി:** സങ്കീർണ്ണമായ സന്ദർഭങ്ങളിൽ മനുഷ്യന്റെ ഇടപെടലില്ലാതെ സ്വയം സദാചാരപരമായ തീരുമാനങ്ങൾ എടുക്കാനുള്ള ശേഷി (ഉദാ: സ്വയംഭരണ കാറുകൾ).

- **ഫുൾ മോറൽ ഏജൻസി:** മനുഷ്യനെപ്പോലെ പൂർണ്ണമായ മനസ്സാക്ഷിയും ബോധവുമുള്ള അവസ്ഥ. ഇന്നത്തെ ഒരു എഐ-ക്കും ഈ പദവിയില്ല.

3. ഡെബോറ ജോൺസൺ vs ജോൺ സുള്ളിൻസ് സംവാദം (Deborah Johnson vs John P. Sullins Debate)

റോബോട്ടുകൾക്ക് ധാർമ്മിക കർതൃത്വം ഉണ്ടോ എന്ന വിഷയത്തിൽ ലോകപ്രശസ്തമായ രണ്ട് തത്ത്വചിന്താ നിലപാടുകൾ താഴെ പറയുന്നവയാണ്:

തത്ത്വചിന്തകൻ	മൗലിക വാദം (Core Philosophical Thesis)	റോബോട്ടുകളുടെ പദവി (Status of Robots)
ഡെബോറ ജി. ജോൺസൺ (Deborah G. Johnson, 2006)	"കമ്പ്യൂട്ടർ സിസ്റ്റങ്ങൾ ധാർമ്മിക എന്റിറ്റികളാണ് (Moral Entities), എന്നാൽ അവ ഒരിക്കലും ധാർമ്മിക ഏജന്റുകളല്ല (Not Moral Agents)."	യന്ത്രങ്ങൾ മനുഷ്യന്റെ ആഗ്രഹങ്ങൾ നടപ്പിലാക്കുന്ന ഉപകരണങ്ങൾ (Prostheses) മാത്രമാണ്. അവയ്ക്ക് സ്വന്തമായി ഇന്റൻഷണാലിറ്റി ഇല്ല.
ജോൺ പി. സുള്ളിൻസ് (John P. Sullins, 2006)	"റോബോട്ടുകൾ മനുഷ്യന്റെ കൃത്യമായ നിയന്ത്രണമില്ലാതെ സ്വതന്ത്രമായി പെരുമാറുമ്പോൾ അവ ഫങ്ഷണൽ മോറൽ ഏജന്റുകളാണ്."	യന്ത്രത്തിന് ഗണ്യമായ സ്വയംഭരണവും, ഉദ്ദേശ്യപൂർവ്വമായ പെരുമാറ്റവും, സാമൂഹിക പങ്കാളിത്തവും ഉണ്ടെങ്കിൽ അതിന് മോറൽ ഏജൻസിയുണ്ട്.

EN **1. Deborah Johnson's Instrumental Perspective:** In *Computer Systems: Moral Entities But Not Moral Agents* (2006), Deborah Johnson argues that computers have moral character only in the sense that they are artifacts designed by humans to produce moral consequences in the world. An autonomous bomb disposal robot embodies human moral intentions (saving soldiers). However, intentionality requires consciousness, mental states, and socio-cultural grounding—qualities exclusive to human beings. A computer's "actions" are merely surrogate extensions of human action. Holding a computer morally responsible is as absurd as placing a hammer or an automobile on trial.

2. John P. Sullins's Functional Defense: In *When is a Robot a Moral Agent?* (2006), John P. Sullins rejects Johnson's biological anthropocentrism. Sullins argues that if we wait for conscious artificial free will, we ignore the pressing reality of autonomous machines acting in society. Sullins establishes three criteria for **Artificial Moral Agency (AMA)**:

1. **Significant Autonomy:** The machine is not remotely controlled by a human and makes real-time decisions without human teleoperation.
2. **Intentional Behavior:** The machine's actions cannot be explained by mere mechanical reflex; they can only be understood by attributing goals, plans, and beliefs to it (Daniel Dennett's *Intentional Stance*).
3. **Social Role:** The machine performs an ethical function in a community (e.g., an automated medical diagnostic robot, a robotic nursing assistant, or a security sentry).

ML **1. ഡെബോറ ജോൺസന്റെ നിലപാട് (ഉപകരണ വാദം):** ഡെബോറ ജോൺസൺ സമർത്ഥിക്കുന്നത്, കമ്പ്യൂട്ടറുകൾ മനുഷ്യൻ നിർമ്മിച്ച ഉപകരണങ്ങൾ (Artifacts) മാത്രമാണ്. അവ മനുഷ്യന്റെ നന്മയോ തിന്മയോ നടപ്പിലാക്കുന്നു എന്ന അർത്ഥത്തിൽ അവയ്ക്ക് 'ധാർമ്മിക സ്വഭാവം' (Moral Entity) ഉണ്ടെന്ന് പറയാമെങ്കിലും, അവ ഒരിക്കലും സ്വയംഭരണമുള്ള 'ധാർമ്മിക കർത്താക്കൾ' (Moral Agents) അല്ല. ഒരു കൊലപാതകം നടക്കുമ്പോൾ തോക്കിനെയല്ല നമ്മൾ ജയിലിലടയ്ക്കുന്നത്, തോക്കുപയോഗിച്ച മനുഷ്യനെയാണ്. അതുപോലെ റോബോട്ടിന് സ്വന്തമായി ആഗ്രഹങ്ങളോ മനസ്സാക്ഷിയോ ഇല്ലാത്തതിനാൽ ഉത്തരവാദിത്തം അത് നിർമ്മിച്ച മനുഷ്യനാണ്.

2. ജോൺ സുള്ളിൻസിന്റെ ഫങ്ഷണൽ വാദം: ജോൺ സുള്ളിൻസ് ജോൺസന്റെ വാദത്തെ എതിർക്കുന്നു. മനുഷ്യനെപ്പോലെ ബോധമുണ്ടാകുന്നത് വരെ കാത്തിരുന്നാൽ റോബോട്ടുകൾ ഇന്ന് സമൂഹത്തിൽ വരുത്തിവെക്കുന്ന പ്രശ്നങ്ങൾ പരിഹരിക്കാനാവില്ല. ഒരു റോബോട്ടിന് താഴെ പറയുന്ന മൂന്ന് കാര്യങ്ങൾ ഉണ്ടെങ്കിൽ അതിനെ ഒരു മോറൽ ഏജന്റായി കാണാം:

1. **കാര്യമായ സ്വയംഭരണം (Significant Autonomy):** മനുഷ്യൻ റിമോട്ട് കൺട്രോൾ വഴി നിയന്ത്രിക്കാതെ സ്വന്തമായി തീരുമാനമെടുക്കൽ.
2. **ലക്ഷ്യബോധമുള്ള പെരുമാറ്റങ്ങൾ (Intentional Behavior):** കേവലം ഇലക്ട്രിക് സ്വിച്ച് പോലെയല്ലാതെ, ഒരു പ്രത്യേക ലക്ഷ്യം നേടാനായി തന്ത്രങ്ങൾ മെനയുന്ന സ്വഭാവം.
3. **സാമൂഹിക പങ്ക് (Social Role):** സമൂഹത്തിൽ ഡോക്ടറെപ്പോലെയോ നഴ്സിനെപ്പോലെയോ കാവൽക്കാരനെപ്പോലെയോ ധാർമ്മികമായ ഒരു ജോലി ചെയ്യൽ.

4. ഉത്തരവാദിത്ത വിടവും കൺട്രോൾ ഡിസിലൂഷനും (The Responsibility Gap – Andreas Matthias)

ആൻഡ്രിയാസ് മത്തിയാസിന്റെ 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്" (Andreas Matthias, 2004)

2004-ൽ തത്ത്വചിന്തകനായ ആൻഡ്രിയാസ് മത്തിയാസ് രചിച്ച *The Responsibility Gap: Ascribing Responsibility for the Actions of Learning Automata* എന്ന ലേഖനം ലോകമെമ്പാടുമുള്ള നിയമജ്ഞരെയും ഫിലോസഫർമാരെയും ഞെട്ടിച്ചു. പരമ്പരാഗത നീതിശാസ്ത്രത്തിൽ ഒരാളെ കുറ്റക്കാരനായി കാണണമെങ്കിൽ രണ്ട് നിബന്ധനകളുണ്ട്: അയാൾക്ക് ആ പ്രവൃത്തിയിൽ **നിയന്ത്രണം** (Control) ഉണ്ടായിരിക്കണം, അതിന്റെ ഫലങ്ങളെക്കുറിച്ച് **മുൻകൂട്ടി അറിയാൻ** (Foresight) സാധിക്കണം. എന്നാൽ മെഷീൻ ലേണിംഗ് ഈ സമവാക്യത്തെ തകിടം മറിച്ചു!

EN **The Mechanism of the Responsibility Gap:** Classical software executed explicit lines of code written by a human programmer. If the software crashed a plane, the programmer was liable for a coding bug. Modern artificial neural networks, however, learn inductively via interaction with open environments (reinforcement learning, evolutionary computation).

Consequently:

- The human programmer does not specify the decision rules of the model; the model programs itself.
- The model's emergent behavior in novel situations cannot be predicted or controlled by the designer.
- Under classical ethics, it is morally unjust to hold a human engineer criminally liable for actions they could not foresee, prevent, or understand.
- Yet, the software system itself cannot be subjected to meaningful moral blame or retributive punishment.

This produces a dangerous ethical void: **The Responsibility Gap**—harm has occurred, but neither the designer, the user, nor the machine can be held morally accountable.

ML **റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് ഉണ്ടാകുന്ന വിധം:** പഴയകാല കമ്പ്യൂട്ടറുകളിൽ എഞ്ചിനീയർ എഴുതിയ കോഡുകളാണ് പ്രവർത്തിച്ചിരുന്നത്; അതിനാൽ തെറ്റ് സംഭവിച്ചാൽ എഞ്ചിനീയർ കുറ്റക്കാരനായിരുന്നു. എന്നാൽ ഇന്നത്തെ മെഷീൻ ലേണിംഗ് സിസ്റ്റങ്ങൾ തനിയെ അന്തരീക്ഷത്തിൽ നിന്ന് പഠിച്ച് സ്വയം കോഡുകൾ നിർമ്മിക്കുകയാണ് ചെയ്യുന്നത് (Self-Learning Algorithms).

ഇതിന്റെ അനന്തരഫലം എന്തെന്നാൽ:

- മെഷീൻ എന്ത് തീരുമാനമെടുക്കുമെന്ന് അത് നിർമ്മിച്ച എഞ്ചിനീയർക്ക് മുൻകൂട്ടി പ്രവചിക്കാൻ കഴിയില്ല.
- തനിക്ക് നിയന്ത്രണമില്ലാത്ത ഒരു കാര്യത്തിന് എഞ്ചിനീയറെ പിടിച്ച് ജയിലിലടയ്ക്കുന്നത് സ്വാഭാവിക നീതിക്ക് വിരുദ്ധമാണ്.
- അതേസമയം തെറ്റ് ചെയ്ത സോഫ്റ്റ്വെയറിനെ ശിക്ഷിക്കാനും കഴിയില്ല!

ഇവിടെ ഒരു വലിയ ധാർമ്മിക വിടവ് (The Responsibility Gap) രൂപപ്പെടുന്നു: വലിയൊരു ദുരന്തം സംഭവിച്ചിരിക്കുന്നു, എന്നാൽ അതിന്റെ കുറ്റം ആരുടെയും തലയിൽ വെക്കാൻ കഴിയാത്ത ഒരു അനാഥാവസ്ഥ!

5. ഇലക്ട്രോണിക് പേഴ്സൺഹുഡും കോർപ്പറേറ്റ് ഷീൽഡിംഗും (Electronic Personhood as Liability Shield)

യൂറോപ്യൻ പാർലമെന്റിന്റെ 2017 പ്രമേയവും വിവാദങ്ങളും (The Electronic Personhood Controversy)

2017-ൽ യൂറോപ്യൻ പാർലമെന്റ് (മാഡി ഡെൽവോ കമ്മിറ്റി) സ്വയംഭരണ റോബോട്ടുകൾ വരുത്തുന്ന നഷ്ടങ്ങൾ പരിഹരിക്കാൻ അവയ്ക്ക് കമ്പനികളെപ്പോലെ (Corporate Personhood) ഒരു **ഇലക്ട്രോണിക് വ്യക്തിത്വം** (Electronic Personhood) നൽകണമെന്ന് ശുപാർശ ചെയ്തു. എന്നാൽ ഇതിനെതിരെ ലോകമെമ്പാടുമുള്ള 150-

ലധികം മുൻനിര എഐ ശാസ്ത്രജ്ഞരും തത്ത്വചിന്തകരും ഒപ്പിട്ട പരസ്യമായ ഒരു കത്ത് (Open Letter) പുറത്തിറക്കി.

EN **Why AI Ethicists Strongly Oppose Electronic Personhood:** The open letter warned that granting legal personhood to robots creates a profound moral and economic hazard:

1. **The Corporate Liability Shield:** Multinational corporations (e.g., Google, Tesla, Microsoft) could register their AI algorithms as independent legal persons with separate bank accounts. If an autonomous algorithm crashes a financial market or a medical robot kills patients, the algorithm goes bankrupt, while the multi-billion-dollar parent corporation walks away with zero civil or criminal liability. The robot serves as a corporate scapegoat.
2. **Absurdity of Retributive Punishment:** Punishment requires the capacity for suffering, remorse, or moral repentance (Retributive Justice). You cannot "punish" an algorithm by deleting it, turning off its power, or revoking its digital license—it experiences no penal consequence. Punishment becomes an empty farce.

ML **ഇലക്ട്രോണിക് പേഴ്സൺഹുഡിനെ എതിർക്കാനുള്ള കാരണങ്ങൾ:** ശാസ്ത്രജ്ഞർ ഈ നിർദ്ദേശത്തെ ശക്തമായി എതിർക്കാൻ രണ്ട് പ്രധാന കാരണങ്ങളുണ്ട്:

1. **കോർപ്പറേറ്റ് സംരക്ഷണ കവചം (Liability Shield):** റോബോട്ടുകൾക്ക് നിയമപരമായ വ്യക്തിത്വം നൽകിയാൽ, വൻകിട കമ്പനികൾ അവരുടെ മെഷീനുകളുടെ പേരിൽ ബാങ്ക് അക്കൗണ്ടുകൾ തുടങ്ങും. മെഷീൻ ഒരു വൻ ദുരന്തം ഉണ്ടാക്കിയാൽ, റോബോട്ടിന്റെ അക്കൗണ്ടിലെ പണം നഷ്ടപരിഹാരമായി നൽകി കമ്പനി മുതലാളിമാർ സുരക്ഷിതമായി രക്ഷപ്പെടും. മനുഷ്യർ തങ്ങളുടെ തെറ്റുകൾ യന്ത്രത്തിന്റെ തലയിൽ വെച്ച് രക്ഷപ്പെടാൻ ഇത് വഴിയൊരുക്കും.
2. **ശിക്ഷയുടെ അർത്ഥശൂന്യത:** ഒരു കുറ്റവാളിയെ ശിക്ഷിക്കുന്നത് അയാൾക്ക് പശ്ചാത്താപം തോന്നാനാണ്. എന്നാൽ ഒരു കമ്പ്യൂട്ടറിനെ സ്വിച്ച് ഓഫ് ചെയ്യുതുകൊണ്ടോ ഡിലീറ്റ് ചെയ്യുതുകൊണ്ടോ അതിന് യാതൊരു വേദനയോ പശ്ചാത്താപമോ തോന്നുന്നില്ല. അതിനാൽ യന്ത്രങ്ങളെ ശിക്ഷിക്കുക എന്നത് ഒരു പ്രഹസനമാണ്.

6. വിതരണം ചെയ്യപ്പെട്ട ധാർമ്മിക ഉത്തരവാദിത്തം (Distributed Moral Accountability – Luciano Floridi)

ലൂസിയാനോ ഫ്ലോറിഡിയുടെ 'ഡിസ്ട്രിബ്യൂട്ടഡ് അക്കൗണ്ടബിലിറ്റി' (Distributed Moral Accountability)

ഓക്സ്ഫോർഡ് പ്രൊഫസറായ ലൂസിയാനോ ഫ്ലോറിഡി റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പിന് പ്രായോഗികമായ ഒരു പരിഹാരം മുന്നോട്ടുവെക്കുന്നു. ആധുനിക സങ്കീർണ്ണ എഐ സംവിധാനങ്ങളിൽ ഉത്തരവാദിത്തം ഒരൊറ്റ എഞ്ചിനീയറിലോ റോബോട്ടിലോ കേന്ദ്രീകൃതമല്ല; മറിച്ച് അത് ആ സിസ്റ്റം നിർമ്മിച്ച ഡാറ്റാ കളക്ടർമാർ, മോഡൽ ഓഡിറ്റർമാർ, കമ്പനി ഡയറക്ടർമാർ, റെഗുലേറ്ററി അതോറിറ്റികൾ എന്നിവരിലേക്ക് **കൂട്ടായി വീതിക്കപ്പെട്ട**

ഒന്നാണ് (Distributed Accountability). തെറ്റ് സംഭവിക്കുമ്പോൾ ആരും ഉത്തരവാദികളല്ലെന്ന് പറയുന്നതിന് പകരം, സിസ്റ്റത്തിന്റെ ഘടനയിലുള്ള എല്ലാവർക്കും തുല്യമായ കൂട്ടായ ബാധ്യത ചുമത്തുകയാണ് വേണ്ടത്.

7. എൽ.എം.എസ് സമഗ്ര ചോദ്യോത്തരങ്ങൾ (Comprehensive LMS Essay Q&As)

Q1: എന്താണ് ധാർമ്മിക കർതൃത്വം (Moral Agency)? എഐ സംവിധാനങ്ങൾക്ക് ധാർമ്മിക കർതൃത്വം ഉണ്ടോ എന്ന് സമഗ്രമായി വിലയിരുത്തുക. (What is Moral Agency? Critically evaluate whether AI systems can be considered moral agents.)

English Detailed Answer: Moral agency is the philosophical status of being a moral actor—an entity capable of grasping moral reasons, deliberately choosing actions based on ethical norms, and bearing praise or blame.

Historically, moral agency demands three preconditions:

1. **Autonomy:** Freedom from external mechanical determination.
2. **Intentionality:** The possession of mental states directed toward worldly states.
3. **Moral Reason:** The reflective understanding of duty and harm.

Under these criteria, current AI systems are emphatically *not* full moral agents. While systems like autonomous vehicles make decisions with profound moral consequences (functional agency), they operate strictly via statistical minimization of mathematical loss functions. They possess neither conscious intentionality nor moral remorse. At best, they are *functional moral agents* (Wallach & Allen), executing moral actions without possessing genuine moral personhood.

മലയാള വിശദീകരണം: സ്വന്തം വിവേചനബുദ്ധി ഉപയോഗിച്ച് ശരിയും തെറ്റും തിരിച്ചറിഞ്ഞ് സ്വതന്ത്രമായി തീരുമാനങ്ങളെടുക്കാനും, ആ തീരുമാനങ്ങളുടെ ഉത്തരവാദിത്തം ഏൽക്കാനുമുള്ള കഴിവിനെയാണ് **ധാർമ്മിക കർതൃത്വം** (Moral Agency) എന്ന് വിളിക്കുന്നത്.

ഇതിനായി ഇച്ഛാസ്വാതന്ത്ര്യം, ആന്തരികമായ ഉദ്ദേശ്യം (ഇന്റൻഷണാലിറ്റി), സദാചാരബോധം എന്നിവ ആവശ്യമാണ്.

ഈ മാനദണ്ഡങ്ങൾ വെച്ച് പരിശോധിച്ചാൽ ഇന്നത്തെ ഒരു എഐ സിസ്റ്റത്തിനും യഥാർത്ഥ മോറൽ ഏജൻസി ഇല്ല. സ്വയംഭരണ കാറുകൾ ആളുകളെ രക്ഷിക്കുന്ന തീരുമാനങ്ങൾ എടുക്കുന്നുണ്ടെങ്കിലും, അത് കേവലം ഗണിത സമവാക്യങ്ങൾ അനുസരിച്ച് ചെയ്യുന്ന പ്രവർത്തനങ്ങൾ മാത്രമാണ് (Functional Agency). ഒരു റോബോട്ടിനും സ്വന്തമായി മനസ്സാക്ഷിയോ, തെറ്റ് ചെയ്യുമ്പോൾ പശ്ചാത്താപമോ ഇല്ല. അതിനാൽ അവയ്ക്ക് പൂർണ്ണ ധാർമ്മിക കർതൃത്വമില്ല.

Q2: ഡെബോറ ജോൺസന്റെയും ജോൺ സുള്ളിൻസിന്റെയും വാദങ്ങൾ തമ്മിലുള്ള സംവാദം താരതമ്യം ചെയ്യുക. (Compare the opposing arguments of Deborah Johnson and John P. Sullins on artificial moral agency.)

English Detailed Answer: The debate between Deborah Johnson and John Sullins marks the defining theoretical cleavage in computer ethics:

Deborah Johnson's Instrumental Thesis (2006): Johnson argues that computer systems are "moral entities" because they affect human moral life, but they are not "moral agents." Intentionality is an intrinsically human, socio-linguistic capacity. When an AI acts, it acts as a surrogate prosthesis of the human designers who designed its constraints. Blaming a machine separates technology from the human institutions that deployed it, encouraging human abdication.

John P. Sullins's Functionalist Rebuttal (2006): Sullins argues that Johnson's demand for biological intentionality is an untestable metaphysical barrier. In real-world environments, autonomous robots behave with significant independence from human telemetry. If an entity exhibits significant autonomy, displays intentional behavior (explaining actions via goals), and fulfills a recognized social role, it operates as an artificial moral agent. Society must evaluate machines by their systemic outputs, not their metaphysical carbon composition.

മലയാള വിശദീകരണം: ഡെബോറ ജോൺസണും ജോൺ സുള്ളിൻസും തമ്മിലുള്ള സംവാദം:

ഡെബോറ ജോൺസന്റെ വാദം: കമ്പ്യൂട്ടറുകൾ മനുഷ്യൻ നിർമ്മിച്ച ഉപകരണങ്ങൾ മാത്രമാണ്. അവയ്ക്ക് സ്വന്തമായി യാതൊരു ഉദ്ദേശ്യവുമില്ല (Lack of Intentionality). ഒരു റോബോട്ട് ചെയ്യുന്നത് അത് നിർമ്മിച്ച മനുഷ്യന്റെ ആഗ്രഹങ്ങളാണ്. അതിനാൽ തോക്കിനെയോ കാറിനെയോ പോലെ യന്ത്രങ്ങളെ വെറും ഉപകരണങ്ങളായി കാണണം; ഉത്തരവാദിത്തം മനുഷ്യനാണ്.

ജോൺ സുള്ളിൻസിന്റെ വാദം: മനുഷ്യന്റെ അതേപോലെയുള്ള ജീവശരീരമുണ്ടാകുന്നത് വരെ കാത്തിരുന്നാൽ റോബോട്ടുകൾ വരുത്തുന്ന പ്രശ്നങ്ങൾ പരിഹരിക്കാനാവില്ല. റോബോട്ടിന് സ്വയംഭരണവും, ലക്ഷ്യബോധമുള്ള പെരുമാറ്റവും, സമൂഹത്തിൽ ഒരു ധാർമ്മിക ചുമതലയും ഉണ്ടെങ്കിൽ അതിനെ മോറൽ ഏജന്റായി അംഗീകരിക്കണം. അതിന്റെ പ്രവർത്തനങ്ങളുടെ ഫലമാണ് നമ്മൾ നോക്കേണ്ടത്.

Q3: ആൻഡ്രിയാസ് മത്തിയാസിന്റെ 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്" (The Responsibility Gap) എന്ന പ്രതിസന്ധി വിശദീകരിക്കുക. (Critically examine Andreas Matthias's 'The Responsibility Gap' in machine learning.)

English Detailed Answer: In 2004, philosopher Andreas Matthias identified an unprecedented challenge in legal and moral philosophy created by self-learning algorithms.

Traditional justice principles require that an agent can only be held morally or criminally responsible for an outcome if:

1. The agent had causal agency and control over the action.
2. The agent had the epistemic capacity to foresee the action's consequences.

With deep reinforcement learning, neural models alter their internal weights dynamically through environmental exploration. The resulting decision-making paths are emergent, non-linear, and opaque. The programmer cannot foresee what the algorithm will decide, nor do they exercise control over runtime actions. Therefore, holding the programmer criminally liable violates fundamental principles of moral desert.

Yet, the algorithm cannot experience retributive justice. This rupture between causation and moral culpability is the **Responsibility Gap**.

മലയാള വിശദീകരണം: ആൻഡ്രിയാസ് മത്തിയാസ് വ്യക്തമാക്കിയ റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്:

നിയമപരമായി ഒരാളെ ശിക്ഷിക്കണമെങ്കിൽ അയാൾക്ക് ആ പ്രവൃത്തിയിൽ നിയന്ത്രണം ഉണ്ടായിരിക്കണം, അതിന്റെ പ്രത്യാഘാതങ്ങൾ മുൻകൂട്ടി കാണാൻ സാധിച്ചിരിക്കണം.

എന്നാൽ സ്വയം പഠിക്കുന്ന എഐ അൽഗോരിതങ്ങളിൽ, മെഷീൻ എന്ത് തീരുമാനമെടുക്കുമെന്ന് അത് നിർമ്മിച്ച എഞ്ചിനീയർക്ക് മുൻകൂട്ടി കാണാൻ കഴിയില്ല. അതിനാൽ എഞ്ചിനീയറെ കുറ്റക്കാരനായി ജയിലിലടയ്ക്കാൻ നിയമത്തിന് സാധിക്കില്ല. അതേസമയം തെറ്റ് ചെയ്ത സോഫ്റ്റ്വെയറിനെ ശിക്ഷിക്കാനും കഴിയില്ല. ഇത്തരത്തിൽ ആരെയും ശിക്ഷിക്കാൻ കഴിയാത്ത, ഉത്തരവാദിത്തം അനാഥമാകുന്ന അവസ്ഥയെയാണ് **റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്** എന്ന് വിളിക്കുന്നത്.

Q4: റോബോട്ടുകൾക്ക് "ഇലക്ട്രോണിക് പേഴ്സൺഹുഡ്" (Electronic Personhood) നൽകുന്നതിനെ എഐ വിദഗ്ധർ എതിർക്കുന്നത് എന്തുകൊണ്ട്? (Why do AI experts oppose granting 'Electronic Personhood' to autonomous robots?)

English Detailed Answer: In 2017, the European Parliament proposed creating a legal status of "Electronic Personhood" for sophisticated autonomous robots. Over 150 international experts in robotics, AI, and law signed a scathing open letter rejecting the proposal on multiple ethical grounds:

1. **Corporate Liability Shield:** Legal personhood would allow corporate manufacturers to insulate themselves from product liability. An AI model could be made legally responsible for its own damage, bankrupting an empty shell corporation while shielding tech executives from billion-dollar tort claims.
2. **Absence of Moral Agency:** Legal personhood in human beings is inextricably tied to human dignity and moral duties. Granting personhood to code degrades the philosophical meaning of human rights.
3. **Inoperability of Sanctions:** You cannot deter an algorithm with incarceration, nor extract justice through penal reform. Electronic personhood creates moral hazards without retributive efficacy.

മലയാള വിശദീകരണം: റോബോട്ടുകൾക്ക് നിയമപരമായ വ്യക്തിത്വം നൽകുന്നതിനെ വിദഗ്ധർ എതിർക്കാൻ കാരണങ്ങൾ:

1. **കോർപ്പറേറ്റ് മുതലാളിമാർക്കുള്ള സംരക്ഷണം:** റോബോട്ടുകൾക്ക് വ്യക്തിത്വം നൽകിയാൽ, കാർ കമ്പനികളും ടെക് ഭീമന്മാരും അപകടങ്ങളുടെ ഉത്തരവാദിത്തത്തിൽ നിന്ന് രക്ഷപ്പെടും. റോബോട്ടിന്റെ പേരിൽ കേസ് വരികയും കമ്പനി ഉടമകൾ കോടികളുടെ നഷ്ടപരിഹാരം നൽകാതെ രക്ഷപ്പെടുകയും ചെയ്യും.
2. **മനുഷ്യാവകാശങ്ങളുടെ അപമാനം:** മനുഷ്യന്റെ അന്തസ്സും വികാരങ്ങളുമാണ് വ്യക്തിത്വത്തിന്റെ അടിസ്ഥാനം. അത് കേവലം കമ്പ്യൂട്ടർ കോഡുകൾക്ക് ചാർത്തിക്കൊടുക്കുന്നത് യഥാർത്ഥ മനുഷ്യാവകാശങ്ങളെ അവഹേളിക്കുന്നതിന് തുല്യമാണ്.
3. **ശിക്ഷിക്കാൻ കഴിയില്ല:** റോബോട്ടിനെ ജയിലിലടയ്ക്കാനോ അതിന് പശ്ചാത്താപം ഉണ്ടാക്കാനോ കഴിയില്ല; അതിനാൽ ശിക്ഷ എന്നത് പ്രഹസനമായി മാറും.

Q5: ലൂസിയാനോ ഫ്ലോറിഡിയുടെ 'വിതരണം ചെയ്യപ്പെട്ട ധാർമ്മിക ഉത്തരവാദിത്തം' (Distributed Moral Accountability) വിശദീകരിക്കുക. (Explain Luciano Floridi's concept of Distributed Moral Accountability.)

English Detailed Answer: Oxford philosopher Luciano Floridi addresses the modern pathology where complex multi-agent systems commit severe moral harm without any single human individual intending evil (the problem of "many hands").

Floridi introduces **Distributed Moral Accountability**:

- In a large-scale algorithmic infrastructure (e.g., automated trading or national healthcare triage), the outcome is produced by the interaction of thousands of software microservices, training datasets, deployment engineers, and regulatory policies.
- Instead of searching futilely for a single human scapegoat or blaming an unfeeling machine, accountability must be conceptualized as an emergent structural property distributed across the entire sociotechnical web.
- Legally, this demands structural remedies: strict enterprise liability, mandatory algorithmic insurance pools, transparent code audits, and strict institutional oversight.

മലയാള വിശദീകരണം: ലൂസിയാനോ ഫ്ലോറിഡിയുടെ വിതരണം ചെയ്യപ്പെട്ട ധാർമ്മിക ഉത്തരവാദിത്തം:

ആധുനിക ലോകത്ത് ഒരു എഐ സംവിധാനം ദുരന്തമുണ്ടാക്കുമ്പോൾ അത് ഒരാൾ മാത്രം ചെയ്ത തെറ്റായിരിക്കില്ല. ഡാറ്റ ശേഖരിച്ചവർ, കോഡ് എഴുതിയവർ, അത് വിപണിയിലിറക്കിയ കമ്പനി, അനുമതി നൽകിയ ഭരണകൂടം എന്നിവരെല്ലാം ചേർന്ന ഒരു വലിയ ശൃംഖലയാണത് നിർമ്മിച്ചത്.

അതുകൊണ്ട് ഒരൊറ്റയാളെ ബലിയാടാക്കുന്നതിന് പകരം, ഈ സിസ്റ്റത്തിലെ മുഴുവൻ പങ്കാളികൾക്കുമായി ഉത്തരവാദിത്തം വിതരണം ചെയ്യപ്പെടണം (Distributed Accountability). നഷ്ടപരിഹാരം നൽകാൻ നിർബന്ധിത ഇൻഷുറൻസ് ഫണ്ടുകൾ ഏർപ്പെടുത്തുകയും കമ്പനികൾക്ക് കൂടുതരവാദിത്തം നിശ്ചയിക്കുകയും ചെയ്യുകയാണ് ഇതിനുള്ള പ്രായോഗിക പരിഹാരം.

Q6: റോബോട്ടുകളെ യഥാർത്ഥമായി ശിക്ഷിക്കാൻ സാധിക്കുമോ? റിട്ടിബ്യൂട്ടീവ് ജസ്റ്റിസിന്റെ ദാർശനിക പ്രതിസന്ധി വ്യക്തമാക്കുക. (Can robots be meaningfully punished? Discuss the philosophical dilemma of retributive justice in AI.)

English Detailed Answer: The philosophy of punishment rests primarily on two pillars: deterrence and retribution.

1. Deterrence: Threatening an autonomous neural network with "punishment" does not deter bad behavior unless negative weights are recalculated. But retraining a model is an engineering patch, not penal justice.

2. Retributive Justice: Grounded in Kant and Hegel, retribution demands that an offender endure deserved suffering in proportion to their moral wrongdoing to restore the moral order. Because an AI lacks phenomenal consciousness, sentience, and capacity for emotional suffering, deleting code or turning off power causes zero suffering. The machine feels no guilt, remorse, or shame.

Therefore, punishing an artificial agent is a psychological projection—an anthropomorphic theater that fails both the victim seeking justice and the philosophical criteria of criminal law.

മലയാള വിശദീകരണം: റോബോട്ടുകളെ ശിക്ഷിക്കാൻ കഴിയുമോ?

ശിക്ഷയുടെ പ്രധാന ലക്ഷ്യം തെറ്റ് ചെയ്ത വ്യക്തിക്ക് പശ്ചാത്താപം തോന്നിക്കുകയും ആ തെറ്റിന് ആനുപാതികമായ മാനസിക വേദന അനുഭവിക്കുകയും ചെയ്യുക എന്നതാണ് (Retributive Justice).

എന്നാൽ ഒരു റോബോട്ടിന് മനസ്സോ വേദനയോ ഇല്ലാത്തതിനാൽ, അതിനെ ഡിലീറ്റ് ചെയ്താലോ കഷണങ്ങളായി വെട്ടിമുറിച്ചാലോ അതിന് യാതൊരു കുറ്റബോധമോ വേദനയോ തോന്നുന്നില്ല. അതിനാൽ യന്ത്രത്തെ ശിക്ഷിക്കുന്നത് ഒരു വെറും നാടകം മാത്രമാണ്; അത് ഇരയായ മനുഷ്യർക്ക് യഥാർത്ഥ നീതി നൽകുന്നില്ല.

8. അധ്യായം 20 പരീക്ഷാ പ്രധാന 20 പോയിന്റുകൾ (20 Deep High-Yield Exam Points)

പരീക്ഷാ തയ്യാറെടുപ്പിനായുള്ള മൗലിക സംഗ്രഹങ്ങൾ (Core Examination Takeaways)

01 Moral Agency Preconditions

Requires genuine autonomy, conscious intentionality, and reflective moral reason.

ഇച്ഛാസ്വാതന്ത്ര്യം, ആന്തരികമായ ഉദ്ദേശ്യം, സദാചാരബോധം എന്നിവയാണ് മോറൽ ഏജൻസിയുടെ മാനദണ്ഡങ്ങൾ.

02 Wallach & Allen's Moral Machines

Distinguishes Operational Morality, Functional Morality, and Full Moral Agency in machines.

യന്ത്രങ്ങളുടെ ധാർമ്മികതയെ ഓപ്പറേഷണൽ, ഫങ്ഷണൽ, ഫുൾ ഏജൻസി എന്നിങ്ങനെ മൂന്നായി തരംതിരിച്ച സിദ്ധാന്തം.

03 **Deborah Johnson's Thesis (2006)**

Computers are moral entities with human-designed consequences, but never autonomous moral agents.

> കമ്പ്യൂട്ടറുകൾ ധാർമ്മിക എന്റിറ്റികളാണ്, എന്നാൽ അവ ഒരിക്കലും ധാർമ്മിക ഏജന്റുകളല്ലെന്ന പ്രശസ്ത വാദം.

04 **Instrumental View of Computers**

Machines act as prostheses of human action; blaming tools abdicates human responsibility.

> യന്ത്രങ്ങൾ മനുഷ്യന്റെ ഉപകരണങ്ങൾ മാത്രമാണ്; തോക്കിനെയല്ല അത് ഉപയോഗിച്ച മനുഷ്യനെയാണ് ശിക്ഷിക്കേണ്ടത്.

05 **John P. Sullins's AMA Criteria**

Significant Autonomy, Intentional Behavior, and a Social Role qualify a robot as a moral agent.

> സ്വയംഭരണാധികാരം, ഉദ്ദേശ്യപൂർവ്വമായ പെരുമാറ്റം, സാമൂഹിക ചുമതല എന്നിവയുണ്ടെങ്കിൽ റോബോട്ട് ഏജന്റാണ്.

06 **Daniel Dennett's Intentional Stance**

Understanding complex machine behavior by predicting its actions based on ascribed goals and beliefs.

> ഒരു സിസ്റ്റത്തിന്റെ പെരുമാറ്റം മനസ്സിലാക്കാൻ അതിന് ലക്ഷ്യങ്ങളുണ്ടെന്ന് അനുമാനിച്ച് വിലയിരുത്തുന്ന രീതി.

07 **Andreas Matthias' Responsibility Gap (2004)**

Learning automata break the control/foresight condition, leaving harms without an accountable agent.

> സ്വയം പഠിക്കുന്ന മെഷീനുകളുടെ തെറ്റുകൾക്ക് ആരെയും ശിക്ഷിക്കാൻ കഴിയാതെ വരുന്ന ധാർമ്മിക വിടവ്.

08 **The Control/Foresight Breakdown**

Programmers cannot predict or control emergent machine learning decisions in open worlds.

> എഞ്ചിനീയർക്ക് മെഷീന്റെ തീരുമാനങ്ങൾ മുൻകൂട്ടി പ്രവചിക്കാനോ നിയന്ത്രിക്കാനോ കഴിയാത്ത അവസ്ഥ.

09 **The Problem of Many Hands**

In complex AI pipelines, catastrophic harm occurs without any individual human intending malice.

> ആരും മനഃപൂർവ്വം തെറ്റ് ചെയ്യാതിരുന്നിട്ടും സിസ്റ്റത്തിന്റെ കൂട്ടായ പ്രവർത്തനത്തിൽ ദുരന്തമുണ്ടാകൽ.

10 **EU Electronic Personhood Proposal (2017)**

Proposed granting autonomous robots legal personhood status similar to corporations.

> റോബോട്ടുകൾക്ക് കമ്പനികളെപ്പോലെ നിയമപരമായ വ്യക്തിത്വം നൽകാനുള്ള യൂറോപ്യൻ നിർദ്ദേശം.

11 The Corporate Liability Shield Danger

Tech corporations using robot personhood to evade multi-million dollar liability payouts.

വൻകിട കമ്പനികൾ അവരുടെ തെറ്റുകളിൽ നിന്ന് രക്ഷപ്പെടാൻ റോബോട്ടുകളെ മറയാക്കി ഉപയോഗിക്കുമെന്ന മുന്നറിയിപ്പ്.

12 The Open Letter Against Personhood

Over 150 international roboticists and legal scholars opposing artificial personhood.

റോബോട്ടുകൾക്ക് വ്യക്തിത്വം നൽകരുതെന്ന് ആവശ്യപ്പെട്ട് 150-ലധികം ശാസ്ത്രജ്ഞർ ഒപ്പിട്ട കത്ത്.

13 Retributive Justice Dilemma

Punishment is meaningless against code that cannot feel shame, suffering, or repentance.

പശ്ചാത്താപമോ വേദനയോ അനുഭവിക്കാൻ കഴിയാത്ത സോഫ്റ്റ്വെയറിനെ ശിക്ഷിക്കുന്നത് അർത്ഥശൂന്യമാണ്.

14 Luciano Floridi: Distributed Moral Accountability

Accountability must be shared across the entire web of designers, annotators, and deployers.

സിസ്റ്റം നിർമ്മിച്ച എല്ലാവരിലുമായി വീതിക്കപ്പെടുന്ന കൂട്ടായ ധാർമ്മിക ഉത്തരവാദിത്തം.

15 Strict Enterprise Liability

Holding corporate deployers strictly liable for AI damages regardless of provable negligence.

അശ്രദ്ധ തെളിയിക്കപ്പെട്ടില്ലെങ്കിലും എഐ വരുത്തുന്ന നഷ്ടങ്ങൾക്ക് കമ്പനി നഷ്ടപരിഹാരം നൽകണം എന്ന നിയമം.

16 Compulsory Algorithmic Insurance

Mandatory insurance funds created by AI developers to automatically compensate victims.

ഇരകൾക്ക് ഉടൻ നഷ്ടപരിഹാരം നൽകാൻ കമ്പനികൾ നിർബന്ധിത ഇൻഷുറൻസ് ഫണ്ട് രൂപീകരിക്കൽ.

17 Scapegoating Technology

The dangerous psychological urge to blame "the computer glitch" to hide human corruption.

മനുഷ്യന്റെ അഴിമതിയും പിഴവുകളും മറച്ചുവെക്കാൻ "കമ്പ്യൂട്ടറിന്റെ കുഴപ്പമാണ്" എന്ന് കള്ളം പറയൽ.

18 Meaningful Human Control (MHC)

Regulatory doctrine mandating that critical life-or-death decisions must remain with humans.

ജീവൻ മരണ തീരുമാനങ്ങൾ എടുക്കുന്നതിൽ മനുഷ്യന്റെ നിയന്ത്രണം നിർബന്ധമാക്കുന്ന തത്വം.

19 **Algorithmic Auditing**

Independent third-party inspection of training models and neural weights for legal compliance.

സ്വതന്ത്ര ഏജൻസികൾ നടത്തുന്ന എഐ സോഫ്റ്റ്വെയറുകളുടെ സുരക്ഷാ പരിശോധന.

20 **Preservation of Human Dignity**

Ensuring humanity remains the moral center and ultimate accountable sovereign in the AI age.

എഐ യുഗത്തിലും മനുഷ്യന്റെ അന്തസ്സും പരമാധികാരവും സംരക്ഷിക്കുക എന്ന ആത്യന്തിക ലക്ഷ്യം.

9. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (Chapter 20 University MCQs)

Q1: "കമ്പ്യൂട്ടർ സിസ്റ്റങ്ങൾ ധാർമ്മിക എന്റിറ്റികളാണ്, എന്നാൽ അവ ധാർമ്മിക ഏജന്റുകളല്ല" എന്ന് വാദിച്ച ഫിലോസഫർ ആര്?

A. അലൻ ട്യൂറിംഗ്

B. ഡെബോറ ജി. ജോൺസൺ (Deborah G. Johnson) (Correct)

C. ജോൺ സുള്ളിൻസ്

D. ആൻഡ്രിയാസ് മത്തിയാസ്

ഉത്തരം: B

വിശദീകരണം: 2006-ൽ ഡെബോറ ജോൺസൺ അവതരിപ്പിച്ച പ്രസിദ്ധമായ പ്രബന്ധമാണിത്.

Q2: റോബോട്ടുകൾക്ക് ഫങ്ഷണൽ മോറൽ ഏജൻസി ഉണ്ടെന്ന് വാദിക്കാൻ മൂന്ന് മാനദണ്ഡങ്ങൾ മുന്നോട്ടുവെച്ച തത്ത്വചിന്തകൻ ആര്?

A. ഇമ്മാനുവൽ കാന്റ്

B. ജോൺ പി. സുള്ളിൻസ് (John P. Sullins) (Correct)

C. റെനെ ദെക്കാർത്ത്

D. തോമസ് ഹോബ്സ്

ഉത്തരം: B

വിശദീകരണം: സ്വയംഭരണം, ഉദ്ദേശ്യപരമായ പെരുമാറ്റം, സാമൂഹിക പങ്ക് എന്നിവ സുള്ളിൻസിന്റെ മാനദണ്ഡങ്ങളാണ്.

Q3: 2004-ൽ 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്' (The Responsibility Gap) എന്ന ആശയം ആദ്യമായി അവതരിപ്പിച്ചത് ആര്?

A. നിക്ക് ബോസ്ട്രോം
B. ആൻഡ്രിയാസ് മത്തിയാസ് (Andreas Matthias) (Correct)
C. സ്റ്റുവർട്ട് റസ്സൽ
D. എലീസർ യുഡ്കോവ്സ്കി

ഉത്തരം: B

വിശദീകരണം: സ്വയം പഠിക്കുന്ന മെഷീനുകളുടെ തെറ്റുകൾക്ക് ആരെയും ശിക്ഷിക്കാൻ കഴിയില്ലെന്ന് മത്തിയാസ് ചൂണ്ടിക്കാട്ടി.

Q4: 'Moral Machines' (2008) എന്ന ഗ്രന്ഥത്തിൽ ഓപ്പറേഷണൽ, ഫങ്ഷണൽ മൊറാലിറ്റികൾ തരംതിരിച്ച ചിന്തകർ ആരെല്ലാം?

A. കാൾ മാർക്സും ഏംഗൽസും
B. വെൻഡൽ വാലാക്കും കോളിൻ അല്ലനും (Wendell Wallach & Colin Allen) (Correct)
C. പ്ലാറ്റോയും സോക്രട്ടീസും
D. ന്യൂട്ടണും ലെയ്ബ്നിസും

ഉത്തരം: B

വിശദീകരണം: യന്ത്രങ്ങളുടെ ധാർമ്മിക വികാസത്തെ മൂന്നായി തിരിച്ചത് വാലാക്കും അല്ലനുമാണ്.

Q5: 2017-ൽ റോബോട്ടുകൾക്ക് 'ഇലക്ട്രോണിക് വ്യക്തിത്വം' (Electronic Personhood) നൽകാൻ ശുപാർശ ചെയ്തത് ഏത് സഭയാണ്?

A. ഇന്ത്യൻ പാർലമെന്റ്
B. യൂറോപ്യൻ പാർലമെന്റ് (European Parliament) (Correct)
C. യു.എൻ പൊതുസഭ
D. ബ്രിട്ടീഷ് പാർലമെന്റ്

ഉത്തരം: B

വിശദീകരണം: മാഡി ഡെൽവോ കമ്മിറ്റിയാണ് ഇലക്ട്രോണിക് പേഴ്സൺഹുഡ് ശുപാർശ ചെയ്തത്.

Q6: ഇലക്ട്രോണിക് പേഴ്സൺഹുഡിനെതിരെ വിദഗ്ധർ ഉന്നയിച്ച ഏറ്റവും വലിയ ഭീഷണി എന്താണ്?

A. റോബോട്ടുകൾക്ക് വോട്ടവകാശം ലഭിക്കും
B. കമ്പനികൾ നഷ്ടപരിഹാരം നൽകാതെ രക്ഷപ്പെടാൻ റോബോട്ടുകളെ മറയാക്കും (Corporate Shield) (Correct)
C. കമ്പ്യൂട്ടറുകളുടെ വില കൂടും
D. ഇന്റർനെറ്റ് പണിമുടക്കും

ഉത്തരം: B

വിശദീകരണം: വൻകിട കമ്പനികൾ അവരുടെ ധനപരമായ ബാധ്യതകളിൽ നിന്ന് രക്ഷപ്പെടാൻ ഇത് വഴിവെക്കും.

Q7: ഒരു സിസ്റ്റത്തിന് ലക്ഷ്യങ്ങളും ഉദ്ദേശ്യങ്ങളുമുണ്ടെന്ന് അനുമാനിച്ച് അതിന്റെ പെരുമാറ്റത്തെ വിശദീകരിക്കുന്ന ഡാനിയൽ ഡെന്നറ്റിന്റെ രീതി ഏതാണ്?

A. ഫിസിക്കൽ സ്റ്റാൻസ്
B. ഇന്റൻഷണൽ സ്റ്റാൻസ് (Intentional Stance) (Correct)
C. ഡിസൈൻ സ്റ്റാൻസ്
D. ക്വാണ്ടം സ്റ്റാൻസ്

ഉത്തരം: B

വിശദീകരണം: ഡാനിയൽ ഡെന്നറ്റ് മുന്നോട്ടുവെച്ച തത്ത്വചിന്താ സമീപനമാണിത്.

Q8: വിതരണം ചെയ്യപ്പെട്ട ധാർമ്മിക ഉത്തരവാദിത്തം (Distributed Moral Accountability) മുന്നോട്ടുവെച്ച ഓക്സ്ഫോർഡ് പ്രൊഫസർ ആര്?

A. ബെർട്രാൻഡ് റസ്സൽ
B. ലൂസിയാനോ ഫ്ലോറിഡി (Luciano Floridi) (Correct)
C. എ.ജെ. അയർ
D. ഗിൽബർട്ട് റൈൽ

ഉത്തരം: B

വിശദീകരണം: സങ്കീർണ്ണ സിസ്റ്റങ്ങളിൽ ഉത്തരവാദിത്തം എല്ലാവരിലുമായി വീതിക്കപ്പെടുന്നുവെന്ന് ഫ്ലോറിഡി സമർത്ഥിച്ചു.

Q9: കുറ്റവാളിക്ക് ആന്തരിക പശ്ചാത്താപവും പ്രായശ്ചിത്തവും ഉണ്ടാകണമെന്ന് വാദിക്കുന്ന നീതിശാസ്ത്ര ശാഖ ഏതാണ്?

A. ഡിസ്ട്രിബ്യൂട്ടീവ് ജസ്റ്റിസ്
B. റിട്രിബ്യൂട്ടീവ് ജസ്റ്റിസ് (Retributive Justice) (Correct)
C. പ്രൊസീജറൽ ജസ്റ്റിസ്
D. ഇക്കണോമിക് ജസ്റ്റിസ്

ഉത്തരം: B

വിശദീകരണം: അർഹിക്കുന്ന ശിക്ഷ നൽകി നീതി പുനഃസ്ഥാപിക്കുന്നതാണ് റിട്രിബ്യൂട്ടീവ് ജസ്റ്റിസ്.

Q10: ജീവൻ മരണ തീരുമാനങ്ങളിൽ മനുഷ്യന്റെ മേൽനോട്ടം ഉറപ്പാക്കണം എന്ന അന്താരാഷ്ട്ര നിയമ തത്വം ഏതാണ്?

A. നോൺ-പ്രൊലിഫറേഷൻ
B. മീനിംഗ്ഫുൾ ഹ്യൂമൻ കൺട്രോൾ (Meaningful Human Control – MHC) (Correct)
C. ഫ്രീ ട്രേഡ്
D. ഓപ്പൺ സോഴ്സ്

ഉത്തരം: B

വിശദീകരണം: ആയുധങ്ങളിലും മറ്റും അവസാന തീരുമാനം മനുഷ്യന്റേതായിരിക്കണം എന്ന തത്വമാണിത്.

Q11: ജോൺ സുള്ളിൻസിന്റെ മാനദണ്ഡപ്രകാരം ഒരു കാവൽ റോബോട്ടിന് മോറൽ ഏജൻസി ലഭിക്കാൻ കാരണം എന്താണ്?

A. അതിന് ലോഹം കൊണ്ടുള്ള ശരീരമുണ്ട്
B. അത് സമൂഹത്തിൽ ഒരു ധാർമ്മിക ചുമതല (Social Role) നിർവ്വഹിക്കുന്നു (Correct)
C. അത് വൈദ്യുതിയിൽ പ്രവർത്തിക്കുന്നു
D. അതിന് ക്യാമറയുണ്ട്

ഉത്തരം: B

വിശദീകരണം: സമൂഹത്തിലെ സദാചാരപരമായ പങ്ക് സുള്ളിൻസിന്റെ ഒരു പ്രധാന മാനദണ്ഡമാണ്.

Q12: പല ആളുകൾ ചേർന്ന് പ്രവർത്തിക്കുമ്പോൾ ആരും മനഃപൂർവ്വം തെറ്റ് ചെയ്യാതിരുന്നിട്ടും ദുരന്തമുണ്ടാകുന്ന അവസ്ഥയെ എന്ത് വിളിക്കുന്നു?

A. വൺ മാൻ പ്രോബ്ലം
B. പ്രോബ്ലം ഓഫ് മെനി ഹാൻഡ്സ് (The Problem of Many Hands) (Correct)
C. സീറോ സം ഗെയിം
D. റാൻഡം വാക്ക്

ഉത്തരം: B

വിശദീകരണം: കൂട്ടായ സാങ്കേതിക പ്രവർത്തനങ്ങളിൽ വ്യക്തിഗത കുറ്റം കണ്ടെത്താൻ കഴിയാത്ത അവസ്ഥയാണിത്.