CALICUT UNIVERSITY · MINOR PHILOSOPHY (PHL1MN102)

അധ്യായം 20: AI സംവിധാനങ്ങൾ ധാർമ്മിക കർത്താക്കളാകുമോ? ഉത്തരവാദിത്തവും നിയമപരമായ പദവിയും

Chapter 20: Can AI Be Moral Agents? Accountability and The Responsibility Gap

📚 Module 4 · Unit 4.3 (c) | ⏱️ 15 Hours Module Weightage · 15 Marks

പാഠ്യസംഗ്രഹം (Module Scope): കൃത്രിമ ബുദ്ധി സംവിധാനങ്ങൾക്ക് സ്വന്തമായി ധാർമ്മിക കർത്താക്കളാകാൻ (Moral Agents) കഴിയുമോ എന്ന് ഈ അധ്യായം പരിശോധിക്കുന്നു. ഡെബോറ ജോൺസന്റെ സിദ്ധാന്തം (Moral Entities but not Moral Agents), ജോൺ പി. സള്ളിൻസിന്റെ വ്യവസ്ഥകൾ, ആൻഡ്രിയാസ് മത്യാസിന്റെ റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് (Responsibility Gap), വിതരണ ഉത്തരവാദിത്തം എന്നിവ ഇതിൽ വിശകലനം ചെയ്യുന്നു.

1. ധാർമ്മിക കർത്തൃത്വത്തിന്റെ മാനദണ്ഡങ്ങൾ (Criteria for Moral Agency)

What Defines a Moral Agent?

ആരാണ് ധാർമ്മിക കർത്താവ്?

ഒരു പ്രവൃത്തിയുടെ നന്മതിന്മകളെ തിരിച്ചറിഞ്ഞ്, സ്വന്തം സ്വാതന്ത്ര്യത്തോടെ (Free Will) തെരഞ്ഞെടുപ്പ് നടത്താനും, ആ പ്രവൃത്തിയുടെ ധാർമ്മിക ഉത്തരവാദിത്തം (Accountability) സ്വയം ഏൽക്കാനും കഴിവുള്ള അസ്തിത്വത്തെയാണ് **മോറൽ ഏജന്റ് (Moral Agent)** എന്ന് വിളിക്കുന്നത്.

പരമ്പരാഗതമായി മനുഷ്യർ മാത്രമാണ് ധാർമ്മിക കർത്താക്കൾ. എന്നാൽ സ്വതന്ത്രമായി തീരുമാനങ്ങളെടുക്കുന്ന ഡ്രോണുകളും അൽഗോരിതങ്ങളും വരുമ്പോൾ അവയെ ധാർമ്മിക കർത്താക്കളായി കാണാമോ എന്ന ചോദ്യമുയരുന്നു.

Autonomy, Intentionality, and Free Will

A **moral agent** is an entity capable of moral deliberation, intentional action, autonomous choice governed by free will, and accountable for the normative consequences of its conduct.

Historically, full moral agency was unique to adult humans. The advent of autonomous algorithmic systems executing lethal or life-altering choices forces philosophy to reconsider this boundary.

2. ഡെബോറ ജോൺസന്റെ വാദം: എഐ ധാർമ്മിക ഉപകരണങ്ങൾ മാത്രം (Deborah Johnson's View)

Moral Entities But Not Moral Agents

മനുഷ്യന്റെ ഇച്ഛാശക്തിയുടെ വ്യാപ്തി

പ്രശസ്ത കമ്പ്യൂട്ടർ എത്തിക്സ് ചിന്തകയായ ഡെബോറ ജോൺസൺ (Deborah G. Johnson) വ്യക്തമാക്കുന്നത്: കമ്പ്യൂട്ടർ സംവിധാനങ്ങൾ *ധാർമ്മിക സത്തകളാണ് (Moral Entities), എന്നാൽ ധാർമ്മിക കർത്താക്കളല്ല (Not Moral Agents).*

എഐ സംവിധാനങ്ങൾക്ക് സ്വന്തമായി **ഉദ്ദേശ്യബോധമോ (Intentionality) സ്വതന്ത്ര ഇച്ഛയോ (Free Will)** ഇല്ല. അവ പ്രവർത്തിക്കുന്നത് മനുഷ്യരായ പ്രോഗ്രാമർമാരുടെയും സ്ഥാപനങ്ങളുടെയും ഇച്ഛകളെ നടപ്പിലാക്കുന്ന മാധ്യമങ്ങളായാണ് (Mediators of human intentionality). അതിനാൽ ധാർമ്മികമായ കുറ്റം യന്ത്രത്തിന് മേൽ ചുമത്താനാവില്ല.

Tools Mediating Human Intentionality

Deborah G. Johnson contends that computer systems are **moral entities, but not moral agents**. Systems act within moral domains, but possess neither genuine intentionality nor autonomous free will.

AI functions as an extension and mediator of human purpose. The moral causality remains anchored to the human designers, deployers, and institutions orchestrating the system.

3. ജോൺ പി. സള്ളിൻസിന്റെ മൂന്ന് വ്യവസ്ഥകൾ (John P. Sullins' Framework)

When is a Robot a Moral Agent?

റോബോട്ടിന്റെ മൂന്ന് പടവുകൾ

റോബോട്ട് എത്തിക്സ് ഗവേഷകനായ ജോൺ പി. സള്ളിൻസ് (John P. Sullins) ഒരു റോബോട്ടിന് ധാർമ്മിക കർത്തൃത്വം നൽകാൻ മൂന്ന് നിബന്ധനകൾ നിർദ്ദേശിക്കുന്നു:

1. കാര്യമായ സ്വയംഭരണാധികാരം (Significant Autonomy): ബാഹ്യ നിയന്ത്രണമില്ലാതെ സ്വതന്ത്രമായി തീരുമാനങ്ങളെടുക്കാനുള്ള ശേഷി.

2. ഉദ്ദേശ്യപൂർവ്വമായ പെരുമാറ്റം (Intentional Behavior): കേവലം റാൻഡം ചലനമല്ല, മറിച്ച് ഒരു പ്രത്യേക ലക്ഷ്യത്തിലേക്കുള്ള യുക്തിപൂർവ്വമായ പ്രവർത്തനം.

3. സാമൂഹിക പങ്കാളിത്തം (Responsibility in Social Roles): നേഴ്സ് റോബോട്ട്, ഡ്രൈവർ തുടങ്ങിയ സാമൂഹിക ഉത്തരവാദിത്തമുള്ള റോളുകൾ നിർവ്വഹിക്കൽ.

ഈ മൂന്നും ഒത്തുചേരുമ്പോൾ അവയെ പ്രവർത്തനപരമായ ധാർമ്മിക കർത്താക്കളായി (Functional Moral Agents) കണക്കാക്കാം.

Autonomous Functionality in Social Roles

John P. Sullins establishes three criteria for acknowledging robotic moral agency:

1. Autonomy: The machine operates independently without direct real-time human control.

2. Intentional Behavior: Its actions are goal-directed and comprehensible via intentional explanations.

3. Social Role: The machine occupies a designated role involving moral responsibility (e.g., healthcare robot).

Systems meeting these criteria qualify as *functional moral agents*.

4. റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പും വിതരണ ഉത്തരവാദിത്തവും (The Responsibility Gap)

Andreas Matthias & Distributed Accountability

ആരെ കുറ്റപ്പെടുത്തും? (The Responsibility Gap)

ആൻഡ്രിയാസ് മത്യാസ് (Andreas Matthias) ചൂണ്ടിക്കാണിച്ച വലിയ പ്രതിസന്ധിയാണ് **റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് (Responsibility Gap)**: മെഷീൻ ലേണിംഗ് മോഡലുകൾ പ്രോഗ്രാമർമാർ പോലും മുൻകൂട്ടി കാണാത്ത പുതിയ തന്ത്രങ്ങൾ സ്വയം പഠിച്ചെടുക്കുമ്പോൾ, ഒരു വലിയ അപകടമുണ്ടായാൽ അതിന്റെ പൂർണ്ണ കുറ്റം പ്രോഗ്രാമറുടെ മേൽ ചുമത്താൻ കഴിയില്ല, യന്ത്രത്തെ ജയിലിലിടാനും കഴിയില്ല!

ഇതിനുള്ള പരിഹാരമായി തത്ത്വചിന്തകർ **വിതരണ ഉത്തരവാദിത്തം (Distributed Responsibility)** മുന്നോട്ടുവെക്കുന്നു: കമ്പനികൾ, പ്രോഗ്രാമർമാർ, പരിശോധകർ, സർക്കാരുകൾ എന്നിവർ കൂട്ടായി ആപത്തുകളുടെ ഉത്തരവാദിത്തം പങ്കിടണം.

Autonomous Learning & Distributed Liability

Andreas Matthias articulated the **Responsibility Gap**: when deep neural networks learn behaviors unforeseen and unprogrammed by their creators, traditional moral attribution collapses.

We cannot justly punish the human programmer for unpredicted actions, nor can we punish the machine. Philosophy resolves this through **Distributed Responsibility**: shared legal and moral accountability across corporations, regulators, and developers.

ധാർമ്മിക കർത്തൃത്വ സിദ്ധാന്തങ്ങളുടെ വിശകലനം

Theories of Machine Moral Agency

ചിന്തകൻ / തത്ത്വം	നിലപാട്	ഉത്തരവാദിത്തത്തിന്റെ കേന്ദ്രം
ഡെബോറ ജോൺസൺ (Deborah Johnson)	എഐ ധാർമ്മിക ഉപകരണങ്ങൾ മാത്രം, സ്വതന്ത്ര ഏജന്റുകളല്ല	പ്രോഗ്രാമർമാരും ഉപയോക്താക്കളും മാത്രമാണ് ഉത്തരവാദികൾ
ജോൺ പി. സള്ളിൻസ് (John P. Sullins)	സ്വയംഭരണവും സാമൂഹിക റോളുമുള്ള റോബോട്ടുകൾ പ്രവർത്തനപരമായ ഏജന്റുകളാണ്	യന്ത്രങ്ങൾക്കും മനുഷ്യർക്കും പങ്കുവെക്കപ്പെട്ട ഉത്തരവാദിത്തം
ആൻഡ്രിയാസ് മത്യാസ് (Andreas Matthias)	സ്വയം പഠിക്കുന്ന മെഷീനുകൾ റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് സൃഷ്ടിക്കുന്നു	പരമ്പരാഗത കുറ്റപ്പെടുത്തൽ മാതൃകകൾ പരാജയപ്പെടുന്നു
വിതരണ ഉത്തരവാദിത്തം (Distributed Model)	എഐ തീരുമാനങ്ങൾ ഒരു നെറ്റ്‌വർക്കിന്റെ പ്രവർത്തനമാണ്	കോർപ്പറേറ്റുകൾ, നിയമനിർമ്മാതാക്കൾ, സിസ്റ്റം ഡിസൈനർമാർ എന്നിവരുടെ കൂട്ടായ ബാധ്യത

പ്രധാന പരീക്ഷാ ആശയങ്ങൾ (Key Examination Points)

Core Revision Points

മലയാളം സംഗ്രഹം (Key Takeaways)

• **മോറൽ ഏജന്റ്:** സ്വന്തം ഇച്ഛാശക്തിയാൽ നന്മതിന്മകൾ തെരഞ്ഞെടുക്കാൻ കഴിയുന്ന അസ്തിത്വം.
• **ഡെബോറ ജോൺസൺ:** ഉദ്ദേശ്യബോധമില്ലാത്തതിനാൽ എഐ യന്ത്രങ്ങൾ ധാർമ്മിക ഉപകരണങ്ങൾ മാത്രമാണ്.
• **ജോൺ പി. സള്ളിൻസ്:** സ്വയംഭരണാധികാരവും സാമൂഹിക റോളുകളുമുള്ള യന്ത്രങ്ങളെ പ്രവർത്തനപരമായ ഏജന്റുകളായി കാണാം.
• **റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്:** സ്വയം പഠിക്കുന്ന യന്ത്രങ്ങൾ ഉണ്ടാക്കുന്ന അപകടങ്ങളിൽ കുറ്റപ്പെടുത്തൽ വിഭജിക്കാൻ കഴിയാത്ത അവസ്ഥ.

English Summary (Key Takeaways)

• **Moral Agency:** Requires autonomous intent, deliberation, and liability for normative outcomes.
• **Deborah Johnson:** AI represents moral entities mediating human intentionality, lacking intrinsic moral agency.
• **John P. Sullins:** Autonomy, intentionality, and social role establish functional moral agency.
• **Responsibility Gap:** Matthias' recognition that unpredictable machine learning outpaces traditional culpability attribution.

വിചിന്തന ചോദ്യങ്ങൾ (Review & Discussion Questions)

Academic Essay & Short Questions

1. ഡെബോറ ജോൺസന്റെ അഭിപ്രായത്തിൽ കമ്പ്യൂട്ടറുകൾ 'ധാർമ്മിക സത്തകളാണ് എന്നാൽ ധാർമ്മിക കർത്താക്കളല്ല' എന്ന് പറയുന്നതിന്റെ അർത്ഥമെന്ത്?

കമ്പ്യൂട്ടറുകൾ ആളുകളുടെ ജീവിതത്തെ ബാധിക്കുന്ന ധാർമ്മിക സാഹചര്യങ്ങളിൽ പ്രവർത്തിക്കുന്നുവെങ്കിലും അവയ്ക്ക് സ്വന്തമായി ഉദ്ദേശ്യബോധമോ സ്വതന്ത്ര ഇച്ഛയോ ഇല്ല. അവ മനുഷ്യന്റെ ഇച്ഛകളെ നടപ്പിലാക്കുന്ന ഉപകരണങ്ങൾ മാത്രമായതിനാൽ അവ സ്വതന്ത്ര ധാർമ്മിക കർത്താക്കളല്ല.

2. എന്താണ് ആൻഡ്രിയാസ് മത്യാസ് വിശദീകരിച്ച 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്' (Responsibility Gap)?

സ്വയംഭരണ ലേണിംഗ് അൽഗോരിതങ്ങൾ സ്വന്തം അനുഭവങ്ങളിൽ നിന്ന് പ്രോഗ്രാമർമാർ ഉദ്ദേശിക്കാത്ത തീരുമാനങ്ങൾ സ്വയം പഠിച്ചെടുക്കുമ്പോൾ, ഒരു വൻ ദുരന്തമുണ്ടായാൽ അതിന്റെ ധാർമ്മിക കുറ്റം പ്രോഗ്രാമറുടെ മേലോ യന്ത്രത്തിന്റെ മേലോ മാത്രമായി ചുമത്താൻ കഴിയാതെ വരുന്ന വിടവാണിത്.