മൊഡ്യൂൾ 4: ധാർമ്മികവും ദാർശനികവുമായ പ്രത്യാഘാതങ്ങൾ (MODULE 4: ETHICAL & PHILOSOPHICAL IMPLICATIONS)

അധ്യായം 20: AI സംവിധാനങ്ങൾക്ക് ധാർമ്മിക കർതൃത്വം ഉണ്ടോ? ഉത്തരവാദിത്ത വിചാരം (Moral Agency & Accountability in AI)

Module 4 · Chapter 20: Moral Agency, Responsibility Gap & Deborah Johnson vs John Sullins · Calicut University B.A. Philosophy FYUGP (PHL1MN 102) · Complete Bilingual Study Guide

1. എൽ.എം.എസ് അവലോകനവും പഠന ലക്ഷ്യങ്ങളും (LMS Module Overview & Objectives)

LMS Overview: Syllabus unit 4.3(c) examines the climax of AI ethics: *Can AI systems be moral agents? If so, how should we hold them accountable?* We explore the necessary conditions for moral agency (intentionality, moral reasoning, free will), the famous debate between Deborah Johnson (*Computer Systems: Moral Entities But Not Moral Agents*) and John P. Sullins (*When is a Robot a Moral Agent?*), the Responsibility Gap (Andreas Matthias), and distributed accountability frameworks.

LMS ലക്ഷ്യങ്ങൾ: ധാർമ്മിക കർതൃത്വം (Moral Agency) എന്താണെന്ന് നിർവ്വചിക്കുക; ഡെബോറ ജോൺസന്റെയും ജോൺ സുള്ളിൻസിന്റെയും വിരുദ്ധ വാദങ്ങൾ താരതമ്യം ചെയ്യുക; സ്വതന്ത്ര ഇച്ഛയും (Free Will) ഇന്റൻഷണാലിറ്റിയും AI-ക്ക് ഉണ്ടോ എന്ന് പരിശോധിക്കുക; റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് (The Responsibility Gap) പഠിക്കുക; എഐ വരുത്തുന്ന തെറ്റുകളിൽ നിയമപരവും ധാർമ്മികവുമായ ഉത്തരവാദിത്തം എങ്ങനെ വീതിക്കണം എന്ന് കണ്ടെത്തുക.

2. ധാർമ്മിക കർതൃത്വത്തിന്റെ മാനദണ്ഡങ്ങൾ (Criteria for Moral Agency)

EN **Classical Requirements of Moral Agency:** In classical philosophy, an entity is a genuine **Moral Agent** if and only if it satisfies three strict metaphysical criteria:

1. **Intentionality:** Possessing conscious internal mental states directed toward worldly states of affairs.
2. **Moral Deliberation:** The capacity to reflect upon normative rules, evaluate ethical trade-offs, and comprehend moral concepts like duty, virtue, and fairness.
3. **Free Will & Autonomy:** The capacity to have chosen otherwise, meaning actions are not deterministically hardwired by programming.

Without these conditions, an entity cannot legitimately be praised, blamed, punished, or held morally accountable.

ML **ധാർമ്മിക കർതൃത്വത്തിന്റെ മാനദണ്ഡങ്ങൾ:** തത്ത്വചിന്തയിൽ ഒരാളെ **മോറൽ ഏജന്റ്** (Moral Agent) ആയി കണക്കാക്കണമെങ്കിൽ മൂന്ന് പ്രധാന ഘടകങ്ങൾ നിർബന്ധമാണ്:

1. **ഇന്റൻഷണാലിറ്റി (Intentionality):** ബോധപൂർവ്വമായ ചിന്തയും ലക്ഷ്യബോധവുമുള്ള മനസ്സ് ഉണ്ടായിരിക്കുക.
2. **ധാർമ്മിക വിവേചന ശേഷി:** ശരിയും തെറ്റും എന്താണെന്ന് ചിന്തിക്കാനും, ന്യായവും അന്യായവും തിരിച്ചറിയാനുമുള്ള ബൗദ്ധിക ശേഷി.
3. **ഇച്ഛാസ്വാതന്ത്ര്യം (Free Will):** ഒരു പ്രത്യേക രീതിയിൽ പ്രവർത്തിക്കാൻ ബാഹ്യമായ പ്രോഗ്രാമിംഗിന്റെ പ്രേരണയില്ലാതെ സ്വതന്ത്രമായി തീരുമാനമെടുക്കാനുള്ള കഴിവ്.

ഈ മൂന്ന് ഗുണങ്ങളില്ലാത്ത ഒന്നിനെയും നമുക്ക് കുറ്റപ്പെടുത്താനോ, ശിക്ഷിക്കാനോ, ധാർമ്മികമായി ഉത്തരവാദിയാക്കാനോ കഴിയില്ല.

ധാർമ്മിക കർതൃത്വ തർക്കം (THE MORAL AGENCY DEBATE)

ഡെബോറ ജോൺസൺ (2006)
Deborah Johnson
AI കേവലം മനുഷ്യന്റെ ഉപകരണമാണ്;
ധാർമ്മിക ഉത്തരവാദിത്തം മനുഷ്യർക്ക് മാത്രം

VS

ജോൺ സുള്ളിൻസ് (2006)
John P. Sullins
സ്വയംഭരണവും സാമൂഹിക പങ്കുമുള്ള റോബോട്ടുകൾ
ധാർമ്മിക ഏജന്റുകളായി മാറും

3. ഡെബോറ ജോൺസൺ vs ജോൺ സുള്ളിൻസ് (The Great Debate)

1. ഡെബോറ ജോൺസൺ: 'കമ്പ്യൂട്ടറുകൾ ധാർമ്മിക ഘടകങ്ങളാണ്, എന്നാൽ ഏജന്റുകളല്ല' (Deborah Johnson, 2006):

കമ്പ്യൂട്ടറുകൾക്ക് മനുഷ്യന്റെ ഉദ്ദേശ്യങ്ങളെ പ്രവർത്തനക്ഷമമാക്കാൻ കഴിയും (Intentionality in the system). എന്നാൽ കമ്പ്യൂട്ടറുകൾക്ക് സ്വന്തമായി വികാരങ്ങളോ, മനസ്സാക്ഷിയോ, ഇച്ഛാസ്വാതന്ത്ര്യമോ ഇല്ല. അവ കേവലം

മനുഷ്യർ നിർമ്മിച്ച ഉപകരണങ്ങൾ മാത്രമാണ്. അതിനാൽ ഒരു AI തെറ്റ് വരുത്തിയാൽ അതിന്റെ പൂർണ്ണ ഉത്തരവാദിത്തം അത് നിർമ്മിച്ച എഞ്ചിനീയർമാർക്കും കമ്പനികൾക്കുമാണ്.

2. ജോൺ സുള്ളിൻസ്: 'എപ്പോഴാണ് ഒരു റോബോട്ട് ധാർമ്മിക ഏജന്റാകുന്നത്?' (John P. Sullins, 2006):
ഒരു റോബോട്ടിന് ധാർമ്മിക ഏജന്റാകാൻ പൂർണ്ണമായ മനുഷ്യ മനസ്സ് വേണമെന്നില്ല. മൂന്ന് കാര്യങ്ങൾ ഉണ്ടായാൽ മതി: (1) കാര്യമായ സ്വയംഭരണാധികാരം (Significant Autonomy), (2) ഉദ്ദേശ്യത്തോടെയുള്ള പെരുമാറ്റം (Intentional Behavior), (3) സാമൂഹികമായ ധർമ്മം നിർവ്വഹിക്കൽ (Social Role). ഉദാഹരണത്തിന്, രോഗികളെ പരിചരിക്കുന്ന ഒരു റോബോട്ട് ധാർമ്മിക തീരുമാനങ്ങൾ എടുക്കുന്നുണ്ടെങ്കിൽ അതിനെ ഒരു ഫങ്ഷണൽ മോറൽ ഏജന്റായി കാണണം.

3. ഉത്തരവാദിത്ത വിടവ് (The Responsibility Gap – Andreas Matthias, 2004):
ന്യൂറൽ നെറ്റ്‌വർക്കുകൾ സ്വയം പഠിച്ച് തീരുമാനങ്ങളെടുക്കുമ്പോൾ, അതിന്റെ പ്രവർത്തികൾ എഞ്ചിനീയർമാർക്ക് മുൻകൂട്ടി കാണാൻ കഴിയില്ല. ഒരു മെഷീൻ വലിയ അപകടമുണ്ടാക്കുമ്പോൾ, നിയമപരമായി ആരെ ശിക്ഷിക്കണം എന്നറിയാത്ത പ്രതിസന്ധിയെയാണ് "റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്" എന്ന് വിളിക്കുന്നത്.

4. ദാർശനിക വിമർശനം: യന്ത്രങ്ങളെ ശിക്ഷിക്കാൻ കഴിയുമോ? (Can Robots Be Punished?)

EN **The Absurdity of Retributive Punishment:** Legal and moral punishment relies on retribution, deterrence, or rehabilitation. You cannot punish a piece of code: turning off a computer or wiping its hard drive causes no subjective remorse or suffering. If society declares an AI a "moral agent," humans (corporations, programmers) will conveniently hide behind the algorithm, using the robot as a "liability sponge" to evade legal penalties for negligence.

ML **യന്ത്രങ്ങളെ ശിക്ഷിക്കുന്നതിലെ നിരർത്ഥകത:** ഒരു തെറ്റ് ചെയ്ത ആളെ ശിക്ഷിക്കുന്നത് അവർക്ക് പശ്ചാത്താപം ഉണ്ടാകാനും മറ്റുള്ളവർ തെറ്റ് ചെയ്യാതിരിക്കാനുമാണ്. ഒരു കമ്പ്യൂട്ടർ പ്രോഗ്രാമിനെ ജയിലിലടയ്ക്കാനോ അതിന് കുറ്റബോധം നൽകാനോ കഴിയില്ല. ഒരു AI-ക്ക് നിയമപരമായ വ്യക്തിത്വം നൽകിയാൽ, യഥാർത്ഥ കുറ്റക്കാരായ വൻകിട കമ്പനികളും എഞ്ചിനീയർമാരും ശിക്ഷയിൽ നിന്ന് രക്ഷപ്പെടാൻ യന്ത്രത്തെ ഒരു പരിചയായി (Liability sponge) ഉപയോഗിക്കാൻ തുടങ്ങും.

5. എൽ.എം.എസ് സമഗ്ര ചോദ്യോത്തരങ്ങൾ (Comprehensive LMS Questions & Answers)

EN **LMS Core Question 1: Why does Deborah Johnson argue that computer systems cannot be moral agents?**

Answer: Johnson argues that agency requires mental states with genuine intentionality and the capacity to suffer punishment. Since computers lack mental states and cannot experience guilt, praise, or legal incarceration, they remain moral entities embedded in human action, but not independent moral agents.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 1: കമ്പ്യൂട്ടറുകൾക്ക് ധാർമ്മിക കർതൃത്വം ഇല്ലെന്ന് ഡെബോറ ജോൺസൺ വാദിക്കുന്നത് എന്തുകൊണ്ട്?**

ഉത്തരം: ഒരു ഏജന്റാകാൻ സ്വന്തമായ മനസ്സും, ചെയ്ത തെറ്റിൽ പശ്ചാത്തപിക്കാനും ശിക്ഷ അനുഭവിക്കാനുമുള്ള ശേഷിയും വേണം. കമ്പ്യൂട്ടറുകൾക്ക് സ്വന്തമായി മനസ്സില്ലാത്തതിനാലും, അവയ്ക്ക് ജയിൽ ശിക്ഷയോ കുറ്റബോധമോ അനുഭവിക്കാൻ കഴിയില്ലെന്നതിനാലും അവ മനുഷ്യന്റെ ഉപകരണങ്ങൾ മാത്രമാണെന്ന് ജോൺസൺ വാദിക്കുന്നു.

EN **LMS Core Question 2: What is "Distributed Moral Accountability"?**

Answer: Formulated by Luciano Floridi, distributed accountability recognizes that in complex AI deployments, moral responsibility does not rest on a single actor, but is distributed across data collectors, algorithm engineers, corporate executives, and regulatory monitors.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 2: 'ഡിസ്ട്രിബ്യൂട്ടഡ് മോറൽ അക്കൗണ്ടബിലിറ്റി' (Distributed Accountability) എന്നാൽ എന്ത്?**

ഉത്തരം: ലൂസിയാനോ ഫ്ലോറിഡി മുന്നോട്ടുവെച്ച ഈ തത്വം അനുസരിച്ച്, ഒരു എഐ വരുത്തുന്ന തെറ്റിന്റെ ഉത്തരവാദിത്തം ഒരാളിൽ മാത്രമായി ഒതുങ്ങുന്നതല്ല; മറിച്ച് ഡാറ്റ ശേഖരിച്ചവർ, കോഡിങ് ചെയ്ത എഞ്ചിനീയർമാർ, ആ സിസ്റ്റം വിറ്റ കമ്പനി, മേൽനോട്ടം വഹിച്ച സർക്കാർ എന്നിവർക്കെല്ലാം തുല്യമായി വീതിക്കപ്പെടേണ്ട ഒന്നാണ്.

EN **LMS Core Question 3: What is the "Responsibility Gap" identified by Andreas Matthias (2004)?**

Answer: Andreas Matthias proved that as autonomous machine learning systems operate based on stochastic self-learning rather than deterministic rules, programmers lose the ability to foresee or control the machine's actions. When catastrophic harm occurs, traditional moral and legal models fail because neither the designer nor the user possessed the requisite direct control or foresight to be held strictly blameworthy.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 3: ആൻഡ്രിയാസ് മത്തിയാസ് അവതരിപ്പിച്ച 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്' (Responsibility Gap) എന്താണ്?**

ഉത്തരം: ന്യൂറൽ നെറ്റ്വർക്കുകൾ സ്വയം പഠിച്ച് പുതിയ വഴികൾ കണ്ടെത്തുമ്പോൾ, ആ യന്ത്രം ഭാവിയിൽ എന്ത് ചെയ്യുമെന്ന് മുൻകൂട്ടി കാണാൻ അത് നിർമ്മിച്ച എഞ്ചിനീയർമാർക്ക് പോലും സാധിക്കില്ല. അത്തരം ഒരു മെഷീൻ വൻ ദുരന്തമുണ്ടാക്കുമ്പോൾ, നിയമപരമായി എഞ്ചിനീയറെയോ ഉപയോക്താവിനെയോ യന്ത്രത്തെയോ പൂർണ്ണമായി കുറ്റപ്പെടുത്താൻ കഴിയാത്ത നിയമ-ധാർമ്മിക ശൂന്യതയെയാണ് റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് എന്ന് വിളിക്കുന്നത്.

EN **LMS Core Question 4: How does Strict Liability address harm caused by autonomous algorithms?**
Answer: Strict liability is a legal standard where a manufacturer or deploying corporation is held legally liable for compensatory damages caused by a defective or dangerous product regardless of whether the corporation exhibited fault, negligence, or bad intent. This incentivizes rigorous pre-deployment safety testing.

ML **എൽ.എം.എസ് പ്രധാന ചോദ്യം 4: സ്വയംഭരണ അൽഗോരിതങ്ങൾ വരുത്തുന്ന നഷ്ടങ്ങളിൽ 'സ്ടിക്റ്റ് ലയബിലിറ്റി' (Strict Liability) എങ്ങനെ പരിഹാരമാകുന്നു?**
ഉത്തരം: കമ്പനി മനഃപൂർവ്വം തെറ്റ് ചെയ്തിട്ടുണ്ടോ ഇല്ലയോ എന്ന് നോക്കാതെ തന്നെ, അവരുടെ ഉൽപ്പന്നം കാരണം ഉപഭോക്താവിനോ പൊതുജനങ്ങൾക്കോ അപകടം സംഭവിച്ചാൽ അതിന്റെ പൂർണ്ണ നഷ്ടപരിഹാരം ആ കമ്പനി തന്നെ നൽകണം എന്ന നിയമ തത്വമാണിത്. ഇത് വിപണിയിലിറക്കുന്നതിന് മുൻപ് പരമാവധി സുരക്ഷ ഉറപ്പുവരുത്താൻ കമ്പനികളെ നിർബന്ധിതരാക്കുന്നു.

6. പരീക്ഷാ കേന്ദ്രീകൃത 20 സുപ്രധാന പോയിന്റുകൾ (20 Deep Exam Points)

1

Moral Agency (ധാർമ്മിക കർതൃത്വം): The status of an entity capable of moral deliberation, intentional action, and bearing moral responsibility. ധാർമ്മികമായി ചിന്തിക്കാനും തീരുമാനങ്ങൾ എടുക്കാനും ഉത്തരവാദിത്തം വഹിക്കാനുമുള്ള ശേഷി.

2

Three Pillars of Agency: Intentionality (conscious mental states), Moral Deliberation (understanding duties), and Free Will (metaphysical autonomy).

3

Deborah Johnson (2006): "Computer Systems: Moral Entities but not Moral Agents"—computers embody human intentionality but lack independent agency.

4

Socio-Technical Artifacts: Deborah Johnson's view that computers act in the world only as part of human social systems, never as detached moral actors.

5

John P. Sullins (2006): Proposed functional robotic moral agency based on autonomy, intentional behavior, and social positioning.

6

Functional vs Metaphysical Agency: Judging agency by external reliable moral behavior rather than demanding unobservable internal metaphysical free will.

7

The Responsibility Gap (Andreas Matthias, 2004): Disconnection between human designers and autonomous learning machines that renders traditional fault attribution void.

8

Luciano Floridi's Mindless Morality: Theory that agents can perform morally significant actions without possessing subjective intentionality or blameworthiness.

9

Distributed Moral Accountability: Spreading culpability across institutions, corporate boards, programmers, and dataset collectors.

10

Strict Liability Model: Imposing automatic legal liability on deploying entities regardless of algorithmic unpredictability or developer innocence.

11

Vicarious Liability Analogy: Treating AI like an employee or pet where the master/owner bears financial liability for subordinate actions.

12

Electronic Personhood (EU Parliament Proposal, 2017): Controversial rejected draft to create legal status for sophisticated robots, criticized as an evasion of human corporate liability.

13

Liability Sponge Danger: The moral hazard where corporations blame the algorithm as a scapegoat to avoid criminal and civil penalties.

14

Retributive Punishment Incompatibility: Impossibility of punishing code because algorithms experience neither remorse, pain, nor rehabilitation.

15

Meaningful Human Control (MHC): Regulatory mandate ensuring that humans retain contextual oversight and the physical capacity to abort automated decisions.

16

Epistemic Luck in Autonomous Outcomes: Unpredictable environmental interactions producing catastrophic failures without any identifiable programmer malice.

17

Corporate Legal Personhood Analogy: Argument that just as corporations possess artificial legal personhood, advanced AI could hold dedicated liability insurance funds.

18

Moral Hazard of Automation: Human operators lapsing into complacency, uncritically trusting algorithm outputs under the assumption the machine is responsible.

19

Explainability as a Legal Prerequisite: Without interpretable decision trees, determining whether a system exhibited defectiveness in court is impossible.

20

Irreducible Human Responsibility: Final consensus that machines remain tools of human agency; moral accountability must always terminate in human beings.

7. സർവ്വകലാശാലാ മാതൃകാ മൾട്ടിപ്പിൾ ചോയ്സ് ചോദ്യങ്ങൾ (MCQs & Solutions)

Q107: Deborah Johnson's primary argument in "Computer Systems: Moral Entities but not Moral Agents" is that:

A. Computers have conscious free will and should be sent to federal prisons

B. Computers have intentionality only through human design and use; they lack mental states, so moral responsibility belongs solely to humans (ശരിയുത്തരം)

C. Silicon chips have souls granted by electrical power

D. Robots should be granted voting rights in parliamentary elections

പാഠഭാഗ വിശകലനം: കമ്പ്യൂട്ടറുകൾ മനുഷ്യന്റെ ഉദ്ദേശ്യങ്ങൾ നടപ്പിലാക്കുന്ന ഉപകരണങ്ങൾ മാത്രമാണ്; അവയ്ക്ക് സ്വന്തമായി ഉത്തരവാദിത്തമില്ല.

വിശദീകരണം: ധാർമ്മികമായ കർതൃത്വം മനുഷ്യന് മാത്രമേ ഉണ്ടാകൂ എന്ന് ജോൺസൺ സമർത്ഥിക്കുന്നു.

Q108: Andreas Matthias (2004) identified the "Responsibility Gap" in autonomous systems because:

A. Programmers are paid too little to care about system bugs

B. Autonomous learning algorithms act beyond designer foresight and control, breaking traditional models of moral and legal accountability (ശരിയുത്തരം)

C. Robots run out of battery during court depositions

D. Legal jurisdictions have no judges trained in computer science

പാഠഭാഗ വിശകലനം: സ്വയം പഠിക്കുന്ന മെഷീനുകൾ എഞ്ചിനീയർമാർ ഉദ്ദേശിക്കാത്ത കാര്യങ്ങൾ ചെയ്യുമ്പോൾ നിയമപരമായി ആരെ ശിക്ഷിക്കണം എന്നറിയാത്ത പ്രതിസന്ധി.

വിശദീകരണം: നിയന്ത്രണമില്ലാത്ത പ്രവർത്തനങ്ങൾക്ക് എഞ്ചിനീയറെ കുറ്റപ്പെടുത്താൻ കഴിയാത്ത അവസ്ഥയാണിത്.

Q109: John P. Sullins argues that a robot can be considered a moral agent if it satisfies which criteria?

A. Carbon biological DNA and psychological trauma

B. Significant autonomy, intentional behavior, and a social role (ശരിയുത്തരം)

C. High stock market valuation and corporate ownership

D. Ability to calculate chess moves faster than Garry Kasparov

പാഠഭാഗ വിശകലനം: കാര്യമായ സ്വയംഭരണവും, ലക്ഷ്യബോധമുള്ള പെരുമാറ്റവും, സാമൂഹിക പങ്കാളിത്തവും ഉണ്ടെങ്കിൽ റോബോട്ടിനെ ഏജന്റായി കാണാം.

വിശദീകരണം: സുള്ളിൻസ് മുന്നോട്ടുവെച്ച ഫങ്ഷണൽ മോറൽ ഏജൻസിയുടെ മൂന്ന് മാനദണ്ഡങ്ങളാണിവ.

Q110: Why did legal and ethical scholars criticize the European Parliament's 2017 proposal for "Electronic Personhood"?

A. Because robots cannot physically wear human courtroom suits

B. Because creating electronic personhood allows corporations to use robots as "liability shields" to escape financial and criminal responsibility (ശരിയുത്തരം)

C. Because software compilers refuse to sign international treaties

D. Because it would increase electrical utility tariffs

പാഠഭാഗ വിശകലനം: റോബോട്ടുകൾക്ക് നിയമപരമായ പദവി നൽകിയാൽ വൻകിട കമ്പനികൾ അവരുടെ തെറ്റുകൾ റോബോട്ടിന്റെ തലയിൽ വെച്ച് രക്ഷപ്പെടും.

വിശദീകരണം: ഉത്തരവാദിത്തത്തിൽ നിന്ന് മനുഷ്യർ ഒളിച്ചോടാൻ ഇത് കാരണമാകും എന്ന് വിദഗ്ധർ ചൂണ്ടിക്കാട്ടി.

Q111: "Distributed Moral Accountability" (Luciano Floridi) suggests that when an AI system causes catastrophic failure:

A. No one is ever held accountable because software is inherently mysterious

B. Accountability is shared across the entire network of software engineers, dataset curators, deployers, and regulators (ശരിയുത്തരം)

C. The physical computer tower must be publicly dismantled with a hammer

D. Only the end-user who clicked the mouse is legally liable

പാഠഭാഗ വിശകലനം: ഒരു സിസ്റ്റം പരാജയപ്പെടുമ്പോൾ അതിന്റെ ഉത്തരവാദിത്തം ഡാറ്റയും കോഡും നിയമവും നിർമ്മിച്ച എല്ലാവരിലുമായി വീതിക്കപ്പെടുന്നു.

വിശദീകരണം: ആധുനിക സങ്കീർണ്ണ സിസ്റ്റങ്ങളിൽ ഉത്തരവാദിത്തം കൂട്ടായ ഒന്നാണ്.
