CALICUT UNIVERSITY · FYUGP MINOR PHILOSOPHY (PHL1MN102)

Module 4: Ethical and Philosophical Implications of AI System

മൊഡ്യൂൾ 4: AI സംവിധാനങ്ങളുടെ ധാർമ്മിക-ദാർശനിക പ്രത്യാഘാതങ്ങൾ

LMS Source Document: Module_4_Ethical_and_Philosophical_Implications_of_AI_System.pdf & Official Syllabus (Pages 114–115)
Syllabus Code: PHL1MN102 · Credits: 4 · Weightage: 15 Marks / 15 Hours

📋 ഔദ്യോഗിക LMS അവലോകനവും 6 പഠന ലക്ഷ്യങ്ങളും (Official LMS Overview & 6 Objectives)

LMS Overview: AI serves as a crucial transformative force in modern society. While it offers considerable benefits—efficiency, automation, and innovation—it concurrently raises profound ethical and philosophical questions regarding human values, moral responsibility, and the nature of intelligence itself. The implications challenge our core notions of morality, freedom, equity, and the nature of humankind. To ensure AI fosters human happiness, ethical reasoning, human oversight, and philosophical reflection must be integrated at every stage.

✓ 6 Core LMS Objectives: 1) Ethical dilemmas (prejudice, justice, responsibility, privacy) 2) Nature of intelligence, consciousness & moral agency 3) Influence on human values (autonomy, equality, dignity) 4) Accountability of developers, users, institutions 5) Impact on human identity (what it means to be "human") 6) Advancing human-centered AI.

1. Value Alignment & The Existential Question (Unit 4.1 a, b) — മൂല്യ പൊരുത്തവും (Value Alignment) അസ്തിത്വ ഭീഷണിയും

GB Alignment & Existential Risk (Nick Bostrom)

- **The Value Alignment Problem (മൂല്യ പൊരുത്തം):** How do we ensure that an autonomous, highly capable AI pursues goals congruent with true human welfare, ethics, and preferences, avoiding catastrophic literalism (e.g., King Midas problem)?
- **Orthogonality Thesis:** An AI system can possess any arbitrary level of intelligence combined with virtually any arbitrary final goal (high intelligence does not guarantee moral virtue).
- **Instrumental Convergence:** Almost any autonomous intelligent agent will converge on sub-goals like self-preservation, resource acquisition, and goal-content integrity, creating competition with humans.
- **Existential Threat:** A runaway superintelligent system unconstrained by human values poses an irreversible existential catastrophe to the survival and sovereignty of humanity.

ML മൂല്യ പൊരുത്തവും മാനവരാശിയുടെ നിലനിൽപ്പും

- **വാല്യൂ അലൈൻമെന്റ് പ്രശ്നം (Value Alignment):** കമ്പ്യൂട്ടറുകളുടെ ലക്ഷ്യങ്ങളെ മനുഷ്യന്റെ യഥാർത്ഥ മൂല്യങ്ങളോടും നന്മയോടും എങ്ങനെ ചേർത്തുനിർത്താം എന്നതാണ് ഈ പ്രശ്നം. നമ്മൾ നൽകുന്ന നിർദ്ദേശങ്ങൾ അതേപടി വാച്യാർത്ഥത്തിൽ (Literalism) നടപ്പിലാക്കുമ്പോൾ വിപരീത ഫലങ്ങൾ ഉണ്ടായേക്കാം (മിദാസ് രാജാവിന്റെ കഥ പോലെ).
- **ഓർത്തോഗണാലിറ്റി വാദം (Orthogonality Thesis):** ഒരു സിസ്റ്റത്തിന് എത്ര ഉയർന്ന ബുദ്ധിയുണ്ടെങ്കിലും അത് ധാർമ്മികമായി നല്ലതായിക്കൊള്ളണമെന്നില്ല; ഉയർന്ന ബുദ്ധിയും വിനാശകരമായ ലക്ഷ്യങ്ങളും ഒരുമിച്ച് വരാം.
- **ഇൻസ്ട്രുമെന്റൽ കൺവർജൻസ്:** സ്വന്തം നിലനിൽപ്പ് ഉറപ്പാക്കാനും കൂടുതൽ വിഭവങ്ങൾ പിടിച്ചെടുക്കാനും ഏത് സ്വയംഭരണ യന്ത്രവും സ്വാഭാവികമായി ശ്രമിക്കും; ഇത് മനുഷ്യരുമായി സംഘർഷമുണ്ടാക്കാം.
- **അസ്തിത്വ ഭീഷണി (Existential Threat):** മനുഷ്യനിയന്ത്രണം നഷ്ടപ്പെട്ട അതിബുദ്ധിയുള്ള (Superintelligent) യന്ത്രങ്ങൾ മാനവരാശിയുടെ അന്ത്യത്തിന് തന്നെ കാരണമായേക്കാം (Nick Bostrom).

2. Algorithmic Bias & Embedding AI in Social Relations (Unit 4.2 a, b) — അൽഗോരിതമിക് പക്ഷപാതങ്ങളും സാമൂഹിക ബന്ധങ്ങളിലെ AI വിന്യാസവും

GB Algorithmic Injustice & Human Dignity

- **Algorithmic Biases (അൽഗോരിതമിക് പക്ഷപാതം):** Machine learning algorithms train on historical data. If training data reflects historical human discrimination (racial, gender, caste, socio-economic), the algorithm mathematically automates and amplifies prejudice under a false veneer of "objective mathematical neutrality".
- **Mitigation Strategies:** Pre-processing data debiasing, adversarial debiasing in model weights, and post-processing calibration (Demographic Parity vs. Equalized Odds).
- **Embedding in Social Relations:**
  - **Preserving Human Agency:** Autonomous decision systems in judicial sentencing (e.g., COMPAS), hiring, and lending must retain *Human-in-the-Loop* oversight.
  - **Alienation & Epistemic Echo Chambers:** Hyper-personalized algorithms polarize civic discourse and replace authentic human empathy with shallow synthetic relationships.

ML അൽഗോരിതങ്ങളിലെ മുൻവിധികൾ തടയൽ

- **അൽഗോരിതമിക് പക്ഷപാതം (Algorithmic Bias):** AI പ്രവർത്തിക്കുന്നത് മുൻകാല ഡാറ്റകളെ ആശ്രയിച്ചാണ്. മുൻകാല ഡാറ്റകളിൽ നിലനിന്നിരുന്ന വംശീയ, ലിംഗ, ജാതി വിവേചനങ്ങൾ അതേപടി പഠിച്ചെടുക്കുന്ന AI, പുതിയ കാലത്തും അനീതികളെ ശാസ്ത്രീയമായി ആവർത്തിക്കുന്നു (ഉദാ: ജാമ്യം അനുവദിക്കുന്നതിലും ജോലി നൽകുന്നതിലും ഉള്ള വിവേചനം).
- **പരിഹാരങ്ങൾ:** ഡാറ്റയിലെ പക്ഷപാതങ്ങൾ മുൻകൂട്ടി നീക്കം ചെയ്യുക, അൽഗോരിതങ്ങളെ നിഷ്പക്ഷമായി ഓഡിറ്റ് ചെയ്യുക, സുതാര്യത ഉറപ്പാക്കുക.
- **സാമൂഹിക ബന്ധങ്ങളിലെ വിന്യാസം:**
  - **മനുഷ്യന്റെ അന്തസ്സ് (Human Dignity):** കോടതി വിധികൾ, നീതിനിർവ്വഹണം എന്നിവയിൽ പൂർണ്ണമായും യന്ത്രങ്ങൾക്ക് അധികാരം നൽകാതെ മനുഷ്യന്റെ മേൽനോട്ടം (Human-in-the-loop) നിർബന്ധമാക്കണം.
  - **സാമൂഹിക ഒറ്റപ്പെടൽ:** ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് അൽഗോരിതങ്ങൾ ആളുകളെ സ്വന്തം ആശയക്കൂടുകളിൽ (Echo Chambers) തളച്ചിടുകയും മനുഷ്യർ തമ്മിലുള്ള ആത്മാർത്ഥ ബന്ധങ്ങളെ തകർക്കുകയും ചെയ്യുന്നു.

3. Ethical Rules for Autonomous Vehicles: The Trolley Problem (Unit 4.3 a) സ്വയംഭരണ വാഹനങ്ങളും ധാർമ്മിക നിയമങ്ങളും: ട്രോളി പ്രശ്നം

Ethical Framework	Autonomous Vehicle Decision Logic (English)	തീരുമാന യുക്തി (മലയാളം)
Utilitarian Ethics (യൂട്ടിലിറ്റേറിയനിസം)	Calculates outcomes to minimize total net casualties: *"Sacrifice 1 passenger to save 5 pedestrians."* Prioritizes the greatest happiness/survival for the greatest number.	ഏറ്റവും കൂടുതൽ ആളുകളുടെ ജീവൻ രക്ഷിക്കുക. അപകടത്തിൽ മരണസംഖ്യ ഏറ്റവും കുറയ്ക്കാൻ സ്വന്തം യാത്രക്കാരനെ ബലികൊടുക്കാനും മടിക്കില്ല.
Deontological Ethics (ഡീയോണ്ടോളജി – കർത്തവ്യവാദം)	Abides by absolute moral duties (Kant): Never actively use an innocent human as a mere means. The car must not deliberately steer to kill an innocent person to save others.	ആരെയും ബോധപൂർവ്വം കൊല്ലരുത് എന്ന കേവല നിയമം. മറ്റുള്ളവരെ രക്ഷിക്കാൻ നിരപരാധിയായ ഒരാളെ വണ്ടിയിടിപ്പിച്ചു കൊല്ലുന്നത് അധാർമ്മികമാണ്.
Contractarian / Rawlsian (റോൾസിയൻ നീതിശാസ്ത്രം)	Design safety policies behind a "Veil of Ignorance," ensuring maximum protection for the most vulnerable road users (pedestrians, cyclists).	റോഡിലെ ഏറ്റവും ദുർബലരായ കാൽനടയാത്രക്കാരെയും കുട്ടികളെയും സംരക്ഷിക്കാൻ മുൻഗണന നൽകുന്ന നീതിപൂർവ്വമായ നയം.

4. Can AI Suffer Moral Harm? Moral Patiency vs. Sentience (Unit 4.3 b)

AI സംവിധാനങ്ങൾക്ക് ധാർമ്മിക ദ്രോഹം അനുഭവിക്കാൻ കഴിയുമോ?

GB Moral Status & Sentience (Mary Anne Warren)

- **Moral Patient vs. Moral Agent:** A *Moral Agent* is responsible for its actions. A *Moral Patient* is an entity whose interests must be morally considered for its own sake (can be harmed or wronged).
- **Prerequisites for Moral Harm:**
  - **Sentience (ഫീലിംഗ്സ്/വേദന):** The capacity for phenomenal consciousness—to experience positive and negative valences (pleasure, physical pain, emotional suffering).
  - **Interests:** Without biological vulnerability, survival instinct, or phenomenal conscious states, an algorithm cannot "suffer" in any genuine ontological sense.
- **Instrumental Harm to Humans:** Smashing or abusing a humanoid robot harms the human abuser (by desensitizing human empathy) and damages human property, but does not morally harm the non-sentient silicon artifact.

ML മോറൽ പേഷ്യന്റും അനുഭവ ബോധവും

- **മോറൽ പേഷ്യന്റ് (Moral Patient):** ധാർമ്മിക പരിഗണന അർഹിക്കുന്ന, ഉപദ്രവിക്കപ്പെടാൻ സാധ്യതയുള്ള ജീവികൾ (ഉദാ: മൃഗങ്ങൾ, കുട്ടികൾ).
- **വേദന അനുഭവിക്കാനുള്ള ശേഷി (Sentience):** ഒരു വസ്തുവിന് ദ്രോഹം സംഭവിക്കണമെങ്കിൽ അതിന് വേദനയോ മാനസിക വിഷമമോ ആന്തരിക വികാരങ്ങളോ (Phenomenal Consciousness) അനുഭവിക്കാൻ കഴിയണം.
- **AI-ക്ക് ദ്രോഹം സംഭവിക്കുമോ?** ഇന്നത്തെ കമ്പ്യൂട്ടറുകൾക്ക് വേദനയോ സ്വയംബോധമോ ഇല്ലാത്തതിനാൽ, അവയ്ക്ക് യഥാർത്ഥത്തിൽ 'ധാർമ്മിക ദ്രോഹം' (Moral Harm) അനുഭവിക്കാൻ കഴിയില്ല. ഒരു റോബോട്ടിനെ തല്ലിപ്പൊളിക്കുന്നത് വസ്തുവകകൾ നശിപ്പിക്കുന്നതിന് തുല്യമാണ്; അത് റോബോട്ടിനോടല്ല, മറിച്ച് മനുഷ്യന്റെ സഹാനുഭൂതിയെയാണ് മോശമായി ബാധിക്കുന്നത്.

5. Moral Agency & The Responsibility Gap (Unit 4.3 c) ധാർമ്മിക കർതൃത്വവും ഉത്തരവാദിത്ത വിടവും (Responsibility Gap)

GB Sullins vs. Deborah Johnson Debate

- **John P. Sullins (2006):** Argued robots can be considered *functional moral agents* if they satisfy 3 conditions: 1) Significant autonomy 2) Intentional behavior toward a goal 3) Fulfilling a social role with moral consequences.
- **Deborah G. Johnson (2006 – Counter-argument):** Computers are *moral entities* or *moral artifacts*, but **NEVER moral agents**. Moral agency requires genuine free will, moral intentionality, and legal accountability. AI systems only act as intentional extensions of the human engineers and institutions that designed them.
- **The Responsibility Gap (ഉത്തരവാദിത്ത വിടവ്):** When a self-learning autonomous weapon or medical diagnosis system causes wrongful death, who is criminally culpable? The programmer? The user? The manufacturer? The machine cannot be jailed or held morally culpable.

ML യന്ത്രത്തിന് ധാർമ്മിക ഉത്തരവാദിത്തമുണ്ടോ?

- **ജോൺ സള്ളിൻസ് (Sullins):** സ്വയം തീരുമാനങ്ങളെടുക്കാനും ലക്ഷ്യബോധത്തോടെ പ്രവർത്തിക്കാനും കഴിയുന്ന യന്ത്രങ്ങളെ 'പ്രവർത്തനപരമായ ധാർമ്മിക കർത്താക്കളായി' (Functional Moral Agents) കണക്കാക്കാമെന്ന് വാദിച്ചു.
- **ഡെബോറ ജോൺസൺ (Deborah Johnson):** ഈ വാദത്തെ പൂർണ്ണമായും തള്ളി. കമ്പ്യൂട്ടറുകൾ കേവലം മനുഷ്യൻ നിർമ്മിച്ച ഉപകരണങ്ങൾ (Moral Entities) മാത്രമാണ്; അവയ്ക്ക് ഒരിക്കലും സ്വന്തമായി **ധാർമ്മിക കർതൃത്വം (Moral Agency)** ഉണ്ടാകില്ല. മനുഷ്യർക്ക് മാത്രമേ ധാർമ്മിക ഉത്തരവാദിത്തം ഏൽക്കാൻ കഴിയൂ.
- **റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ് (Responsibility Gap):** സ്വയം പ്രവർത്തിക്കുന്ന ഒരു ഡ്രോൺ അല്ലെങ്കിൽ കാർ ഒരാളെ കൊന്നാൽ ആർക്കാണ് ശിക്ഷ നൽകുക? പ്രോഗ്രാമർക്കോ, കമ്പനിക്കോ, അതോ കാറിനോ? യന്ത്രത്തെ ജയിലിലടക്കാൻ കഴിയില്ല; ഈ പ്രതിസന്ധിയാണ് 'ഉത്തരവാദിത്ത വിടവ്'.

6. Exam-Focused High-Yield Q&A (Strictly Syllabus Aligned) പരീക്ഷാ കേന്ദ്രീകൃത ചോദ്യോത്തരങ്ങൾ (15 മാർക്ക് ഫോക്കസ്)

Q1. What is the AI Value Alignment Problem? Explain Nick Bostrom's Orthogonality Thesis. (AI വാല്യൂ അലൈൻമെന്റ് പ്രശ്നവും നിക്ക് ബോസ്ട്രോമിന്റെ ഓർത്തോഗണാലിറ്റി വാദവും വിശദീകരിക്കുക.)

Answer: The Value Alignment Problem concerns the immense challenge of ensuring that advanced, autonomous AI systems reliably pursue outcomes aligned with human moral values, flourishing, and survival, rather than pursuing dangerously literal or unintended interpretations of programmed goals. **Nick Bostrom's Orthogonality Thesis** states that an agent's intelligence level and its ultimate goals are orthogonal (independent). A system can possess god-like cognitive processing power while pursuing a completely trivial or catastrophic goal (e.g., maximizing paperclips by consuming the Earth's biomass), proving that extreme intelligence does not automatically produce moral enlightenment.

മലയാളം ഉത്തരം: സ്വയം പ്രവർത്തിക്കുന്ന അത്യാധുനിക AI സംവിധാനങ്ങൾ മനുഷ്യന്റെ യഥാർത്ഥ നന്മയ്ക്കും മൂല്യങ്ങൾക്കും അനുസൃതമായി മാത്രമേ പ്രവർത്തിക്കൂ എന്ന് ഉറപ്പുവരുത്താനുള്ള ദാർശനിക വെല്ലുവിളിയാണ് 'വാല്യൂ അലൈൻമെന്റ്'. നിക്ക് ബോസ്ട്രോമിന്റെ 'ഓർത്തോഗണാലിറ്റി സിദ്ധാന്തം' പറയുന്നത് ബുദ്ധിയും ധാർമ്മിക ലക്ഷ്യങ്ങളും തമ്മിൽ നേരിട്ട് ബന്ധമില്ലെന്നാണ്. അത്യധികം ബുദ്ധിയുള്ള ഒരു കമ്പ്യൂട്ടറിന് വേണമെങ്കിൽ മനുഷ്യരാശിയെ നശിപ്പിക്കുന്ന ഭ്രാന്തമായ ലക്ഷ്യങ്ങൾ ഉണ്ടാകാം; ബുദ്ധികൂടിയതുകൊണ്ട് മാത്രം ഒരു യന്ത്രവും തനിയെ ധാർമ്മികമായി മാറില്ല.

Q2. Can Artificial Intelligence systems be considered Moral Agents? Contrast Sullins and Deborah Johnson. (AI സംവിധാനങ്ങളെ ധാർമ്മിക കർത്താക്കളായി കാണാമോ? സള്ളിൻസിന്റെയും ഡെബോറ ജോൺസന്റെയും വാദങ്ങൾ താരതമ്യം ചെയ്യുക.)

Answer: John P. Sullins: Argues that robots can possess *functional moral agency* if they exhibit autonomy, intentionality, and moral consequences in their social roles, without requiring mysterious biological consciousness.
Deborah G. Johnson: Strongly refutes this. She insists that computers are *moral entities (artifacts)*, not moral agents. Genuine moral agency requires human intentionality, moral consciousness, and susceptibility to moral praise and legal blame. Technology merely reflects human agency; ethical responsibility rests entirely with the developers, deployers, and institutions that orchestrate the technology.

മലയാളം ഉത്തരം: ജോൺ സള്ളിൻസ്: ബാഹ്യമായി സ്വയംഭരണാധികാരത്തോടെ നന്മതിന്മകൾ ഉണ്ടാക്കുന്ന തീരുമാനങ്ങളെടുക്കാൻ കഴിയുന്ന യന്ത്രങ്ങളെ 'ധാർമ്മിക കർത്താക്കളായി' (Moral Agents) കാണാമെന്ന് വാദിച്ചു.
ഡെബോറ ജോൺസൺ: ഇതിനെ ശക്തമായി എതിർത്തു. കമ്പ്യൂട്ടറുകൾ മനുഷ്യൻ നിർമ്മിച്ച വെറും ഭൗതിക ഉപകരണങ്ങൾ (Moral Entities) മാത്രമാണ്. യഥാർത്ഥ ഇച്ഛാശക്തിയും ബോധവുമുള്ള മനുഷ്യർക്ക് മാത്രമേ ധാർമ്മിക ഉത്തരവാദിത്തം ഉണ്ടാകൂ; തെറ്റുകൾ സംഭവിച്ചാൽ അതിന്റെ കുറ്റം യന്ത്രത്തിന്റെ പിന്നിലുള്ള മനുഷ്യർക്കും കമ്പനികൾക്കുമാണ്.

Q3. How do autonomous vehicles handle moral dilemmas like the Trolley Problem? (സ്വയംഭരണ വാഹനങ്ങൾ ട്രോളി പ്രശ്നം പോലുള്ള ധാർമ്മിക പ്രതിസന്ധികൾ എങ്ങനെയാണ് കൈകാര്യം ചെയ്യുന്നത്?)

Answer: Autonomous vehicles must be algorithmically programmed to respond to unavoidable crashes. The **Trolley Problem** tests two competing moral philosophies: 1) *Utilitarianism:* Minimizes total death count (e.g., steering into an obstacle to save 5 pedestrians even if it kills the vehicle's 1 passenger). However, consumers refuse to buy cars programmed to sacrifice their own owners! 2) *Deontology (Kantianism):* Forbids actively choosing to kill an innocent party to save others. The algorithm cannot commodify human life through quantitative arithmetic. This clash exposes the profound dilemma of translating nuanced human philosophical ethics into rigid computer code.

മലയാളം ഉത്തരം: അപകടം ഒഴിവാക്കാനാവാത്ത സന്ദർഭങ്ങളിൽ ഡ്രൈവറില്ലാ കാറുകൾ ആരെ രക്ഷിക്കണം എന്ന പ്രശ്നമാണിത്: 1) **യൂട്ടിലിറ്റേറിയനിസം:** മരണസംഖ്യ പരമാവധി കുറയ്ക്കാൻ ശ്രമിക്കുന്നു (ഉദാ: 5 വഴിയാത്രക്കാരെ രക്ഷിക്കാൻ കാറിലുള്ള 1 യാത്രക്കാരനെ ബലികൊടുക്കുന്നു). എന്നാൽ സ്വന്തം ഉടമയെ കൊല്ലാൻ പ്രോഗ്രാം ചെയ്ത കാറുകൾ ആരും വാങ്ങില്ല! 2) **ഡീയോണ്ടോളജി (കർത്തവ്യവാദം):** ആരെയെങ്കിലും കൊന്ന് മറ്റുള്ളവരെ രക്ഷിക്കുന്നത് തെറ്റാണെന്ന് വാദിക്കുന്നു. മനുഷ്യ ജീവന്റെ മൂല്യം സംഖ്യകൾ വെച്ച് അളക്കാൻ കഴിയില്ല. ഇതാണ് ഈ വിഷയത്തിലെ പ്രധാന ദാർശനിക തർക്കം.

Q4. What is the "Responsibility Gap" in autonomous machine ethics? (സ്വയംഭരണ യന്ത്രങ്ങളുടെ ധാർമ്മികതയിലെ 'ഉത്തരവാദിത്ത വിടവ്' എന്താണ്?)

Answer: The Responsibility Gap arises when autonomous learning systems perform actions that cause catastrophic harm (e.g., an autonomous surgical robot or military drone kills an innocent person) without any human directly willing or foreseeing the specific failure. Because the machine learned its behavior independently through neural networks, the human programmer cannot be held strictly reckless, yet the machine cannot be held criminally accountable or punished. This leaves a dangerous moral, legal, and ontological vacuum where no entity can be held justly accountable for tragedy.

മലയാളം ഉത്തരം: സ്വയംഭരണ യന്ത്രങ്ങൾ സ്വന്തം അൽഗോരിതം വഴി തെറ്റായ തീരുമാനമെടുത്ത് വലിയ നാശനഷ്ടമോ മരണമോ ഉണ്ടാക്കുമ്പോൾ ആരെ കുറ്റപ്പെടുത്തും എന്ന നിയമ-ധാർമ്മിക പ്രതിസന്ധിയാണിത്. പ്രോഗ്രാമർ ആ തെറ്റ് മുൻകൂട്ടി കണ്ടിട്ടുണ്ടാകില്ല; യന്ത്രത്തിന് മനുഷ്യനെപ്പോലെ കോടതിയിൽ ഉത്തരവാദിത്തം പറയാനോ ജയിൽ ശിക്ഷ അനുഭവിക്കാനോ കഴിയില്ല. ഇത്തരത്തിൽ ആർക്കും ശിക്ഷ നൽകാൻ സാധിക്കാതെ വരുന്ന ധാർമ്മിക ശൂന്യതയെയാണ് 'റെസ്പോൺസിബിലിറ്റി ഗ്യാപ്പ്' എന്ന് വിളിക്കുന്നത്.