കാലിക്കറ്റ് സർവ്വകലാശാല ഔദ്യോഗിക പാഠ്യപദ്ധതി (PAGES 113-116)

സിലബസ്: ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസിന്റെ തത്ത്വചിന്ത (PHL1MN 102)

B.A. Philosophy Honours (FYUGP) · Minor Course · 4 Credits · 60 Instructional Hours · സമഗ്ര ഇംഗ്ലീഷ് & മലയാള വിശദീകരണം

ശ്രദ്ധിക്കുക (Academic Notice): ഈ രേഖ കാലിക്കറ്റ് സർവ്വകലാശാലയുടെ ഔദ്യോഗിക പാഠ്യപദ്ധതി രേഖയായ *'Minor-Philosophy.pdf'* (പേജുകൾ 113 മുതൽ 116 വരെ) പൂർണ്ണമായും അടിസ്ഥാനമാക്കി തയ്യാറാക്കിയ സമഗ്രമായ പഠന സഹായിയാണ്. വിദ്യാർത്ഥികൾക്ക് സിലബസിന്റെ ഓരോ ഘടകവും വ്യക്തമായി മനസ്സിലാകുന്നതിനായി ഇംഗ്ലീഷിലും മലയാളത്തിലും ആഴത്തിലുള്ള വിശദീകരണം നൽകിയിരിക്കുന്നു. ഇതിൽ ചോദ്യോത്തരങ്ങളോ (Q&A) ബഹുവിശേഷ ചോദ്യങ്ങളോ (MCQ) ഉൾപ്പെടുത്തിയിട്ടില്ല; ഔദ്യോഗിക സിലബസ് ഉള്ളടക്ക വിശകലനം മാത്രമാണ് നൽകിയിരിക്കുന്നത്.

1. കോഴ്സ് തിരിച്ചറിയൽ വിവരങ്ങളും ഘടനയും (Course Identification & Official Metadata)

കാലിക്കറ്റ് സർവ്വകലാശാല നാലുവർഷ ബിരുദ പ്രോഗ്രാമിലെ (FYUGP) ഗ്രൂപ്പ് II (Philosophy and Human Values) വിഭാഗത്തിന് കീഴിൽ ഒന്നാം സെമസ്റ്റർ വിദ്യാർത്ഥികൾക്കായി നിശ്ചയിച്ചിട്ടുള്ള മൈനർ കോഴ്സാണ് **PHL1MN 102: Philosophy of Artificial Intelligence.** ഔദ്യോഗിക രേഖയിലെ പേജ് 113 പ്രകാരമുള്ള അടിസ്ഥാന വിവരങ്ങൾ താഴെ നൽകുന്നു:

ഘടകം (Parameter)	ഔദ്യോഗിക വിവരണം (Official English Specification)	മലയാള വിശദീകരണം (Malayalam Explanation)
Programme / പ്രോഗ്രാം	B.A. PHILOSOPHY HONOURS	ബി.എ. ഫിലോസഫി ഓണേഴ്സ് പ്രോഗ്രാം
Course Name / കോഴ്സിന്റെ പേര്	PHILOSOPHY OF ARTIFICIAL INTELLIGENCE	ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസിന്റെ തത്ത്വചിന്ത
Academic Group / ഗ്രൂപ്പ്	GROUP II: Philosophy and Human Values	ഗ്രൂപ്പ് 2: തത്ത്വചിന്തയും മാനുഷിക മൂല്യങ്ങളും
Type of Course / കോഴ്സ് തരം	MINOR	മൈനർ കോഴ്സ് (അനുബന്ധ ശാഖ)
Course Code / കോഴ്സ് കോഡ്	**PHL1MN 102**	ഔദ്യോഗിക കോഡ്: PHL1MN 102
Course Level / കോഴ്സ് തലം	100–199 (Introductory / Foundational Level)	100–199 (പ്രാരംഭ ഫൗണ്ടേഷൻ തലം)
Semester / സെമസ്റ്റർ	Semester I	ഒന്നാം സെമസ്റ്റർ
Total Credits / ആകെ ക്രെഡിറ്റുകൾ	4 Credits	4 അക്കാദമിക് ക്രെഡിറ്റുകൾ
Total Instructional Hours / ആകെ മണിക്കൂറുകൾ	60 Hours	ആകെ 60 അധ്യയന മണിക്കൂറുകൾ
Learning Approach / ബോധന രീതി	Lecture: 4 Hours / Week (Tutorial: –, Practical: –, Practicum: –)	ആഴ്ചയിൽ 4 മണിക്കൂർ സിദ്ധാന്ത പ്രഭാഷണങ്ങൾ

2. കോഴ്സിന്റെ ഔദ്യോഗിക സംക്ഷിപ്ത വിവരണം (Brief Description of the Course)

> *Official Course Description (Verbatim from Page 114):*
> *"This is a philosophy of artificial intelligence course, no knowledge in computer science or cognitive science will be presupposed, though any prior exposure to either can be an asset. This course will teach students how to think philosophically about artificial intelligence, at a high level of abstraction and from a certain distance from practice. The course aims at a concise introduction to the history and philosophy of AI, the Classical version of AI, Theories of artificial intelligence in Indian & Western and the ethical & philosophical implications of AI."*

സമഗ്ര മലയാള പരിഭാഷയും ആശയ വിശകലനവും (Comprehensive Malayalam Analysis):

ഇത് ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസിന്റെ തത്ത്വചിന്താപരമായ പഠനത്തിനായുള്ള കോഴ്സാണ്. ഈ കോഴ്സ് പഠിക്കുന്നതിനായി വിദ്യാർത്ഥികൾക്ക് കമ്പ്യൂട്ടർ സയൻസിലോ കോഗ്നിറ്റീവ് സയൻസിലോ മുൻകാല അറിവോ സാങ്കേതിക വൈദഗ്ധ്യമോ ഉണ്ടായിരിക്കണമെന്ന് നിർബന്ധമില്ല; എങ്കിലും അത്തരം വിഷയങ്ങളിലുള്ള മുൻപരിചയം ഗുണകരമായിരിക്കും. പ്രായോഗിക കമ്പ്യൂട്ടർ കോഡിംഗിൽ നിന്നും സാങ്കേതിക നിർവ്വഹണങ്ങളിൽ നിന്നും നിശ്ചിത അകലം പാലിച്ചുകൊണ്ട്, ഉയർന്ന തലത്തിലുള്ള ദാർശനിക-അമൂർത്ത ചിന്തയിലൂടെ നിർമ്മിത ബുദ്ധിയെ സമീക്ഷണം ചെയ്യാനാണ് ഈ കോഴ്സ് വിദ്യാർത്ഥികളെ പരിശീലിപ്പിക്കുന്നത്.

കോഴ്സിന്റെ നാല് പ്രധാന ദൗത്യങ്ങൾ:

1. **എഐയുടെ ചരിത്രവും തത്ത്വചിന്താപരമായ ഉത്ഭവവും:** പുരാതന യുക്തിചിന്ത മുതൽ 1956-ലെ ഡാർട്ട്മൗത്ത് കോൺഫറൻസ് വരെയുള്ള വളർച്ചയും അലൻ ട്യൂറിംഗിന്റെ മൗലിക അന്വേഷണങ്ങളും.
2. **ക്ലാസിക്കൽ AI പതിപ്പ് (Classical version of AI):** പ്രതീകാത്മക കമ്പ്യൂട്ടേഷണൽ മാതൃകകൾ (GOFAI), ട്യൂറിംഗ് ടെസ്റ്റ്, ജോൺ സിയർളിന്റെ ചൈനീസ് റൂം പരീക്ഷണം, കാർട്ടീഷ്യൻ ശരീരേതര ബുദ്ധി (Disembodied intelligence).
3. **ഭാരതീയ-പാശ്ചാത്യ ജ്ഞാനശാസ്ത്ര സിദ്ധാന്തങ്ങൾ:** ബുദ്ധമതത്തിലെയും ന്യായ ദർശനത്തിലെയും പ്രമാണ വിചാരങ്ങൾ, പാശ്ചാത്യ ഐഡന്റിറ്റി തിയറി, ബിഹേവിയറിസം, ഫങ്ഷണലിസം.
4. **ധാർമ്മിക-ദാർശനിക പ്രത്യാഘാതങ്ങൾ:** എഐ അലൈൻമെന്റ്, അൽഗോരിതം പക്ഷപാതങ്ങൾ, സ്വയംഭരണ കാറുകളിലെ ധാർമ്മിക നിയമങ്ങൾ, റോബോട്ട് എത്തിക്സ്, മനുഷ്യരാശിയുടെ നിലനിൽപ്പ് ഭീഷണി.

3. പ്രതീക്ഷിക്കുന്ന കോഴ്സ് നേട്ടങ്ങൾ (Expected Course Outcomes – CO1 to CO6)

ഔദ്യോഗിക പാഠ്യപദ്ധതി രേഖയുടെ പേജ് 114 പ്രകാരം, ഈ കോഴ്സ് വിജയകരമായി പൂർത്തിയാക്കുന്ന വിദ്യാർത്ഥികൾ കൈവരിക്കേണ്ട 6 പ്രധാന നേട്ടങ്ങൾ താഴെ പറയുന്നവയാണ്:

CO1 **Foundations in Critical Concepts:** Gain a foundation of knowledge in critical concepts of as well as theoretical approaches to artificial intelligence.

CO1 **അടിസ്ഥാന സങ്കല്പങ്ങളും സൈദ്ധാന്തിക സമീപനങ്ങളും:** കൃത്രിമ ബുദ്ധിയുടെ മൗലിക ആശയങ്ങളിലും സിദ്ധാന്തങ്ങളിലും ദൃഢമായ അറിവ് നേടുക.

CO2 **Critical Review of Recent History:** Understand and critically review the recent history of thought about artificial intelligence.

CO2 **സമീപകാല ചരിത്ര ചിന്തകളുടെ വിമർശനാത്മക അവലോകനം:** ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസിനെക്കുറിച്ചുള്ള ആധുനിക ചിന്താധാരകളുടെ ചരിത്രപരമായ വികാസം വിമർശനാത്മകമായി വിലയിരുത്തുക.

CO3 **Classical AI & Disembodied Intelligence:** Identify the classical version of AI and disembodied intelligence.

CO3 **ക്ലാസിക്കൽ AI-യും ശരീരേതര ബുദ്ധിയും:** ക്ലാസിക്കൽ പ്രതീകാത്മക AI മാതൃകകളെയും ശരീരമില്ലാത്ത ബുദ്ധിശക്തിയെക്കുറിച്ചുള്ള (Disembodied intelligence) സങ്കല്പങ്ങളെയും തിരിച്ചറിയുക.

CO4 **Comparative Epistemologies (Indian & Western):** Understand theories of knowledge in artificial intelligence in Indian as well as Western perspectives.

CO4 **ഇന്ത്യൻ-പാശ്ചാത്യ ജ്ഞാനശാസ്ത്ര സിദ്ധാന്തങ്ങൾ:** ഭാരതീയ ദർശനങ്ങളിലെയും (ബുദ്ധ, ന്യായ) പാശ്ചാത്യ ചിന്താധാരകളിലെയും (ഭൗതികവാദം, ഫങ്ഷണലിസം) ജ്ഞാനശാസ്ത്ര സിദ്ധാന്തങ്ങളെ AI-യുമായി താരതമ്യം ചെയ്ത് മനസ്സിലാക്കുക.

CO5 **Ethical & Philosophical Implications:** Identify and analyze ethical and philosophical implications of both artificial intelligence and our interaction with it.

CO5 **ധാർമ്മിക, ദാർശനിക പ്രത്യാഘാതങ്ങൾ:** എഐ സംവിധാനങ്ങളും മനുഷ്യരുമായുള്ള അവയുടെ ഇടപെടലുകളും സൃഷ്ടിക്കുന്ന ധാർമ്മിക, ദാർശനിക പ്രത്യാഘാതങ്ങൾ വിശകലനം ചെയ്യുക.

CO6 **The Meta-Goal (Interdisciplinary Integration):** This course also has a meta-goal, and that is to teach you how to integrate insights from philosophy and cognitive science while being critical of both.

CO6 **മെറ്റാ-ലക്ഷ്യം (അന്തർവൈജ്ഞാനിക സമന്വയം):** തത്ത്വചിന്തയിൽ നിന്നും കോഗ്നിറ്റീവ് സയൻസിൽ നിന്നുമുള്ള ഉൾക്കാഴ്ചകളെ സമന്വയിപ്പിക്കാനും, അതേസമയം ഇരുമേഖലകളെയും വിമർശനാത്മകമായി സമീപിക്കാനുമുള്ള ചിന്താശേഷി വളർത്തിയെടുക്കുക.

4. ബ്ലൂംസ് ടാക്സോണമി അനുസരിച്ചുള്ള വൈജ്ഞാനിക തലങ്ങൾ (Bloom's Taxonomy Framework)

സിലബസ് രേഖയിലെ പേജ് 114-ൽ കോഴ്സ് നേട്ടങ്ങളെ ബ്ലൂംസ് ടാക്സോണമിയിലെ (Bloom's Taxonomy) 7 വൈജ്ഞാനിക തലങ്ങളുമായി ബന്ധപ്പെടുത്തിയിരിക്കുന്നു. അവയുടെ അക്കാദമിക് പ്രസക്തി താഴെ വിശദീകരിക്കുന്നു:

1. Remember (ഓർമ്മിക്കുക)

എഐ ചരിത്രത്തിലെ നാഴികക്കല്ലുകൾ (1956 ഡാർട്ട്മൗത്ത്), പ്രധാന തത്ത്വചിന്തകർ (ട്യൂറിംഗ്, സിയർൾ, ഡെസ്കാർട്ടസ്), സാങ്കേതിക സംജ്ഞകൾ എന്നിവ ഓർത്തെടുക്കൽ.

2. Understand (മനസ്സിലാക്കുക)

സിന്റാക്സും സെമാന്റിക്സും തമ്മിലുള്ള വ്യത്യാസം, പ്രതീകാത്മക സിസ്റ്റങ്ങൾ, ഭാരതീയ പ്രമാണങ്ങൾ എന്നിവയുടെ പൊരുൾ ഗ്രഹിക്കൽ.

3. Apply (പ്രയോഗിക്കുക)

4. Analyze (വിശകലനം ചെയ്യുക)

തത്ത്വചിന്താ സിദ്ധാന്തങ്ങളെ (യൂട്ടിലിറ്റേറിയനിസം, കാന്റിയൻ എത്തിക്സ്) സ്വയംഭരണ കാറുകൾ, റോബോട്ടുകൾ തുടങ്ങിയ യഥാർത്ഥ സാഹചര്യങ്ങളിൽ പ്രയോഗിക്കൽ.

അൽഗോരിതങ്ങളിലെ മുൻവിധികൾ (Bias), ബ്ലാക്ക് ബോക്സ് പ്രതിസന്ധി, മനസ്സ്-ശരീര പ്രശ്നങ്ങൾ എന്നിവയെ സൂക്ഷ്മമായി അപഗ്രഥിക്കൽ.

5. Evaluate (വിലയിരുത്തുക)

ടൂറിംഗ് ടെസ്റ്റിനെതിരെയുള്ള ആക്ഷേപങ്ങൾ, ചൈനീസ് റൂം വാദം, മെഷീൻ ബോധത്തെക്കുറിച്ചുള്ള വാദപ്രതിവാദങ്ങൾ എന്നിവയെ വസ്തുനിഷ്ഠമായി വിലയിരുത്തൽ.

6. Critical Thinking (വിമർശനാത്മക ചിന്ത)

സാങ്കേതിക അന്ധവിശ്വാസങ്ങളെയും അമിത പ്രതീക്ഷകളെയും ദാർശനിക യുക്തിയിലൂടെ ചോദ്യം ചെയ്യാനുള്ള കഴിവ്.

7. Create (സൃഷ്ടിക്കുക)

തത്ത്വചിന്തയും കോഗ്നിറ്റീവ് സയൻസും സമന്വയിപ്പിച്ച് സ്വതന്ത്രമായ വിമർശനാത്മക പ്രബന്ധങ്ങൾ (Critical Response Papers), എത്തിക്കൽ മാർഗ്ഗരേഖകൾ എന്നിവ രൂപപ്പെടുത്തൽ.

5. അഞ്ച് പ്രധാന മൊഡ്യൂളുകളുടെ പൂർണ്ണ പാഠ്യപദ്ധതി വിവരണം (Detailed 5-Module Blueprint)

സിലബസ് രേഖയിലെ പേജ് 114 മുതൽ 115 വരെയുള്ള 5 മൊഡ്യൂളുകളുടെ ഔദ്യോഗിക ഉള്ളടക്കം, യൂണിറ്റുകൾ, അനുവദിച്ചിട്ടുള്ള മണിക്കൂറുകൾ, മാർക്കുകൾ എന്നിവയുടെ പൂർണ്ണരൂപം:

MODULE 1

10 Hours · 15 Marks

മൊഡ്യൂൾ 1: ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസിലേക്കുള്ള ആമുഖം (Introduction to Artificial Intelligence)

യൂണിറ്റ് 1.1 പാഠ്യവിഷയങ്ങൾ (Course Topics):

- **a) History and Foundations of Artificial Intelligence:** പുരാതന യുക്തിചിന്ത മുതൽ ലെബ്നിസ്, ജോർജ്ജ് ബൂൾ, അലൻ ടൂറിംഗ് (1948) വഴിയുള്ള വികാസം; 1956-ലെ പ്രശസ്തമായ ഡാർട്ട്മൗത്ത് സമ്മേളനം (ജോൺ മക്കാർത്തി, മാർവിൻ മിൻസ്കി, ക്ലോഡ് ഷാനൻ, നഥാനിയൽ റോച്ചസ്റ്റർ); ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസ് എന്ന വിജ്ഞാനശാഖയുടെ ഔദ്യോഗിക പിറവി.
- **b) Can a machine think?:** അലൻ ടൂറിംഗിന്റെ 1950-ലെ 'കമ്പ്യൂട്ടിംഗ് മെഷിനറി ആൻഡ് ഇന്റലിജൻസ്' എന്ന ഗവേഷണ പ്രബന്ധം; ഇമിറ്റേഷൻ ഗെയിം (ടൂറിംഗ് ടെസ്റ്റ്); ചിന്തയെ അമൂർത്തമായ ആന്തരികാവസ്ഥയായി കാണുന്നതിന് പകരം പ്രായോഗിക പെരുമാറ്റമായി നിർവ്വചിക്കുന്ന പ്രവർത്തനപരമായ സമീപനം (Operationalism); ലേഡി ലവ്‌ലേസ് ഒബ്ജക്ഷൻ, ബോധത്തിന്റെ പ്രശ്നം എന്നിവയുൾപ്പെടെ ടൂറിംഗ് നൽകിയ 9 പ്രതിരോധങ്ങൾ.
- **c) Philosophy in the light of AI:** നിർമ്മിത ബുദ്ധിയുടെ ആവിർഭാവം പരമ്പരാഗത തത്ത്വചിന്താ ശാഖകളായ ഓന്റോളജി (സത്തയെക്കുറിച്ചുള്ള പഠനം), എപ്പിസ്റ്റമോളജി (അറിവിന്റെ സിദ്ധാന്തം), എത്തിക്സ് (നീതിശാസ്ത്രം) എന്നിവയിൽ വരുത്തിയ വിപ്ലവകരമായ മാറ്റങ്ങൾ; പോൾ താഗാർഡിന്റെ കമ്പ്യൂട്ടേഷണൽ ഫിലോസഫി വീക്ഷണം.

MODULE 2

20 Hours · 20 Marks

മൊഡ്യൂൾ 2: ക്ലാസിക്കൽ AI പതിപ്പ് (Classical Version of Artificial Intelligence)

യൂണിറ്റ് 2.1: ക്ലാസിക്കൽ AI മോഡലിലെ പ്രശ്നങ്ങൾ (Problems in the Classical model of AI):

- **a) Alan Turing Test:** പ്രവർത്തനപരമായ തുല്യത (Behavioral Equivalence); ട്യൂറിംഗ് ടെസ്റ്റിന്റെ കരുത്തും പരിമിതികളും; വെറും അനുകരണവും യഥാർത്ഥ ഗ്രഹണശക്തിയും തമ്മിലുള്ള വ്യത്യാസം; നെഡ് ബ്ലോക്കിന്റെ 'ബ്ലോക്ക്ഹെഡ്' വാദം.
- **b) Chinese Room Experiment:** ജോൺ സിയർളിന്റെ (John Searle, 1980) ചിന്താപരീക്ഷണം; 'മൈൻഡ്സ്, ബ്രെയിൻസ് ആൻഡ് പ്രോഗ്രാംസ്'; സിന്റാക്സ് അർത്ഥമുണ്ടാക്കില്ല (Syntax is not Semantics); കമ്പ്യൂട്ടർ പ്രോഗ്രാമുകൾക്ക് ഉദ്ദേശ്യബോധം (Intentionality) ഇല്ലെന്ന വാദം; സിസ്റ്റംസ് റിപ്ലൈ, റോബോട്ട് റിപ്ലൈ, ബ്രെയിൻ സിമുലേറ്റർ റിപ്ലൈ എന്നിവയോടുള്ള സിയർളിന്റെ മറുപടികൾ.

യൂണിറ്റ് 2.2: മനസ്സിന്റെ തത്ത്വചിന്തയും ശരീരേതര ബുദ്ധിയും:

- **a) Descartes and the inception of Philosophy of Mind:** റെനെ ദെക്കാർത്തെയുടെ ദ്രവ്യദ്വൈതവാദം (Substance Dualism); ചിന്തിക്കുന്ന സത്തയും (res cogitans) ഭൗതിക സത്തയും (res extensa) തമ്മിലുള്ള വേർതിരിവ്; മനസ്സ്-ശരീര ബന്ധത്തിലെ പ്രശ്നങ്ങൾ.
- **b) Disembodied intelligence:** ഭൗതിക ശരീരമില്ലാതെ തന്നെ പ്രതീകാത്മക കമ്പ്യൂട്ടർ പ്രോഗ്രാമുകളിൽ ബുദ്ധി സാക്ഷാത്കരിക്കാമെന്ന ക്ലാസിക്കൽ AI (GOFAI) വാദം; ഇതിനെതിരെയുള്ള ഹ്യൂബർട്ട് ഡ്രെയ്ഫസിന്റെയും ഫിനോമിനോളജിക്കൽ ചിന്തകരുടെയും വിമർശനങ്ങൾ; യഥാർത്ഥ ബുദ്ധിക്ക് ഭൗതിക ശരീരവും ലോകവുമായുള്ള അനുഭവസമ്പർക്കവും (Embodiment) അനിവാര്യമാണെന്ന വാദം.

MODULE 3

15 Hours · 20 Marks

മൊഡ്യൂൾ 3: ആർട്ടിഫിഷ്യൽ ഇന്റലിജൻസിലെ ജ്ഞാനശാസ്ത്ര സിദ്ധാന്തങ്ങൾ (Theories of Knowledge in Artificial Intelligence)

യൂണിറ്റ് 3.1: ഇന്ത്യൻ ജ്ഞാനശാസ്ത്രം (Indian Epistemology):

- **a) Buddhism (ബുദ്ധദർശനം):** ദിഗ്നാഗനും ധർമ്മകീർത്തിയും വികസിപ്പിച്ച ബൗദ്ധ പ്രമാണ ചിന്തകൾ; പ്രത്യക്ഷം (Pratyaksha), അനുമാനം (Anumana) എന്നീ രണ്ട് പ്രമാണങ്ങൾ മാത്രമാണ് സ്വീകാര്യം; ക്ഷണികവാദവും പ്രതീത്യസമുത്പാദവും (പരസ്പരാശ്രിതമായ ഉത്ഭവം); അനാത്മവാദം (ശാശ്വതമായ ആത്മാവില്ലെന്ന സങ്കല്പം); ഇത് ആധുനിക ന്യൂറൽ നെറ്റ്വർക്കുകളുമായും കണക്ഷനിസവുമായും സംവദിക്കുന്ന രീതി.
- **b) Nyaya (ന്യായദർശനം):** അക്ഷപാദ ഗൗതമന്റെ ന്യായസൂത്രങ്ങൾ; 4 പ്രമാണങ്ങൾ (പ്രത്യക്ഷം, അനുമാനം, ഉപമാനം, ശബ്ദം); പഞ്ചാവയവ യുക്തിചിന്താരീതി (പ്രതിജ്ഞ, ഹേതു, ഉദാഹരണം, ഉപനയം, നിഗമനം); മനുഷ്യന്റെ യുക്തിചിന്തയെ ചിട്ടപ്പെടുത്തുന്ന ഈ രീതി ആധുനിക എക്സ്പർട്ട് സിസ്റ്റങ്ങൾക്കും റൂൾ-ബേസ്ഡ് AI-ക്കും നൽകുന്ന ശക്തമായ മാതൃക.

യൂണിറ്റ് 3.2: പാശ്ചാത്യ മനസ്സിന്റെ തത്ത്വചിന്ത (Western Theories of Mind & Epistemology):

- a) Identity theory (ഐഡന്റിറ്റി തിയറി): യു.ടി. പ്ലേസ് (U.T. Place 1956), ജെ.ജെ.സി. സ്മാർട്ട് എന്നിവരുടെ ഭൗതികവാദ സിദ്ധാന്തം; മാനസികാവസ്ഥകൾ തലച്ചോറിലെ ന്യൂറോബയോളജിക്കൽ പ്രക്രിയകളുമായി പൂർണ്ണമായും സമമാണ് (Mind–Brain Identity).
- b) Behaviourism (ബിഹേവിയറിസം): ഗിൽബർട്ട് റൈലിന്റെ (Gilbert Ryle) ദാർശനിക ബിഹേവിയറിസം; 'മെഷീനിലെ പ്രേതം' (Ghost in the Machine) എന്ന സങ്കല്പം ഒരു കാറ്റഗറി മിസ്റ്റേക്ക് ആണെന്ന വാദം; മനസ്സിനെ ബാഹ്യ പെരുമാറ്റ പ്രവണതകളായി നിർവ്വചിക്കൽ.
- c) Functionalism (ഫങ്ഷണലിസം): ഹിലരി പുട്ട്നാം (Hilary Putnam 1975); മാനസികാവസ്ഥകളെ നിർവ്വചിക്കുന്നത് അവ നിർവ്വഹിക്കുന്ന പ്രവർത്തനപരമായ ധർമ്മങ്ങളാണ് (Functional roles); മൾട്ടിപ്പിൾ റിയലൈസബിലിറ്റി (Multiple Realizability) — ജൈവിക മസ്തിഷ്കത്തിലും സിലിക്കൺ ചിപ്പുകളിലും കമ്പ്യൂട്ടറുകളിലും ഒരുപോലെ ചിന്ത സാക്ഷാത്കരിക്കാമെന്ന സിദ്ധാന്തം.

MODULE 4

15 Hours · 15 Marks

മൊഡ്യൂൾ 4: AI സിസ്റ്റങ്ങളുടെ ധാർമ്മിക, ദാർശനിക പ്രത്യാഘാതങ്ങൾ (Ethical and Philosophical Implications of AI System)

യൂണിറ്റ് 4.1: എഐ അലൈൻമെന്റും നിലനിൽപ്പ് ഭീഷണിയും:

- a) How do we align the aims of autonomous AI systems with our own?: സ്വയംഭരണ AI സംവിധാനങ്ങളുടെ ലക്ഷ്യങ്ങളെ മനുഷ്യരുടെ യഥാർത്ഥ മൂല്യങ്ങളുമായി എങ്ങനെ പൊരുത്തപ്പെടുത്താം (Value Alignment Problem); സ്റ്റുവർട്ട് റസ്സലിന്റെ മാനുഷിക ലക്ഷ്യങ്ങളോടുള്ള വിധേയത്വം.
- b) Does the future of AI pose an existential threat to humanity?: എഐയുടെ ഭാവി മനുഷ്യരാശിയുടെ നിലനിൽപ്പിന് ഭീഷണിയാകുമോ? നിക്ക് ബോസ്ട്രോമിന്റെ (Nick Bostrom) സൂപ്പർ ഇന്റലിജൻസ്, കൺട്രോൾ പ്രോബ്ലം, ഇൻസ്ട്രുമെന്റൽ കൺവെർജൻസ് വാദങ്ങൾ.

യൂണിറ്റ് 4.2: അൽഗോരിതം പക്ഷപാതവും സാമൂഹിക ബന്ധങ്ങളും:

- a) How do we prevent learning algorithms from acquiring morally objectionable biases?: മെഷീൻ ലേണിംഗ് അൽഗോരിതങ്ങൾ ചരിത്രപരമായ ഡാറ്റയിൽ നിന്നും ലിംഗ-വംശീയ വിവേചനങ്ങളും അന്യായമായ മുൻവിധികളും പഠിച്ചെടുക്കുന്നത് എങ്ങനെ തടയാം? ഫെയർനസ്, ട്രാൻസ്പരൻസി, അക്കൗണ്ടബിലിറ്റി.
- b) How should AI systems be embedded in our social relations?: എഐ സംവിധാനങ്ങൾ നമ്മുടെ സാമൂഹിക ബന്ധങ്ങളിൽ എങ്ങനെ സംയോജിപ്പിക്കപ്പെടണം? എലിസ ഇഫക്ട്, ചാറ്റ്ബോട്ടുകളോടുള്ള മാനസിക അടുപ്പം, സ്വകാര്യത, സർവൈലൻസ് ക്യാപിറ്റലിസം.

യൂണിറ്റ് 4.3: റോബോട്ട് എത്തിക്സ്, ധാർമ്മിക പദവികൾ, ഉത്തരവാദിത്തം:

- a) What sort of ethical rules should AI like a self-driving car use?: സെൽഫ്-ഡ്രൈവിംഗ് കാറുകൾ ഏതുതരം ധാർമ്മിക നിയമങ്ങളാണ് പിന്തുടരേണ്ടത്? ട്രോളി പ്രോബ്ലം (Trolley Problem); ഡ്രൈവറെ

രക്ഷിക്കണമോ അതോ കാൽനടയാത്രക്കാരെ രക്ഷിക്കണമോ എന്ന ധർമ്മസങ്കടങ്ങൾ.

- **b) Can AI systems suffer moral harm? And if so, of what kinds?:** എഐ സംവിധാനങ്ങൾക്ക് ധാർമ്മികമായ ദ്രോഹങ്ങൾ (Moral Harm) ഏൽക്കാൻ കഴിയുമോ? മേരി ആൻ വാറന്റെ ധാർമ്മിക പദവി മാനദണ്ഡങ്ങൾ; സെന്റിയൻസ് (വേദനയും സന്തോഷവും അനുഭവിക്കാനുള്ള ശേഷി), മോറൽ പേഷ്യന്റ്ഹുഡ്.
- **c) Can AI systems be moral agents? If so, how should we hold them accountable?:** എഐ സംവിധാനങ്ങൾക്ക് ധാർമ്മിക കർത്താക്കളാകാൻ (Moral Agents) കഴിയുമോ? അവർ തെറ്റ് ചെയ്താൽ അവരെ എങ്ങനെ ഉത്തരവാദികളാക്കാം? ജോൺ പി. സള്ളിൻസ്, ഡെബോറ ജോൺസൺ എന്നിവരുടെ വീക്ഷണങ്ങൾ; ലീഗൽ പേഴ്സൺഹുഡ്.

MODULE 5

10 Hours · 10 Marks

മൊഡ്യൂൾ 5: AI-യുടെ ദാർശനിക അടിത്തറയും മനുഷ്യരാശിയുടെ ഭാവിയും (Philosophical Underpinning of AI and the Future of Humanity)

> **ഓപ്പൺ എൻഡഡ് മൊഡ്യൂൾ (Open Ended Module):** ഔദ്യോഗിക സിലബസ് രേഖ പ്രകാരം ഈ മൊഡ്യൂളിന്റെ ഉള്ളടക്കവും മൂല്യനിർണ്ണയവും അതത് കോളേജുകളിലെയും വകുപ്പുകളിലെയും ഫാക്കൽറ്റിക്ക് തീരുമാനിക്കാവുന്നതാണ് (*"Content and Evaluation Decided by the faculty"*).

ഈ മൊഡ്യൂളിന്റെ അക്കാദമിക് പ്രാധാന്യവും പരിഗണനാ വിഷയങ്ങളും:

എഐ സാങ്കേതികവിദ്യ അതിവേഗം വികസിച്ചുകൊണ്ടിരിക്കുന്ന ഒന്നായതിനാൽ, പുതിയ ഗവേഷണ മുന്നേറ്റങ്ങളെയും സമകാലിക ദാർശനിക ചർച്ചകളെയും സിലബസിൽ ഉൾക്കൊള്ളിക്കുന്നതിനായാണ് കാലിക്കറ്റ് സർവ്വകലാശാല ഇതിനെ ഒരു 'ഓപ്പൺ-എൻഡഡ്' മൊഡ്യൂളായി നിശ്ചയിച്ചിരിക്കുന്നത്. പ്രധാനമായും ക്ലാസ് സെമിനാറുകൾ, വിമർശനാത്മക പ്രതികരണ പ്രബന്ധങ്ങൾ (Critical Response Papers), ചർച്ചകൾ എന്നിവയിലൂടെയാണ് ഇതിന്റെ 10 മാർക്കിനായുള്ള നിരന്തര മൂല്യനിർണ്ണയം നടക്കുന്നത്.

- ആർട്ടിഫിഷ്യൽ ജനറൽ ഇന്റലിജൻസ് (AGI) സംബന്ധിച്ച ആധുനിക വാദങ്ങൾ.
- റെയ് കുർസ്വീലിന്റെ ടെക്നോളജിക്കൽ സിംഗുലാരിറ്റി (Technological Singularity) സങ്കല്പം.
- ട്രാൻസ്-ഹ്യൂമനിസവും മനുഷ്യ-മെഷീൻ സഹവർത്തിത്വവും (Human-AI Co-evolution).
- യുനെസ്കോ (UNESCO) പോലുള്ള അന്താരാഷ്ട്ര സംഘടനകളുടെ എഐ എത്തിക്സ് ചട്ടക്കൂടുകൾ.

6. അധ്യാപന-പഠന സമീപനങ്ങളും ക്ലാസ്റൂം പ്രവർത്തനങ്ങളും (Teaching and Learning Approach)

സിലബസ് രേഖയിലെ പേജ് 116 പ്രകാരം, ഈ കോഴ്സ് ക്ലാസ്റൂമുകളിൽ കൈകാര്യം ചെയ്യേണ്ടത് താഴെ പറയുന്ന ബോധന രീതികളിലൂടെയാണ് (Classroom Procedure / Mode of Transaction):

1. സോക്രട്ടീസ് രീതി (Socratic Method)

വിദ്യാർത്ഥികളോട് ചോദ്യങ്ങൾ ചോദിച്ചുകൊണ്ട് ചിന്ത, ബുദ്ധി, ബോധം, ധാർമ്മികത എന്നിവയുടെ പരമ്പരാഗത നിർവ്വചനങ്ങളെ സ്വയം പരിശോധിക്കാൻ പ്രേരിപ്പിക്കുന്ന രീതി.

2. പ്രഭാഷണങ്ങൾ (Lectures)

ചരിത്രപരമായ പശ്ചാത്തലം, തത്ത്വചിന്തകരുടെ മൗലിക വാദങ്ങൾ, ശാസ്ത്രീയ സിദ്ധാന്തങ്ങൾ എന്നിവ വ്യക്തമായി വിശദീകരിക്കുന്ന ക്ലാസ് പ്രഭാഷണങ്ങൾ.

3. സംവാദങ്ങളും ചർച്ചകളും (Discussion)

സെൽഫ്-ഡ്രൈവിംഗ് കാറുകളിലെ ധാർമ്മിക പ്രതിസന്ധികൾ, അൽഗോരിതം പക്ഷപാതം തുടങ്ങിയ സമകാലിക വിഷയങ്ങളിൽ വിദ്യാർത്ഥികൾ തമ്മിലുള്ള ആശയവിനിമയം.

4. സെമിനാർ അവതരണങ്ങൾ (Seminar Presentations)

നിശ്ചിത തത്ത്വചിന്താ പ്രബന്ധങ്ങളെ അടിസ്ഥാനമാക്കി വിദ്യാർത്ഥികൾ നടത്തുന്ന വിശദമായ ക്ലാസ് സെമിനാറുകൾ.

5. വിമർശനാത്മക പ്രബന്ധം (Critical Response Paper)

പ്രധാനപ്പെട്ട പുസ്തകങ്ങളോ പ്രബന്ധങ്ങളോ വായിച്ച് അവയിലെ വാദങ്ങളെ യുക്തിപൂർവ്വം വിലയിരുത്തിക്കൊണ്ട് വിദ്യാർത്ഥികൾ തയ്യാറാക്കുന്ന രേഖാമൂലമുള്ള പഠനക്കുറിപ്പുകൾ.

6. കൂട്ടായ വായന (Collaborative Reading)

ടൂറിംഗ്, സിയർൾ തുടങ്ങിയ ചിന്തകരുടെ കഠിനമായ മൂലകൃതികൾ അധ്യാപകരുടെ സാന്നിധ്യത്തിൽ ഒത്തൊരുമിച്ച് വായിച്ച് അർത്ഥം ഗ്രഹിക്കുന്ന രീതി.

7. ഔദ്യോഗിക പാഠ്യപദ്ധതി റഫറൻസുകൾ (Official Prescribed References 1-16)

സിലബസ് രേഖയിലെ പേജ് 116-ൽ സർവ്വകലാശാല ഔദ്യോഗികമായി നിർദ്ദേശിച്ചിട്ടുള്ള 16 റഫറൻസ് ഗ്രന്ഥങ്ങളും പ്രബന്ധങ്ങളും അവയുടെ അക്കാദമിക് പശ്ചാത്തലവും താഴെ നൽകുന്നു:

1. **Mariusz Flasiński (2016).** "History of Artificial Intelligence" Chapter 1 in *Introduction to Artificial Intelligence*.

   പ്രസക്തി (Module 1): AI-യുടെ ചരിത്രപരമായ വികാസം, ലോജിക് ഗേറ്റുകൾ, ആദ്യകാല തിയറം പ്രൂവിംഗ് പ്രോഗ്രാമുകൾ എന്നിവയെക്കുറിച്ചുള്ള ആധികാരിക അധ്യായം.

2. **Stuart Russell and Peter Norvig (2020).** "Introduction" Chapter 1 in *Artificial Intelligence: A Modern Approach*.

   പ്രസക്തി (Module 1): ലോകപ്രശസ്തമായ AI പാഠപുസ്തകം; മനുഷ്യനെപ്പോലെ ചിന്തിക്കുക, യുക്തിപൂർവ്വം പ്രവർത്തിക്കുക (Rational Agents) തുടങ്ങിയ 4 AI നിർവ്വചനങ്ങളെ വ്യക്തമാക്കുന്നു.

3. **Paul Thagard (1990).** "Philosophy and Machine Learning". *Canadian Journal of Philosophy*, 20(2): 261-276.

   പ്രസക്തി (Module 1): കമ്പ്യൂട്ടേഷണൽ ഫിലോസഫിയും മെഷീൻ ലേണിംഗും തത്ത്വചിന്താപരമായ ജ്ഞാനനിർമ്മാണത്തിന് എങ്ങനെ സഹായകരമാകുന്നു എന്ന് സമർത്ഥിക്കുന്നു.

4 **J. R. Searle (1980).** "Minds, brains and programs". *Behavioral and Brain Sciences*, 3: 417-457.

പ്രസക്തി (Module 2): ചൈനീസ് റൂം പരീക്ഷണം അവതരിപ്പിച്ച ചരിത്രപ്രസിദ്ധമായ പ്രബന്ധം; കമ്പ്യൂട്ടറുകൾക്ക് സിന്റാക്സ് ഉണ്ടെങ്കിലും സെമാന്റിക്സ് ഇല്ലെന്ന് സ്ഥാപിക്കുന്നു.

5 **Jaegwon Kim (2011).** "Mind as Immaterial Substance: Descartes's Dualism." In *Philosophy of Mind*, 3rd ed.

പ്രസക്തി (Module 2): കാർട്ടീഷ്യൻ ദ്രവ്യദ്വൈതവാദത്തെയും മനസ്സ്-ശരീര പ്രശ്നത്തെയും കുറിച്ചുള്ള ആഴത്തിലുള്ള അപഗ്രഥനം.

6 **Girish Nath Jha (2007).** "Indian theories of knowledge compared with Western theories and artificial intelligence." *Creative Forum*, vol. 20, no. 1.

പ്രസക്തി (Module 3): ഇന്ത്യൻ ദർശനങ്ങളിലെ (ന്യായ, ബൗദ്ധ) പ്രമാണ ചിന്തകളെ പാശ്ചാത്യ വിജ്ഞാനശാസ്ത്രവുമായും AI സിസ്റ്റങ്ങളുമായും താരതമ്യം ചെയ്യുന്ന മൗലിക പഠനം.

7 **U. T. Place (1956).** "Is Consciousness a Brain Process?". *British Journal of Psychology*.

പ്രസക്തി (Module 3): മൈൻഡ്-ബ്രെയിൻ ഐഡന്റിറ്റി തിയറിയുടെ ആദ്യകാല അടിസ്ഥാന രേഖ; ബോധം എന്നത് ഒരു മസ്തിഷ്ക പ്രക്രിയയാണെന്ന ഭൗതികവാദ സമീപനം.

8 **Jaegwon Kim (2011).** "Mind and Behavior: Behaviorism." In *Philosophy of Mind*, 3rd ed.

പ്രസക്തി (Module 3): ദാർശനിക ബിഹേവിയറിസവും ഗിൽബർട്ട് റൈലിന്റെ 'മെഷീനിലെ പ്രേതം' എന്ന സിദ്ധാന്തത്തിന്റെ നിരാകരണവും.

9 **Hilary Putnam (1975).** "The Nature of Mental States". In *Mind, Language and Reality*.

പ്രസക്തി (Module 3): ഫങ്ഷണലിസത്തിന്റെ ഉത്ഭവം; മനസ്സിനെ പ്രവർത്തനപരമായ റോളുകളിലൂടെ നിർവ്വചിക്കുന്ന മൾട്ടിപ്പിൾ റിയലൈസബിലിറ്റി സിദ്ധാന്തം.

10 **Mary Anne Warren (1997).** *Moral Status: Obligations to Persons and Other Living Things*. Clarendon Press, Excerpt pp. 4-17.

പ്രസക്തി (Module 4): ധാർമ്മിക പദവി (Moral Status), മോറൽ ഏജന്റ്, മോറൽ പേഷ്യന്റ് എന്നിവയെ നിർവ്വചിക്കുന്ന മാനദണ്ഡങ്ങൾ.

11 **John P. Sullins (2006).** "When is a Robot a Moral Agent?". *International Review of Information Ethics*, 6(12), pp. 23-30.

പ്രസക്തി (Module 4): റോബോട്ടുകൾ എപ്പോഴാണ് ധാർമ്മിക കർത്താക്കളാകുന്നത് (Moral Agency)? സ്വയംഭരണ ശേഷിയും ഉദ്ദേശ്യബോധവും തമ്മിലുള്ള ബന്ധം.

12 **Michael LaBossiere (2017).** "Testing the Moral Status of Artificial Beings, or I'm Going to Ask You Some Questions...". In *Robot Ethics 2.0*, Oxford University Press, pp. 1–22.

പ്രസക്തി (Module 4): നിർമ്മിത ജീവികൾക്ക് ധാർമ്മിക അവകാശങ്ങളുണ്ടോ എന്ന് പരിശോധിക്കുന്നതിനുള്ള പരീക്ഷണ രീതികൾ.

13 **Deborah G. Johnson (2006).** "Computer Systems: Moral Entities But Not Moral Agents." *Ethics and Information Technology*, 8(4), pp. 195–204.

പ്രസക്തി (Module 4): കമ്പ്യൂട്ടറുകൾ ധാർമ്മിക സത്തകളാണ്, എന്നാൽ അവയ്ക്ക് സ്വതന്ത്ര ധാർമ്മിക കർത്തൃത്വമില്ല എന്ന വിഖ്യാത വാദം.

14 **The Guardian (2012).** "Philosophy of Artificial Intelligence". (http://www.theguardian.com/science/2012/oct/03/philosophy-artificial-intelligence).

പ്രസക്തി (Module 4 & 5): നിർമ്മിത ബുദ്ധിയുടെ ദാർശനിക വശങ്ങളെ പൊതുജനങ്ങൾക്ക് എളുപ്പത്തിൽ മനസ്സിലാകുന്ന രീതിയിൽ വിശദീകരിക്കുന്ന അക്കാദമിക് ലേഖനം.

15 **Nick Bostrom (2016).** "The Control Problem. Excerpts from Superintelligence." In *Science Fiction and Philosophy: From Time Travel to Superintelligence* (2nd ed.).

പ്രസക്തി (Module 4 & 5): മനുഷ്യന്റെ നിയന്ത്രണം നഷ്ടപ്പെടുന്ന സൂപ്പർ ഇന്റലിജൻസും അതിനെ മുൻകൂട്ടി സുരക്ഷിതമാക്കാനുള്ള കൺട്രോൾ പ്രോബ്ലവും.

16 **Nick Bostrom (2016).** "Paths, Dangers, Strategies" In *Science Fiction and Philosophy: From Time Travel to Superintelligence* (2nd ed.).

പ്രസക്തി (Module 4 & 5): നിർമ്മിത ബുദ്ധിയുടെ അപകടസാധ്യതകളും മനുഷ്യരാശിയുടെ നിലനിൽപ്പിനായുള്ള ദീർഘവീക്ഷണ തന്ത്രങ്ങളും.